

Sports Analytics

Hansjörg Fromm

Inhalt

1 Einführung	2
2 Daten	5
3 Verfahren der Sports Analytics	10
4 Anwendungen der Sports Analytics	27
5 Zusammenfassung	39
Literatur	39

Zusammenfassung

Mit der fortschreitenden Digitalisierung im Sport erlebten auch die sogenannten Sports Analytics einen enormen Aufschwung. Das Buch „Moneyball“ und dessen Verfilmung waren die Initialzündung für eine beachtliche Erfolgsgeschichte von Analytics innerhalb und außerhalb des Sports. Die Geschichte der Sports Analytics begann aber schon lange vor Moneyball. Seit es Sport gibt, werden Ergebnisse aufgezeichnet und miteinander verglichen. Die Entwicklung der Datenverarbeitung und der gleichzeitige Fortschritt auf den Gebieten Statistik, Operations Research und Machine Learning trugen jedoch dazu bei, dass eine immense Vielfalt an Methoden und An-

wendungen entstanden ist. Es wurden kommerzielle Lösungen geschaffen, die zur Grundlage eines bedeutenden Wirtschaftszweigs geworden sind. In der Forschung entwickelten sich die Sports Analytics zu einer eigenständigen Disziplin. Ziel dieses Kapitels ist es, die Methoden und Anwendungen der Sports Analytics mit besonderer Berücksichtigung ihrer historischen Entwicklung vorzustellen. Die Auswahl soll dabei die Vielfalt aufzeigen, kann aber bei weitem nicht vollständig sein.

Schlüsselwörter

Analytics · Statistik · Machine Learning · Operations Research · Künstliche Intelligenz

H. Fromm (✉)
Karlsruhe Service Research Institute, Karlsruher Institut
für Technologie (KIT), Karlsruhe, Deutschland
E-Mail: hansjoerg.fromm@kit.edu

1 Einführung

Sucht man nach der Herkunft des Begriffs *Sports Analytics*, so stößt man unweigerlich auf den Bestseller „Moneyball“ von Michael Lewis aus dem Jahr 2003 (Lewis, 2003) und dessen gleichnamige Verfilmung aus dem Jahr 2011. Moneyball beschreibt, wie Billy Beane, der Sportdirektor des Baseballteams Oakland Athletics (im Film Brad Pitt), aufgrund finanzieller Engpässe gezwungen war, nach alternativen Methoden zur Wiedererlangung der Wettbewerbsfähigkeit des Clubs zu suchen. Diese Methoden lagen in der Anwendung von Data Analytics zur optimalen Spielerakquisition. Welchen Stellenwert Moneyball für den Sport hat, zeigt sich darin, dass manche Autoren bereits von Sports Analytics vor *Moneyball* (Hintz, 2022) und Sports nach *Moneyball* (Millington et al., 2023) sprechen.

Im Jahr 2006 veröffentlichte Thomas H. Davenport im Harvard Business Review einen Artikel „Competing on Analytics“ (Davenport, 2006) und ein Jahr später, zusammen mit Jeanne Harris, das Buch „Competing on Analytics: The New Science of Winning“ (Davenport & Harris, 2007). Darin wird Moneyball als herausragendes Beispiel genannt, um die Bedeutung von Analytics zur Steigerung der Wettbewerbsfähigkeit nicht nur im Sport, sondern für die gesamte Businesswelt zu demonstrieren.

Lewis und Davenport ist es zu verdanken, dass sie *Analytics* als Sammelbegriff für eine ganze Reihe mathematisch-analytischer Verfahren bekannt machten, die sich über die Jahre in unterschiedlichen Disziplinen entwickelt hatten. Zu diesen Disziplinen gehören Statistik, Operations Research, Data Mining und Machine Learning.¹

Davenport und Harris (2007) definieren Analytics als „the extensive use of data, statistical and quantitative analysis, explanatory and predictive models, and fact-based management to drive deci-

sions and actions“ und schlagen eine Unterscheidung in die drei Kategorien der deskriptiven, prädiktiven und präskriptiven Verfahren vor. Nach dieser Einteilung fällt die Statistik vorwiegend in den deskriptiven, Data Mining und Machine Learning in den deskriptiven und prädiktiven, und die mathematische Optimierung als Teil des Operations Research (OR) in den präskriptiven Bereich. So kann Analytics als Oberbegriff über sämtliche Verfahren verwendet werden (vgl. auch Lustig et al., 2010).

Wir werden im Folgenden die vielfältigen Anwendungsmöglichkeiten der Sport Analytics vorstellen. Dabei ist zunächst festzustellen, dass es zwei große Bereiche gibt, die mit den Sports Analytics in unmittelbarem Zusammenhang stehen: Analytics im Gesundheitswesen (Healthcare Analytics) und Analytics im unternehmerischen Bereich (Business Analytics) (Abb. 1).

(a) Analytics im Gesundheitswesen (Healthcare Analytics)

Der Sport ist aufs Engste mit dem Gesundheitswesen verbunden. Im Gesundheitswesen haben sich mit der zunehmenden Digitalisierung und der daraus resultierenden Möglichkeit, Gesundheitsdaten zu erfassen, Data Analytics etabliert (Reddy & Aggarwal, 2020). Datenquellen sind z. B. elektronische Gesundheitsakten, bildgebende Verfahren, Sensordaten (erfasst über „Wearable Devices“), oder Genomdaten. Die Anwendungen von Analytics reichen von der Gesundheitsförderung und der Prävention über die Diagnose und Therapie bis hin zur Rehabilitation.

Die Schnittmenge zwischen Gesundheitswesen und Sport bildet die Sportmedizin. Die




Abb. 1 Analytics im Gesundheitswesen, Sports Analytics und Analytics im unternehmerischen Bereich überschneiden sich

¹ Data Mining und Machine Learning umfassen im Wesentlichen dieselben analytischen Verfahren. Data Mining betont das explorative Vorgehen bei der Anwendung der Verfahren, während Machine Learning die besondere Eigenschaft von Verfahren beschreibt, selbstständig aus Daten zu lernen (vgl. Mitchell, 1999).

Sportmedizin ist derjenige Teilbereich der Medizin, der die Auswirkungen von Bewegung, Training und Sport auf die Gesundheit untersucht. Dabei werden vorwiegend dieselben analytischen Verfahren eingesetzt wie in anderen Bereichen der Medizin (Sikka et al., 2019). Die Überwachung wichtiger Körperfunktionen und deren Analyse ist für den Herzinfarktpatienten genauso wichtig wie für den Sportler,² ebenso die Auswertung von Röntgenaufnahmen oder EKGs.

Die Besonderheit der Sportmedizin ist die Unterstützung der Leistungssteigerung durch optimale Trainings- und Ernährungspläne. Nicht weniger bedeutsam ist die Verletzungsprävention. In beiden Bereichen werden Analytics mit Erfolg eingesetzt. Über Wearables (kleine, vernetzte Computer, die am Körper getragen werden) wie Smart Watches oder Fitness Trackers sind Analytics schon sehr nahe an den Menschen herangerückt (Olsen et al., 2024). Viele Menschen nutzen diese Möglichkeiten bereits, um ihre Gesundheit und Leistungsfähigkeit zu überwachen und zu verbessern.

(b) Analytics im unternehmerischen Bereich (Business Analytics)

Das andere angrenzende Gebiet ist Business Analytics. Sport ist längst zu einem „Big Business“ geworden. Clubs werden wie Wirtschaftsunternehmen geführt, und für Ligen und internationale Verbände und Organisationen haben wirtschaftliche Überlegungen einen hohen Stellenwert. Für diese Business-Seite des Sports spielen Analytics eine genauso wichtige Rolle wie für jedes andere Unternehmen außerhalb des Sports. Allgemein geht es in Unternehmen um die Steigerung der Wettbewerbsfähigkeit in Bereichen wie Sales und Marketing, Kundenbeziehungen (Customer Relationship Management), Finanzen, Einkauf, oder Unternehmensbeziehungen. In Sportunternehmen sind das speziell Ticketverkäufe und Merchandising, Fan Engagement und Social-Media-Auftritte, Einkauf und Transfer

von Spielern, wie auch Akquisition und Pflege von Sponsoren.

Davenport spricht dem Sport im Hinblick auf Analytics sogar eine gewisse Vorbildfunktion für das Business zu. Dies ist wenig verwunderlich, wenn man die Parallelen sieht: bei beiden – Sport und Business – geht es um Leistung, Teambildung, Wettbewerb, Konkurrenz, Gewinner und Verlierer. In der Geschäftswelt werden viele Metaphern aus dem Sport benutzt. Wenn auch besonders im Profisport das Humankapital eine herausragende Rolle spielt (Spielerakquisition, Spielertransfer) so werden doch Methoden, wie sie in Moneyball beschrieben werden, zur Stellenbesetzung auch in Wirtschaftsunternehmen eingesetzt.

Mit dem Sport eng verknüpft ist das Wetterschaft, das sich mit der Digitalisierung enorm verändert hat. Viele Wettteilnehmer nutzen für ihre Tipps Statistiken der Spieler und Mannschaften, die sie im Internet finden. Dasselbe gilt für die Teilnehmer an Fantasy Sports, die aus realen Spielern virtuelle Teams zusammenstellen, um in einer Fantasy-Liga gegen andere Teilnehmer anzutreten. Die Leistung der virtuellen Mannschaften wird dabei nach den aktuellen Leistungen der ausgewählten realen Spieler gemessen.

Weil es sowohl für die Anwendung der Analytics im Gesundheitsbereich als auch die Business Analytics umfangreiche Einzeldarstellungen gibt, wollen wir uns in diesem Kapitel auf den Bereich konzentrieren, der von keinem der beiden erfasst wird: Die Analyse der sportlichen, spielerischen Leistung der Athleten und Teams.

Seit es den Sport gibt, werden in Wettkämpfen Leistungen und Ergebnisse erfasst und miteinander verglichen. Schon ab Ende des neunzehnten Jahrhunderts spielt die Statistik im Baseball eine große Rolle. Mit der Entwicklung der Mathematik und Informatik im zwanzigsten Jahrhundert und der Möglichkeit, Daten im Sport digital zu erfassen, zu speichern und auszuwerten, wurde auch die Anwendung der Analytics im Sport immer umfassender und beliebter und erstreckt sich heute über sämtliche Disziplinen.

Beteiligte und Interessengruppen

Aus dem Vorangegangenen ist deutlich geworden, dass es eine Vielzahl von Beteiligten (stake-

²In diesem Kapitel wird das generische Maskulinum verwendet. Sportler und Athleten können Personen verschiedener Geschlechter sein.

holders) gibt, für die Sports Analytics von großem Interesse und Nutzen sind: dazu gehören nicht nur die Athleten, Teams, Trainer, Sportmediziner und Mannschaftschefs, sondern auch die Clubchefs, Vertreter der Ligen und Organisationen, Medien, Fans und Sponsoren, Wettbüros und eSports-Anbieter – das ganze „Sport-Ökosystem“. Heute hat eine breite Öffentlichkeit Zugang zu Sports Analytics. Fast jede Sportübertragung im Fernsehen wird in der einen oder anderen Form von Analytics begleitet.

Sports Analytics entwickelten sich selbst zu einem eigenen Wirtschaftszweig (Link, 2018b). Fortune Business Insights (2024) schätzen, dass der weltweite Sport Analytics-Markt von 4,81 Mrd. US-Dollar im Jahr 2024 auf 32,31 Mrd. US-Dollar im Jahr 2032 wächst. Das entspricht einer jährlichen Wachstumsrate von 26,9 %. Führende Sports Analytics-Anbieter sind Hudl (USA), Instat Sport (Irland), PFF (USA), Opta Sports (UK), Catapult (Australien), letzterer ein Spezialist für Wearable Devices. Auch IT-Firmen wie IBM und SAP sind signifikant am Sportgeschäft beteiligt.

Der Bereich Sports Analytics hat auch in der wissenschaftlichen Forschung über die Jahre erheblich an Bedeutung gewonnen. Einer Studie zufolge publizierten zwischen 1997 und 2020 insgesamt 3141 Autoren von 1181 verschiedenen Institutionen zum Thema Sports Analytics (Safari et al., 2022). Eine Abfrage mit Google Scholar zum Schlüsselwort „Sports Analytics“ liefert heute bereits 9550 Treffer.

Seit 2006 gibt es sogar eine eigene Konferenz für Sports Analytics: die jährlich stattfindende MIT Sloan Sports Analytics Conference. Darüber hinaus gibt es in der Disziplin eigene Zeitschriften. Seit 2005 erscheint das *Journal of Quantitative Analysis in Sports* und seit 2015 das *Journal of Sports Analytics*. Und dann gibt es noch die zahlreichen Monografien und Sammelbände über Sports Analytics (Alamar, 2013; Minton, 2016; Fried & Mumcu, 2016; Harrison & Bukstein, 2016; Jayal et al., 2018; Severini, 2020; MacLean & Ziemba, 2021; Winston et al., 2022), auch speziell für einzelne Sportarten wie Baseball (Marchi & Albert, 2013; Kissell & Poserina, 2017), Basket-

ball (Shea, 2014; Goldsberry, 2024), Hockey (Shea & Baker, 2017), Fußball (Link, 2018a; Memmert & Raabe, 2024; Beggs, 2024), American Football (Eager & Erickson, 2023), Cricket (Ganesh, 2017) und Golf (Gerdeen, 2017).

Universitäten und andere Organisationen veranstalten regelmäßig Analytics-Wettbewerbe zur Vorhersage von Spielergebnissen, für die sie jeweils eigene Datensätze zur Verfügung stellen, z. B. die Wharton School der University of Pennsylvania (North American Soccer League) oder die Online-Community Kaggle (Basketball, Fußball, American Football). Besonders erwähnenswert ist die Soccer Prediction Challenge, die von mehreren Universitätsinstituten und der Zeitschrift Machine Learning veranstaltet wird und zuletzt 2017 und 2023 stattfand. Ergebnisse des Wettbewerbs werden im Journal *Machine Learning* veröffentlicht (Berrar et al., 2019; Dubitzky et al., 2019; Razali et al., 2022).

Anwendungen von Sports Analytics

Die Anwendungsmöglichkeiten von Sports Analytics sind vielfältig und unterscheiden sich vor allem danach, ob die Leistung einzelner Sportler (Einzelsportarten) oder die Leistung einer ganzen Mannschaft (Mannschaftssportarten) im Blickpunkt steht. Ausschlaggebend ist auch, ob die Leistung in einem Einzelwettkampf, in einem Zweikampf oder in einem Mannschaftsspiel erbracht wird. Der Mannschaftssport stellt die größte Herausforderung an Sports Analytics dar, weil hier das komplexe Zusammenspiel der Athleten und die Spieltaktiken und -strategien eine herausragende Rolle spielen.

In diesem Kapitel werden folgende Anwendungsgebiete vorgestellt, die für den Mannschaftssport, teilweise aber auch für den Individualsport von Bedeutung sind (Abb. 2):

1. Leistungsbewertung von Spielern und Mannschaften
2. Talentsuche (talent identification, scouting) und Rekrutierung (recruiting) von Spielern
3. Training
4. Verletzungsanalyse (Verletzungsprognose und -prävention)



Abb. 2 Die in diesem Kapitel vorgestellten Anwendungen der Sports Analytics

5. Ergebnisvorhersage (outcome prediction)
6. Spielanalyse

Die ineinandergreifenden Pfeile im Diagramm sollen verdeutlichen, dass viele der sportlichen Entscheidungen aufeinander aufbauen (vgl. auch Beal et al., 2019). So kann die Spielanalyse und Spielerbewertung Anlass für die Rekrutierung neuer Spieler sein (Beispiel: Moneyball). Die Gestaltung des Trainings hat einen großen Einfluss auf die Verletzungsgefahr. Und Verletzungen sind ein wichtiger Faktor, wenn es um die Vorhersage von Spielergebnissen geht.

Der Hauptteil dieses Kapitels gliedert sich in drei Teile. In Abschn. 2 wird zunächst beschrieben, wie sich die Erfassung von Daten im Sport über einen langen Zeitraum entwickelt hat und wie sie mit den heute verfügbaren Technologien auf ein völlig neues Niveau gehoben wurde. Abschn. 3 stellt die wichtigsten analytischen Verfahren (Analytics) vor, die in einem ähnlich langen Zeitraum auf den Gebieten der Mathematik und später der Informatik entwickelt wurden. In Abschn. 4 werden Anwendungsgebiete der Sports Analytics vorgestellt. Insbesondere wird darauf eingegangen, welche Daten und Verfahren bei den jeweiligen Anwendungen eine Rolle spielen.

2 Daten

Daten werden erfasst und aufgezeichnet, seit es den Sport gibt. So kennen wir etwa die Namen der Sieger bei den antiken olympischen Spielen. Tony Collins (2013) bezeichnet den bereits 1727 publizierten Racing Calendar für Pferderennen in England als Beginn der Sport-Statistik. Mit der zunehmenden Standardisierung der Regeln im Sport ist auch der Wunsch gewachsen, Leistungen über Wettkämpfe hinweg zu vergleichen. Das begann mit dem Baseball. Baseball ist eine Sportart, die den Leistungsvergleich zwischen einzelnen Spielern besonders leicht, aber auch besonders interessant macht. Dementsprechend wurden im Baseball schon sehr früh – zum ersten Mal 1859 vom Sportjournalisten Henry Chadwick – Leistungsdaten von Spielern wie Runs, Hits, Assists, Errors in Form sogenannter *Box Scores* in Zeitungen veröffentlicht (Stauff, 2018). Die Zeitmessung mit Stoppuhren wurde bei den ersten modernen Olympischen Spiele 1896 in Athen allgemein eingeführt. Anders als Zeiten konnten Spielereignisse (Treffer, Bewegungen) lange Zeit nur manuell durch Zählen erhoben werden. Um diese Datenerhebung zu erleichtern, wurden spezielle Notationssysteme – vergleichbar mit der Stenografie – für verschiedene Sportarten eingeführt – etwa im Baseball schon 1910 von Evers und Fullerton (Eaves, 2015).

Im Jahr 1931 konstruierte L. L. Messersmith zunächst für Basketball, dann für American Football einen elektrischen Apparat, der es einem Bediener erlaubte, auf einer Zinnplatte – einem maßstabsgetreu verkleinerten Spielfeld – mit einem Stift die Bewegung eines Spielers während des Spiels nachzuempfinden. Der Apparat ermittelte dann rechnerisch die zurückgelegte Wegstrecke (Lyons, 1994). Messersmiths Erfindung geriet allerdings aufgrund schlechter Bedienbarkeit und mangelnder Genauigkeit schnell wieder in Vergessenheit. Für den europäischen Fußball entwickelte Charles Reep 1950 ein Notationssystem, das er selbst intensiv einsetzte, über das aber nur wenige Details bekannt wurden (Pollard, 2002).

Nachdem aber in der zweiten Hälfte des 20. Jahrhunderts die elektronische Datenverarbeitung auch den Sport erreicht hatte, veränderte sich die Situation grundlegend. Plötzlich war es möglich, Sportdaten in großer Zahl zu sammeln, elektronisch zu speichern und maschinell auszuwerten. Besonders erwähnenswert ist dabei Retrosheet (www.retrosheet.org), eine 1989 gegründete Organisation, die sich zum Ziel gesetzt hat, alle zugänglichen historischen Baseballdaten der amerikanischen Major League zu sammeln und in einer Datenbank zur Verfügung zu stellen.

Sportdaten werden sowohl im Training als auch im Wettkampf erhoben. Besonderes Interesse liegt natürlich auf den Daten des Wettkampfs. Die Daten können *Ergebnisse* eines Wettkampfs beschreiben (je nach Sportart Zeiten, Weiten, Gewichte oder Torergebnisse), aber auch *Ereignisse* während des Wettkampfs (im Fußball z. B. die Anzahl der Pässe, Eckstöße, Einwürfe oder Fouls). Die Aufzeichnung von Ereignisdaten kann einen Zeitstempel enthalten (Zu welcher Zeit beging der Spieler das Foul?) und eine räumliche Information (An welcher Stelle beging er das Foul?). Nach dem Vorhandensein dieser zeitlichen und räumlichen Informationen unterscheidet man die Sportdaten in folgende Kategorien:

1. *Statistiken* oder *Metriken* (ohne zeitliche und räumliche Informationen)
2. *Ereignisprotokolle* (mit zeitlichen, aber ohne räumliche Informationen)
3. *Spatio-temporale Daten* (mit zeitlichen und räumlichen Informationen)

2.1 Statistiken oder Metriken

Zur Bildung von sogenannten *Statistiken* (*statistics*, *stats*) oder *Metriken* (*metrics*) wird im einfachsten Fall die Anzahl von Ereignissen zusammengezählt. Es können auch Zahlen ins Verhältnis gesetzt oder Durchschnitte gebildet werden. Beispiel: Der Spieler beging während des Spiels drei Fouls. Der Spieler verwandelte drei von fünf Torschüssen. In der Saison waren 15 % seiner Pässe Fehlpässe. Statistiken können für einzelne Spieler, Teams oder Spiele ermittelt werden. Sie können über ein Spiel, ein Turnier, eine Saison oder über einen beliebigen zurückliegenden Zeitraum gebildet werden.

Die typischen Darstellungsformen von Sportstatistiken sind Tabellen oder Listen, aber auch Grafiken und Diagramme. Im Baseball werden die Statistiken seit Chadwick *Box Scores* genannt (Stauff, 2018). Abb. 3 zeigt einen typischen Box

BOSTON.	T.	R.	1B.	PO.	A.	E.	ATHLETIC.	T.	R.	1B.	PO.	A.	E.
G. Wright, s.s	6	4	4	1	5	2	Force, s.s	5	1	2	1	3	2
Leonard, 2 b.	6	3	3	4	4	3	Eggler, c. f. .	5	3	3	0	0	3
O'Rourke, 1 b	6	2	3	9	0	1	Fisler, r. f. . .	5	0	1	2	0	1
Murnan, l. f.	6	1	0	3	1	0	Meyerle, 3db	5	1	2	2	3	0
Schafer, 2d b	6	3	3	3	1	2	Suttou, 1st b.	5	1	2	10	0	2
McGinley, c.f.	6	0	0	0	0	1	Coons, c. . . .	5	1	0	1	1	1
Manning, r.f.	6	0	2	2	0	0	Hall, l. f. . . .	5	1	3	5	0	0
Morrill, c . . .	6	2	2	4	1	2	Fowser, 2d b.	6	1	2	6	7	2
Josephs, p . .	5	4	4	1	1	2	Knight, p . . .	5	2	2	0	1	2
—	—	—	—	—	—	—	—	—	—	—	—	—	—
Totals	53	19	21	27	13	13	Totals	46	11	17	27	15	15
Boston	0			1	3	3	4	1	0	2		5	—19
Athletic	1			0	0	0	3	3	2	2		0	—11
Runs earned —Boston, 4; Athletic, 5. Home-run —Hall, 1. Total bases on hits —Boston, 22; Athletic, 20. First base by errors —Boston, 8; Athletic, 5. Umpire, George White of Lowell, Mass. Time 2h. 47m.													

Abb. 3 Statistik (Box Score) des Baseballspiels Boston Red Caps vs. Philadelphia Athletics vom 13. Mai 1876

Score, der sowohl teambezogene als auch spielerbezogene Daten enthält.

Der Nachteil von Box Scores ist, dass durch die Aufsummierung von Ereignisdaten die zeitliche Komponente und damit auch mögliche Ursache-Wirkung-Beziehungen verloren gehen. So ist etwa nicht mehr ersichtlich, dass ein Tor kurz nach einem Eckstoß gefallen ist, und damit ursächlich auf diesen zurückgeführt werden kann.

2.2 Ereignisprotokolle

Um diesen zeitlichen Zusammenhang zu bewahren, ist eine zeitgenaue und zeitmarkierte Aufzeichnung der Ereignisdaten notwendig. Diese Aufzeichnungen werden häufig als *Event Logs* (Pappalardo et al., 2019), *Event Streams* (Decroos, 2020), oder *Play-by-Play-Daten* (Vračar et al., 2016; Garnica Caparrós, 2024) bezeichnet, im Deutschen auch als *Ereignisprotokolle*. Ereignisprotokolle erlauben eingehendere Analysen als Statistikdaten, bilden aber sehr große Datenströme, die zunächst wenig übersichtlich sind. Abb. 4 zeigt einen Ausschnitt aus dem Ereignisprotokolls eines Basketballspiels der National Basketball

Association (NBA). Statistikdaten können durch entsprechende Aggregation von Ereignisdaten aus den Ereignisprotokollen gewonnen werden.

2.3 Spatio-temporale Daten

Werden Ereignisse nicht nur mit einem Zeitstempel, sondern auch mit exakten räumlichen Koordinaten versehen, so spricht man von *spatio-temporalen Ereignisdaten* (Gudmundsson & Horton, 2017; Pappalardo et al., 2019).


Davon zu unterscheiden sind die *Trajektorien* (Abb. 5). Trajektorien sind Bewegungsdaten von Spielern (Kovalchik, 2023) oder dem Ball (Kamble et al., 2019), die im Gegensatz zu Ereignisdaten zeitkontinuierlich oder nahezu zeitkontinuierlich sind. Trajektorien können mit Hilfe spezieller Technologien erfasst werden, die man Tracking-Technologien nennt. Daher spricht man auch von *Tracking-Daten*. Abtastfrequenzen sind beispielsweise 25 Aufzeichnungen pro Sekunde (Klemp et al., 2021).

Tracking-Daten können außer der Raum-Zeit-Komponente auch weitere Eigenschaften der Bewegung enthalten. In Ballsportarten werden oft

Charlotte Hornets	Detroit Pistons
	12:00 Jump Ball Wiseman vs. Williams: Tip to Oubre Jr.
MISS Rozier 8' Pullup Jump Shot	11:51
Hornets Rebound	11:51
	11:50 Livers L.B.FOUL (P1.T1) (M.Ervin)
MISS Hayward 13' Pullup Jump Shot	11:43
	11:39 Wiseman REBOUND (Off:0 Def:1)
	11:26 Ivey 26' 3PT Jump Shot (3 PTS) (McGruder 1 AST)
Washington 15' Pullup Jump Shot (2 PTS) (Rozier 1 AST)	0-3
	11:14
	2-3
	10:54 Livers Bad Pass Turnover (P1.T1)
Rozier STEAL (1 STL)	10:54
Washington 1' Running Dunk (4 PTS) (Rozier 2 AST)	10:49
	4-3
	10:43 McGruder 2' Driving Layup (2 PTS)
MISS Washington 24' 3PT Jump Shot	10:24
Williams REBOUND (Off:1 Def:0)	10:23
Washington 6' Hook Shot (6 PTS) (Williams 1 AST)	10:20

Abb. 4 Ereignisprotokoll (Event Log) aus dem Basketballspiel der Charlotte Hornets gegen die Detroit Pistons vom 12.03.2024. (Datenquelle: NBA, 2024)

Abb. 5 Trajektorien von drei Spielern in einem Zeitintervall von 10 min eines Fußballspiels



Geschwindigkeit, Beschleunigung oder Spin des Balls aufgezeichnet.

Es ist klar, dass spatio-temporale Daten nicht vom Spielfeldrand aus durch Zählen und Aufschreiben erfasst werden können. Deshalb wurden sie – wenn man von L. L. Messersmiths kurioser Erfindung in den 30er-Jahren absieht – von Sportanalysten lange nicht beachtet. Erst gegen Ende des 20. Jahrhunderts standen Technologien zur Verfügung, die es erlaubten, Sportdaten nicht nur digital zu speichern und zu verarbeiten, sondern auch digital zu erfassen.

Einen Durchbruch erzielten die Analytics-Firmen Amisco und Prozone in den Jahren 2001–2002, als sie erstmalig professionelle Video-Tracking-Systeme im Profi-Fußball einsetzten (Zubillaga et al., 2007). Dazu wurden Video-Kameras fest in Stadien installiert. Die Bewegungen von Spielern und Ball wurden mit Computer-Vision-Technologie erfasst, mussten aber von Experten manuell ergänzt und bei Bedarf korrigiert werden (Valter et al., 2006). In den Jahren danach kamen weitere Analytics-Anbieter dazu (z. B. Opta, Mediacoach, Instat, Wyscout). Die Verfahren wurden weiterentwickelt, und auch die Qualität der Tracking-Ergebnisse verbesserte sich ständig (Gudmundsson & Wolle, 2012; Castellano et al., 2014; Otero-Saborido et al., 2021; Liu et al., 2023).

Mit Beginn der Saison 2008 wurde in den 30 Stadien der Major League Baseball (MLB) ein von Sportsvision entwickeltes System PITCHf/x

eingeführt, mit Hilfe dessen es möglich wurde, die 3D-Trajektorie und Geschwindigkeit des vom Pitcher geworfenen Balles zu erfassen (Healey, 2017; Kagan & Nathan, 2017). Grundlage war wiederum ein Video-Tracking über drei fest im Stadion installierten Kameras. Trajektorie und Geschwindigkeit werden während einer Fernsehübertragung direkt ins Bild eingeblendet. Sie können auch den Schiedsrichter (Umpire) bei der Entscheidung unterstützen, ob der Ball in der Strike Zone war oder nicht. Seit 2015 ist in der MLB ein System von Statcast in Betrieb, das mit 12 Kameras arbeitet, wobei 5 Kameras das Duell zwischen Pitcher und Batter beobachten und 7 weitere Kameras Bewegungen des Balles und der Spieler im Außenfeld aufzeichnen (Romero, 2015; Mizels et al., 2022; Goldbeck, 2024). Vergleichbare Systeme werden heute auch im Hockey und American Football eingesetzt (Mallepalle et al., 2019).

Die Video-Tracking-Technologie wurde immer leistungsfähiger und präziser – letztlich aber bot sie immer nur eine Beobachtung des Spielgeschehens „vom Spielfeldrand aus“. Erst mit den modernen Sensor- und GPS-Technologien, die Anfang der 2000er-Jahre in Form von *Wearable Devices* auf den Markt kamen, ist das Tracking auch direkt auf das Spielfeld gekommen. Die ersten Wearables, die im Sport verwendet wurden, waren *Smart Watches* wie der Garmin Forerunner, der 2003 speziell für Läufer eingeführt wurde. Es folgten der Fitbit

Tracker und die Apple Watch. Diese Geräte, auch Fitness Trackers genannt, verfolgen die zurückgelegte Wegstrecke, Geschwindigkeit, Herzfrequenz oder auch den Kalorienverbrauch. Fitness Trackers werden von Freizeit- als auch Profisportlern zur Leistungsüberwachung im Training eingesetzt, aber auch von Menschen außerhalb des Sports für das Gesundheitsmonitoring.

Nach der ersten Smart Watch gab es eine rasante Entwicklung von Wearable Devices. Einerseits hat sich die Sensor-Technologie enorm weiterentwickelt – heute gibt es eine Vielzahl von Sensoren zur Erfassung physiologischer und biomechanischer Parameter, von Umgebungs- und Positionsdaten. Als Beispiel sei nur der Elektromyografie-Sensor (EMG) genannt, der Muskelaktivität über elektrische Signale auf der Haut misst (Aroganam et al., 2019). Andererseits sind diese Sensoren in eine Vielzahl von Wearables integriert worden, z. B. in Helme, Armbänder, Brustgurte, Westen, Handschuhe, Gürtel oder Schuhe (Seshadri et al., 2019; Seçkin et al., 2023; Liu et al., 2023).

Im Jahr 2015 führte die National Football League (NFL) zusammen mit Zebra Technologies das System *Next Gen Stats* ein, das Spieler- und Ballbewegungen mit Hilfe von in die Schulterpolster der Spieler und in den Ball eingebauter RFID-Tags und 20–30 Ultra-Breitbandempfängern im Stadion erfasst (Sanchez et al., 2023).

Europäische Fußballklubs nutzten Wearables – Westen, die unter dem Trikot getragen werden – bereits ab 2009 (Studnicka, 2020; D’Onofrio, 2024). Die FIFA setzte 2017 ein Zertifizierungsprogramm für Electronic Performance Tracking Systems (EPTS) auf. Als erster Hersteller erhielt Catapult 2018 eine Zulassung; viele andere Hersteller folgten (Pino-Ortega & Rico-González, 2021). Bei den Fußball-Weltmeisterschaften 2018 in Russland setzten bereits alle 32 Teams Wearables ein (Datta et al., 2018). Zur Fußball-Weltmeisterschaft 2022 in Katar lieferte Adidas den offiziellen Ball. Der Ball ist im Inneren mit einem Bewegungssensor ausgestattet, der 500 Mal in der Sekunde die genaue Position des Balls misst und auch Berührungen des Balls erkennt (Adidas, 2022).

Es wurde bereits erwähnt, dass Videodaten eine große Rolle bei der Erfassung spatio-temporaler Daten und Trajektorien spielen. Dazu werden spezielle Kameras, beim Baseball sind es etwa 12, fest am Spielfeldrand installiert, sodass sie gemeinsam das gesamte Spielfeld erfassen. Ganz anders stellt sich die Situation dar, wenn Videodaten aus Fernsehübertragungen (broadcast videos) analysiert werden sollen. Hier können sich Blickwinkel und Bildausschnitt ständig ändern. Dies stellt eine neue Herausforderung an die Bestimmung der Spieler- oder Ballposition auf dem Spielfeld dar (Sato & Aggarwal, 2005; Miura et al., 2009). Durch den Bildausschnitt wird das Spielgeschehen nur teilweise erfasst, ein Verfahren muss nach Möglichkeit fehlende Informationen ergänzen. Die wichtigsten Ereignisse – Tore, Fouls, Freistöße – sind aber typischerweise in der Aufzeichnung enthalten, sodass Ereignisse erkannt und Ereignisprotokolle (event streams) mit entsprechenden Verfahren aus dem Video erzeugt werden können (Shih, 2017). Der Reiz, vorhandene Videoaufzeichnungen von Sportveranstaltungen nachträglich zu analysieren, ist groß. Viele historische Aufnahmen stehen heute in Archiven, Mediatheken und auf Internet-Plattformen zur Verfügung. Wegen der langen Spieldauer entsteht oft der Wunsch, die wichtigsten Abschnitte eines Spiels zu extrahieren und eine kurze Zusammenfassung des Spiels (Video Summarization) zu erstellen (Ajmal et al., 2012; Vasudevan & Gounder, 2023). Für solche Zwecke gibt es bereits kommerzielle Lösungen wie SkillCorner oder Track160.

Mit den spatio-temporalen Daten erreichte das Volumen der im Sport erzeugten Daten eine derartige Größenordnung, dass man von *Big Data* sprechen kann. In einem Baseballspiel der Major League Baseball (MLB) wurden 2015 beispielsweise schon 7 Terabytes an unkomprimierten, bzw. 80 Gigabytes an komprimierten Daten erzeugt (Event-, Positions- und Videodaten). Mit 2430 Begegnungen pro Jahr summiert sich das auf 17 Petabytes an Daten jährlich (Darrow, 2015; Mizels et al., 2022).

Zusammenfassend bietet Abb. 6 einen Überblick über die Entwicklung der Sportdaten und ihrer Erfassung von 1859 bis heute.




Abb. 6 Entwicklung der Sportdaten und ihrer Erfassung von 1859 bis heute

Der Besitz von Daten ist auch im Sportgeschäft längst zu einem Wettbewerbsfaktor geworden, ganz im Sinne der berühmten Überschrift „The world’s most valuable resource is no longer oil, but data“ aus dem *Economist* vom Mai 2017. Deshalb ist es nicht verwunderlich, wenn Clubs, Ligen, Verbände und Analytics-Firmen ihre wertvollsten Daten für sich behalten oder zu hohen Preisen verkaufen. Demzufolge beklagen Forscher eine „Datenlücke“ (data gap), die heute zwischen proprietären und öffentlichen Daten im Sport besteht (Harell & Bajic, 2019).

Dennoch gibt es heute eine Vielzahl an Sport-Datasets, die öffentlich verfügbar sind (Dubitzky et al., 2019; Wakelam et al., 2022). Auf der Plattform Kaggle (www.kaggle.com) zum Beispiel sind derzeit 5332 Datasets unter dem Stichwort „Sport“ zu finden. Die meisten öffentlich zugänglichen Dateien enthalten jedoch vorwiegend Statistik- und Event-Daten, aber keine spatio-temporalen Daten. Eine bemerkenswerte Ausnahme bildet das Dataset, das im Rahmen der schon erwähnten *Soccer Data Challenge* für Datenanalysten von der Firma Wyscout öffentlich zur Verfügung gestellt wird. Die Daten basieren auf Spielen verschiedener europäischer Ligen und der Fußball-Weltmeisterschaft 2018 (Pappalardo et al., 2019).

Mit dem wachsenden Volumen an Daten und der zunehmenden Präzision wuchs auch der Wunsch, diese Daten eingehender zu analysieren. Dazu bedurfte es immer anspruchsvollerer Verfahren, die wir heute als *Big Data Analytics* bezeichnen. Im nächsten Abschnitt werden diese

Analytics auch mit Hinweisen auf ihre historische Entwicklung vorgestellt, die parallel zur Digitalisierung im Sport stattgefunden hat.

3 Verfahren der Sports Analytics

Davenport and Harris gaben uns eine sehr brauchbare Definition von Analytics: „By analytics we mean the extensive use of data, statistical and quantitative analysis, explanatory and predictive models, and fact-based management to drive decisions and actions“ (Davenport & Harris, 2007). Davenport und Harris verstehen unter Analytics die Nutzung von Werkzeugen, die Entscheidungsträgern – im Sport beispielsweise dem Trainer oder Clubmanager – helfen, bessere Entscheidungen zu treffen.

In letzter Zeit verschwindet der Begriff *Analytics* zunehmend zugunsten des Begriffs *Künstliche Intelligenz*. Vielfach wird *Analytics* einfach durch *Künstliche Intelligenz* ersetzt, und inhaltlich bleibt alles beim Alten. Wir bräuchten aber den Begriff *Künstliche Intelligenz* nicht, wenn nicht mehr damit gemeint wäre. Einen Hinweis liefert uns Mainzer (2016): „Ein System heißt intelligent, wenn es selbstständig und effizient Probleme lösen kann“ oder Boobier (2018): „Analytics acts as an informed advisor, giving greater insight to the decision maker. Artificial intelligence is the process whereby the system actually makes the decision“. Roboter, ChatBots, oder Autonomes Fahren kann man dieser Definition von KI unterordnen. Für die mathematischen

Verfahren, die auch diesen KI-Systemen zugrunde liegen, bleiben wir lieber bei der Bezeichnung *Analytics*.

Diese analytischen Verfahren stammen aus verschiedenen wissenschaftlichen Disziplinen, vor allem aus der Statistik und Wahrscheinlichkeitstheorie, dem aus der Informatik hervorgegangenen Data Mining und Machine Learning sowie dem Operations Research (OR). Nicht erst seit Davenport und Harris, die diese Kategorisierung populär machten, unterscheiden wir Analytics in

- *Deskriptive Verfahren:*

Hierunter fallen Verfahren, die vorhandene Daten aufbereiten, zusammenfassen und beschreiben, um dem Entscheidungsträger Hilfestellung zu geben. Der Entscheidungsträger muss die Ergebnisse allerdings selbst interpretieren und gegebenenfalls extrapolieren, um sie in Entscheidungen umzusetzen. Mit wachsenden Datenmengen fällt diese Interpretation allerdings immer schwerer. Das war der Grund für die Entwicklung des *Data Mining*. Data Mining zielt darauf ab, in großen, unübersichtlichen Datenmengen bisher unbekannte Zusammenhänge, Muster, Auffälligkeiten und Trends zu erkennen.

- *Prädiktive Verfahren:*

Diese Verfahren generieren aus vorhandenen Daten Vorhersagen (predictions, forecasts). Mit Vorhersagen ist immer eine gewisse Unsicherheit verbunden. Der Entscheidungsträger muss abwägen, inwieweit er der Vorher-

sage traut, um seine Entscheidung darauf zu stützen.

- *Präskriptive Verfahren:*

Diese Verfahren berechnen aus vorhandenen Daten und einer vorgegebenen Zielsetzung die beste Entscheidung. Der Entscheidungsträger kann das Ergebnis des Verfahrens als Vorschrift (prescription) oder als Empfehlung (recommendation) ansehen.

Die folgende Vorstellung der Verfahren orientiert sich an dieser bekannten Einteilung in deskriptive, prädiktive und präskriptive Verfahren (Abb. 7). Dabei soll auch auf die Herkunft dieser Verfahren aus den unterschiedlichen Wissenschaftsdisziplinen eingegangen werden. Einige Verfahren können unterschiedlich eingesetzt werden. Deshalb orientiert sich die Zuordnung der Verfahren zu den Kategorien an ihrer überwiegen- den Verwendung.

3.1 Deskriptive Verfahren

Deskriptive Verfahren haben ihre Wurzeln in der klassischen, beschreibenden Statistik. Aus der Informatik kommen Techniken der grafischen Datenverarbeitung, die mit der Visualisierung zu einem besseren Verständnis von Statistiken beitragen, und Data-Mining-Verfahren, die es ermöglichen, bislang unbekannte Muster und Zusammenhänge in den Daten zu entdecken.




Abb. 7 Übersicht über die in diesem Kapitel vorgestellten Verfahren der Sports Analytics

3.1.1 Beschreibende Statistik

Unter den genannten Disziplinen hat die Statistik die längste Geschichte. Sie entwickelte sich bereits im 18. und 19. Jahrhunderts. So konnte der Sport schon früh auf diese Verfahren zurückgreifen. Wie schon im letzten Kapitel erwähnt, begann die Erfassung und Veröffentlichung detaillierter Sportstatistiken bereits im 19. Jahrhundert im Baseball. Neben der Dokumentation reiner Zählergebnisse (Zeiten bei Laufwettbewerben; Toren, Pässen, Eckstößen, Fouls im Fußball; Hits, Runs, Balls, Walks im Baseball) werden häufig auch Durchschnittswerte gebildet.

Welchen Stellenwert die Statistik im Baseball errungen haben, zeigt sich am Titel eines Buches von Alan Schwarz: „The Numbers Game: Baseball’s Lifelong Fascination with Statistics“. Schwarz beschreibt darin, „wie Baseball und seine Zahlen seit der Entstehung des Sports untrennbar miteinander verbunden sind“ (Schwarz, 2004). Auch wenn in anderen Sportarten die Zahlen nicht so sehr im Vordergrund stehen, so hat doch fast jeder Sportverband heute seine „Statistikseiten“. In der Bundesliga sind das beispielsweise die Spieler- und Mannschaftsstatistiken (www.bundesliga.com/de/bundesliga/statistiken).

Ein wichtiges Element der beschreibenden Statistik sind Häufigkeitsverteilungen. Schon seit den 1950er-Jahren beschäftigen sich Wissenschaftler damit, Häufigkeitsverteilungen für stark dem Zufall unterworfenen Zählgrößen, wie z. B. die Anzahl der in einem Fußballspiel geschossenen Tore oder die in einem Basketballspiel erzielten Punkte, zu identifizieren (Abb. 8).

Dabei zeigt sich, dass in Sportarten mit niedrigerer Punktzahl, wie Fußball oder Baseball, die Verteilung einer Poisson-Verteilung ähnelt (Moroney, 1956; Reep & Benjamin, 1968; Maher, 1982), während in Sportarten mit hoher Punktzahl, wie Basketball oder American Football, die Verteilung einer Normalverteilung nahekommt (Abb. 8 rechts). Aufgrund der großen Zahl von Beobachtungen, über die man im Sport zweifellos verfügt, kann man gemäß dem Gesetz der großen Zahlen davon ausgehen, dass die ermittelte Häufigkeitsverteilung einer theoretischen Wahrscheinlichkeitsverteilung entspricht, die auch in Zukunft Gültigkeit hat. Wie diese Wahrscheinlichkeitsverteilung zur Prognose von Spielergebnissen eingesetzt werden kann, soll in Abschn. 4.5 gezeigt werden.

3.1.2 Visualisierung

Neben den Listen und Tabellen der beschreibenden Statistik kommt der Visualisierung von Sportdaten eine herausragende Rolle zu (Perin et al., 2018; Du & Yuan, 2021). Visualisierung macht komplexe Zusammenhänge verständlich und erleichtert die Kommunikation zwischen den Beteiligten. Die Geschichte der Datenvisualisierung reicht weit in die vordigitale Zeit zurück. Eines der bekanntesten historischen Beispiele ist die grafische Darstellung von Napoleons Russlandfeldzug 1812–1813, die von Charles Minard 1869 veröffentlicht wurde (Tuft, 1983).

In der ersten Hälfte des zwanzigsten Jahrhunderts visualisierten Zeitungen bereits Sportdaten. Einige interessante Beispiele aus dem Fußball




Abb. 8 Häufigkeitsverteilung der Gesamtanzahl der Tore pro Spiel im Fußball (links) und der Anzahl von Heim- (blau) und Auswärtspunkten (rot) pro Spiel im Basketball

(rechts). Datenbasis: Bundesligaspiele von 1993 bis 2018, NBA-Spiele von 2014 bis 2022. (Quelle: www.kaggle.com)

gibt es in einer ungarischen Sportzeitung der Jahre 1922 bis 1942 (Bátorfy, 2020). Mit der im letzten Kapitel beschriebenen Entwicklung des Volumens und der Komplexität der Sportdaten erhöhte sich der Bedarf an Visualisierung weiter. Es gibt kaum eine Visualisierungstechnik, die im Sport nicht eingesetzt wurde. Grundlage für die Visualisierung sind Box-Score-Daten, Event-Daten und spatio-temporale Daten. Dabei müssen aus einer Vielzahl von Dimensionen (Objekte, Attribute, Raum, Zeit) einige wenige ausgewählt werden, die sich auf den zwei Dimensionen des Papiers oder des Bildschirms verständlich darstellen lassen. *Stern- oder Spinnennetzdiagramme (radar charts)* eignen sich für die Visualisierung von Attributen eines oder mehrerer Objekte. Sie werden häufig zur Darstellung und zum Vergleich von Spielereigenschaften herangezogen (Abb. 17, siehe auch Knutson, 2021). Auf manchen Baseball-Sammelbildern sind die Spieler zusammen mit ihrem individuellen Radar Chart abgebildet (Hooper, 2024).

In anderen Darstellungen steht der zeitliche Verlauf von Größen im Vordergrund. Einfache *Liniendiagramme (line charts)* werden häufig eingesetzt, um die Position einer Mannschaft in der Tabelle oder die Position eines Spielers in der Rangliste über einen Zeitraum hinweg zu visualisieren (siehe z. B. <http://clubelo.com/ManCity>). In der oben erwähnten ungarischen Sportzeitung wurde bereits 1922 der Verlauf eines Fußballspiels über 90 min in einem Liniendiagramm visualisiert, wobei die x-Achse die Zeit und die y-Achse die jeweilige „Ballhöhe“ (gemessen von der Mittellinie in Richtung des einen oder anderen Tores) abbildet. Ereignisse wie Torschüsse, erzielte Tore, Freistöße usw. sind an den entsprechenden Stellen eingetragen. In Abwandlung dazu wird auf der y-Achse eines *Säulendiagramms (vertical bar chart)* oder eines *Splinediagramms (spline chart)* das „Momentum“ eingetragen, eine nicht einheitlich definierte Metrik, die den „Schwung“ oder die „Dynamik“ einer Mannschaft beschreiben soll (Grootjans, 2014; Whitmore, 2021). Wird das Momentum der einen Mannschaft nach oben und das der anderen nach unten abgetragen, so zeigt das Diagramm sehr anschaulich den Wechsel des jeweiligen Mo-

mentums und die Balance der beiden Mannschaften über die Spielzeit hinweg.

Eine weitere Darstellung eines zeitlichen Verlaufes bietet die *Storyline-Visualisierung*, die für eine Anwendung bei eSports, League of Legends, genutzt (Wallner et al., 2023) und an anderer Stelle schon als *Movie Narrative Chart* vorgestellt wurde (Munroe, 2009). Die Storyline-Visualisierung ordnet auf der y-Achse eine Reihe diskreter Orte des Geschehens an. Verbindungslinien visualisieren die Bewegungen von Spielern von Ort zu Ort und lassen so etwa Begegnungen von Spielern leicht erkennen. Mit Icons können zusätzlich bestimmte Ereignisse kenntlich gemacht werden.

Die räumliche Visualisierung im Sport findet vorwiegend im zweidimensionalen (2D), gelegentlich auch im dreidimensionalen (3D) Raum statt, dann auf 2D projiziert. Wieder zeigt Bátorfy ein frühes Beispiel (1936) eines *Punktdiagramms (scatter plot)*, das auf einer vertikalen Fläche über der Torlinie eines Fußballfeldes die Trefferpositionen des Balles beschreibt – Positionen innerhalb und außerhalb des Tores. Dabei ist die Stärke des jeweiligen Schusses noch zusätzlich gekennzeichnet. Ähnliche Vertikaldarstellungen sind auch aus dem Schießsport (Zielscheibe) und dem Baseball (striking zone) bekannt.

Viel häufiger findet man die Visualisierung allerdings auf einem horizontalen Abbild des Spielfeldes. Auf dieser Fläche können Ereignisse dargestellt werden (z. B. Schüsse, Würfe, Pässe), Häufigkeiten bzw. Wahrscheinlichkeiten, aber auch Trajektorien von Spielern oder Ball.

Wie Bátorfy an einem Beispiel zeigt, wurden schon im Jahr 1942 Schusspositionen auf einem Fußballfeld visualisiert. Aber erst mit der Digitalisierung wurde diese Darstellungsart auch für Sportarten mit hohen Ereignisfrequenzen wie z. B. dem Basketball, American Football, oder auch Tennis zugänglich. Für Basketballspiele wurden von Goldsberry (2012) sogenannte *Shot Charts (Wurfkarten)* entwickelt: sie zeigen die Wurfpositionen eines Spielers oder aller Spieler einer Mannschaft auf dem Spielfeld wiederum in Form eines Punktdiagramms (scatter plot). Die Trefferquoten der Würfe werden dabei durch die Farbe der Punkte gekennzeichnet.

Betrachtet man eine Vielzahl von Spielen, so beginnen die Punkte sich so zu überlappen, dass sie am Ende nicht mehr unterscheidbar sind. Die Punktwolke geht in kontinuierliche farbige Flächen über, die an Landkarten mit Höhenlinien erinnern (*Konturdiagramme, contour plots*). Solche farbigen Landkarten werden z. B. für die Visualisierung der Erfolgswahrscheinlichkeit von Torschüssen (Expected Goals) im Fußball erstellt (Abb. 9, vgl. auch Abschn. 4.1).

Eine ähnliche Idee liegt auch den *Heat Maps* oder *Intensity Maps* (Gudmundsson & Horton, 2017) zugrunde, die im Gegensatz zu den Konturdiagrammen das Spielfeld nicht in kontinuierliche Bereiche, sondern in kleine farbige Quadrate zerlegen. Dabei wird oft eine Farbskala von Blau bis Rot gewählt, die man mit den Temperaturen kalt und heiß assoziiert. Solche Heat Maps werden z. B. verwendet, um die Aufenthaltshäufigkeit einzelner Spieler oder aller Spieler einer Mannschaft in bestimmten Bereichen des Spielfeldes zu visualisieren (Abb. 10).

Oftmals ist neben der räumlichen Aufenthaltshäufigkeit eines Spielers auch sein tatsächliches Laufverhalten von Interesse. Dazu werden *Trajektorien* einzelner Spieler auf dem 2D-Abbild des Spielfeldes visualisiert (Pingali et al., 2001; Raabe et al., 2022). Die Zeitdimension ist hierbei nicht sichtbar, aber implizit in der Darstellung enthalten (Abb. 5).

Eine besondere Visualisierung von Event-Daten, entstanden im Fußball, sind die *Pass* oder *Passing Networks* (Peña & Touchette, 2012; Linke, 2020). Pass Networks sind Graphen, bei denen die Spieler einer Mannschaft die Knoten bilden

und Pässe zwischen den jeweiligen Spielern die Kanten. Die Anzahl der Pässe, die ein Spieler insgesamt geschossen hat, bestimmt die Größe eines Knoten, und die Anzahl der Pässe zwischen zwei Spielern die Stärke der Kanten. Die Knoten des Graphen sind so angeordnet, dass sie dem mittleren Aufenthaltsort des Spielers auf dem Spielfeld entsprechen.


Balltrajektorien werden sinnvollerweise in 3D dargestellt und kommen unter anderem in Sportarten wie Tennis (Pingali et al., 2001), Baseball (Guéziec, 2002; Chen et al., 2008), Golf (Takahashi et al., 2019) zum Einsatz. Bei Fernsehübertragungen werden diese Trajektorien häufig ins Bild mit eingeblendet (Cavallaro et al., 2011).

Datenvisualisierung wird in nahezu allen Sportarten eingesetzt, und es gibt, beginnend mit dem Scouting und der Rekrutierung über das Training und die Spielanalyse bis hin zur Medienberichterstattung, kaum eine Anwendung im Sport, die nicht durch Visualisierung unterstützt werden könnte.

3.1.3 Clustering

Die ersten Clustering-Verfahren wurden in den 1960er-Jahren entwickelt. Sie werden heute dem Data Mining und Machine Learning zugerechnet. Das Ziel des Clusterings besteht darin, eine Menge von Objekten so in Gruppen (Cluster) aufzuteilen, dass Objekte innerhalb einer Gruppe einander ähnlich sind, während sich Objekte in unterschiedlichen Gruppen voneinander unterscheiden. Ähnlichkeit wird dabei als Grad der Übereinstimmung von Merkmalen (Features) der Objekte definiert. Zur mathematischen Beschrei-

Abb. 9 Konturdiagramm für Erfolgswahrscheinlichkeit von Torschüssen (Expected Goals) im Fußball. (Vgl. Hjort, 2021)






Abb. 10 Heat Map für die Aufenthaltshäufigkeit der Spieler einer Mannschaft

bung dieser Ähnlichkeit (oder Unähnlichkeit) stehen eine Reihe von Ähnlichkeits- oder Distanzmaßen zur Verfügung. Die Anzahl der zu bildenden Cluster steht im Allgemeinen zu Beginn noch nicht fest – der Algorithmus soll eine nach bestimmten Kriterien optimale Anzahl von Clustern finden. Das macht Clustering zu einem explorativen Verfahren. Für das Clustering gibt es eine Vielzahl von Algorithmen (Fahad et al., 2014). Die bekanntesten unter ihnen sind Hierarchisches Clustering (zurückgehend auf Ward, 1963), partitionierendes Clustering (z. B. K-Means), und dichtebasierte Algorithmen (z. B. DBSCAN).

Clustering ist in der Sportanalytik weit verbreitet. Schwerpunkte des Einsatzes liegen in der Spieler- und Mannschaftsbewertung und in der Spielanalyse, auf die in den Abschn. 4.1 und 4.6 näher eingegangen wird. In technischen Sportarten spielt die Analyse von Bewegungsabläufen eine große Rolle. Clustering wird hier häufig eingesetzt, um Ähnlichkeiten und Unterschiede zwischen Bewegungen zu erkennen (siehe Abschn. 4.3).

3.1.4 Association Mining

Association Mining kommt ursprünglich aus der Warenkorbanalyse im Handel, wo es darum geht, zu analysieren, welche Artikel häufig zusammen gekauft werden. Dieses Verfahren kann auch auf

Ereignisse angewandt werden, also auf die Frage, welche Ereignisse über einen gewissen Zeitraum hinweg häufig zusammen auftreten, oder genauer: welche Ereignisse häufig nacheinander auftreten. Man spricht dann von *Frequent Pattern Mining*, *Sequential Pattern Mining* oder *Rule Mining*. Mit den Ereignisprotokollen (event streams), die im Sport gesammelt werden, bieten sich vielfältige Möglichkeiten der Analyse. Insbesondere lassen sich häufig genutzte Aktionsfolgen erkennen, die für einen Spieler oder eine Mannschaft typisch sind, oder Aktionsfolgen, die zu einem Punkterfolg führten (UmaMaheswari & Rajaram, 2009). Beides sind wertvolle Bestandteile einer Spielanalyse.

3.1.5 Hauptkomponentenanalyse

Die *Hauptkomponentenanalyse* (*Principal Component Analysis, PCA*) ist ein Verfahren der multivariaten Statistik (entwickelt von Pearson, 1901 und Hotelling, 1933), das mit der Zunahme der Datenvolumen (big data) neue Bedeutung erlangte. Die PCA transformiert die ursprünglichen Variablen eines gegebenen Datensatzes, die oft stark miteinander korreliert sind, in wenige unkorrelierte Variablen, die sog. Hauptkomponenten, die aber immer noch nahezu denselben Informationsgehalt besitzen wie die ursprünglichen Daten. Meist wird mit der PCA eine *Dimensionsreduktion* durch-

geführt, bevor andere analytische Verfahren wie Clustering oder Entscheidungsbäume eingesetzt werden (Plakias et al., 2023; Parmar et al., 2018). Da oft schon wenige Hauptkomponenten die Daten gut beschreiben, eignet sich die PCA auch sehr gut für eine Visualisierung von Daten in 2D oder 3D (Nishida, 2018).

3.1.6 Process Mining

Process Mining ist ein Spezialgebiet des Data Mining, das sich mit der Analyse von Prozessabläufen beschäftigt (Van der Aalst, 2011). Process Mining geht von der Existenz eines Prozessmodells aus, das unter Umständen nicht bekannt ist, sich aber aus der Analyse von Ereignisdaten (event streams) konstruieren lässt (process discovery). Bei bekanntem Prozessmodell kann überprüft werden, ob eine beobachtete Folge von Ereignissen mit dem Prozessmodell übereinstimmt (process conformity).

Kröckel und Bodendorf (2020) setzten Process Mining ein, um die Event-Daten eines Fußballspiels zu analysieren. Für beide Mannschaften wurden Prozessmodelle aufgestellt und miteinander verglichen. Die Autoren konnten beispielsweise ermitteln, welche Eventfolgen zu einem Tor führten oder welche Ereignisse auf ein Foul folgten. So liefert das Process Mining wertvolle Informationen für die Spielanalyse. Über eine Analyse von Verletzungsverläufen mittels Process Mining (Pi-Rusiñol et al., 2024) wird in Abschn. 4.4 ausführlicher berichtet.

3.2 Prädiktive Verfahren

Prädiktive Verfahren gehen von einer Reihe von vorliegenden Beobachtungen von Objekten oder Ereignissen aus, um eine Aussage über ein unbekanntes Objekt oder ein in der Zukunft zu erwartendes Ereignis zu machen. Die Beobachtung bestehen meist aus einer Anzahl von Werten, die die Eigenschaften bzw. Merkmale eines Objekts oder des Ereignisses beschreiben. Ein Beispiel hierfür sind die Leistungsmerkmale eines Spielers, die sogenannten Spielerprofile, die im letzten Abschnitt mit deskriptiven Verfahren analysiert wurden.

Bei der Prädiktion kommt ein weiterer Wert zu den Merkmalen hinzu: die Zielvariable. Prädiktive Verfahren versuchen nun, aus einer (möglichst großen) Zahl von Beobachtungen Zusammenhänge zwischen Merkmalen und Zielwerten zu verstehen, um mit diesem Verständnis aus den Merkmalen eines neu beobachteten Objektes auf dessen Zielvariable zu schließen. In der Sprache des Machine Learning spricht man von „Lernen“. Merkmale werden als *Features*, Zielvariablen als *Labels* (deutsch seltener als *Marken*) bezeichnet. Liegen Beobachtungen vor, deren Labels man bereits kennt, so spricht man von *überwachtem Lernen* (*supervised Learning*) in Anlehnung an die Situation in der Schule, wo der Lehrer die Lösung einer Aufgabe bereits kennt und der Schüler diese durch das Feedback des Lehrers erlernt. Im Gegensatz dazu arbeitet das *unüberwachte Lernen* (*unsupervised learning*) mit nicht markierten Daten. Prädiktive Verfahren sind also dem überwachten Lernen zuzuordnen, während deskriptive Verfahren wie Clustering oder Hauptkomponentenanalyse zum unüberwachten Lernen zählen.

Prädiktive Verfahren machen heute den Löwenanteil der im Sport angewandten analytischen Verfahren aus. Zu den wichtigsten Anwendungen zählen die Leistungsprognose von Spielern und Mannschaften, die Verletzungsprognose und die Prognose von Spielergebnissen. Lange bevor in der zweiten Hälfte des letzten Jahrhunderts die Begriffe Data Mining und Machine Learning geprägt wurden, waren in der Mathematik Verfahren bekannt, die wir heute zu den prädiktiven Verfahren zählen. Dazu gehören z. B. die Regression und die Zeitreihenanalyse.

3.2.1 Regression

Die *Regression*, genauer gesagt die lineare Regression, geht auf Galton (1894) zurück. Die lineare Regression ist ein Verfahren, mit dem versucht wird, eine abhängige Variable durch eine oder mehrere unabhängige Variablen zu erklären bzw. durch eine lineare Funktion der unabhängigen Variablen zu approximieren.

In der Sprache des Machine Learning bezeichnet man die unabhängigen Variablen meist als *Features* (Eigenschaften eines Objekts) und die

abhängige Variable als *Target* (Zielvariable). Die Zielvariable der linearen Regression ist eine numerische, kontinuierliche Variable. Ist einmal der Zusammenhang zwischen den Features und der Zielvariablen hergestellt – im ML-Jargon: „gelernt“ –, kann man die Features als Prädiktoren für die Zielvariable verwenden und für ein noch unbekanntes Objekt die Zielvariable auf Basis seiner Features vorhersagen. Diese Vorhersage ist im Allgemeinen fehlerbehaftet, da der Zusammenhang zwischen Features und Zielvariable nur approximiert wurde.

Wenn ein linearer Zusammenhang zwischen den Variablen nicht festgestellt werden kann, geht man zur nicht linearen Regression über. Beispiele sind die polynomielle Regression, die exponentielle Regression und die logistische Regression. Letztere verwendet zur Approximation die S-förmige logistische oder Sigmoid-Funktion (vgl. Abb. 11). Die Funktion kann auch als Wahrscheinlichkeit für das Ausprägung einer binären Variablen interpretiert werden. Dann ist die logistische Regression den Klassifikationsverfahren zuzuordnen.

Bei der Anwendung der Regression besteht das Problem des *Overfitting*, d. h. einer zu engen Anpassung der Regressionsfunktion an die vorhandenen Beobachtungen, sodass die Gefahr einer Fehleinschätzung neuer Objekte besteht.


Um dieses Overfitting zu vermeiden, wurden spezielle Verfahren wie die *Ridge Regression* und die *Lasso Regression* entwickelt (James et al., 2013).

Lineare und nicht lineare Regression werden für verschiedenste Aufgaben in allen Gebieten der Sports Analytics eingesetzt, beispielsweise für das Studium der Auswirkungen des Trainings auf die sportliche Leistung (Fox et al., 2018) oder das Verletzungsrisiko, oder die Analyse des Zusammenhangs zwischen Torentfernung und Schusswinkel und der Erfolgswahrscheinlichkeit eines Torschusses im Fußball (Umami et al., 2021). Die Regression ist aber auch Grundlage von Zeitreihenprognosen, die im nächsten Abschnitt vorgestellt werden.

3.2.2 Zeitreihenprognose (Forecasting)

Sind die vorliegenden Beobachtungen zeitlich geordnet, so spricht man von einer Zeitreihe. Ziel der *Zeitreihenprognose* ist die Vorhersage zukünftiger Werte dieser Zeitreihe. Viele Verfahren gehen von Beobachtungen zu äquidistanten Zeitpunkten $1, 2, \dots, t$ aus und extrapolieren dieser Zeitreihe auf mehrere zukünftige Zeitpunkte $t+1, t+2, t+3, \dots$. Das bekannteste Beispiel ist die Wettervorhersage. Man beachte den Unterschied etwa zur Vorhersage eines Spielergebnisses im Sport, wo das Interesse ganz auf ein einzelnes,

Abb. 11 Weltrekorde im 800m-Lauf, umgerechnet in m/sec, von Männern (blau) und Frauen (rot) mit angepassten logistischen Funktionen, fortgeschrieben in Anlehnung an Nevill und Whyte (2005)



bevorstehendes Ereignis gerichtet ist. Für die beiden Fälle gibt es im Englischen eine sprachliche Unterscheidung: im ersten Fall spricht man eher von *forecasting* (*time series forecasting*), im zweiten Fall von *prediction* (*outcome prediction*).

Forecasting-Verfahren kommen aus einem eigenen Zweig der Statistik, der *Zeitreihenanalyse*. Bekannte Verfahren sind der *gleitende Durchschnitt* (*moving average*) oder die *exponentielle Glättung* (*exponential smoothing*), letztere auch unter Berücksichtigung von Trends und Periodizität. Yule (bereits 1927) und insbesondere Box und Jenkins (1970) formulierten die Zeitreihenanalyse auf Basis der Theorie der stochastischen Prozesse. Daraus entstanden Verfahren wie *ARMA* (*auto-regressive moving average*) und *ARIMA* (*auto-regressive integrated moving average*), die auf einer Regression der zu prognostizierenden Variablen mit ihren eigenen Vergangenheitswerten beruhen.

Daneben gibt es *kausale Forecasting-Verfahren*, die die zu prognostizierende Variable auf eine oder mehrere sie beeinflussende unabhängige Variable zurückführen, dann eine Zeitreihenprognose der unabhängigen Variablen vornehmen, um im Anschluss diese Werte auf die zu prognostizierende Variable zu transformieren. Die zugrunde liegende mathematische Methode ist typischerweise die lineare Regression.

Life-Cycle Forecasting geht davon aus, dass es Variablen gibt, die einen ganz bestimmten, für sie charakteristischen Verlauf über die Zeit aufweisen. Ursprünglich kommt diese Idee aus dem Marketing, wo früh erkannt wurde, dass sich Produktlebenszyklen von der Markteinführung bis zum Produktauslauf immer wieder ähneln (Kovac & Dague, 1972). Führt man ein neues Produkt ein, für das schon erste Beobachtungen vorliegen, so kann durch die Analogiebildung mit möglichst ähnlichen Produkten, deren Verlaufskurven aus der Vergangenheit bereits bekannt sind, eine Prognose gemacht werden. Für diese Analogiebildung gibt es zwei Ansätze: einen modellbasierten und einen datenbasierten.

Der *modellbasierte Ansatz* geht davon aus, dass sich der charakteristische Verlauf eines bestimmten Typs von Variablen durch eine mathe-

mathematische Funktion beschreiben lässt. Solche Funktionen wurden auf der Basis vieler empirischer Beobachtungen z. B. von Bass und Gompertz für die Produkteinführung vorgeschlagen (sog. Diffusionsmodelle). Aber auch andere Verlaufsmodelle werden genutzt (Janssen & Laatz, 1997). Diese Funktionen haben typischerweise mehrere Parameter. Liegt eine Reihe von Beobachtungen der zu prognostizierenden Variablen vor, so können mit Hilfe der nicht linearen Regression die Parameter eines gegebenen Funktionstyps so eingestellt werden, dass die parametrisierte Funktion möglichst genau die beobachteten Werte approximiert. Man spricht auch von einer *Kurvenanpassung* (*curve fitting*). Der über die Beobachtungen hinausgehende Kurvenverlauf wird als Prognose betrachtet.

Kurvenanpassungsverfahren wurden öfters zur Prognose von Rekorden eingesetzt. Abb. 11 zeigt den Verlauf der Weltrekorde im 800m-Lauf, umgerechnet in m/sec, von Männern und Frauen vom Beginn des letzten Jahrhunderts bis heute. Nevill und Whyte (2005) approximierten diese Verläufe mittels sogenannter logistischer oder Sigmoid-Funktionen und lieferten so eine Prognose für mögliche zukünftige Entwicklungen. Bei den Männern gab es 2010 und 2012 neue Weltrekorde, die sehr gut mit der 2005 prognostizierten Entwicklung übereinstimmen. Bei den Frauen gab es seit 1983 keinen weiteren Weltrekord mehr.

Der *datenbasierte Ansatz* kommt ohne Modell aus. Im einfachsten Fall wird eine ganze Sammlung vergangener Verläufe vergleichbarer Situationen in einem Repository gespeichert. Sobald die ersten Beobachtungen der zu prognostizierenden Variablen vorliegen, kann im Repository nach der Kurve gesucht werden, die dem neuen Werteverlauf am ähnlichsten ist. Die Kurve aus dem Repository wird dann für die Prognose verwendet. Um nicht Unmengen vielfach redundanter Kurvenverläufe speichern zu müssen, können diese zu Clustern zusammengefasst werden. Aus diesen Clustern wird ein typischer Repräsentant ausgewählt, der *Archetyp*, der in der Folge zur Analogiebildung herangezogen wird. Dieses Verfahren wird auch *Similarity-Based Forecasting* genannt (Gilboa et al., 2014). Eine Anwendung

des Similarity-Based Forecasting auf die Leistungsprognose von Spielern wird in Abschn. 4.1 vorgestellt.

3.2.3 Klassifikation

Im Gegensatz zur Regression und Zeitreihenanalyse arbeitet die Klassifikation mit diskreten, kategoriellen Zielvariablen. Diese Zielvariablen nennt man auch *Klassen*, daher der Name *Klassifikation*. Klassen können binär sein (0 oder 1, positiv oder negativ, richtig oder falsch, Sieg oder Niederlage) oder auch mehrwertig (Sieg, Niederlage, Unentschieden). Wie bereits erwähnt, sind die Klassifikationsverfahren dem überwachten maschinellen Lernen zuzuordnen.

Klassifikationsverfahren waren Teil der Entwicklungen auf den Gebieten Data Mining und Machine Learning in der zweiten Hälfte des letzten Jahrhunderts, hatten jedoch Vorläufer in der Statistik wie die lineare Diskriminanzanalyse (1936) oder die logistische Regression (ca. 1930–1940). Die bekanntesten Klassifikationsverfahren sind Entscheidungsbäume (decision trees), der Naive-Bayes-Klassifikator (NB), K-nearest-neighbor

(KNN), Support Vector Machines (SVM), die logistische Regression und (künstliche) neuronale Netze (Han & Kamber, 2006). Die Wahl eines geeigneten Klassifikationsverfahrens ist von der Aufgabenstellung abhängig, insbesondere von der Art und vom Umfang der vorliegenden Daten. Da es für diese Wahl kein einfaches Rezept gibt, werden in Projekten oft mehrere Verfahren parallel angewandt und deren Leistungsfähigkeit miteinander verglichen.

Nachfolgend wird der Entscheidungsbaum als eines der am häufigsten eingesetzten Klassifikationsverfahren exemplarisch vorgestellt. Aufgrund ihrer besonderen Entwicklungsgeschichte werden die neuronalen Netze in zwei darauf folgenden Abschnitten separat behandelt.

Der *Entscheidungsbaum* (decision tree) ist ein Klassifikationsverfahren, das sich durch seine Verständlichkeit und Nachvollziehbarkeit auszeichnet. Der Name leitet sich vom Ergebnis des Verfahrens ab, welches in Form einer flussdiagrammähnlichen Baumstruktur visualisiert werden kann (Abb. 12).




Abb. 12 Entscheidungsbaum zur Ergebnisprognose eines Fußballspiels. Die wichtigste Variable ist das erste im Spiel geschossene Tor, gefolgt von den Torschüssen

insgesamt, gefolgt vom Heimvorteil und der Anzahl der Befreiungsschläge. (Bilek & Ulas, 2019)

Beim Entscheidungsbaum handelt es sich um ein iteratives Verfahren, bei dem zunächst nach einem Merkmal und einem dazugehörigen Merkmalswert gesucht wird, mit dem sich der Objektraum hinsichtlich der Zielvariablen am saubersten in zwei Teilräume zerlegen lässt. Dieses Merkmal bildet dann den Wurzelknoten des Entscheidungsbaumes mit einer Abfrage des Merkmalswertes. Für beide Teilräume sucht man wiederum das beste diskriminierende Merkmal, was zu weiteren Zerlegungen des Objektraums und im Baum zu weiteren Knoten mit Abfragen führt. Das geht so lange, bis der Objektraum vollständig in klassenreine Teilräume zerlegt ist. Der daraus entstandene Baum kann jetzt zur Klassifizierung bisher unbekannter Objekte verwendet werden. Der Entscheidungsbaum ist ein Verfahren, das dem Anwender die Klassifikation leicht nachvollziehbar und verständlich macht. Allerdings kann es auch hier, wie bei allen Machine-Learning-Verfahren, zu einem Overfitting kommen. Analysten bemühen sich, diesen Fehler durch geschickte Trainingstechniken klein zu halten und damit die Genauigkeit der Klassifikation zu erhöhen.

Eine Form dieser Trainingstechniken sind die sog. *Ensemble-Methoden*, bei denen das Verfahren mehrfach parallel auf verschiedene Teilmengen der Objektdaten angewandt und die Ergebnisse miteinander verknüpft werden (z. B. durch Durchschnittsbildung). Bekannte Verknüpfungsverfahren sind *Bagging* und *Boosting*. Ensemble-Methoden wurden auch auf Entscheidungsbäume angewandt. Bei Anwendung des Baggings führt das zu *Random Forests*. Das Verfahren *XGBoost* (*gradient-boosted trees*) ist eine Realisierung des Boosting.

Beispiele für die Anwendung von Entscheidungsbäumen im Sport gibt es reichlich. Sumathi et al. (2023) nutzen Random Forests zur Leistungsvorhersage von Spielern im Cricket. Rossi et al. (2018) verwenden Entscheidungsbäume zur Prognose von Verletzungen im Fußball. Ebenso werden Entscheidungsbäume zur Prognose von Spielergebnissen eingesetzt, z. B. im Fußball (Bilek & Ulas, 2019), im American Football (Young et al., 2019), im Tischtennis (Lennartz et al., 2021) oder im Cricket (Kumar

et al., 2018). In allen diesen Arbeiten werden neben dem Entscheidungsbaum auch andere Klassifikationsverfahren zum Vergleich herangezogen.

3.2.4 Neuronale Netze

Neuronale Netze oder *künstliche neuronale Netze* (*artificial neural networks*) bilden eine Gruppe von Machine-Learning-Verfahren, die vorwiegend zur Klassifikation und Regression eingesetzt werden und in diesem Fall dem überwachten Lernen (*supervised learning*) zuzurechnen sind.


Neuronale Netze haben eine lange Geschichte (Schmidhuber, 2022). Sie wurden inspiriert durch die Ergebnisse der Neurowissenschaften, die den Aufbau und die Arbeitsweise von Nervenzellen (Neuronen) im Gehirn erforscht haben. Axone, Dendriten und Synapsen regeln dort die Weitergabe von Informationen von einem Neuron zum anderen. Diese Weiterleitung unterliegt einem sehr komplizierten chemisch-elektrischen Prozess. Man spricht auch von „feuern“, wenn die Eingangssignale am Neuron einen gewissen Schwellenwert überschreiten und damit die Information weiterfließen kann.

Künstliche neuronale Netze versuchen, diese Gehirnstrukturen nachzubilden. Sie sind gerichtete Graphen, deren Knoten den Neuronen und deren Kanten den Axonen, Dendriten und Synapsen entsprechen. Die Stärke der Verbindungen wird durch Gewichte an den Kanten abgebildet, das „Feuern“ am Eingang zum Neuron wird durch eine *Aktivierungsfunktion* beschrieben.

Rosenblatt beschrieb bereits 1958 in der Physiologie ein *Perceptron*, das aus drei Schichten von Neuronen, der *Eingabeschicht* (*input layer*), einer *Zwischen- oder verdeckten Schicht* (*hidden layer*) und einer *Ausgabeschicht* (*output layer*) besteht (Abb. 13). Dieses Modell wurde zum Grundbaustein aller künstlichen neuronalen Netze und wird heute *Multi-Layer Perceptron* (MLP) genannt. Das MLP kann eine oder mehrere verdeckte Schichten besitzen. Außerdem ist das MLP ein sogenanntes *Feed-Forward-Netz* (FFN), in dem die Verbindungen streng nur in einer Richtung von der Eingabeschicht zur Ausgabeschicht verlaufen.

Das neuronale Netz wird trainiert, indem man viele Inputdaten nacheinander einspeist und die

Abb. 13 Multi-Layer Perceptron (MLP)



Ausgabe jeweils mit dem bekannten Zielwert vergleicht (supervised learning). Bei Nichtübereinstimmung werden die Gewichte angepasst, wofür es die unterschiedlichsten Verfahren gibt (z. B. den *Back Propagation-Algorithmus*). Aufgrund dieses Prozesses kann man das neuronale Netz als *selbstlernendes System* bezeichnen. Alle weiteren neuronale Netze unterscheiden sich durch die Anzahl der Schichten und Verbindungen (die „Architektur“), und durch die Aktivierungsfunktion.

Die Inputvariablen eines neuronalen Netzes entsprechen den Merkmalswerten (features) einer Beobachtung, die Outputvariable kann numerisch, binär oder allgemein kategoriell sein. Damit kann das neuronale Netz sowohl eine Regression als auch eine Klassifikation durchführen. Claudino et al. (2019) zeigten, dass neuronale Netze, mit einigem Abstand gefolgt von Entscheidungsbäumen, die im Mannschaftssport sowohl zur Leistungs-, als auch zur Verletzungsanalyse am häufigsten eingesetzten Verfahren sind. Für die Prognose von Spielergebnissen stellten Horvat und Job (2020) eine nahezu gleiche Nutzungshäufigkeit von neuronalen Netzen, Support Vector Machines, Regression, Naive-Bayes-Klassifikator und Entscheidungsbaum-Verfahren fest.

Bei der Anwendung von Verfahren des überwachten Lernens ist oftmals nicht nur das Ergebnis der Regression oder Klassifikation interessant, sondern auch der Einfluss der einzelnen Inputvariablen (Merkmale) auf dieses Ergebnis. Einige Klassifikationsverfahren liefern diese sogenannte

Merkmalsrelevanz quasi als Nebenprodukt mit. Das sind insbesondere Entscheidungsbäume und Random Forests. Auch bei der Regression können die Koeffizienten als Relevanz der Merkmale interpretiert werden. Andere Klassifikationsverfahren wie SVM oder neuronale Netze liefern diese Information über Merkmalsrelevanz nicht. Man spricht im letzteren Fall auch von *Black-Box-Verfahren* im Gegensatz zu den ersteren, den *White-Box-Verfahren*. Wegen der mangelnden *Erklärungskomponente* der Black-Box-Verfahren hat sich ein eigenes Forschungsgebiet entwickelt, die *Explainable AI (XAI)*. Bekannte XAI-Methoden zur Erklärung der Merkmalsrelevanz sind z. B. die Local Interpretable Model-Agnostic Explanations (LIME) oder die Shapley Additive Explanation (SHAP) (Kamath & Liu, 2021).

3.2.5 Deep Learning

Tiefe neuronale Netze (deep neural networks, DNN) sind Netze, deren Anzahl an mittleren Schichten (hidden layers) die des Multi-Layer Perceptrons (MLP) oft bei weitem übersteigt (Abb. 14), und die zudem deutlich kompliziertere Strukturen aufweisen können. DNNs wurden zunächst bei der Spracherkennung, der Bildverarbeitung, der Signalverarbeitung, aber auch in der Genforschung eingesetzt (LeCun et al., 2015).

In der Bildverarbeitung spielen *Convolutional Neural Networks (CNN)* eine wichtige Rolle. Das CNN baut auf der Pixel-Repräsentation eines Bildes auf. Diese werden aber nicht einzeln und parallel in das Netz eingespeist, sondern das




Abb. 14 Tiefes neuronales Netz mit drei verdeckten Schichten

CNN fährt quasi wie mit einem Fenster (sliding window) über das Bild und überführt diese zusammenhängenden Bildbereiche in das Netz. Mit Mechanismen wie Faltung (convolution) und Pooling werden in den folgenden Schichten schrittweise Bildmerkmale (features) wie Kanten, Ecken oder Texturen, dann einfache Formen, und dann höherwertige wie z. B. Gesichter extrahiert (Albawi et al., 2017). Die abschließenden Schichten des CNN entsprechen einem Feed-Forward-Netzwerk, das auf Basis der extrahierten Features eine Klassifikation durchführt.

Rekurrente Neuronale Netze (RNN) sind Netze, die sich im Gegensatz zu den Feed-Forward-Netzen durch Verbindungen von Neuronen einer Schicht zu Neuronen derselben oder einer vorangegangenen Schicht auszeichnen. Damit entwickelt das Netz quasi ein „Gedächtnis“, denn für die Verarbeitung von aktuellen Eingabedaten stehen auch Daten aus zurückliegenden Eingaben zur Verfügung. Damit eignet sich das RNN besonders für Aufgaben mit sequenziellen Daten oder Zeitreihen, etwa zum Forecasting (vgl. Abschn. 2.2). Von Hochreiter und Schmidhuber wurde 1997 das rekurrente neuronale Netzwerk *Long Short-Term Memory (LSTM)* entwickelt, das das häufig beim Lernen in neuronalen Netzen auftretende *vanishing gradient problem* vermeidet.

Aufgrund ihrer besonderen Eignung für die Bildverarbeitung werden neuronale Netze wie CNN, RNN und LSTM häufig zur Analyse von

Sport-Videos eingesetzt (Naik et al., 2022; Akan & Varlı, 2023; Zhao et al., 2023). Mit den ebenfalls auf neuronalen Netzen beruhenden Methoden der *Generative AI*, den sogenannten *Large Language Models*, können aus den extrahierten Spielereignissen automatisch Kommentare generiert werden (Baughman et al., 2024).

3.2.6 Probabilistische Verfahren

Aus der Tradition der Wahrscheinlichkeitstheorie und der stochastischen Prozesse sind besondere Verfahren der Prädiktiven Analytics hervorgegangen, die in Monografien und Kursen über Maschinelles Lernen oft übergangen werden: *Bayes-Netze (bayesian networks)*, *Markov-Ketten (Markov chains)* und verdeckte *Markov-Modelle (Hidden Markov Models, HMM)*. *Bayes-Netze* stellen Ursache-Wirkungs-Zusammenhänge zwischen verschiedenen Variablen durchgerichtete Graphen dar, deren Knoten Variablen (oft Zustände oder Ereignisse beschreibend) darstellen und deren Kanten mit bedingten Übergangswahrscheinlichkeiten belegt sind. Am Ende des Graphen steht eine *Zielvariable (variable of interest, query variable)*, deren Ergebniswahrscheinlichkeit im Mittelpunkt des Interesses steht. Die Knotenstruktur und Kantenparametrisierung von Bayes-Netzen kann auf der Basis vorhandenen Daten gelernt werden. Dafür gibt es eine ganze Reihe von Algorithmen. Da die Zielvariable mit betrachtet wird, handelt es sich um ein Verfahren des überwachten Lernens. Der Reiz der Bayes-Netze be-

steht darin, dass bei fortschreitender Kenntnis eingetretener Ereignisse (Zustände) die (konditionale) Wahrscheinlichkeit des Endergebnisses neu berechnet wird. Dadurch lässt sich gut nachvollziehen, wie stark der Einfluss eingetretener Ereignisse auf das Endergebnis ist. Implementierungen von Bayes-Netzen erlauben das interaktive Arbeiten, z. B. das probeweise Setzen von Bedingungen (Fixierung von Variablen) zur Durchführung von „what-if“-Analysen. Wichtige Anwendungen von Bayes-Netzen im Sport sind die Verletzungsanalyse (Näheres in Abschn. 4.4) und die Ergebnissvorhersage (Razali et al., 2018; vgl. auch Abschn. 4.5).

Markov-Ketten beschreiben ebenfalls die möglichen Zustände eines Systems und Übergänge zwischen diesen Zuständen in Form eines gerichteten Graphen. Zustände sind wiederum durch Knoten repräsentiert und Übergänge durch Kanten, denen jeweils eine Übergangswahrscheinlichkeit zugeordnet ist. Im Gegensatz zum Bayes-Netz besitzt die Markov-Kette allerdings kein Gedächtnis, d. h. die Übergangswahrscheinlichkeit von einem aktuellen Zustand in einen neuen Zustand ist immer gleich, unabhängig davon, wie der aktuelle Zustand erreicht wurde. Bei *diskreten Markov-Ketten* erfolgen die Übergänge zu diskreten Zeitpunkten, während bei *kontinuierlichen Markov-Ketten* die Übergänge zeitkontinuierlich erfolgen. Markov-Ketten können *Zielzustände* ha-

ben, das sind Zustände, aus denen kein weiterer Übergang möglich ist. Übergangswahrscheinlichkeiten können durch Beobachtung des Systems über einen Zeitraum hinweg bestimmt werden. Für jeden beliebigen Anfangszustand können dann mit Hilfe der *Übergangsmatrix* die Wahrscheinlichkeiten aller Zustände berechnet werden.

Abb. 15 zeigt die 25 Zustände einer Markov-Kette, die das Spielgeschehen im Baseball innerhalb eines Spielabschnittes (half inning) beschreibt (Bukiet et al., 1997; Sokol, 2004). Jeder Zustand wird beschrieben durch die Besetzung der drei Field Bases (123 = alle Bases besetzt) und die Anzahl der Outs (ein Spielabschnitt endet mit dem dritten Out). Die Zustandsübergänge sind nur exemplarisch für den Zustand (3, 1) dargestellt.

Die Übergangswahrscheinlichkeiten können den üblichen Spielerstatistiken entnommen werden. Das Ergebnis der Berechnung der Markov-Kette ist die sogenannte *Run Expectancy Matrix*, aus der sich Entscheidungen hinsichtlich der weiteren Spieltaktik ableiten lassen (Baumer & Zimbalist, 2014).

Verdeckte Markov-Modelle (Hidden Markov Models) unterscheiden zwischen *beobachtbaren* und *nicht beobachtbaren, verdeckten (hidden)* Zuständen. Die verdeckten Zustände bilden eine Markov-Kette, deren Knoten (Variablen) die beobachtbaren Zustände beeinflussen. Ziel ist es




Abb. 15 Die Markov-Kette mit 25 Zuständen, die im Half Inning auftreten können

jetzt, aus vorliegenden Folgen beobachtbarer Zustände (z. B. die Aktionen in einem Event Stream) die dazugehörige Folge verdeckter Zustände (z. B. die zugrunde liegenden taktischen Bewegungsmuster) zu konstruieren. Ist das HMM einmal trainiert, können aus neu vorliegenden Beobachtungen das entsprechende Muster, aber auch die wahrscheinlichste nächste Aktion bestimmt werden. Hidden Markov Models werden häufig zur Event-Erkennung in Sport-Videos eingesetzt (Motoi et al., 2012).

3.3 Präskriptive Verfahren

Präskriptive Verfahren kommen vorwiegend aus dem *Operations Research (OR)*, einem Zweig der Mathematik, der etwa Mitte des letzten Jahrhunderts begründet wurde. Einen Teilbereich des Operations Research bildet die *Mathematische Optimierung*, der die folgenden Verfahren zuzuordnen sind.

3.3.1 Lineare Optimierung

Die *lineare Optimierung (linear programming)* ist eine Technik zur Optimierung einer linearen Zielfunktion unter Nebenbedingungen, die als lineare Gleichungen oder Ungleichungen formuliert werden können. Die lineare Optimierung zeichnet sich durch einfache Modellbildung und effiziente Lösungsverfahren aus (Nickel et al., 2022). Bekannt ist das Simplex-Verfahren, das in seiner heute bekannten Form von George B. Dantzig 1947 entwickelt wurde.

3.3.2 Ganzzahlige Optimierung

Die *ganzzahlige Optimierung (integer programming)* ist eine Optimierung, bei der einige oder alle Variablen ganzzahlige Werte annehmen. Meist geht man implizit von einer linearen Zielfunktion aus. Nach der Variablenausprägung unterscheidet man die *reine ganzzahlige Optimierung*, die *gemischt-ganzzahlige Optimierung* und die *0-1-ganzzahlige Optimierung*. Oft wird die ganzzahlige Optimierung auch *kombinatorische Optimierung* genannt. Verfahren zur Lösung ganzzahliger Optimierungsprobleme sind z. B. das *Branch & Bound-Verfahren* oder das *Schnitt-*

ebenenverfahren (cutting plane method) von Gomory.

Eine klassische Aufgabenstellung für die ganzzahlige Optimierung im Sport ist die optimale Aufstellung von Saisonspielplänen von Ligen, sogenannten Runden- bzw. Doppelrundenturnieren (round-robin tournaments), aber auch die optimale Planung von anderen Turnierarten, z. B. nach dem K.-O.-System oder gemischten Systemen (Briskorn & Drexler, 2009; Ribeiro et al., 2023). Auch für die Neuordnung von Vereinen zu Ligen und Bezirken wurde die ganzzahlige Optimierung herangezogen (Macdonald & Pulleyblank, 2014; Toffolo et al., 2019).

Eine weitere Aufgabenstellung für die ganzzahlige Optimierung, die nicht nur im Sport Bedeutung erlangte, ist die Zusammenstellung von Teams (team formation) (Juárez et al., 2021). Ausgangspunkt für diese Aufgabe ist eine Beschreibung der zu besetzenden Teampositionen und deren Anforderungen sowie ein Vorrat an Kandidaten, aus dem diejenigen Kandidaten ausgewählt und auf Positionen verteilt werden, deren Eigenschaften die Anforderungen am besten erfüllen. Teambildung kann zu verschiedenen Zeitpunkten notwendig sein: vor der Spielsaison, vor einem Spiel, und während des Spiels. Vor dem Spiel ist sie eine strategische Aufgabe, bei der insbesondere finanzielle Restriktionen eine Rolle spielen (vgl. Moneyball). Der Pool ist hierbei nicht beschränkt, sondern schließt mögliche Transferkandidaten mit ein. Vor und während des Spiels ist der Kandidatenvorrat begrenzt, sodass die Auswahlentscheidungen doch eher der Intuition des Trainers überlassen werden (Budak et al., 2019). Ein Beispiel für die Anwendung der ganzzahligen Optimierung für die Teamzusammenstellung im Fußball wird in Abschn. 4.2 gegeben.

3.3.3 Stochastische Optimierung

Die *stochastische Optimierung* unterstützt Entscheidungen bei Unsicherheit. Dabei wird angenommen, dass die unsicheren Variablen Zufallsvariablen sind, die sich durch Wahrscheinlichkeitsverteilungen beschreiben lassen. Bekannte Verfahren zur Lösung von stochastischen Optimierungsproblemen sind die *Monte-Carlo-Simu-*

lation und die *Szenario-Analyse* (z. B. Best-Case, Worst-Case-Szenarien).

Eine interessante Anwendung der stochastischen Optimierung kommt aus dem Segelsport: Hierbei geht es um die Bestimmung optimaler Segelrouten bei großen internationalen Hochseeregatten. Die unsichere, aber für das Segeln ausschlaggebende Variable ist die Windrichtung, für deren Wahrscheinlichkeitsverteilung aber Schätzungen aus langfristigen Wettervorhersagen vorliegen. Auf Basis dieser Wahrscheinlichkeiten wird die Segelroute mit der minimalen erwarteten Zeit zum Ziel bestimmt (Philpott, 2005).

3.3.4 Dynamische Optimierung

Bei der *dynamischen Optimierung* geht es um Entscheidungsprobleme, die sich aus einer Abfolge aufeinanderfolgender und möglicherweise voneinander abhängiger Entscheidungen zusammensetzen. Es wird eine Lösung gesucht, die das Gesamtproblem optimiert (Domschke et al., 2015). Die dynamische Optimierung wurde von Richard Bellman in den 40er-Jahren begründet. Bellman selbst setzte sie zur Lösung von taktischen Überlegungen bei Brettspielen und beim Baseball ein (Bellman, 1965, 1977).

Die dynamische Programmierung kann auf deterministische und stochastische Aufgabenstellungen angewandt werden. Im stochastischen Fall sind dies insbesondere die *Markov-Entscheidungsprozesse* (Howard, 1960). Taktische Entscheidungen während des Spiels im Hinblick auf den Gesamterfolg zu optimieren, ist insbesondere in Sportarten von Bedeutung, bei denen dem Spieler oder der Mannschaft mehrere Handlungsalternativen zur Verfügung stehen, die unterschiedliche Erfolgsaussichten haben, aber auch unterschiedlich zum Spielerfolg beitragen. Im Baseball hat der Schlagmann (batter) beispielsweise die Möglichkeit, mit einem starken, aber riskanten Schlag auf einen eigenen Homerun zu setzen, oder mit einem wenig riskanten Abpraller („bunt“) einen Mitspieler eine Base nach vorne zu bringen. Im American Football gibt es nach einem Touchdown die taktische Entscheidung zwischen einem „Point-after-Touchdown“ (Field Goal) oder einer „Two-Point Conversion“. Für solche taktischen Entscheidungsprobleme wurde die dyna-

misches Optimierung beim Baseball (Kira et al., 2019), beim Cricket (Clarke & Norman, 1999) und beim American Football (Sackrowitz, 2004) eingesetzt.

Die dynamische Programmierung und Markov-Entscheidungsprozesse können nicht nur dazu beitragen, taktische Entscheidungen in Sportarten zu treffen, sondern auch, Bewegungsabläufe zu verbessern oder Trainingspläne zu optimieren (Vales-Alonso et al., 2012).


3.3.5 Reinforcement Learning

Reinforcement Learning ist ein Verfahren, das aus der Machine Learning-Tradition kommt (Sutton & Barto, 1999). Es wird neben dem überwachten Lernen (supervised learning) und unüberwachten Lernen (unsupervised learning) oft als dritte, eigenständige Kategorie des Machine Learning angesehen. Ähnlich wie bei Markov-Entscheidungsprozessen soll in einer bestimmten Situation eine Entscheidung getroffen werden, die letztlich zum Gesamtoptimum führt. Im Gegensatz zur dynamischen Programmierung setzt Reinforcement Learning allerdings kein vorliegendes mathematisches Modell voraus. Das Konzept des Reinforcement Learning ist das eines autonomen Agenten, der ohne direkte Anweisungen (also unsupervised) eine Entscheidung zu treffen hat, die jeweils unterschiedlich belohnt wird (reward). Man spricht auch von „trial-and-error“. Dabei versucht der Agent, ein Gleichgewicht zwischen Explorationen (Ausprobieren neuer Alternativen) und Exploitation (Ausnutzung bewährter, lohnender Alternativen) zu finden.


Reinforcement Learning ist konzeptionell eng mit der Verhaltensweise eines Sportlers im Spiel, aber auch mit der Interaktion zwischen Trainer und Sportler im Training verwandt. Daher eignet es sich auch besonders zur Beschreibung, Untersuchung und Verbesserung von Entscheidungsprozessen im Sport (Ashley, 2020; Luo et al., 2020).

Abb. 16 gibt einen Überblick über die Entstehungsgeschichte der in diesem Kapitel behandelten analytischen Verfahren, die aus den Disziplinen Statistik, Operations Research und Machine Learning hervorgegangen sind.


Statistik



Operations Research



Machine Learning



Machine Learning - Neuronale Netze




Abb. 16 Entwicklungsgeschichte der in diesem Kapitel behandelten analytischen Verfahren. Entwicklungen sind oft kontinuierlich verlaufen, und die ausgewählten Nen-

nungen stellen nur gut datierbare Meilensteine dar, typischerweise Daten einer ersten Veröffentlichung

4 Anwendungen der Sports Analytics

4.1 Leistungsanalyse von Spielern und Mannschaften

Schon seit frühester Zeit wurden im Sport Daten gesammelt, um die Leistung von Athleten quantitativ zu erfassen. Diese Leistungskennzahlen, im Englischen oft als *Statistics (Stats)* oder *Metrics* bezeichnet, liefern Informationen über die physischen, technischen, taktischen und mentalen Fähigkeiten eines Athleten. Sportmanager und Trainer, aber auch die Athleten selbst, nutzen Kennzahlen, um im Training und im Wettkampf die sportliche Leistung zu bewerten, zu überwachen, Ziele zu setzen und Vergleiche mit anderen Athleten anzustellen. Kennzahlen ergänzen die subjektive Einschätzung der Leistung und liefern Ansatzpunkte für Verbesserungsmaßnahmen.

Im Scouting und Recruiting werden Kennzahlen genutzt, um die Suche nach Talenten datenbasiert zu unterstützen. Dazu werden von den Scouts oder Datenanalysten Anforderungsprofile erstellt, die einen quantitativen Vergleich mit den Leistungsprofilen möglicher Kandidaten ermöglichen. Auch die Medien und Fans haben ein großes Interesse an Spielerkennzahlen. Seit den Box Scores von Henry Chadwick 1859 (Abb. 3) werden in der Sportpresse Kennzahlen veröffentlicht. Besonders bei der Fernsehübertragung von Baseballspielen werden Spielerkennzahlen regelmäßig eingeblendet. Ligen, Verbände und Analytics-Firmen stellen auf ihren Websites Spieler- wie auch Mannschaftskennzahlen zur Verfügung.

Enthielt der Box Score von 1859 noch sechs Kennzahlen pro Baseballspieler, so enthält die offizielle Statistik der MLB heute 22 Kennzahlen für Batters und 19 Kennzahlen für Pitchers. Die Bundesliga veröffentlicht 18 Kennzahlen für Spieler und 31 für Mannschaften und für jede Kennzahl ein Ranking von Spielern und Mannschaften. Die FIFA (Fußball), die ATP (Tennis), die amerikanischen Ligen NFL (Football), NBA (Basketball) und NHL (Eishockey) bieten ähnliche Statistiken und Ranglisten, um nur einige Beispiele zu nennen. Die Internet-Plattform whoscored.com erfasst über 200 Spielerkennzah-

len von acht europäischen Fußball-Ligen (England, Deutschland, Frankreich, Spanien, Italien, Niederlande, Russland, Türkei) und die ursprünglich auf Scouting spezialisierte Sports Analytics-Firma Wyscout führt über 250 Spielerkennzahlen aus Fußball-Wettbewerben weltweit.

Kennzahlen sind nicht nur für Fans interessant, sondern auch für die Teilnehmer an Sportwetten, insbesondere die Teilnehmer an Fantasy Sports, deren Mechanismen ja gerade auf der Leistung einzelner Spieler in den zusammengestellten Fantasy-Mannschaften aufbauen.

Im Vergleich zur Leistung eines Athleten im Einzelwettkampf ist die Leistung eines Spielers innerhalb des Mannschaftssports nicht einfach zu bewerten. Jedem Spieler ist eine Rolle zugewiesen, sodass sein Beitrag entsprechend dieser Rolle bewertet werden muss. Außerdem ist nicht jede Aktion auf dem Spielfeld zielführend. Erfolgreiche Hits im Baseball müssen nicht zum Punktgewinn führen und gute Pässe im Fußball nicht zum Tor. Deshalb waren und sind Experten in den verschiedenen Disziplinen ständig auf der Suche nach neuen, aussagekräftigeren Kennzahlen, die sich stärker am Spielerfolg orientieren als an der Einzelaktion. Moneyball hat diese Entwicklung eingeleitet, indem die einfache Kennzahl Batting Average (BA) ergänzt wurde durch komplexere Kennzahlen wie On-Base Percentage (OBP), On-base Plus Slugging Plus (OPS+), Wins Above Replacement (WAR) für Batters oder Adjusted Earned Run Average (ERA+) für Pitchers (Albert, 2010; www.mlb.com/glossary/advanced-stats).

Im Fußball sind typische Spielerstatistiken die Anzahl der vom Spieler erzielten Tore, die Anzahl der Torvorlagen, die Anzahl der Schüsse aufs Tor, die Passgenauigkeit, die Ballbesitzzeit, die Laufleistung oder die Quote der gewonnenen Zweikämpfe (<https://fbref.com/de/>).

Zu diesen Statistiken ist neuerdings eine Kennzahl dazugekommen, die ihrerseits nur mit Hilfe von Analytics ermittelt werden kann: Expected Goals (xG). Dazu wird für jede Position auf dem Spielfeld aus Daten vergangener Jahre berechnet, mit welcher Wahrscheinlichkeit ein von dieser Position abgegebener Torschuss, auch unter Berücksichtigung des Abstands zu den Gegenspielern, im Tor landet (Pollard & Reep, 1997; Ensum

et al., 2005; Mead et al., 2023). So liegt beispielsweise die Erfolgswahrscheinlichkeit eines Elfmeters bei etwa 0,8, während die Erfolgswahrscheinlichkeit für einen Schuss aus gleicher Entfernung im regulären Spiel nur 0,2 und für einen Schuss von der Strafraumgrenze sogar nur 0,1 beträgt (vgl. Abb. 9).

Für jeden Torschuss eines Spielers – ob erfolgreich oder nicht – wird der der Position entsprechende xG-Wert akkumuliert. Das ergibt eine Kennzahl für die Torchancen, die der Spieler insgesamt herausgespielt hat. Vergleicht man diese Zahl mit den tatsächlich erzielten Toren, so sieht man, wie gut der Spieler seine Chancen verwertet hat. Die Summe der Torchancen über alle Spieler ergibt den xG-Wert für die Mannschaft. So hatte der FC Arsenal in der Saison 2023/2024 der Premier League einen xG-Wert von 84,39 bei 89 erzielten Toren und der FC Liverpool einen xG-Wert von 94,79 bei nur 82 erzielten Toren (<https://understat.com/league/EPL>). Die Chancenverwertung, die sich als Quotient zwischen erzielten Toren und xG ergibt und größer oder kleiner als 1 sein kann, war beim FC Arsenal bedeutend besser. Die Kennzahl xG für Spieler und Mann-

schaften kam in der Saison 2017/2018 erstmalig in der britischen Sendung *Match of the Day* zum Einsatz und ist heute Bestandteil jeder gängigen Fußball-Statistik.

Zur Darstellung der Leistungskennzahlen eines Spielers werden bevorzugt Spinnennetz-Diagramme eingesetzt (Abb. 17). Diese sind auch für Nichtexperten besonders verständlich, müssen sich allerdings der Übersichtlichkeit halber auf einige wenige Kennzahlen beschränken. Das Spinnennetz-Diagramm erlaubt auch einen einfachen Vergleich zweier oder mehrerer Spieler, wobei die Unterschiede zwischen den Spielern visuell deutlich hervortreten. Genauso können im Spinnennetz-Diagramm Spielerprofile mit dem Anforderungsprofil verglichen werden.

Eine komplexere Anwendung ist das Clustering von Spielern. Die Leistungsmerkmale eines Spielers, auch Spielerprofil genannt, bilden mathematisch gesehen einen Vektor, und zwischen je zwei Spielervektoren lässt sich eine Ähnlichkeit definieren, die auf dem Grad der Übereinstimmung der einzelnen Merkmale beruht. Mit den bekannten Clustering-Verfahren, z. B. k-Means, werden jetzt Gruppen von Spielern ähnlichen Ver-




Abb. 17 Leistungskennzahlen eines Fußballspielers im Spinnennetz-Diagramm

haltens gebildet. Wird ein Clustering über alle Spieler einer Mannschaft durchgeführt, so bilden sich Cluster heraus, die – wenig überraschend – der bekannten Rollenverteilung in einer Mannschaft entspricht. Das Ergebnis einer Cluster-Analyse gibt Aufschluss über die Zusammensetzung und Ausgewogenheit der Spielerfähigkeiten in einer Mannschaft, aber auch über mögliche Fehlbesetzungen, und ist somit eine wichtige Entscheidungsgrundlage für die Teamchefs und Trainer. Zur Visualisierung der Cluster in zwei Dimensionen wird eine Hauptkomponentenanalyse durchgeführt, und die Cluster werden häufig mit verbalen Beschreibungen oder mit den Namen bekannter Spieler als Repräsentanten bezeichnet (Akhanli & Hennig, 2023).

In jüngster Zeit haben Sportanalysten damit begonnen, neben den Leistungskennzahlen von Spielern auch deren *Spielstile* zu analysieren. Nach Decroos und Davis (2020) wird der Spielstil beschrieben durch die bevorzugte Position eines Spielers auf dem Feld und die Art von Aktionen und Bewegungen, die er normalerweise während eines Spiels ausführt. Die Analysen basieren typischerweise auf Spielertrajektorien (Plakias et al., 2023). Meist werden unüberwachte Verfahren eingesetzt, um die Spieler nach ihren Stilen zu clustern und dadurch die Anzahl und Verschiedenartigkeit möglicher Stile herauszuarbeiten (z. B. Ingram et al., 2022).

Auf einem Clustering von Spielerprofilen beruht auch ein interessantes Verfahren zur Leistungsprognose von Spielern über einen längeren Zeitraum (Vinué & Epifanio, 2019). Die Leistung eines Spielers verändert sich mit dem Alter. Typischerweise steigt sie zunächst an, bevor sie in späteren Jahren wieder abfällt. Ob diese Veränderungen früh oder spät, schnell oder langsam stattfinden, d. h. welche genaue Form die Leistungskurve über die Zeit annimmt, ist sehr von der individuellen Entwicklung eines Spielers abhängig. Man beobachtete aber, dass Leistungsverläufe von Spielern sehr ähnlich sein können und clusterte Spieler nach ihrem Leistungsverlauf. Zur Leistungsprognose eines jüngeren Spielers wird zunächst ermittelt, welchem dieser Cluster sein bisheriger Leistungsverlauf am besten zugeordnet

werden kann. Der prototypische Kurvenverlauf dieses Clusters wird dann zur Leistungsprognose des beobachteten Spielers herangezogen.

4.2 Talentsuche und Rekrutierung (Scouting and Recruiting)

Der Scouting-Prozess im Teamsport liegt traditionell in der Hand von Insidern und Experten (Gerrard, 2017), die ihre Aufgabe mit viel Intuition und langjähriger Erfahrung angehen und sich eines weiten Netzwerkes von Informanten bedienen. Der Film Moneyball erweckte den Eindruck, dass diese Experten durch einen Datenanalysten mit seinen Algorithmen ersetzt werden könnten. Tatsächlich kombinierten die Oakland Athletics die Erkenntnisse der Scouts sinnvoll mit den Erkenntnissen aus den Analytics.

Die zweite Botschaft von Moneyball ist, dass für das Scouting die richtigen Leistungskriterien herangezogen werden müssen. Mit der On-Base Percentage (OBP) hatten die Oakland Athletics eine Kennzahl gefunden, mit der sie für das Team wertvolle, aber auf dem Markt unterbewertete Spieler günstig einkaufen konnten (Hakes & Sauer, 2006).

Analytics haben beim Scouting den Vorteil, dass sie eine Vielzahl von Leistungskriterien in Betracht ziehen können – mehr als der Mensch normalerweise überblicken kann. Der datengestützte Scouting-Prozess beginnt mit dem Aufstellen einer Anforderungsmatrix W_{jc} , die die Wichtigkeit bestimmter Leistungskriterien für jede zu besetzende Position beschreibt (Ozceylan, 2016). In einer Spielermatrix V_{ic} wird jeder potenzielle Kandidat von den Scouting-Experten nach genau diesen Kriterien bewertet (Abb. 18).

Die Aufgabe, die jetzt zu lösen ist, nennt man auch *matching demand with supply* (Boon & Sierksma, 2003). Ein Spieler c eignet sich besonders gut für eine zu besetzende Position, wenn für alle Kriterien das Produkt $v_{ic}w_{jc}$ aus seiner Merkmalerfüllung v_{ic} und der Kriterienwichtigkeit w_{jc} besonders hoch ist. Im Operations Research spricht man von einem Maximum-Weight Matching Problem, das wie folgt formuliert wird:

	Position 1	Position 2	Position 3	Position 4	Position 5	Position 6	Position 7	Position 8	Position 9	Position 10	Position 11
Schnelligkeit	5	9	8	4	7	10	5	9	6	5	9
Wendigkeit	9	6	6	6	5	7	4	8	8	9	2
Antrittsschnelligkeit	8	7	9	8	4	8	6	4	9	3	5
Ausdauer	3	7	5	9	6	9	8	5	6	5	9
Torgefährlichkeit	0	4	2	6	6	6	9	9	10	10	10
Spielintelligenz	7	6	5	4	8	7	6	10	9	2	7
Antizipationsvermögen	10	8	8	9	9	5	4	9	4	8	5
Weitsicht	9	9	7	9	6	4	7	2	6	5	4
Ballkontrolle	4	6	7	6	4	6	2	4	8	8	6
Passgenauigkeit	0	4	7	7	9	8	9	10	9	7	8
Zweikampfstärke	6	9	7	5	9	9	10	8	6	8	9
Kopfballstärke	3	4	7	4	6	3	9	5	6	10	10
Stellungsspiel	7	10	7	6	7	10	4	8	9	6	7
Raumkontrolle	8	8	7	6	8	9	10	9	4	7	2
Abschlusstechnik	0	4	7	3	7	4	7	6	9	7	9
Sprungkraft	10	8	7	6	8	10	5	4	4	8	3
Reaktionsschnelligkeit	10	6	7	9	9	8	4	9	2	9	4
Fangsicherheit	10	0	7	2	6	4	6	9	9	2	3
Selbstvertrauen	9	8	7	6	7	5	4	6	9	10	3
Spielwitz	5	7	7	7	6	6	6	8	9	6	7

	Spieler 1	Spieler 2	Spieler 3	Spieler 4	Spieler 5	Spieler 6	Spieler 7	Spieler 8	Spieler 9	Spieler 10	Spieler 11	Spieler 12	Spieler 13	Spieler 14
Schnelligkeit	5	2	5	7	9	8	10	5	2	9	6	9	8	10
Wendigkeit	4	2	4	8	4	7	9	9	5	0	4	4	7	9
Antrittsschnelligkeit	6	5	6	9	0	8	4	9	8	7	6	7	8	6
Ausdauer	8	8	8	6	6	9	0	2	9	10	8	2	5	2
Torgefährlichkeit	9	7	9	7	3	6	6	2	4	9	9	7	8	4
Spielintelligenz	7	8	6	5	7	7	8	7	8	4	6	10	5	8
Antizipationsvermögen	2	5	2	4	6	9	8	10	6	0	4	9	7	8
Weitsicht	8	8	4	2	7	4	4	9	6	6	9	4	9	9
Ballkontrolle	5	9	7	8	5	6	3	4	3	3	4	3	6	10
Passgenauigkeit	6	6	2	6	4	8	8	0	7	5	2	6	7	9
Zweikampfstärke	9	7	8	9	6	9	5	6	2	9	5	4	5	4
Kopfballstärke	4	5	4	8	7	9	8	4	8	6	8	9	4	0
Stellungsspiel	6	4	7	5	9	8	9	7	5	3	7	9	6	6
Raumkontrolle	8	6	2	4	6	7	9	8	6	6	8	6	8	3
Abschlusstechnik	4	8	7	3	4	4	6	7	9	9	9	7	9	7
Sprungkraft	7	9	10	9	9	7	7	3	4	2	6	5	6	
Reaktionsschnelligkeit	2	4	9	7	9	5	5	8	6	5	8	6	6	9
Fangsicherheit	8	9	4	5	6	7	9	3	8	9	9	7	3	6
Selbstvertrauen	4	8	5	8	8	6	5	6	5	6	6	5	7	7
Spielwitz	7	6	5	7	6	7	3	4	5	4	2	4	6	9

Abb. 18 Anforderungsmatrix W_{jc} und Spielermatrix V_{ic} und der jeweiligen Wichtigkeit bzw. dem jeweiligen Erfüllungsgrad der Kriterien (jeweils auf einer Skala von 1 bis

$$\begin{aligned}
 & \text{Maximiere} \quad \sum_{i=1}^m \sum_{j=1}^n \sum_c^C v_{ic} w_{jc} x_{ij} \\
 & \text{unter der Bedingung} \quad \sum_{j=1}^n x_{ij} \leq 1 \quad \text{für } i = 1, \dots, m \\
 & \quad \quad \quad \sum_{i=1}^m x_{ij} \leq 1 \quad \text{für } j = 1, \dots, n \\
 & \quad \quad \quad x_{ij} \in \{0, 1\} \quad \text{für } i = 1, \dots, m \text{ und } j = 1, \dots, n.
 \end{aligned}$$

Dabei ist m die Anzahl der in Frage kommenden Spieler, n die Anzahl der zu besetzenden Stellen, also im Fußball $n = 11$, falls eine komplette Mannschaft zu besetzen ist. Wenn ein Spieler i für die Position j ausgewählt wurde, wird $x_{ij} = 1$ gesetzt, wenn nicht, $x_{ij} = 0$.

Dieses ganzzahlige Optimierungsproblem ist seit langem bekannt und mit den Methoden des Operations Research gut lösbar. Özceylan (2016) verfeinerte die Aufgabenstellung, indem er nicht alle Spielerkandidaten auf die 11 Teampositionen gesamtheitlich zuordnet, sondern Kandidaten für Torhüter, Innen- und Außenverteidiger, Mittelfeldspieler, Innen- und Außenstürmer nach unterschiedlichen Kriterien beurteilt, den einzelnen Positionsgruppen ebenfalls unterschiedliche Anforderungen zuweist und dann das Matching vornimmt. Außerdem führt er weitere Neben-

bedingungen ein, z. B. eine obere Grenze für das Durchschnittsalter der Mannschaft und eine Budgetbegrenzung. Es ist klar, dass diese Aufgabenstellung nicht nur im Sport, sondern ganz allgemein in der Unternehmenspraxis relevant ist, wo es um die Besetzung offener Stellen geht.

4.3 Training

Ziel des Trainings ist es, die Leistungsfähigkeit des Athleten zu erhalten oder zu steigern, um ihn optimal auf den Wettbewerb vorzubereiten. Prieske und Granacher (2023) unterscheiden vier Phasen des sportlichen Trainings: Planung, Durchführung, Kontrolle und Auswertung.

Digitale Technologien erlangen in allen Phasen des Trainings Bedeutung. Zu nennen wären die

Wearable Devices von der Smart Watch bis hin zur Weste, die primär zur Kontrolle und Auswertung eingesetzt werden (Cardinale & Varley, 2017), oder die VR-Brille für die Ausbildung und Trainingsdurchführung (Soltani & Morice, 2020).

Von den vielen Anwendung von Analytics im Training (Rajšp & Fister, 2020) seien zwei maßgebliche herausgegriffen: die Erstellung von Trainingsplänen und die Analyse von Bewegungsabläufen.

4.3.1 Trainingspläne

Zur Planung eines Trainingsprogrammes ist es wichtig, den Zusammenhang zwischen der Trainingsbelastung und der resultierenden Leistungssteigerung zu verstehen. Diese „load-response“ oder „dose-response“ wird von Sportwissenschaftlern schon seit Jahrzehnten untersucht. Banister et al. (1975) schlugen ein „antagonistisches“ Trainingsmodell vor, das „Fitness-Fatigue-Modell“, das heute auch Banister-Modell genannt wird. Es geht davon aus, dass Training leistungssteigernd wirkt, gleichzeitig aber auch leistungsmindernd (ermüdend). Diese positiven und negativen Effekte treten jedoch mit unterschiedlichen zeitlichen Verläufen auf, sodass bei geschickter Terminierung von Trainingseinheiten und Trainingspausen die gewünschte Leistungssteigerung erzielt werden kann. Trainingseinheiten werden durch ihre Intensität und Dauer bestimmt, wobei sich die Intensität am individuellen Fitnesslevel des Athleten orientiert und an der trainingswirksamen Herzfrequenz ausgerichtet ist.

Das Banister-Modell kann nicht alle Effekte des Trainings vollständig erklären. Deshalb wurden über die Jahre neue Varianten des Modells entwickelt. Insbesondere aber wurden Prädiktive Analytics eingesetzt, um zu einer vorgegebenen Trainingseinheit oder einer Reihe von Trainingseinheiten den zu erwarteten Trainingseffekt (load response) vorherzusagen. Zum Einsatz kamen z. B. neuronale Netze (Edelmann-Nusser et al., 2002), Random Forests, und Regressionsverfahren (Imbach et al., 2022). Die Modelle wurden für einzelne Athleten oder für Gruppen von Athleten parametrisiert und empirisch validiert. Die Analysen wurden auf der Grundlage von Trainingsplänen durchgeführt, die in der jeweiligen Sportart aus langjähriger Erfahrung entstanden sind und an den

Prinzipien Periodisierung und Zyklisierung (kurz-, mittel- und langfristige Maßnahmen) ausgerichtet sind.

In jüngerer Zeit wurden Verfahren zur optimalen *Erstellung* von individuellen Trainingsplänen entwickelt. Diese Verfahren betrachten einen festen Zeitraum von Tagen und ordnen jedem Tag eine Trainingslast zu, die eine bestimmte Belastungsgrenze nicht überschreiten darf, aber auch null sein kann, was dann einem Ruhetag entspricht. Da die Leistungsverlaufskurven nach Banister Exponentialfunktionen sind, handelt es sich hierbei um ein nicht lineares Optimierungsproblem, für dessen Lösung sich besonders heuristische Optimierungsverfahren, z. B. genetische Algorithmen oder die Partikelschwarmoptimierung eignen (Schaefer et al., 2015; Connor et al., 2021).

Einen Schritt weiter gehen Schelling et al. (2021): sie fügen Trainings- und Ruhe- und Reisezeiten so in einen vorgegebenen Wettkampfkalendar ein, dass die Leistung zu den jeweiligen Wettkampfzeiten einen optimalen Wert erreicht.

4.3.2 Analyse von Bewegungsabläufen

Das gleichzeitige Aufkommen neuer Technologien wie Wearable Devices und Sensorik und bahnbrechender analytischer Verfahren wie tiefer neuronaler Netze führten in den letzten Jahren zu einem explosionsartigen Anstieg von Analytics-Anwendungen im Trainingsprozess. Tiefe neuronale Netze schufen auch neue Möglichkeiten für die Auswertung von Videomaterial. Viele dieser Anwendungen erstrecken sich in den Bereich Healthcare Analytics, die in diesem Kapitel ausgeklammert werden.

Daneben entwickelte sich ein Anwendungsgebiet, das insbesondere für die technischen Sportarten eine große Bedeutung hat: die Analyse von Bewegungsabläufen. Die Bewegungsanalyse kann im Training, aber auch bei der Wettkampfvorbereitung und Nachbesprechung eingesetzt werden. Ziel ist es, die Bewegungen des Sportlers zu erfassen und „gute“ von „schlechten“ Bewegungsabläufen zu unterscheiden. Das kann dem Sportler helfen, seine Technik zu verbessern und das Verletzungsrisiko zu reduzieren.

Die Bewegungsanalyse ist nicht nur für den Sport interessant, sondern auch für andere Anwendungsgebiete wie z. B. die Videoüber-

wachung oder das autonome Fahren. Sie gliedert sich ein in Forschungsaktivitäten, die unter den Bezeichnungen *Human Activity/Action Recognition (HAR)* oder *Human Pose Estimation (HPE)* bekannt sind (Munea et al., 2020; Host & Ivašić-Kos, 2022; Kumar et al., 2024). Für Bewegungsanalysen aus Video- oder Sensordaten wird typischerweise eine Lösungsarchitektur angewandt, wie sie in Abb. 19 dargestellt ist.

Sowohl Video-Daten als auch Sensordaten werden für ähnliche Zwecke verwendet. Für Bewegungsanalysen kommen vorwiegend Trägheitssensoren (inertia sensors) und Elektromyografie-Sensoren (EMG) zum Einsatz. Die Sensoren liefern einen Strom an Rohdaten (Abb. 20), der von Anwendung zu Anwendung verschieden aufbereitet wird. In der Zeit vor Deep Learning wurden aus den Rohdaten Features extrahiert, die auf der Basis von Expertenwissen vorher festgelegt wurden (Beispiele aus der Gesichtserkennung sind Augenabstand oder Nasenlänge). Die Features können aus dem Zeit- oder Frequenzbereich der Sensordaten gewonnen werden, daher werden oft Transformationen wie die Fourier-Transformation, die Hilbert-Transformation, die Diskrete Wavelet Transformation (DWT) oder Time Warping eingesetzt. Deep Learning macht dieses *feature handcrafting* überflüssig.

Tiefe neuronale Netze führen eine Feature-Erkennung in ihren vorderen Schichten durch.

Wie schon in Abschn. 3.2.5 gezeigt wurde, können auch Videodaten direkt (pixelweise) in das tiefe neuronale Netz eingespeist werden. Mit oder ohne explizite Features führt der Machine-Learning-Algorithmus zuletzt seine eigentliche Aufgabe aus: die Klassifizierung oder Bewertung der Bewegungen. Hierbei kommen alle bekannten Klassifikations- und Regressionsverfahren zum Einsatz (Host & Ivašić-Kos, 2022). In vielen Aufgabenstellungen geht es nur darum, eine gute (korrekte) von einer schlechten (inkorrekten) Aktion zu unterscheiden: beim Volleyball ein gutes Pritschen (setting) von einem schlechten (Holatka et al., 2019), beim Ski-sprung einen guten Sprung von einem schlechten (Wang et al., 2019), beim Golf einen korrekt ausgeführten Schlag von einem inkorrekten (Liao et al., 2022), beim Yoga eine gute Haltung von einer schlechten (Swain et al., 2022), beim Boxen einen guten Treffer von einem schlechten (Vales-Alonso et al., 2023), im Tennis einen guten Aufschlag von einem schlechten (Ye et al., 2024). Andere Anwendungen nutzen Regressionsverfahren, um für eine Aktion eine Note zu vergeben, wie es Kampfrichter tun. Beispiele kommen vom Eiskunstlauf und vom Turnspringen (Pirsiavash et al., 2014).





Abb. 19 Typische Lösungsarchitektur für Bewegungsanalysen aus Video- oder Sensordaten

Abb. 20 Datenstrom von Elektromyografie-Sensoren (EMG) aus einer Bewegungsanalyse im Volleyball. (Holatka et al., 2019)



Wieder andere Anwendungen versuchen, Aktionen zu unterscheiden, z. B. verschiedene Bewegungsarten beim Laufen: Stehen, Gehen, Joggen, Rennen, Springen (Ghazali et al., 2018), oder verschiedene Schlagarten beim Tennis (Ganser et al., 2021) und beim Cricket (Siddiqui et al., 2023). Dabei kommen typischerweise die unüberwachten Clustering-Verfahren zum Einsatz. Die Liste der genannten Anwendungsbeispiele ist nur exemplarisch. Host und Ivašić-Kos (2022) geben einen guten Überblick über Sportarten, bei denen Analytics für ein „Smart Training“ eingesetzt wurden.

4.4 Verletzungsanalyse

Verletzungen sind eine unvermeidliche Begleiterscheinung des Sports. Sportverletzungen beeinträchtigen die Gesundheit und Leistungsfähigkeit eines Athleten, können zum Wettkampfausfall führen oder sogar das Karriereende bedeuten. Im Profisport hat der Ausfall von Spielern enorme wirt-

schaftliche Konsequenzen. Deshalb werden seit Jahren große Anstrengungen unternommen, die Ursachen von Sportverletzung besser zu verstehen und daraus Maßnahmen zur Prävention abzuleiten. Bahr und Krosshaug (2005) schlugen ein Erklärungsmodell vor, aus dem hervorgeht, welche Einflussfaktoren an der Entstehung von Sportverletzungen beteiligt sein können (Abb. 21). Einige dieser Faktoren sind beeinflussbar, andere nicht. Art, Häufigkeit und Schwere von möglichen Sportverletzungen können je nach Sportart sehr unterschiedlich sein. Ebenso das Zusammenwirken der Faktoren, die zu diesen Verletzungen führen.

Viele dieser Einflussfaktoren sind quantifizierbar und mit den Fortschritten der Digitalisierung im Sport auch immer präziser erfassbar. Mit der Einführung und Verbreitung von Wearable Devices nahm die Verfügbarkeit physiologischer, motorischer und psychologischer Daten beträchtlich an Volumen zu.

In den letzten Jahrzehnten wurde eine Vielzahl von Studien durchgeführt, die mit Hilfe von Ana-




Abb. 21 Erklärungsmodell für Sportverletzungen von Bahr und Krosshaug (2005)

lytics die Auswirkungen unterschiedlichster Faktoren auf das Auftreten von Verletzungen untersuchten. Die Studien konzentrieren sich häufig auf eine Art von Verletzung oder auf eine Sportart. Vorwiegend werden Verfahren der prädiktiven Analytics eingesetzt, nicht um Verletzungen vorherzusagen, sondern um die wesentlichen Risikofaktoren für deren Entstehung zu bestimmen und mit diesem Wissen Präventionsmaßnahmen zu ergreifen. Da als Zielvariable vorwiegend das Auftreten der Verletzung, seltener die Art der Verletzung, betrachtet wird, nimmt die binäre Klassifikation unter den Verfahren den größten Raum ein. Es gibt kein im Abschn. 3.2 vorgestelltes Klassifikationsverfahren, das nicht schon für die Analyse von Verletzungsursachen verwendet wurde (Van Eetvelde et al., 2021; Amendolara et al., 2023).

Die Klassifikation betrachtet alle Einflussfaktoren als unabhängige Variablen. In Wirklichkeit sind die Einflussfaktoren aber auch untereinander abhängig. Diese Abhängigkeiten können mit Hilfe von Bayes-Netzen analysiert werden (vgl. Abschn. 3.2). In Bayes-Netzen können Variablen sowohl die Rolle der unabhängigen als auch der abhängigen Variablen einnehmen. Bayes-Netze haben außerdem den Vorzug, dass interaktiv bedingte Wahrscheinlichkeiten ermittelt werden können, z. B.: Wenn ich das Alter eines Athleten kenne, wie hoch ist dann die Wahrscheinlichkeit, dass er eine Knieverletzung erleidet? Oder: Wenn ein Athlet eine Trainingspause von 2 Wochen eingelegt hat, wie hoch ist dann die Wahrscheinlichkeit für eine Verletzung im nächsten Wettkampf? So untersuchten Olmedilla et al. (2018), wie psychologische Faktoren wie Wettkampfangst, Risikobewusstsein, Selbstwirksamkeit sich gegenseitig und andere Risikofaktoren für Verletzungen beeinflussen. Ein Beispiel für die Auswirkungen von Umgebungseinflüssen liefern Doelp et al. (2019): Für das Verständnis des Verletzungsrisikos beim Surfen untersuchen sie mit Hilfe eines Bayes-Netzes das Zusammenwirken meteorologischer Faktoren (Lufttemperatur, Wassertemperatur, Windrichtung und Windgeschwindigkeit), geografischer Faktoren (Strandgefälle) und hydrodynamischer Faktoren (Wellenhöhe, Wellenrichtung und Wellenperiode).

Process Mining wurde in Abschn. 3.1.6 als ein geeignetes Verfahren vorgestellt, um die zeitliche Abfolge von Ereignissen zu untersuchen. Pirusiñol et al. (2024) verwendeten Process Mining, um Verletzungshistorien von Fußballspielern des FC Barcelona auf häufig auftretende Folgen von Verletzungen zu analysieren. Die Studie zeigte beispielsweise, dass fast die Hälfte der Verletzungen des Oberschenkelmuskels erneute Verletzungen derselben Art nach sich zogen, ein Fünftel derselben aber auch Verletzungen des Sprunggelenks. Die Autoren betonen aber, dass aus der häufigen Abfolge dieser Verletzungen allein kein kausaler Zusammenhang hergestellt werden darf.

4.5 Ergebnisvorhersage

Eine dominante Rolle unter den Sport Analytics nimmt die Ergebnisvorhersage (outcome prediction) ein. Das ist im Zweikampf- und Mannschaftssport ein Klassifikationsproblem, denn man hat es mit diskreten Spielausgängen zu tun (Horvat & Job, 2020; Bunker & Susnjak, 2022; Bunker et al., 2023). Die Zielvariablen können binär sein (Sieg, Niederlage) oder mehrklassig (Sieg, Niederlage, Unentschieden). Gelegentlich wird die Anzahl der Tore prognostiziert, die eine Mannschaft in einem Spiel (Dutt, 2019), in einem Turnier (Penn & Donnelly 2022) oder in einer Spielsaison (Celik, 2021) erzielt hat. Oder die Anzahl Tore, die ein Spieler in einem Spiel oder in einer Saison geschossen hat (Apostolou & Tjortjis, 2019). Vorhersagen werden auch auf den Ausgang von Turnieren (Ekstrøm et al., 2021), die Positionen von Mannschaften in der Tabelle oder die Positionen von Spielern in der Rangliste gemacht.

Bunker und Susnjak (2022) untersuchten wissenschaftliche Publikationen über Ergebnisvorhersagen in Mannschaftssportarten auf die Häufigkeit der betrachteten Sportarten und der angewandten Klassifikationsverfahren. Der überwiegende Anteil der Publikationen widmet sich dem Fußball, gefolgt von Basketball, American und Australian Football, Rugby, Eishockey, Baseball und Cricket. Die Liste der angewandten Verfahren wird angeführt von neuronalen Netzen, gefolgt von Ent-

scheidungsbaum, SVM, Naive-Bayes-Klassifikator, Boosting, kNN, Bayes-Netzen, linearer Regression, Random Forests, und logistischer Regression.

Als Prädiktoren werden Variablen herangezogen, die letztlich die Spielstärken der beiden Mannschaften ausdrücken. Dafür gibt es prinzipiell drei verschiedene Quellen (Wunderlich & Memmert, 2021).

- (1) Detaillierte Daten aus zurückliegenden Spielen, mit denen sich die Angriffs- und Abwehrstärke für Heim- und Auswärtsspiele beschreiben lassen (Berrar et al., 2019).
- (2) Offizielle Ranglisten der Verbände oder davon abgewandelte Ranglistensysteme
- (3) Daten aus Sportwetten
 - (1) Zu dieser Kategorie gehören Daten wie erzielte Tore, Torschüsse, Ecken, Freistöße, gelbe und rote Karten, getrennt erhoben für Heim- und Auswärtsspiele. Daraus lassen sich einfache Kennzahlen ableiten wie z. B. die Heim-Angriffsstärke (home attacking strength) als mittlere Anzahl der durch die Mannschaft erzielten Heimtore geteilt durch die mittlere Anzahl insgesamt in der Liga erzielten Heimtore. Diese Kennzahlen, die über einen bestimmten zurückliegenden Zeitraum erhoben wurden, können ergänzt werden durch aktuelle Daten über einzelne Spieler, z. B. den Gesundheitszustand.
 - (2) Ranglisten werden von den Verbänden wie ATP oder FIFA nach komplizierten Verfahren ermittelt, wobei Spielergebnisse über einen gewissen Zeitraum, aber evtl. mit unterschiedlicher Gewichtung mit eingehen. Alternativ werden abgewandelte Verfahren eingesetzt, wie z. B. das ELO-Ranking, das aus dem Schach kommt, oder das aus dem Internet bekannte Page-Rank-Verfahren (Coscia, 2024).
 - (3) Sportwetten werden oft als Repräsentation von Expertenwissen angesehen, das sie aufgrund der Setzungen der Buchmacher und Wetten vieler Wettteilnehmer zustande gekommen sind.

Die Anzahl von Prädiktoren, die für die Klassifizierung herangezogen werden, variiert beträchtlich. Die Bandbreite z. B. im Fußball reicht von einigen wenigen bis hin zu ca. 140 Merkmalen (AlMulla et al., 2023; Rico-González et al., 2023). Auch die Genauigkeit (accuracy) der Prognoseergebnisse ist sehr unterschiedlich. So wurde eine Genauigkeit von 80,75 % erzielt für eine binäre Klassifizierung mit RNN und LSTM und eine Genauigkeit von 63,3 % für eine 3-Klassen-Klassifizierung (Yeung et al., 2023).

Diese Ergebnisse beziehen sich auf Prognosen, die vor dem Spiel gemacht werden. Aber auch während des Spiels sind „Live-Prognosen“ möglich. Dabei werden laufend neueste Informationen und Zwischenergebnisse mit einbezogen. Pettersson und Nyquist (2017) machen solche Prognosen (3-klassig) alle 15 min während eines Fußballspiels. Ihr Verfahren (LSTM) liefert eine Genauigkeit von 43,96 % zu Beginn des Spiels und von 98,63 % eine Viertelstunde vor Spielende.

Dass die Prognosegenauigkeit an Grenzen stößt, ist der stochastischen Natur des Spiels zuzuschreiben. Das soll an folgendem Beispiel aus dem Fußball gezeigt werden. Wie in Abschn. 3.1.1 erläutert, kann davon ausgegangen werden, dass die Wahrscheinlichkeit für die Anzahl erzielter Tore einer Poisson-Verteilung folgt. Das gilt für beide Mannschaften, wobei allerdings die spielstärkere Mannschaft eine Verteilung mit höherem Erwartungswert hat. Der folgende Fall beschreibt eine Begegnung zwischen zwei englischen Fußballclubs, Stoke City und Tottenham Hotspur. Nehmen wir an, dass der Torerwartungswert von Stoke City 0,65 und der von Tottenham Hotspur 1,9 ist. Ein binärer Klassifizierungsalgorithmus würde einen Sieg von Tottenham Hotspur voraussagen. Die Tabelle in Abb. 22 zeigt im weißen Bereich die Wahrscheinlichkeiten dafür, dass die jeweiligen Mannschaften 0, 1, 2, 3, 4, 5 Tore schießen. Der farbig unterlegte Bereich gibt die Wahrscheinlichkeiten für mögliche Spielausgänge von 0:0 bis 5:5 an, die sich als Produkt der jeweiligen Einzelwahrscheinlichkeiten ergeben. Das Ergebnis 0:2 ist mit $52,05 \% \cdot 27,07 \% = 14,09 \%$ am wahrscheinlichsten. Die Wahrscheinlichkeit für einen Sieg von Tottenham Hotspur (grün) ist trotz der Überlegenheit nur 68,75 %, für eine Niederlage (rot) 10,99 % und für ein Unentschieden (gelb) 19,54 %.

	Tottenham Hotspur	0	1	2	3	4	5
Stoke City	Wahrscheinlichkeit der Anzahl erzielter Tore	13,32%	26,85%	27,07%	18,19%	9,17%	3,70%
0	52,05%	6,93%	13,98%	14,09%	9,47%	4,77%	1,93%
1	33,99%	4,53%	9,13%	9,20%	6,18%	3,12%	1,26%
2	11,10%	1,48%	2,98%	3,00%	2,02%	1,02%	0,41%
3	2,42%	0,32%	0,65%	0,66%	0,44%	0,22%	0,09%
4	0,39%	0,05%	0,10%	0,11%	0,07%	0,04%	0,01%
5	0,05%	0,01%	0,01%	0,01%	0,01%	0,00%	0,00%

Abb. 22 Wahrscheinlichkeiten für mögliche Spielausgänge eines Spiels zwischen Stoke City und Tottenham Hotspur. Grün: Tottenham gewinnt, Rot: Stoke gewinnt, Gelb: Unentschieden. (Quelle: Smarkets, 2017)

Wenngleich der exakte Spielausgang besonders für Sportwetten von großer Bedeutung ist, so liegt doch das Hauptinteresse vieler Prädiktionsstudien eher darin, den Einfluss einzelner Merkmale auf den Spielausgang zu ermitteln. Wenn das Klassifikationsverfahren diese Merkmalsrelevanz nicht als Nebenprodukt mitliefert, so werden gesonderte Analysen durchgeführt (vgl. Abschn. 3.2.4). Für den Fußball z. B. fassten Lepschy et al. (2018) eine Reihe solcher Studien zusammen. Auf den oberen Plätzen der positiven Einflussfaktoren für den Spielerfolg stehen im Fußball die Anzahl der Schüsse aufs Tor, die Anzahl Pässe, aber besonders das erste im Spiel erzielte Tor (Bilek & Ulas, 2019; de Jong et al., 2020); auf der Negativseite der Erhalt roter Karten. In einer Studie im Volleyball war die Tabellenposition beider Mannschaften in der letzten Spielsaison ausschlaggebend (Lalwani et al., 2022). Der Einsatz von Entscheidungsbäumen zur Ergebnisprognose bei internationalen Tischtennisturnieren brachte als relevante Variablen die Differenz der Weltranglistenposition und das Alter der Spieler hervor (Lennartz et al., 2021).

4.6 Spielanalyse

Spielanalysen werden in vielen Sportarten vor, während und nach dem Wettkampf durchgeführt. Analytics können Spielern und Trainern helfen, objektive und quantifizierbare Informationen über das Spielgeschehen zu erhalten. Ausgangspunkt für die Analyse des Spielgeschehens sind Daten,

wie sie im Abschn. 3.2 beschrieben wurden, insbesondere Ereignisdaten (event data) und spatio-temporale Bewegungsdaten.

Das Spielgeschehen kann auf verschiedenen Ebenen analysiert werden (Abb. 23). Im einfachsten Fall geht es um die Zählung einzelner *Ereignisse (Aktionen)* wie Torschüssen, Toren, Flanken, Pässen, Fehlpässen, Dribblings, usw. Da die einzelnen Aktionen (außer einem erzielten Tor) wenig aussagefähig im Hinblick auf den Spielerfolg sind, gibt es Versuche, aussagekräftigere Metriken zu finden. So führten Decroos et al. (2019) einen Aktionswert (*Action Value*) ein, der den Beitrag der einzelnen Aktion zur Erhöhung der Torchance einer Mannschaft oder zur Verminderung der

Wahrscheinlichkeit eines Gegentores misst. Machine-Learning-Verfahren werden eingesetzt, um diesen Aktionswert zu bestimmen. Die Summe dieser Aktionswerte kann als Leistungsindikator für Spieler und Mannschaft angesehen werden. Fernández et al. (2021) führten auf ähnliche Weise einen Action Value für Ballbesitz ein, den Expected Possession Value (EPV).

Auf der nächsten Ebene geht es um Spielzüge, also z. B. Folgen von Pässen. Pässe kann man aus Event-Daten herauslesen, und zwar ohne Positionsangabe einfach als Kette von aufeinanderfolgenden erfolgreichen Pässen und den daran beteiligten Spielern einer Mannschaft (Abb. 24).

Diese Ketten werden als *Flow Motifs* bezeichnet (Gyarmati et al., 2014). A, B, C und D sind dabei beliebige Spieler einer Mannschaft, vom individuellen Spieler wird abstrahiert. In den




Abb. 23 Verschiedene Ebenen des Spielgeschehens. Vergleiche *Hierarchische Struktur von taktischen Konstrukten* bei Link ([2018b](#))




Abb. 24 Folge von Pässen zwischen Spielern A, B, C und D

meisten Fällen betrachtet man Ketten aus drei Pässen und vier Spielern, die die Motive ABAB, ABAC, ABCA, ABCB und ABCD bilden können. Håland et al. (2020), Peña und Navarro (2015) sowie Bekkers und Dabadghao (2019) untersuchten Flow Motifs Europäischer Fußballmannschaften eingehend und stellten deutliche Unterschiede zwischen einzelnen Mannschaften fest. Bekkers und Dabadghao (2019) analysierten außerdem, welche Flow Motifs am ehesten zum Torerfolg führen.

Malqui et al. (2019) extrahierten aus spatio-temporalen Daten die den Dreierpassfolgen der Flow Motifs entsprechenden Trajektorien. Die

Trajektorien können visualisiert werden und vermitteln einen räumlichen Eindruck der Passfolgen. Ein Clustern der Trajektorien mit dem K-Means-Algorithmus zeigte, dass sich acht räumliche Muster herauskristallisieren.

Wichtige Aktionen geschehen im Fußball auch ohne den Ball. So ist z. B. die Raumkontrolle bzw. der Raumgewinn ein wichtiges Element der Spieltaktik. Die Raumkontrolle (pitch control) eines Spielers ist nicht leicht zu bestimmen. Den Grundgedanken liefert das Voronoi-Diagramm, das jedem Spieler den Raum zuordnet, der ihm gegenüber allen anderen Spielern am nächsten ist (Abb. 25).

Taki et al. (1996) haben den Voronoi-Gedanken erweitert, indem sie die Bewegungsrichtung und Geschwindigkeit der Spieler berücksichtigt haben. Fernandez und Bornn (2018) haben kontinuierliche Übergänge zwischen den kontrollierten Räumen eingeführt. Der von jeder Mannschaft




Abb. 25 Voronoi-Diagramm für die Raumkontrolle von Spielern zweier Mannschaften

kontrollierte Raum kann sehr anschaulich mit Hilfe von Konturdiagrammen visualisiert werden (Martens et al., 2021). Ein Maß für die *Raumkontrolle* (*pitch control*) ist der Raumanteil, den ein Spieler oder eine Mannschaft im Verhältnis zum Gesamtraum kontrolliert. Noch aussagekräftiger ist die Raumkontrolle, wenn sie mit dem *Raumwert* (*pitch value*) gewichtet wird, der Spielfeldpositionen relativ zur jeweiligen Ballposition eine unterschiedliche Wertigkeit zuordnet, vergleichbar den Spielfeldpositionen relativ zum Tor bei Expected Goals (Fernandez & Bornn, 2018).

Auf der nächsten Ebene werden *Spielstile* (*styles of play*) betrachtet. Im Gegensatz zur statischen Grundordnung (Aufstellung, Formation) beschreibt der Spielstil das dynamische Zusammenwirken der Spieler im Hinblick auf ihr gemeinsames Ziel. Variablen, die den Spielstil bestimmen, sind die Anzahl, Art und Länge der Pässe (Steilpässe, Querpässe, Rückpässe), die Anzahl Flanken, die Anzahl Torschüsse, die Länge des Ballbesitzes in verschiedenen Bereichen des Spielfelds, das Tempo der Bewegungen, oder die Flexibilität der Spielerpositionen. Man unterscheidet Spielstile für Angriff und Verteidigung. Über die Anzahl verschiedener Spielstile und deren Bezeichnungen sind sich die Experten jedoch nicht einig. Die zur Bestimmung von Spielstilen eingesetzten Verfahren sind typischerweise die Hauptkomponentenanalyse und das Clustering. Einige Studien bilden Cluster von Stilen, ohne diese mit Namen zu versehen. Andere versuchen, diese Cluster bekannten Spielstilen zuzu-

ordnen, wie z. B. Positionsspiel, direktes Spiel und Konterangriff.

Fernandez-Navarro et al. (2016) untersuchten Mannschaften der Englischen und Spanischen Ligen und identifizierten 12 verschiedene Spielstile (8 für den Angriff, 4 für die Verteidigung), für die sie eigene Bezeichnungen fanden. Bialkowski et al. (2014) entdeckten, dass sich der Spielstil einer Mannschaft im Laufe der Saison verändern kann.

Die *Formation* beschreibt die Anordnung der Spieler auf dem Spielfeld. Aus der Formation ergeben sich Positionsbezeichnungen wie z. B. bei 4-4-2 die Positionen von vier Verteidigern, vier Mittelfeldspielern und zwei Angreifern. Die heute im modernen Fußball gebräuchlichsten Formationen sind 4-3-3, 4-2-4, 4-3-1-2, 3-4-2-1, 3-5-2 und 4-1-4-1, sowie 4-5-1. Die Mannschaftsaufstellung wird rechtzeitig vor dem Spiel vom Trainer festgelegt und meist auch in den Medien kommuniziert. Die Formation sagt allerdings wenig darüber aus, ob sich die Spieler im Verlauf des Spiels auch tatsächlich an diese beabsichtigten Positionen halten. Oftmals wechseln Teams die Formation auch während des Spiels. Deshalb interessieren sich Analysten dafür, Formationen aus dem aktuellen Spielgeschehen „herauszulesen“. Dafür bilden grundsätzlich die Trajektorien der Spieler den Ausgangspunkt. Im einfachsten Fall wird aus jeder Trajektorie der mittlere Aufenthaltsort eines Spielers berechnet, und die Varianz der Bewegung beschreibt die Größe des Wirkungsbereichs (Bialkowski et al., 2014).

Betrachtet man diese Wirkungsbereiche über den gesamten Spielverlauf, so sind die Bereiche einzelner Spieler sehr groß und überschneiden sich weitgehend. Erst die getrennte Betrachtung in einzelnen Spielphasen, insbesondere den offensiven und defensiven Phasen, vermag die Bereiche einzelner Spieler klar zu differenzieren (Bauer et al., 2023).

Visualisierungen dieser Wirkungsbereiche auf dem Spielfeld lassen oft schon eine Formation wie beispielsweise 3-4-3 und die Zuordnung zu offensiven oder defensiven Phasen erkennen. Die vielen unterschiedlichen Beobachtungen werden in eine überschaubare Zahl von Formationen (unüberwacht) geclustert (Shaw & Glickman, 2019;

Bauer et al., (2023). Einen anderen Weg gehen Müller-Budack et al. (2019). Sie geben 12 gängige Formationen vor und klassifizieren die ermittelten Beobachtungen nach diesen Formationen. Bauer et al. (2023) untersuchen außerdem die Veränderungen der Formationen im Verlauf des Spiels und zeigen, wie sich offensive und defensive Spielphasen und deren Übergangsphasen zeitlich abwechseln. Nach der Quantifizierung der Spielformationen können auch Vergleiche über Vereine oder sogar Länder hinweg durchgeführt werden.

5 Zusammenfassung

Die Übersicht über die Methoden und Anwendungen von Sports Analytics sollte gezeigt haben, wie groß die Vielfalt dieser Disziplin ist. Aus vielen der vorgestellten Methoden sind kommerzielle Lösungen entstanden, die heute mindestens im Spitzensport im ständigen Einsatz sind. Mit der Integration in die Sportberichterstattung erreichen Sports Analytics ein breites Publikum. Sports Analytics sind zum Big Business geworden, bleiben aber auch für die Wissenschaft ein lohnendes und spannendes Forschungsgebiet. Allerdings ist die Rolle der Analytics im Sport nicht unumstritten, was möglicherweise auf ein Missverständnis zurückzuführen ist. Denn wenn auch die Möglichkeiten der Sports Analytics beeindruckend sind, so soll doch die menschliche Urteilskraft, das Wissen und die Erfahrung von Experten damit nicht abgelöst werden. Wir verzichten daher bewusst auf den Begriff *Künstliche Intelligenz*, um die entscheidungsunterstützende Funktion der Sports Analytics hervorzuheben.

Literatur

- Adidas. (2022). Adidas reveals the first FIFA World Cup™ official match ball featuring connected ball technology. <https://news.adidas.com/football/adidas-reveals-the-first-fifa-world-cup-official-match-ball-featuring-connected-ball-technology/s/cccb7187-a67c-4166-b57d-2b28f1d36fa0>. Zugegriffen am 08.12.2024.
- Ajmal, M., Ashraf, M. H., Shakir, M., Abbas, Y., & Shah, F. A. (2012). Video summarization: techniques and classification. In *Computer vision and graphics: International conference, ICCVG 2012, Warsaw, Poland, September 24-26 2012. Proceedings* (S. 1–13). Springer.
- Akan, S., & Varlı, S. (2023). Use of deep learning in soccer videos analysis: Survey. *Multimedia Systems*, 29(3), 897–915.
- Akhanli, S. E., & Hennig, C. (2023). Clustering of football players based on performance data and aggregated clustering validity indexes. *Journal of Quantitative Analysis in Sports*, 19(2), 103–123.
- Alamar, B. C. (2013). *Sports analytics: A guide for coaches, managers, and other decision makers*. 2nd Edition 2024. Columbia University Press.
- Albawi, S., Mohammed, T. A., & Al-Zawi, S. (2017). Understanding of a convolutional neural network. In *2017 international conference on engineering and technology (ICET)* (S. 1–6). IEEE.
- Albert, J. (2010). Sabermetrics: The past, the present, and the future. *Mathematics and Sports*, 43, 15.
- AlMulla, J., Islam, M. T., Al-Absi, H. R., & Alam, T. (2023). SoccerNet: A gated recurrent unit-based model to predict soccer match winners. *PLoS One*, 18(8), e0288933.
- Amendolara, A., Pfister, D., Settlemayer, M., Shah, M., Wu, V., Donnelly, S., et al. (2023). An overview of machine learning applications in sports injury prediction. *Cureus*, 15(9), e46170.
- Apostolou, K., & Tjortjis, C. (2019). Sports analytics algorithms for performance prediction. In *10th international conference on information, intelligence, systems and applications (IISA)* (S. 1–4). IEEE.
- Arojanam, G., Manivannan, N., & Harrison, D. (2019). Review on wearable technology sensors used in consumer sport applications. *Sensors*, 19(9), 1983.
- Ashley, K. (2020). Reinforcement learning in sports. In *Applied machine learning for health and fitness: A practical guide to machine learning with deep vision, sensors and IoT* (S. 199–219).
- Bahr, R., & Krosshaug, T. (2005). Understanding injury mechanisms: A key component of preventing injuries in sport. *British Journal of Sports Medicine*, 39(6), 324–329.
- Banister, E. W., Calvert, T. W., Savage, M. V., & Bach, T. (1975). A systems model of training for athletic performance. *Australian Journal of Sports Medicine*, 7(3), 57–61.
- Bátorfy, A. (2020) Three Sportviz inventions by a Hungarian newspaper. <https://medium.com/nightingale/three-sportviz-inventions-by-a-hungarian-newspaper-b5c0df489d6c>. Zugegriffen am 08.12.2024.
- Bauer, P., Anzer, G., & Shaw, L. (2023). Putting team formations in association football into context. *Journal of Sports Analytics*, 9(1), 39–59.
- Baughman, A., Hammer, S., Agarwal, R., Akay, G., Morales, E., Johnson, T., et al. (2024). Large scale generative AI text applied to sports and music. *arXiv preprint, arXiv:2402.15514*.

- Baumer, B., & Zimbalist, A. (2014). *The sabermetric revolution: Assessing the growth of analytics in baseball*. University of Pennsylvania Press.
- Beal, R., Norman, T. J., & Ramchurn, S. D. (2019). Artificial intelligence for team sports: A survey. *The Knowledge Engineering Review*, 34, e28.
- Beggs, C. (2024). *Soccer analytics: An introduction using R*. CRC Press.
- Bekkens, J., & Dabadghao, S. (2019). Flow motifs in soccer: What can passing behavior tell us? *Journal of Sports Analytics*, 5(4), 299–311.
- Bellman, R. (1965). On the application of dynamic programming to the determination of optimal play in chess and checkers. *Proceedings of the National Academy of Sciences*, 53(2), 244–247.
- Bellman, R. (1977). Dynamic programming and Markovian decision processes with application to baseball. In S. P. Ladany & R. E. Machol (Hrsg.), *Optimal strategies in sports* (S. 75–85). Elsevier-North Holland.
- Berrar, D., Lopes, P., Davis, J., & Dubitzky, W. (2019). Guest editorial: Special issue on machine learning for soccer. *Machine Learning*, 108, 1–7.
- Bialkowski, A., Lucey, P., Carr, P., Yue, Y., Sridharan, S., & Matthews, I. (2014). Identifying team style in soccer using formations learned from spatiotemporal tracking data. In *2014 IEEE international conference on data mining workshop* (S. 9–14). IEEE.
- Bilek, G., & Ulas, E. (2019). Predicting match outcome according to the quality of opponent in the English premier league using situational variables and team performance indicators. *International Journal of Performance Analysis in Sport*, 19(6), 930–941.
- Boobier, T. (2018). *Advanced analytics and AI: Impact, implementation, and the future of work*. Wiley.
- Boon, B. H., & Sierksma, G. (2003). Team formation: Matching quality supply and quality demand. *European Journal of Operational Research*, 148(2), 277–292.
- Box, G. E. P., & Jenkins, G. (1970). *Time series analysis forecasting and control*. Holden-Day.
- Briskorn, D., & Drexler, A. (2009). IP models for round robin tournaments. *Computers & Operations Research*, 36(3), 837–852.
- Budak, G., Kara, İ., Iç, Y. T., & Kasimbeyli, R. (2019). New mathematical models for team formation of sports clubs before the match. *Central European Journal of Operations Research*, 27, 93–109.
- Bukiet, B., Harold, E. R., & Palacios, J. L. (1997). A Markov chain approach to baseball. *Operations Research*, 45(1), 14–23.
- Bunker, R., & Susnjak, T. (2022). The application of machine learning techniques for predicting match results in team sport: A review. *Journal of Artificial Intelligence Research*, 73, 1285–1322.
- Bunker, R., Yeung, C., & Fujii, K. (2023). Machine learning for soccer match result prediction. *arXiv preprint, arXiv:2403.07669*.
- Cardinale, M., & Varley, M. C. (2017). Wearable training-monitoring technology: Applications, challenges, and opportunities. *International Journal of Sports Physiology and Performance*, 12(s2), S2–S55.
- Castellano, J., Alvarez-Pastor, D., & Bradley, P. S. (2014). Evaluation of research using computerised tracking systems (Amisco[®] and Prozone[®]) to analyse physical performance in elite soccer: A systematic review. *Sports Medicine*, 44, 701–712.
- Cavallaro, R., Hybinette, M., White, M., & Balch, T. (2011). Augmenting live broadcast sports with 3D tracking information. *IEEE MultiMedia*, 18(4), 38.
- Celik, S. (2021). Predicting the number of goals in football matches with the Poisson distribution: Example of Spain La Liga. *Scholars Journal of Physics, Mathematics and Statistics*, 8, 133–142.
- Chen, H. T., Chen, H. S., Hsiao, M. H., Tsai, W. J., & Lee, S. Y. (2008). A trajectory-based ball tracking framework with visual enrichment for broadcast baseball videos. *Journal of Information Science and Engineering*, 24(1), 143–157.
- Clarke, S. R., & Norman, J. M. (1999). To run or not?: Some dynamic programming models in cricket. *Journal of the Operational Research Society*, 50, 536–545.
- Claudino, J. G., Capanema, D. D. O., de Souza, T. V., Serrão, J. C., Machado Pereira, A. C., & Nassis, G. P. (2019). Current approaches to the use of artificial intelligence for injury risk assessment and performance prediction in team sports: A systematic review. *Sports Medicine-Open*, 5, 1–12.
- Collins, T. (2013). *Sport in capitalist society: A short history*. Routledge.
- Connor, M., Faganan, D., Watters, B., McCaffery, F., & O'Neill, M. (2021). Optimizing team sport training with multi-objective evolutionary computation. *International Journal of Computer Science in Sport*, 20, 92–105.
- Coscia, M. (2024). Which sport is becoming more predictable? A cross-discipline analysis of predictability in team sports. *EPJ Data Science*, 13(1), 8.
- Darrow, B. (2015). Live from Fenway Park: a behind the scenes look at MLB's Statcast. *Fortune*, September 4, 2015. <https://fortune.com/2015/09/04/mlb-statcast-data>. Zugegriffen am 08.12.2024.
- D'Onofrio, G. (2024). *Wearable technology in sports and the need for greater protection* (Student works 1485). Seton Hall University.
- Datta, P., Namin, A. S., & Chatterjee, M. (2018). A survey of privacy concerns in wearable devices. In *2018 IEEE international conference on big data (Big Data)* (S. 4549–4553). IEEE.
- Davenport, T. H. (2006). Competing on analytics. *Harvard Business Review*, 84(1), 98.
- Davenport, T. H., & Harris, J. G. (2007). *Competing on analytics: The new art of winning*. Harvard Business School Press.
- Decroos, T. (2020). *Soccer analytics meets artificial intelligence: Learning value and style from soccer event stream data*. Dissertation, KU Leuven.
- Decroos, T., & Davis, J. (2020). Player vectors: Characterizing soccer players' playing style from match event streams. In *Machine learning and knowledge discovery*

- in databases: European conference, ECML PKDD 2019, Würzburg, Germany, September 16–20 2019, Proceedings, Part III (S. 569–584). Springer International Publishing.
- Decroos, T., Bransen, L., Van Haaren, J., & Davis, J. (2019). Actions speak louder than goals: Valuing player actions in soccer. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining* (S. 1851–1861).
- Doelp, M. B., Puleo, J. A., & Plant, N. G. (2019). Predicting surf zone injuries along the Delaware coast using a Bayesian network. *Natural Hazards*, 98, 379–401.
- Domschke, W., Drexler, A., Klein, R., & Scholl, A. (2015). *Einführung in Operations Research* (9. Aufl.). Springer.
- Du, M., & Yuan, X. (2021). A survey of competitive sports data visualization and visual analysis. *Journal of Visualization*, 24, 47–67.
- Dubitzky, W., Lopes, P., Davis, J., & Berrar, D. (2019). The open international soccer database for machine learning. *Machine Learning*, 108, 9–28.
- Dutt, A. (2019). *Predicting goals scored for football matches*. Stanford University Report.
- Eager, E. A., & Erickson, R. A. (2023). *Football analytics with Python & R: Learning data science through the lens of sports*. O'Reilly Media Inc.
- Eaves, J. S. (2015). A history of sports notational analysis: A journey into the nineteenth century. *International Journal of Performance Analysis in Sport*, 15(3), 1160–1176.
- Edelmann-Nusser, J., Hohmann, A., & Henneberg, B. (2002). Modeling and prediction of competitive performance in swimming upon neural networks. *European Journal of Sport Science*, 2(2), 1–10.
- Ekström, C. T., Van Eetvelde, H., Ley, C., & Brefeld, U. (2021). Evaluating one-shot tournament predictions. *Journal of Sports Analytics*, 7(1), 37–46.
- Ensum, J., Pollard, R., & Taylor, S. (2005). Applications of logistic regression to shots at goal at association football. In *Science and football V: The proceedings of the Fifth World Congress on Science and Football* (S. 214–221). Routledge.
- Fahad, A., Alshatri, N., Tari, Z., Alamri, A., Khalil, I., Zomaya, A. Y., et al. (2014). A survey of clustering algorithms for big data: Taxonomy and empirical analysis. *IEEE Transactions on Emerging Topics in Computing*, 2(3), 267–279.
- Fernandez, J., & Bornn, L. (2018). Wide Open Spaces: A statistical technique for measuring space creation in professional soccer. In *Sloan sports analytics conference* (S. 1–19). MIT Sloan.
- Fernández, J., Bornn, L., & Cervone, D. (2021). A framework for the fine-grained evaluation of the instantaneous expected value of soccer possessions. *Machine Learning*, 110(6), 1389–1427.
- Fernandez-Navarro, J., Fradua, L., Zubillaga, A., Ford, P. R., & McRobert, A. P. (2016). Attacking and defensive styles of play in soccer: Analysis of Spanish and English elite teams. *Journal of sports sciences*, 34(24), 2195–2204.
- Fortune Business Insights. (2024). <https://www.fortunebusinessinsights.com/sports-analytics-market-102217>. Zugegriffen am 08.12.2024.
- Fox, J. L., Stanton, R., Sargent, C., Wintour, S. A., & Scanlan, A. T. (2018). The association between training load and performance in team sports: A systematic review. *Sports Medicine*, 48, 2743–2774.
- Fried, G., & Mumcu, C. (Hrsg.). (2016). *Sport analytics: A data-driven approach to sport business and management*. Taylor & Francis.
- Ganesh, T. V. (2017). *Cricket analytics with cricketr*. Independently published.
- Ganser, A., Hollaus, B., & Stabinger, S. (2021). Classification of tennis shots with a neural network approach. *Sensors*, 21(17), 5703.
- Garnica Caparrós, M. (2024). Event data. In *Computer science in sport: Modeling, simulation, data analysis and visualization of sports-related data* (S. 35–41). Springer.
- Galton, F. (1894). Discontinuity in evolution. *Mind*, 3(11), 362–372.
- Gerdeen, J. C. (2017). *Golf ball putting analytics*. CreateSpace Independent Publishing Platform.
- Gerrard, B. (2017). The role of analytics in assessing playing talent. In *Routledge handbook of talent identification and development in sport* (S. 422–431). Routledge.
- Ghazali, N. F., Shahar, N., Rahmad, N. A., Sufri, N. J., As'ari, M. A., & Latif, H. M. (2018). Common sport activity recognition using inertial sensor. In *2018 IEEE 14th international colloquium on signal processing & its applications (CSPA)* (S. 67–71). IEEE.
- Gilboa, I., Postlewaite, A., Samuelson, L., & Schmeidler, D. (2014). Economic models as analogies. *The Economic Journal*, 124(578), F513–F533.
- Goldbeck, G. (2024). Introducing Statcast 2023: High Frame Rate Bat and Biomechanics Tracking. <https://technology.mlblogs.com/introducing-statcast-2023-high-frame-rate-bat-and-biomechanics-tracking-3844890264a6>. Zugegriffen am 08.12.2024.
- Goldsberry, K. (2012). Courtvision: New visual and spatial analytics for the NBA. In *2012 MIT Sloan sports analytics conference* (Bd. 9, S. 12–15).
- Goldsberry, K. (2024). *Hoop Atlas: Mapping the remarkable transformation of the modern NBA*. Mariner Books.
- Grootjans, M. (2014). *Visualization of spatio-temporal soccer data*. Doctoral dissertation, Master thesis, Eindhoven.
- Gudmundsson, J., & Horton, M. (2017). Spatio-temporal analysis of team sports. *ACM Computing Surveys (CSUR)*, 50(2), 1–34.
- Gudmundsson, J., & Wolle, T. (2012). Football analysis using spatio-temporal tools. In *Proceedings of the 20th international conference on advances in geographic information systems* (S. 566–569). ACM.
- Guézic, A. (2002). Tracking pitches for broadcast television. *Computer*, 35(3), 38–43.

- Gyarmati, L., Kwak, H., & Rodriguez, P. (2014). Searching for a unique style in soccer. *arXiv preprint, arXiv:1409.0308*.
- Hakes, J. K., & Sauer, R. D. (2006). An economic evaluation of the Moneyball hypothesis. *Journal of Economic Perspectives*, 20(3), 173–185.
- Håland, E. M., Wiig, A. S., Hvattum, L. M., & Stålhan, M. (2020). Evaluating the effectiveness of different network flow motifs in association football. *Journal of Quantitative Analysis in Sports*, 16(4), 311–323.
- Han, J., & Kamber, M. (2006). *Data mining. Concepts and techniques* (2. Aufl.). Morgan Kaufmann.
- Harell, A., & Bajic, I. V. (2019). The data gap in sports analytics and how to close it. In *Proceedings of the Artificial Intelligence in Team Sports Workshop at The Thirty Fourth AAAI Conference on Artificial Intelligence*, AAAI, New York, NY.
- Harrison, C. K., & Bukstein, S. (Hrsg.). (2016). *Sport business analytics: Using data to increase revenue and improve operational efficiency*. CRC Press.
- Healey, G. (2017). The new Moneyball: How ballpark sensors are changing baseball. *Proceedings of the IEEE*, 105(11), 1999–2002.
- Hintz, E. S. (2022). Sports analytics before Moneyball. <https://invention.si.edu/sports-analytics-moneyball>. Zugriffen am 08.12.2024.
- Hjort, M. (2021). Expected Goals – die Torwahrscheinlichkeit im Fußball. https://www.matkult.eu/matonline/index.php/de/2021/xg_de/. Zugriffen am 08.12.2024.
- Holatka, A. K., Suwa, H., & Yasumoto, K. (2019). Volleyball setting technique assessment using a single point sensor. In *2019 IEEE international conference on pervasive computing and communications workshops (PerCom workshops)* (S. 567–572). IEEE.
- Hooper, L. (2024). Radar chart baseball cards. <https://dribbble.com/shots/5953048-Radar-Chart-Baseball-Cards>. Zugriffen am 08.12.2024.
- Horvat, T., & Job, J. (2020). The use of machine learning in sport outcome prediction: A review. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 10(5), e1380.
- Host, K., & Ivašić-Kos, M. (2022). An overview of human action recognition in sports based on computer vision. *Helijon*, 8(6), e09633.
- Hotelling, H. (1933). Analysis of a complex of statistical variables into principal components. *Journal of educational psychology*, 24(6), 417.
- Howard, R. A. (1960). *Dynamic programming and Markov processes*. The MIT Press.
- Imbach, F., Perrey, S., Chailan, R., Meline, T., & Candau, R. (2022). Training load responses modelling and model generalisation in elite sports. *Scientific Reports*, 12(1), 1586.
- Ingram, B., Rosman, B., van Alten, C., & Klein, R. (2022). Play-style identification through deep unsupervised clustering of trajectories. In *2022 IEEE conference on games (CoG)* (S. 393–400). IEEE.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning with applications in R* (Springer texts in statistics, 2. Aufl.). Springer.
- Janssen, J., & Laatz, W. (1997). Modelle zur Kurvenanpassung. *Statistische Datenanalyse mit SPSS für Windows: Eine anwendungsorientierte Einführung in das Basis-system und das Modul Exakte Tests*, 405–410.
- Jayal, A., McRobert, A., Oatley, G., & O'Donoghue, P. (2018). *Sports analytics: Analysis, visualisation and decision making in sports performance*. Routledge.
- Jong, L. M. de, Gastin, P. B., Angelova, M., Bruce, L., & Dwyer, D. B. (2020). Technical determinants of success in professional women's soccer: A wider range of variables reveals new insights. *PLoS One*, 15(10), e0240992.
- Juárez, J., Santos, C., & Brizuela, C. A. (2021). A comprehensive review and a taxonomy proposal of team formation problems. *ACM Computing Surveys (CSUR)*, 54(7), 1–33.
- Kagan, D., & Nathan, A. M. (2017). Statcast and the baseball trajectory calculator. *The Physics Teacher*, 55(3), 134–136.
- Kamath, U., & Liu, J. (2021). *Explainable artificial intelligence: An introduction to interpretable machine learning* (Bd. 2). Springer.
- Kamble, P. R., Keskar, A. G., & Bhurchandi, K. M. (2019). Ball tracking in sports: A survey. *Artificial Intelligence Review*, 52, 1655–1705.
- Kira, A., Inakawa, K., & Fujita, T. (2019). A dynamic programming algorithm for optimizing baseball strategies. *Journal of the Operations Research Society of Japan*, 62(2), 64–82.
- Kissell, R., & Poserina, J. (2017). *Optimal sports math, statistics, and fantasy*. Academic Press.
- Klemp, M., Wunderlich, F., & Memmert, D. (2021). In-play forecasting in football using event and positional data. *Scientific Reports*, 11(1), 24139.
- Knutson, T. (2021). Understanding StatsBomb radars. <https://statsbomb.com/articles/soccer/understanding-statsbomb-radars/>. Zugriffen am 08.12.2024.
- Kovac, F. J., & Dague, M. F. (1972). Forecasting by product life cycle analysis. *Research Management*, 15(4), 66–72.
- Kovalchik, S. A. (2023). Player tracking data in sports. *Annual Review of Statistics and Its Application*, 10, 677–697.
- Kröckel, P., & Bodendorf, F. (2020). Process mining of football event data: a novel approach for tactical insights into the game. *Frontiers in Artificial Intelligence*, 3, 47.
- Kumar, J., Kumar, R., & Kumar, P. (2018). Outcome prediction of ODI cricket matches using decision trees and MLP networks. In *2018 first international conference on secure cyber computing and communication (ICSCCC)* (S. 343–347). IEEE.
- Kumar, P., Chauhan, S., & Awasthi, L. K. (2024). Human activity recognition (HAR) using deep learning: Review, methodologies, progress and future research di-

- rections. *Archives of Computational Methods in Engineering*, 31(1), 179–219.
- Lalwani, A., Saraiya, A., Singh, A., Jain, A., & Dash, T. (2022). Machine learning in sports: A case study on using Explainable models for predicting outcomes of volleyball matches. *arXiv preprint, arXiv:2206.09258*.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444.
- Lennartz, J., Groll, A., & van der Wurp, H. (2021). Predicting table tennis tournaments: A comparison of statistical modelling techniques. *International Journal of Racket Sports Science*, 3(2), 39–48.
- Lepschy, H., Wäsche, H., & Woll, A. (2018). How to be successful in football: A systematic review. *The Open Sports Sciences Journal*, 11(1), 3.
- Lewis, M. (2003). *Moneyball: The art of winning an unfair game*. WW Norton & Company.
- Liao, C. C., Hwang, D. H., & Koike, H. (2022). Ai golf: Golf swing analysis tool for self-training. *IEEE Access*, 10, 106286–106295.
- Link, D. (2018a). *Data analytics in professional soccer*. Springer Vieweg.
- Link, D. (2018b). Sports Analytics: Wie aus (kommerziellen) Sportdaten neue Möglichkeiten für die Sportwissenschaft entstehen. *German Journal of Exercise and Sport Research*, 48(1), 13–25.
- Linke, D. (2020). Pass networks, how to render 3D football pass networks. <https://towardsdatascience.com/how-to-render-3d-football-pass-networks-bf889f5ab1b0>. Zugegriffen am 08.12.2024.
- Liu, J., Huang, G., Hyypä, J., Li, J., Gong, X., & Jiang, X. (2023). A survey on location and motion tracking technologies, methodologies and applications in precision sports. *Expert Systems with Applications*, 229, 120492.
- Luo, Y., Schulte, O., & Poupart, P. (2020). Inverse reinforcement learning for team sports: Valuing actions and players. In *Proceedings of the twenty-ninth international joint conference on artificial intelligence, IJCAI-20* (S. 3356–3363). International Joint Conferences on Artificial Intelligence Organization.
- Lustig, I., Dietrich, B., Johnson, C., & Dziekan, C. (2010). The analytics journey. *Analytics Magazine*, 3(6), 11–13.
- Lyons, K. (1994). *Lloyd Lowell Messersmith and the origins of notational analysis*. Centre for Notational Analysis, Cardiff Institute of Higher Education.
- Macdonald, B., & Pulleyblank, W. (2014). Realignment in the NHL, MLB, NFL, and NBA. *Journal of Quantitative Analysis in Sports*, 10(2), 225–240.
- MacLean, L. C., & Ziemba, W. T. (2021). *Sports analytics* (World scientific series in finance, Bd. 18). WSPC.
- Maher, M. J. (1982). Modelling association football scores. *Statistica Neerlandica*, 36(3), 109–118.
- Mainzer, K. (2016). *Künstliche Intelligenz – Wann übernehmen die Maschinen?* Springer.
- Mallepalle, S., Yurko, R., Pelechris, K., & Ventura, S. L. (2019). next-gen-scrapy: Extracting NFL tracking data from images to evaluate quarterbacks and pass defenses. *arXiv preprint, arXiv:1906.03339*.
- Malqui, J. L. S., Romero, N. M. L., Garcia, R., Alemdar, H., & Comba, J. L. (2019). How do soccer teams coordinate consecutive passes? A visual analytics system for analysing the complexity of passing sequences using soccer flow motifs. *Computers & Graphics*, 84, 122–133.
- Marchi, M., & Albert, J. (2013). *Analyzing baseball data with R*. CRC Press.
- Martens, F., Dick, U., & Brefeld, U. (2021). Space and control in soccer. *Frontiers in Sports and Active Living*, 3, 676179.
- Mead, J., O'Hare, A., & McMenemy, P. (2023). Expected goals in football: Improving model performance and demonstrating value. *PLoS One*, 18(4), e0282295.
- Memmert, D., & Raabe, D. (2024). *Data analytics in football: Positional data collection, modelling and analysis* (2. Aufl.). Routledge.
- Millington, B., Naraine, M., Safai, P., Manley, A., & Wanless, L. (2023). Sport after Moneyball: Exploring sports analytics and the digital economy. <https://sirc.ca/blog/sports-analytics/>. Zugegriffen am 08.12.2024.
- Minton, R. B. (2016). *Sports math: An introductory course in the mathematics of sports science and sports analytics*. Chapman and Hall/CRC.
- Mitchell, T. M. (1999). Machine learning and data mining. *Communications of the ACM*, 42(11), 30–36.
- Miura, J., Shimawaki, T., Sakiyama, T., & Shirai, Y. (2009). Ball route estimation under heavy occlusion in broadcast soccer video. *Computer Vision and Image Understanding*, 113(5), 653–662.
- Mizels, J., Erickson, B., & Chalmers, P. (2022). Current state of data and analytics research in baseball. *Current Reviews in Musculoskeletal Medicine*, 15(4), 283–290.
- Moroney, M. J. (1956). *Facts from figures*. Penguin Books.
- Motoi, S., Misu, T., Nakada, Y., Yazaki, T., Kobayashi, G., Matsumoto, T., & Yagi, N. (2012). Bayesian event detection for sport games with hidden Markov model. *Pattern Analysis and Applications*, 15, 59–72.
- Müller-Budack, E., Theiner, J., Rein, R., & Ewerth, R. (2019). “Does 4-4-2 exist?” – An analytics approach to understand and classify football team formations in single match situations. In *Proceedings of the 2nd international workshop on multimedia content analysis in sports* (S. 25–33). ACM.
- Munea, T. L., Jembre, Y. Z., Weldegebriel, H. T., Chen, L., Huang, C., & Yang, C. (2020). The progress of human pose estimation: A survey and taxonomy of models applied in 2D human pose estimation. *IEEE Access*, 8, 133330–133348.
- Munroe, R. (2009). Movie narrative charts. <https://xkcd.com/657/>. Zugegriffen am 08.12.2024.
- Naik, B. T., Hashmi, M. F., & Bokde, N. D. (2022). A comprehensive review of computer vision in sports: Open issues, future trends and research directions. *Applied Sciences*, 12(9), 4429.
- NBA. (2024). National Basketball Association. <https://www.nba.com/game/cha-vs-det-0022200992/play-by-play>. Zugegriffen am 08.12.2024.

- Nevill, A. M., & Whyte, G. (2005). Are there limits to running world records?. *Medicine & Science in Sports & Exercise*, 37(10), 1785–1788.
- Nickel, S., Rebennack, S., Stein, O., & Waldmann, K.-H. (2022). *Operations research*. Springer.
- Nishida, K. (2018). <https://blog.exploratory.io/an-introduction-to-principal-component-analysis-pca-with-2018-world-soccer-players-data-810d84a14eab>. Zugegriffen am 08.12.2024.
- Olmedilla, A., Rubio, V. J., Fuster-Parra, P., Pujals, C., & García-Mas, A. (2018). A Bayesian approach to sport injuries likelihood: Does player's self-efficacy and environmental factors plays the main role? *Frontiers in Psychology*, 9, 290523.
- Olsen, R. J., Hasan, S. S., Woo, J. J., Nawabi, D. H., & Ramkumar, P. N. (2024). The fundamentals and applications of wearable sensor devices in sports medicine: A scoping review. *Arthroscopy: The Journal of Arthroscopic & Related Surgery*, 1–22.
- Otero-Saborido, F. M., Aguado-Méndez, R. D., Torreblanca-Martínez, V. M., & González-Jurado, J. A. (2021). Technical-tactical performance from data providers: A systematic review in regular football leagues. *Sustainability*, 13(18), 10167.
- Ozceylan, E. (2016). A mathematical model using AHP priorities for soccer player selection: A case study. *South African Journal of Industrial Engineering*, 27(2), 190–205.
- Pappalardo, L., Cintia, P., Rossi, A., Massucco, E., Ferragina, P., Pedreschi, D., & Giannotti, F. (2019). A public data set of spatio-temporal match events in soccer competitions. *Scientific Data*, 6(1), 236.
- Parmar, N., James, N., Hearne, G., & Jones, B. (2018). Using principal component analysis to develop performance indicators in professional rugby league. *International Journal of Performance Analysis in Sport*, 18(6), 938–949.
- Pearson, K. (1901). Principal components analysis. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 6(2), 559.
- Peña, J. L., & Navarro, R. S. (2015). Who can replace Xavi? A passing motif analysis of football players. *arXiv preprint, arXiv:1506.07768*.
- Peña, J. L., & Touchette, H. (2012). A network theory analysis of football strategies. *arXiv preprint, arXiv:1206.6904*.
- Penn, M. J., & Donnelly, C. A. (2022). Analysis of a double Poisson model for predicting football results in Euro 2020. *PLoS One*, 17(5), e0268511.
- Perin, C., Vuillemot, R., Stolper, C. D., Stasko, J. T., Wood, J., & Carpendale, S. (2018). State of the art of sports data visualization. *Computer Graphics Forum*, 37(3), 663–686.
- Pettersson, D., & Nyquist, R. (2017). Football match prediction using deep learning. *Psychology of Sport and Exercise*, 15(5), 538–547.
- Philpott, A. B. (2005). Stochastic optimization and yacht racing. In *Applications of stochastic programming* (S. 315–336). Society for Industrial and Applied Mathematics.
- Pingali, G., Opalach, A., Jean, Y., & Carlbom, I. (2001). Visualization of sports using motion trajectories: Providing insights into performance, style, and strategy. In *Proceedings visualization 2001. VIS'01* (S. 75–544). IEEE.
- Pino-Ortega, J., & Rico-González, M. (2021). Standardization of electronic performance and tracking systems. In *The use of applied technology in team sport* (S. 3–10). Routledge.
- Pirsiavash, H., Vondrick, C., & Torralba, A. (2014). Assessing the quality of actions. In *Computer vision – ECCV 2014: 13th European conference, Zurich, Switzerland, September 6–12 2014, Proceedings, Part VI 13* (S. 556–571). Springer International Publishing.
- Pi-Rusiñol, R., Verhagen, E., Blanch, M., & Font, G. R. (2024). Process mining to investigate the relationship between clinical antecedents and injury risk, severity and return to play in professional sports. *BMJ Open Sport & Exercise Medicine*, 10(2), e001890.
- Plakias, S., Moustakidis, S., Kokkoti, C., Papalexi, M., Tsatalas, T., Giakas, G., & Tsaopoulos, D. (2023). Identifying soccer players' playing styles: A systematic review. *Journal of Functional Morphology and Kinesiology*, 8(3), 104.
- Pollard, R. (2002). Charles Reep (1904–2002): Pioneer of notational and performance analysis in football. *Journal of Sports Sciences*, 20(10), 853–855.
- Pollard, R., & Reep, C. (1997). Measuring the effectiveness of playing strategies at soccer. *Journal of the Royal Statistical Society Series D: The Statistician*, 46(4), 541–550.
- Prieske, O., & Granacher, U. (2023). Sportmedizinische Grundlagen: Die Bedeutung der Trainingswissenschaft für die sportliche Leistungsoptimierung und den Gesundheitserhalt. In *Bewegung, Training, Leistung und Gesundheit: Handbuch Sport und Sportwissenschaft* (S. 627–640). Springer.
- Raabe, D., Biermann, H., Bassek, M., Wohlan, M., Komitova, R., Rein, R., et al. (2022). floodlight – A high-level, data-driven sports analytics framework. *arXiv preprint, arXiv:2206.02562*.
- Rajšp, A., & Fister, I., Jr. (2020). A systematic literature review of intelligent data analysis methods for smart sport training. *Applied Sciences*, 10(9), 3013.
- Razali, N., Mustapha, A., Utama, S., & Din, R. (2018). A review on football match outcome prediction using Bayesian networks. In *Journal of Physics: Conference Series*, 1020(1), 012004. IOP Publishing.
- Razali, N., Mustapha, A., Arbaiy, N., & Lin, P. C. (2022). Deep learning for football outcomes prediction based on football rating system. In *AIP conference proceedings* (Bd. 2644, No. 1). AIP Publishing.
- Reddy, C. K., & Aggarwal, C. C. (2020). *Healthcare data analytics*. Chapman and Hall/CRC.
- Reep, C., & Benjamin, B. (1968). Skill and chance in association football. *Journal of the Royal Statistical Society. Series A (General)*, 131(4), 581–585.

- Ribeiro, C. C., Urrutia, S., & de Werra, D. (2023). *Combinatorial models for scheduling sports tournaments*. Springer.
- Rico-González, M., Pino-Ortega, J., Méndez, A., Clemente, F., & Baca, A. (2023). Machine learning application in soccer: A systematic review. *Biology of Sport*, 40(1), 249–263.
- Romero, J. J. (2015). Baseball's player-tracking Statcast system debuts. <https://spectrum.ieee.org/baseballs-player-tracking-system-makes-broadcast-debut>. Zugegriffen am 08.12.2024.
- Rossi, A., Pappalardo, L., Cintia, P., Iaia, F. M., Fernández, J., & Medina, D. (2018). Effective injury forecasting in soccer with GPS training data and machine learning. *PLoS One*, 13(7), e0201264.
- Sackrowitz, H. (2004). Dynamic programming and time related strategies in sports: With an application to on-side kicks. In *Economics, Management and Optimization in Sports* (S. 31–41). Springer.
- Safari, M., Ghousi, R., Masumi, A. H., & Naeini, H. (2022). A review of sports data analytics field: A bibliometric and network analysis of the articles published from 1997 to 2020. *Journal of Industrial and Systems Engineering*, 14(2), 136–158.
- Sanchez, E., Weiss, L., Williams, T., Ward, P., Peterson, B., Wellman, A., & Crandall, J. (2023). Positional movement demands during NFL football games: A 3-year review. *Applied Sciences*, 13(16), 9278.
- Sato, K., & Aggarwal, J. K. (2005). Tracking soccer players using broadcast TV images. In *IEEE conference on advanced video and signal based surveillance* (S. 546–551). IEEE.
- Schaefer, D., Asteroth, A., & Ludwig, M. (2015). Training plan evolution based on training models. In *2015 international symposium on innovations in intelligent systems and applications (INISTA)* (S. 1–8). IEEE.
- Schelling, X., Fernández, J., Ward, P., Fernández, J., & Robertson, S. (2021). Decision support system applications for scheduling in professional team sport. The team's perspective. *Frontiers in Sports and Active Living*, 3, 678489.
- Schmidhuber, J. (2022). Annotated history of modern AI and deep learning. *arXiv preprint, arXiv:2212.11279*.
- Schwarz, A. (2004). *The numbers game: Baseball's lifelong fascination with statistics*. Macmillan.
- Seçkin, A. Ç., Ateş, B., & Seçkin, M. (2023). Review on wearable technology in sports: Concepts, challenges and opportunities. *Applied Sciences*, 13(18), 10399.
- Seshadri, D. R., Li, R. T., Voos, J. E., Rowbottom, J. R., Alfes, C. M., Zorman, C. A., & Drummond, C. K. (2019). Wearable sensors for monitoring the internal and external workload of the athlete. *NPJ Digital Medicine*, 2(1), 71.
- Severini, T. A. (2020). *Analytic methods in sports: Using mathematics and statistics to understand data from baseball, football, basketball, and other sports*. Chapman and Hall/CRC.
- Shaw, L., & Glickman, M. (2019). Dynamic analysis of team strategy in professional football. *Barça sports analytics summit*, 1–13.
- Shea, S. M. (2014). *Basketball analytics: Spatial tracking*. CreateSpace Independent Publishing Platform.
- Shea, S., & Baker, C. (2017). *Hockey analytics: A game-changing perspective*. Advanced Metrics.
- Shih, H. C. (2017). A survey of content-aware video analysis for sports. *IEEE Transactions on circuits and systems for video technology*, 28(5), 1212–1231.
- Siddiqui, H. U. R., Younas, F., Rustam, F., Flores, E. S., Ballester, J. B., Diez, I. D. L. T., et al. (2023). Enhancing cricket performance analysis with human pose estimation and machine learning. *Sensors*, 23(15), 6839.
- Sikka, R. S., Baer, M., Raja, A., Stuart, M., & Tompkins, M. (2019). Analytics in sports medicine: Implications and responsibilities that accompany the era of big data. *JBJS*, 101(3), 276–283.
- Smarmarkets. (2017). <https://help.smarkets.com/hc/en-gb/articles/115001457989-How-to-calculate-Poisson-distribution-for-football-betting>. Zugegriffen am 08.12.2024.
- Sokol, J. S. (2004). An intuitive Markov chain lesson from baseball. *INFORMS Transactions on Education*, 5(1), 47–55.
- Soltani, P., & Morice, A. H. (2020). Augmented reality tools for sports education and training. *Computers & Education*, 155, 103923.
- Stauff, M. (2018). A culture of competition: Sport's historical contribution to datafication. *Tijdschrift voor Mediageschiedenis*, 21(2), 30–51.
- Studnicka, A. (2020). The emergence of wearable technology and the legal implications for athletes, teams, leagues and other sports organizations across amateur and professional athletics. *DePaul Journal of Sports Law*, 16, i.
- Sumathi, M., Prabu, S., & Rajkamal, M. (2023). Cricket players performance prediction and evaluation using machine learning algorithms. In *2023 international conference on networking and communications (ICNWC)* (S. 1–6). IEEE.
- Sutton, R. S., & Barto, A. G. (1999). Reinforcement learning. *Journal of Cognitive Neuroscience*, 11(1), 126–134.
- Swain, D., Satapathy, S., Acharya, B., Shukla, M., Gergiannis, V. C., Kanavos, A., & Giakovis, D. (2022). Deep learning models for yoga pose monitoring. *Algorithms*, 15(11), 403.
- Takahashi, M., Ito, T., Okubo, H., & Mitsumine, H. (2019). Visualization of putting trajectories in live golf broadcasting. In *ACM SIGGRAPH 2019 talks* (S. 1–2). ACM.
- Taki, T., Hasegawa, J., & Fukumura, T. (1996). Development of motion analysis system for quantitative evaluation of teamwork in soccer games. In *Proceedings of 3rd IEEE international conference on image processing* (Bd. 3, S. 815–818). IEEE.
- Toffolo, T. A., Christiaens, J., Spieksma, F. C., & Vanden Bergh, G. (2019). The sport teams grouping problem. *Annals of Operations Research*, 275, 223–243.

- Tufte, E. R. (1983). *The visual display of quantitative information*. Graphics Press.
- UmaMaheswari, P., & Rajaram, M. (2009). A novel approach for mining association rules on sports data using principal component analysis: For cricket match perspective. In *2009 IEEE international advance computing conference* (S. 1074–1080). IEEE.
- Umami, I., Gautama, D. H., & Hatta, H. R. (2021). Implementing the Expected Goal (xG) model to predict scores in soccer matches. *International Journal of Informatics and Information Systems*, 4(1), 38–54.
- Vales-Alonso, J., López-Matencio, P., Alcaraz, J. J., Sieiro-Lomba, J. L., Costa-Montenegro, E., & González-Castaño, F. J. (2012). A dynamic programming approach for ambient intelligence platforms in running sports based on Markov decision processes. *Human – Computer Systems Interaction: Backgrounds and Applications*, 2: Part 1, 165–181.
- Vales-Alonso, J., González-Castaño, F. J., López-Matencio, P., & Gil-Castiñeira, F. (2023). A nonsupervised learning approach for automatic characterization of short-distance boxing training. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 53, 7038–7052.
- Valter, D. S., Adam, C., Barry, M., & Marco, C. (2006). Validation of Prozone[®]: A new video-based performance analysis system. *International Journal of Performance Analysis in Sport*, 6(1), 108–119.
- Van Der Aalst, W. (2011). *Process mining: Discovery, conformance and enhancement of business processes*. Springer Science & Business Media.
- Van Eetvelde, H., Mendonça, L. D., Ley, C., Seil, R., & Tischer, T. (2021). Machine learning methods in sport injury prediction and prevention: a systematic review. *Journal of Experimental Orthopaedics*, 8, 1–15.
- Vasudevan, V., & Gounder, M. S. (2023). A systematic review on machine learning-based sports video summarization techniques. In *Smart computer vision* (S. 1–34). Springer.
- Vinué, G., & Epifanio, I. (2019). Forecasting basketball players' performance using sparse functional data. *Statistical Analysis and Data Mining: The ASA Data Science Journal*, 12(6), 534–547.
- Vračar, P., Štrumbelj, E., & Kononenko, I. (2016). Modeling basketball play-by-play data. *Expert Systems with Applications*, 44, 58–66.
- Wakelam, E., Steuber, V., & Wakelam, J. (2022). The collection, analysis and exploitation of footballer attributes: A systematic review. *Journal of Sports Analytics*, 8(1), 31–67.
- Wallner, G., Wang, L., & Dormann, C. (2023). Visualizing the spatio-temporal evolution of gameplay using storyline visualization: A study with league of legends. *Proceedings of the ACM on Human-Computer Interaction*, 7(CHI PLAY), 1002–1024.
- Wang, J., Qiu, K., Peng, H., Fu, J., & Zhu, J. (2019). AI coach: Deep human pose estimation and analysis for personalized athletic training assistance. In *Proceedings of the 27th ACM international conference on multimedia* (S. 374–382). ACM.
- Whitmore, J. (2021). What is match momentum?. <https://theanalyst.com/eu/2021/11/what-is-match-momentum/>. Zugegriffen am 08.12.2024.
- Winston, W. L., Nestler, S., & Pelechris, K. (2022). *Mathletics: How gamblers, managers, and fans use mathematics in sports*. Princeton University Press.
- Wunderlich, F., & Memmert, D. (2021). Forecasting the outcomes of sports events: A review. *European Journal of Sport Science*, 21(7), 944–957.
- Ye, C., Zhu, R., Ma, J., Huang, H., Li, X., & Wen, J. (2024). Comprehensive tennis serve training system based on local attention-based CNN model. *IEEE Sensors Journal*, 24, 11917.
- Yeung, C., Bunker, R., Umamoto, R., & Fujii, K. (2023). Evaluating soccer match prediction models: A deep learning approach and feature optimization for gradient-boosted trees. *arXiv preprint, arXiv:2309.14807*.
- Young, C. M., Luo, W., Gastin, P., Tran, J., & Dwyer, D. B. (2019). The relationship between match performance indicators and outcome in Australian Football. *Journal of Science and Medicine in Sport*, 22(4), 467–471.
- Zhao, Z., Chai, W., Hao, S., Hu, W., Wang, G., Cao, S., et al. (2023). A survey of deep learning in sports applications: Perception, comprehension, and decision. *arXiv preprint, arXiv:2307.03353*.
- Zubillaga, A., Gorospe, G., Mendo, A. H., & Villaseñor, A. B. (2007). Match analysis of 2005–06 champions league final with Amisco system. *Journal of Sports Science and Medicine*, 6(10), 20.