

Daniel Memmert *Hrsg.*

Sportinformatik

Modellbildung, Simulation,
Datenanalyse und Visualisierung
von sportbezogenen Daten

FLASH-
CARDS
INSIDE

MOREMEDIA



Springer Spektrum

Sportinformatik

Ihr Bonus als Käufer dieses Buches

Als Käufer dieses Buches können Sie kostenlos unsere Flashcard-App „SN Flashcards“ mit Fragen zur Wissensüberprüfung und zum Lernen von Buchinhalten nutzen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den Link aus einem der ersten Kapitel um Zugang zu Ihrem SN Flashcards Set zu erhalten.



Ihr persönlicher SN Flashards Link befindet sich innerhalb der ersten Kapitel.

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „**SN Flashcards**“ und dem Buchtitel an customerservice@springernature.com.

Daniel Memmert
Hrsg.

Sportinformatik

Modellbildung, Simulation, Datenanalyse und Visualisierung
von sportbezogenen Daten



Springer Spektrum

Hrsg.
Daniel Memmert
Institut für Trainingswissenschaft
Deutsche Sporthochschule Köln
Köln, Deutschland

ISBN 978-3-662-67025-5 ISBN 978-3-662-67026-2 (eBook)
<https://doi.org/10.1007/978-3-662-67026-2>

Die Deutsche Nationalbibliothek verzeichnet diese Publikation in der Deutschen Nationalbibliografie; detaillierte bibliografische Daten sind im Internet über <http://dnb.d-nb.de> abrufbar.

© Der/die Herausgeber bzw. der/die Autor(en), exklusiv lizenziert an Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2023

Das Werk einschließlich aller seiner Teile ist urheberrechtlich geschützt. Jede Verwertung, die nicht ausdrücklich vom Urheberrechtsgesetz zugelassen ist, bedarf der vorherigen Zustimmung des Verlags. Das gilt insbesondere für Vervielfältigungen, Bearbeitungen, Mikroverfilmungen und die Einspeicherung und Verarbeitung in elektronischen Systemen.

Die Wiedergabe von allgemein beschreibenden Bezeichnungen, Marken, Unternehmensnamen etc. in diesem Werk bedeutet nicht, dass diese frei durch jedermann benutzt werden dürfen. Die Berechtigung zur Benutzung unterliegt, auch ohne gesonderten Hinweis hierzu, den Regeln des Markenrechts. Die Rechte des jeweiligen Zeicheninhabers sind zu beachten.

Der Verlag, die Autoren und die Herausgeber gehen davon aus, dass die Angaben und Informationen in diesem Werk zum Zeitpunkt der Veröffentlichung vollständig und korrekt sind. Weder der Verlag, noch die Autoren oder die Herausgeber übernehmen, ausdrücklich oder implizit, Gewähr für den Inhalt des Werkes, etwaige Fehler oder Äußerungen. Der Verlag bleibt im Hinblick auf geografische Zuordnungen und Gebietsbezeichnungen in veröffentlichten Karten und Institutionsadressen neutral.

Springer Spektrum ist ein Imprint der eingetragenen Gesellschaft Springer-Verlag GmbH, DE und ist ein Teil von Springer Nature.

Die Anschrift der Gesellschaft ist: Heidelberger Platz 3, 14197 Berlin, Germany

Dieses Lehrbuch „Sportinformatik“ ist dem unvergesslichen Jürgen Perl (1944–2023) gewidmet, meinem geschätzten Kollegen und Freund. Er war der Begründer und wegweisende Pionier der Sportinformatik, sowohl in Deutschland als auch international.

Vorwort

Als mich der Springer-Verlag anfragte, ob ich ein Lehrbuch „Sportinformatik“ schreiben wolle, war ich mir von Beginn an sehr sicher, dass ich dies nicht alleine leisten kann. In den letzten Jahren ist die Sportinformatik extrem gewachsen, vor allem weil immer mehr und neuere Daten vorhanden sind. Ein zentraler Baustein ist sicherlich der Bereich der Spielanalyse als leistungsdiagnostisches Verfahren, mit dem man im Wettkampf systematische Analysen betreiben kann, und dessen Entwicklung und Verbreitung seinen Ursprung bereits im letzten Jahrtausend nahm. Beginnend von nationalen bis hin zu internationalen sportwissenschaftlichen Kongressen werden zentrale Themen der Spielanalyse zurzeit auf der ganzen Welt diskutiert (Memmert, 2022).

Dieses Lehrbuch möchte der mittlerweile breiten Vielfalt der Sportinformatik gerecht werden, in dem 34 Autorinnen und Autoren aus ihrem Spezialgebiet berichten und neuste Erkenntnisse prägnant zusammenfassen. Das Lehrbuch gliedert sich in vier Hauptkapitel: Datensätze, Modellbildung, Simulation sowie Datenanalyse. Neben Hintergründen zu Programmiersprachen und Visualisierung wird es von der Historie und einem Ausblick eingerahmt. Am Herzen liegt mir, dass das Lehrbuch innerhalb der jeweiligen Kapitel einen einheitlichen Aufbau verfolgt. Deshalb bin ich sehr dankbar, dass alle Kolleginnen und Kollegen für ihre Kapitel die folgende Struktur benutzt haben, was es den Studierenden hoffentlich leicht macht, sich in den Kapiteln zielgerichtet zu orientieren. Nach den vier Kernbotschaften wird jedes Kapitel mit einem Beispiel aus dem Sport eingeleitet. Im Anschluss wird der Hintergrund der Thematik zusammen mit einer Definition beschrieben. Final erfolgt die Skizzierung relevanter Anwendungen bzw. Einsatzbereiche, welche von der detaillierten Darstellung einer prominenten Studie, die grundlegend für diesen Bereich ist, in einer Studienbox abgeschlossen werden. Vor dem umfassenden Literaturverzeichnis werden noch zusätzlich Fragen für die Studierenden zu dem Inhalt des Kapitels angeboten. Das ausführliche Index-Wörter-Verzeichnis wird hoffentlich das Verständnis und die Durchdringung der teilweise komplexen Thematiken noch deutlich unterstützen.

Ich denke, dass die Sportinformatik in der deutschen Sportwissenschaft eindrucksvoll gezeigt hat, dass sie in den letzten Jahren den Anschluss an die Mutterwissenschaft Informatik erfolgreich geschafft hat. Dies verdeutlicht beispielhaft ein Blick auf die von deutschen Sportwissenschaftlerinnen und Sportwissenschaftlern eingeworbenen Drittmittel bei der Deutschen Forschungsgemeinschaft (DFG) im Fachkollegium Informatik (vgl. Anhang). Deren Darstellung erhebt natürlich keinen Anspruch auf Vollständigkeit und teilweise werden auch der, der Sportinformatik nahestehenden, Sporttechnologie Projekte thematisch zugeordnet. Gemein ist ihnen aber, dass Wissenschaftlerinnen und Wissenschaftler aus dem Bereich Sportinformatik und/oder Sporttechnologie kompetitiv Projekte aus „Informatik-Töpfen“ der DFG erhalten haben, bei denen die Richtlinien und Maßstäbe der Informatik zur Anwendung kommen.

Ein Lehrbuch zu gestalten setzt eine gute Mischung aus intrinsisch motivierter und teilweise auch harter Arbeit voraus, die eine Vielzahl an Personen exzellent ge-

leistet hat. Bei diesen Personen möchte ich mich an dieser Stelle herzlich bedanken. Allen voran danken wir den Autorinnen und Autoren der Buchkapitel für ihre Bereitschaft, ihre Expertise für unser Lehrbuch einzusetzen, für ihr Mitwirken in unserem internen Peer-Review-Verfahren und für ihren ständigen Optimierungswillen. Besten Dank für die stets gute und freundliche Zusammenarbeit.

Ich danke ebenfalls Frau Erika Graf für das stets wachsame Begleiten des Buches, ihren vielen Anmerkungen und Ratschlägen. Zudem unseren studentischen Mitarbeiterinnen Klara Rinne, Tara Coulson, und David Brinkjans für das Einnehmen einer kritischen studentischen Perspektive, für ihre konstruktiven Rückmeldungen an die Autorenschaft und für zahlreiche Zusarbeiten zum Glätten von Ecken und Kanten.

Schließlich gilt mein großer Dank der stetigen, sehr freundlichen und immer extrem kompetenten Begleitung unseres Buchprojektes durch die Mitarbeitenden des Springer-Verlags. Zuallererst ist hier Ken Kissinger (Programmplanung) zu erwähnen, der viel Zeit, Engagement und Energie in das Buch gesteckt hat. Dies ist nicht selbstverständlich, auch seine Geschwindigkeit im Prozess! Ohne seine Expertise wäre es so nicht zustande gekommen und dafür bedanke ich mich herzlichst. Beim Mitwirken auf Seiten des Springer-Verlags ist weiterhin Anja Herzer (Projektmanagement) zu erwähnen, die das Buchprojekt sehr erfolgreich bis zur Produktionsübergabe begleitet hat, vielen Dank dafür. Zudem möchte ich allen weiteren Beteiligten aus der Produktion (Copy-Edtiting, Satz) für die professionelle Zusammenarbeit während des Herstellungsprozesses danken.

Ich wünsche Ihnen viel Freude und einen großen Erkenntnisgewinn beim Lesen

Daniel Memmert

Köln, Deutschland

Anhang

Von deutschen Sportwissenschaftlerinnen und Sportwissenschaftler kompetitiv eingeworbene Drittmittel der Deutschen Forschungsgemeinschaft (DFG) im Fachkollegium Informatik

Antragsteller:	Titel:	Förderdauer:	Link:
Daniel Memmert	Implementierung der floodlight e-Research Technologie für die Analyse von raum-zeitlichen Bewegungsdaten in der Sportwissenschaft	2023–2026	► https://www.dshs-koeln.de/aktuelles/meldungen-pressemitteilungen/detail/meldung/sportspieldaten-effektiv-nutzbar-machen/
Kerstin Witte	Visuelle periphere Wahrnehmung in der virtuellen Realität	2023–2025	► https://gepris.dfg.de/gepris/projekt/404484468
Daniel Memmert	Datenbasierte Ansätze zur Analyse von Fußballspielen aus der e-science Perspektive	seit 2020	► https://gepris.dfg.de/gepris/projekt/432920202?context=projekt&task=show-Detail&id=432920202&
Daniel Memmert	Ein theoretisches Simulations-Framework zur Analyse von prädiktiven Ratingverfahren auf Netzwerken mit Anwendungsbezug im Sport	2019–2022	► https://gepris.dfg.de/gepris/projekt/432919559?context=projekt&task=show-Detail&id=432919559&
Kerstin Witte	Training in VR unter besonderer Berücksichtigung der visuellen Wahrnehmung und des Vergleiches zur Realität	2018–2022	► https://gepris.dfg.de/gepris/projekt/404484468
Daniel Memmert	Simulation interaktiver Handlungssequenzen am Beispiel des Hochleistungs-Fußballs	2018–2024	► DFG – GEPRIS – Simulation interaktiver Handlungssequenzen am Beispiel des Hochleistungs-Fußballs
Dietmar Saupe	Powerbike – Modellbasierte Optimierung für Rennradfahren	2013–2018	► https://gepris.dfg.de/gepris/projekt/432919559?context=projekt&task=show-Detail&id=432919559&

Antragsteller:	Titel:	Förderdauer:	Link:
Kerstin Witte G. Brunnett	Entwicklung eines autonom interagierenden Gegners in einer Virtual Reality-Umgebung zur Untersuchung der Antizipationsfähigkeit in den Kampfsportarten	2014–2016	► https://gepris.dfg.de/gepris/projekt/252070407
Daniel Memmert Jürgen Perl	Simulation von Interaktionsmustern und simulative Wirksamkeitsanalyse kreativer Handlungen im Sportspiel mittels Neuronaler Netze	2008–2018	► DFG – GEPRIS – Simulation von Interaktionsmustern und simulative Wirksamkeitsanalyse kreativer Handlungen im Sportspiel mittels Neuronaler Netze

Inhaltsverzeichnis

I Historie

1	Historie	3
	<i>Martin Lames</i>	
1.1	Einleitung	4
1.2	Die institutionelle Konstituierung der Sportinformatik	4
	Literatur	8

II Datensätze

2	Künstliche Daten	13
	<i>Fabian Wunderlich</i>	
2.1	Beispiel Sport	14
2.2	Hintergrund	14
2.2.1	Die Limits von echten Daten	14
2.2.2	Die Idee von künstlichen Daten	15
2.2.3	Zufallszahlen und Monte-Carlo-Simulation	16
2.2.4	Vorteile und Nachteile von künstlichen Datensätzen	16
2.3	Anwendungen	17
	Literatur	19
3	Reale Datensätze – Textdaten	23
	<i>Otto Kolbinger</i>	
3.1	Einleitung	24
3.2	Anwendungen	25
3.2.1	Evaluation von Technological Officiating Aids	25
3.2.2	Spielvorhersagen	26
3.2.3	Talentscouting.....	27
	Literatur	28
4	Reale Datensätze – Videodaten	31
	<i>Eric Müller-Budack, Wolfgang Gritz und Ralph Ewerth</i>	
4.1	Beispiel Sport	32
4.2	Hintergrund	33
4.3	Grundlagen und Definition	34
4.4	Anwendungen	34
	Literatur	37

5	Reale Datensätze – Eventdaten	39
	<i>Marc Garnica Caparrós</i>	
5.1	Beispiel Sport	40
5.2	Hintergrund	41
5.3	Anwendung	42
	Literatur	45
6	Reale Datensätze – Positionsdaten	47
	<i>Daniel Memmert</i>	
6.1	Beispiel Sport	48
6.2	Hintergrund	48
6.3	Anwendungen	49
	Literatur	52
7	Reale Datensätze Onlinedaten	55
	<i>Christoph Breuer</i>	
7.1	Beispiel Sport	56
7.2	Hintergrund	56
7.3	Anwendungen	58
	Literatur	61
 III Modellbildung		
8	Modellbildung	65
	<i>Jürgen Perl und Daniel Memmert</i>	
8.1	Beispiel Sport	66
8.2	Hintergrund	67
8.3	Anwendungen	69
	Literatur	72
9	Prädiktive Modelle	73
	<i>Fabian Wunderlich</i>	
9.1	Beispiel Sport	74
9.2	Hintergrund	74
9.2.1	Der Blick in die Zukunft.....	74
9.2.2	Der Sport als Anwendungsfeld für prädiktive Modelle.....	75
9.2.3	Erstellung von prädiktiven Modellen und methodische Beispiele	75
9.3	Anwendungen	77
	Literatur	79

10	Physiologische Modellierung	83
	<i>Manuel Bassek</i>	
10.1	Beispiel Sport	84
10.2	Hintergrund	84
10.3	Anwendungen	85
	Literatur	88
IV	Simulation	
11	Simulation	93
	<i>Jürgen Perl und Daniel Memmert</i>	
11.1	Beispiel Sport	94
11.2	Hintergrund	94
11.3	Anwendungen	98
	Literatur	101
12	Metabolische Simulation	103
	<i>Dietmar Saupe</i>	
12.1	Beispiel Sport	104
12.2	Hintergrund	105
12.3	Anwendungen	106
	Literatur	111
13	Simulation physiologischer Anpassungsprozesse	113
	<i>Mark Pfeiffer und Stefan Endler</i>	
13.1	Beispiel Sport	114
13.2	Hintergrund	115
13.3	Anwendungen	117
	Literatur	120
V	Programmiersprachen	
14	Eine Einführung in die Programmiersprache R für Einsteiger	125
	<i>Robert Rein</i>	
14.1	Geschichte und Philosophie	126
14.2	Konzeption und Programmierparadigmen	127
14.3	Ressourcen zu R	128
14.4	R Community und Pakete	128
14.5	Einstieg in den Umgang mit R	129
14.6	Ein Beispielworkflow in R	132
14.7	Literate Programming	137
	Literatur	141

15	Python	143
	<i>Maximilian Klemp</i>	
15.1	Beispiel Sport	144
15.2	Hintergrund	145
15.3	Anwendungen	147
	Literatur	149

VI Datenanalyse

16	Logistische Regression	153
	<i>Ashwin Phatak</i>	
16.1	Beispiel	154
16.2	Hintergrund	154
16.3	Anwendung	156
	Literatur	158
17	Zeitreihen Data Mining	159
	<i>Rumena Komitova und Daniel Memmert</i>	
17.1	Beispiel Sport	160
17.2	Hintergrund	160
17.3	Anwendungen	162
17.3.1	Data-Mining-Algorithmen	162
17.3.2	Data Mining von Zeitreihen in der Medizin	163
17.3.3	Data Mining im Sport	163
	Literatur	166
18	Process Mining	169
	<i>Marc Garnica Caparrós</i>	
18.1	Beispiel Sport	170
18.2	Hintergrund	171
18.3	Anwendungen	173
18.3.1	Process Mining im Gesundheitswesen.....	173
18.3.2	Process Mining in der Bildung.....	174
18.3.3	Process Mining im Fußball	174
	Literatur	175
19	Zentralität von Netzwerken	177
	<i>João Paulo Ramos, Rui Jorge Lopes, Duarte Araújo und Pedro Passos</i>	
19.1	Eine Netzwerkwissenschaft im Fußball	178
19.2	Hintergrund	178
19.3	Anwendungen	183
	Literatur	186

20	Künstliche neuronale Netze	189
	<i>Markus Tilp</i>	
20.1	Beispiel Sport	190
20.2	Hintergrund	191
20.3	Anwendungen	192
	Literatur	197
21	Tiefe neuronale Netzwerke	199
	<i>Dominik Raabe</i>	
21.1	Beispiel Sport	200
21.2	Hintergrund	201
21.3	Anwendungen	202
	Literatur	206
22	Convolutional Neural Networks	207
	<i>Yannick Rudolph und Ulf Brefeld</i>	
22.1	Beispiel Sport	208
22.2	Hintergrund	209
22.3	Anwendungen	211
	Literatur	214
23	Transfer Learning	217
	<i>Henrik Biermann</i>	
23.1	Beispiel Sport	218
23.2	Hintergrund	219
23.3	Anwendungen	220
	Literatur	224
24	Random Forest	227
	<i>Justus Schlenger</i>	
24.1	Beispiel Sport	228
24.2	Hintergrund	229
24.3	Anwendungen	230
	Literatur	233
25	Statistisches Lernen	235
	<i>Gunther Schauberger und Andreas Groll</i>	
25.1	Beispiel Sport	236
25.2	Hintergrund	236
25.3	Anwendungen	238
	Literatur	241

26	Open-set Recognition	243
	<i>Ricardo da Silva Torres und Daniel Memmert</i>	
26.1	Beispiel Sport	244
26.2	Hintergrund	244
26.3	Anwendungen	246
	Literatur	247

VII Visualisierung

27	Visualisierung-Grundlagen und Konzepte	251
	<i>Daniel Link</i>	
27.1	Beispiel Sport	252
27.2	Hintergrund	252
27.3	Anwendungen	253
	Literatur	257

VIII Ausblick

28	Ausblick	261
	<i>Arnold Baca</i>	
28.1	Tendenzen	262
28.2	Sensoren	262
28.3	Wearables und intelligente Systeme	263
28.4	Big Data & Cloud	264
28.5	Machine Learning & Computer Vision	265
28.6	Virtuelle und augmentierte Realität & Robotik	265
28.7	Datenschutz und Datenmissbrauch	266
	Literatur	267

Serviceteil

Anhang	271
Stichwortverzeichnis	273

Herausgeber- und Autorenverzeichnis

Herausgeber

Prof. Dr. Daniel Memmert Deutsche Sporthochschule Köln, Institut für Trainingswissenschaft, Köln, Deutschland

Autorenverzeichnis

Duarte Araújo Faculdade de Motricidade Humana, Cruz Quebrada-Dafundo, Portugal

Univ.-Prof. Dr. Arnold Baca Leiter des Zentrums für Sportwissenschaft und Universitäts-sport, Universität Wien, Wien, Österreich

Manuel Bassek Institut für Trainingswissenschaft und Sportinformatik, Deutsche Sporthochschule Köln, Köln, Deutschland

Henrik Biermann Bochum, Deutschland

Ulf Brefeld Machine Learning Group / IIS, Universitätsallee 1, Leuphana Universität Lüneburg, Lüneburg, Deutschland

Prof. Dr. Christoph Breuer Deutsche Sporthochschule Köln, Institut für Sportökonomie und Sportmanagement, Köln, Deutschland

Marc Garnica Caparrós Deutsche Sporthochschule Köln, Institut für Trainingswissenschaft und Sportinformatik, Köln, Deutschland

Dr. Stefan Endler Institut für Informatik, Mainz, Deutschland

Prof. Dr. Ralph Ewerth Technische Informationsbibliothek (TIB), Hannover, Deutschland

Wolfgang Gritz Universität Hannover, Hannover, Deutschland

Prof. Dr. Andreas Groll Statistical Methods for Big Data, Fakultät Statistik, Technische Universität Dortmund, Dortmund, Deutschland

Maximilian Klemp Institut für Trainingswissenschaft und Sportinformatik, Deutsche Sporthochschule Köln, Köln, Deutschland

Dr. Otto Kolbinger Schliersee, Deutschland

Rumena Komitova Institut für Trainingswissenschaft und Sportinformatik, Deutsche Sporthochschule Köln, Köln, Deutschland

Univ.-Prof. Dr. Martin Lames Fakultät für Sport- und Gesundheitswissenschaften, Technische Universität München, München, Deutschland

Dr. Daniel Link Dortmund, Deutschland

Rui Jorge Lopes Iscte, Lissabon, Portugal

Eric Müller-Budack Universität Hannover, Hannover, Deutschland

A/C Professor Pedro Passos Faculdade de Motricidade Humana, Cruz Quebrada-Dafundo, Portugal

Jürgen Perl Mainz, Deutschland

Univ.-Prof. Dr. Marc Pfeiffer Mainz, Deutschland

Ashwin Phatak Institut für Trainingswissenschaft und Sportinformatik, Deutsche Sporthochschule Köln, Köln, Deutschland

Dominik Raabe Institut für Trainingswissenschaft und Sportinformatik, Deutsche Sporthochschule Köln, Köln, Deutschland

João Paulo Ramos São Domingos de Rana, Portugal

Robert Rein Institut für Trainingswissenschaft und Sportinformatik, Deutsche Sporthochschule Köln, Köln, Deutschland

Yannick Rudolph Hamburg, Deutschland

Prof. Dr. Dietmar Saupe Konstanz, Deutschland

Gunther Schauburger Lehrstuhl für Epidemiologie, Fakultät für Sport- und Gesundheitswissenschaften, TU München, München, Deutschland

Justus Schlenger Dortmund, Deutschland

Univ. Prof. Dr. Markus Tilp Institute of Human Movement Science, Sport and Health, University of Graz, Graz, Österreich

Ricardo Torres Wageningen, Niederlande

Dr. Fabian Wunderlich Institut für Trainingswissenschaft und Sportinformatik, Deutsche Sporthochschule Köln, Köln, Deutschland

Historie

Inhaltsverzeichnis

Kapitel 1	Historie – 3
	<i>Martin Lames</i>



Historie

Martin Lames

Inhaltsverzeichnis

- 1.1 **Einleitung – 4**
- 1.2 **Die institutionelle Konstituierung
der Sportinformatik – 4**
- Literatur – 8**

1

Kernbotschaften

- Wenn auch im Vergleich zu anderen Bindestrich-Informatiken recht spät, so kann doch die Sportinformatik stetige Fortschritte auf dem Weg zu einer Institutionalisierung als wissenschaftliche Disziplin vorweisen.
- Als Etappen dieses Weges sind freie Arbeitsgruppen, die dvs-Sektion Sportinformatik, die IACSS und schließlich eine organisierte bidirektionale Zusammenarbeit im Sinne der Sportinformatik-Definition von Link und Lames zu nennen.
- Die Zukunft der Disziplin hängt davon ab, ob es gelingen wird, Win-win-Kooperationen zu generieren, auf deren Basis nachhaltig interdisziplinäre Projekte realisiert werden können.

1.1 Einleitung

Möchte man die Entwicklung der Sportinformatik als wissenschaftliche Disziplin nachzeichnen, ist man gut beraten, sich zunächst ihres Gegenstands zu versichern. Eine allgemeine Definition geht auf Link und Lames (2009) zurück:

Definition

Unter der wissenschaftlichen Disziplin „Sportinformatik“ sind multi- und interdisziplinäre Forschungsprogramme zu verstehen, die sportwissenschaftliche und informatische Anteile enthalten. Ihr Gegenstand sind die Anwendung von Werkzeugen, Methoden und Paradigmen aus der Informatik auf Fragestellungen der Sportwissenschaft sowie die Integration sportwissenschaftlicher Erkenntnisse in die Informatik.

1.2 Die institutionelle Konstituierung der Sportinformatik

Die institutionelle Konstituierung der Sportinformatik¹ als wissenschaftliche Disziplin kann man in vier Phasen unterteilen: (1) die prä-institutionelle Phase, (2) die Phase der dvs-Sektion Sportinformatik, (3) die Phase der International Association for Computer Science in Sport und (4) die institutionelle Integration informatischer Arbeitsgruppen.

(1) Die prä-institutionelle Phase (vor 1995)

1 Die hier vorgeschlagenen Phasen der institutionellen Konstituierung der Sportinformatik sind keineswegs mit dem Bestehen und der Bedeutung der einzelnen Institutionen, die als namensbildend genannt werden, identisch, sondern stellen hier vielmehr bedeutsame Etappen auf dem Weg der Institutionalisierung der Sportinformatik dar.

Charakteristisch für die Informatik ist seit ihren Ursprüngen, die mit dem Aufkommen elektronischer Rechenmaschinen Mitte des letzten Jahrhunderts gleichzusetzen sind, dass neben den informatischen Kernbereichen der theoretischen und technischen Informatik auch die Anwendung dieser neuen Methoden verständlicherweise sofort eine ganze Reihe wissenschaftlicher Aktivitäten auslöste. Dabei muss man differenzieren zwischen der Angewandten Informatik, die sich innerhalb der Informatik etablierte, und den sogenannten „Bindestrich-Informatiken“, die (nicht immer zur Freude der „Kerninformatiker“) in der jeweils anwendenden Wissenschaft beheimatet sind, wie z. B. die Medizin-Informatik oder die Wirtschafts-Informatik.

Diese Institutionalisierungen, die teilweise „echte“ interdisziplinäre Wissenschaften hervorbrachten, also solche, die „inter“, also zwischen den beiden Ursprungswissenschaften stehen (Willimczik, 1985; Heckhausen, 1986), ließen in der Sportwissenschaft aber noch lange auf sich warten. Bis 1995 gab es „nur“ eine inhaltliche Zusammenarbeit in Forschungsprogrammen mit informatischen und sportwissenschaftlichen Anteilen, aber davon durchaus eine ganze Reihe, da die Beitragsfähigkeit der Informatik zu Fragestellungen der Sportwissenschaft – wie in vielen anderen Bereichen – unmittelbar gegeben ist.

Etwas kurios mutet daher die Tatsache an, dass der Terminus „Sportinformatik“ bereits sehr früh geprägt wurde: 1976 erschien unter dem Titel *Kreative Sportinformatik* ein Kongressband, herausgegeben von Recla und Timmer, der über eine Tagung der „International Association for Sports Information (IASI)“ 1975 in Graz berichtete. Hier waren im Wesentlichen die Fähigkeiten informatischer Werkzeuge von Interesse, Informationen aus dem Sport wie z. B. Informationen über Olympiateilnehmer, die 1972 in München zum ersten Mal der Presse online zur Verfügung gestellt wurden, zu erfassen, zu speichern und flexibel abrufbar zu machen.

Sehr frühe Anwendungen der Informatik im Sport waren die computer-gestützten Spielbeobachtungssysteme der Sportpädagogen (sic!) Hagedorn (Hagedorn, Ehrich & Schmidt, 1980) im Basketball und Brettschneider (Allendorf & Brettschneider, 1976) im Volleyball. Hier wurden konzeptionell und technologisch hochwertige Arbeiten vorgelegt, die im englischsprachigen Raum leider nicht wahrgenommen wurden. Interessant sind auch die Arbeiten von Gruppen von Informatikern, die entweder nach Anwendungsfeldern im Sport gesucht haben, z. B. die Diplomarbeit der späteren Leibniz-Preisträgerin Elisabeth André über die automatische Annotation im Fußball (André, Herzog & Rist, 1988), oder Informatiker, die aus ihrer Begeisterung für den Sport heraus Computeranwendungen schaffen, z. B. das TOTO-System von Bolch und Cerny (1990), das auf dem Elo-System im Schach basiert.

Die Arbeit von Jürgen Perl sollte für die Entwicklung der Disziplin von entscheidender Bedeutung werden. Zusammen mit seinen Paderborner Kollegen Wolf Miethling und Günter Hagedorn hatte Perl bereits zahlreiche Beiträge zur Sportinformatik geleistet (Miethling & Perl, 1981; Hagedorn, Lorenz & Meseck, 1980). An der Universität Mainz legte er ab 1985 einen wissenschaftlichen Schwerpunkt auf die Sportinformatik. Wesentliche Beiträge der Mainzer Gruppe waren Wettkampfbeobachtungssysteme in verschiedenen Sportarten, die jeweils auf dem neu-

1

ersten Stand der Informationstechnologie waren. Wichtig auf dem Weg zur Institutionalisierung der Sportinformatik war eine Workshopreihe „Sport & Informatik“, die ab 1989 regelmäßig stattfand.

(2) Die Phase der dvs-Sektion Sportinformatik (1995–2003)

Die Deutsche Vereinigung für Sportwissenschaft (dvs) ist die Wissenschaftsorganisation für die akademische deutsche Sportwissenschaft. Sie ist organisiert in Sektionen, die den sportwissenschaftlichen Disziplinen wie Sportpädagogik oder Trainingswissenschaft entsprechen, und Kommissionen, die querschnittlich Themen von überdauerndem wissenschaftlichem Interesse abbilden, wie z. B. sportwissenschaftliche Beiträge zu einzelnen Sportarten. Damit lag die Idee nahe, die Sportinformatik als Sektion im Rahmen der dvs zu institutionalisieren.

Dieses Anliegen zu erreichen war aber keinesfalls ein trivialer Akt, da innerhalb der dvs Befürchtungen bestanden, die Organisation durch die Gründung vieler Untereinheiten zu überdehnen, was darüber hinaus noch der bis dahin überaus einflussreichen Position der „Integrativen Sportwissenschaft“ von Grupe (Krüger, 2015) entsprach. Weiter sahen einige Gruppen, wie z. B. die Arbeitsgruppe „Medien im Sport“, ihren inhaltlichen Vertretungsanspruch durch eine Sektion Sportinformatik bedroht.

Neben zahlreichen Gesprächen mit Funktionsträgern der dvs und fachlich affinen Kollegen sowie natürlich dem Verweis auf eine existierende, durchaus auch interdisziplinäre Community, die sich auf den regelmäßigen Workshops manifestiert hatte, wurde ein Artikel in der Zeitschrift *Leistungssport* platziert, in dem das Fachgebiet der deutschen Öffentlichkeit unter dem Titel „Sportinformatik: Gegenstandsbereich und Perspektiven einer sportwissenschaftlichen Teildisziplin“ vorgestellt wurde (Perl & Lames, 1995). Dort wurde das Potenzial der Sportinformatik für die Sportwissenschaft erläutert, insbesondere mit Hinweisen auf ihre Anschlussfähigkeit zu Themen anderer Sektionen und ihre Beitragsfähigkeit zur Unterstützung des Spitzensports.

Seit der Zustimmung der Hauptversammlung auf dem dvs-Hochschultag 1995 in Frankfurt zur Sektionsgründung firmierte der „Workshop Sport & Informatik“ nun als Tagung der dvs-Sektion Sportinformatik. Die Sektion behauptet sich erfolgreich am Markt der Wissenschaftsorganisationen und organisiert mit den Sprechern Perl (1996–2002), Wiemeyer (2002–2012, Lames (2012–2018) und Link (ab 2018) in geraden Jahren ihre Sektionskonferenzen an den unterschiedlichen Zentren der Disziplin in Deutschland (2014: Wien). Die Tagung 2018 in München wurde zum ersten Mal als Sektion „Sportinformatik und Sporttechnologie“ durchgeführt, womit der entsprechenden Entwicklung in den beiden Wissenschaften zukunftsichernd Rechnung getragen wurde.

(3) Die Phase der IACSS (2003–2019)

Für Jürgen Perl war wohl sehr früh klar, dass die Institutionalisierung der Sportinformatik nicht bei einer nationalen sportwissenschaftlichen Sektion stehen bleiben durfte, sondern auch das internationale Parkett zu „bespielen“ war. Strategisch wurde der gleiche Weg verfolgt wie auf der nationalen Ebene. Erste internationale Kongresse in Köln (1997), Wien (1999) und Cardiff (2001) sammelten

eine kritische Masse auch internationaler Wissenschaftler, die es dann erlaubte, auf der Tagung in Barcelona (2003) die IACSS (International Association of Computer Science in Sport) aus der Taufe zu heben.

In der Folge war das Bestreben, die IACSS nicht auf Europa zu beschränken, was dem Anspruch an eine internationale Wissenschaftsorganisation nicht entsprochen hätte. Tagungen in Kanada, China, Australien und Brasilien zeugen vom Erfolg dieser Bemühungen. Die Einsetzung nationaler Vereinigungen für Sportinformatik, als deren Dachverband sich die IACSS verstehen wollte, war allerdings nur in wenigen Ländern (z. B. Deutschland, Österreich, Türkei, Russland, China) erfolgreich. Hauptsächlich wohl, weil Initiativen zur Gründung einer nationalen Vereinigung, wenn sie im Wesentlichen nur auf die Initiative einzelner Forscherpersönlichkeiten zurückgehen, sich nicht als nachhaltig erwiesen. Durch die Anerkennung der IACSS als Mitglied in der ICSSPE (International Council for Sport Science and Physical Education), der Dachorganisation für sportwissenschaftliche Vereinigungen, wurde ein wichtiger Schritt zur institutionellen Konsolidierung unternommen.

Schon sehr früh wurde unter der Redaktion von Arnold Baca (ab 2002) eine Fachzeitschrift eingerichtet, die IJCSS (International Journal of Computer Science in Sport), was als weiteres wichtiges Merkmal für den Institutionalisierungsgrad einer Wissenschaft angesehen werden kann. Die Zeitschrift wird seit 2016 als Open Access Journal zusammen mit dem DeGruyter Verlag herausgegeben.

Den jeweiligen IACSS-Präsidenten Perl (2003–2007), Baca (2007–2013), Lames (2013–2022) und Zhang (ab 2022) ist es gelungen, eine weltweit anerkannte und tätige Organisation mit regelmäßigen Tagungs- und Publikationsaktivitäten zu etablieren.

(4) Die Phase der institutionellen Integration informatischer Arbeitsgruppen (ab 2019)

Auf der IACSS-Vollversammlung in Moskau 2019 wurde beschlossen, dass sich die IACSS stärker in Richtung Informatik bewegen und dort existierende Arbeitsgruppen, die sich mit dem Thema Sport befassen, integrieren solle. Erfolgreich in diese Richtung waren bisher Kontakte zur MLSA-Gruppe (Machine Learning in Sports Analytics) um Jesse Davis, Jan van Haaren, Albrecht Zimmermann und Ulf Brefeld. Diese richtet seit 2013 entweder eigene Workshops oder Satelliten-Workshops bei großen Informatik-Konferenzen aus, zuletzt 2022 in Grenoble, davor wurde 2021 ein virtueller Workshop ausgerichtet und – genau wie die sieben Workshops davor – in Proceedings dokumentiert (Brefeld et al., 2022). Eine Zusammenarbeit mit weiteren, vergleichbaren Gruppen, etwa aus dem Bereich Computer Vision, steht noch aus.

Ein wichtiges Instrument zur Integration von Informatikern und Sportwissenschaftlern sind Seminare in Schloss Dagstuhl, einer internationalen Tagungsstätte der Informatik. Von den bisher fünf Seminaren zu sportwissenschaftlichen Themen, die unter Beteiligung der IACSS ausgerichtet wurden, fand das bisher letzte im Oktober 2021 gemeinsam mit der MLSA zum Thema „Machine Learning in Sports“ statt (Organisatoren: Brefeld, Davis, Lames, Little). In Zukunft ist der Besuch der gegenseitigen Tagungen erforderlich, und im Idealfall gelingt es, Projekt-

1

gruppen einzurichten, die Sportwissenschaft und Informatik auch personell in ihren Reihen abbilden.

Eine institutionelle Einbindung ist umso wichtiger, als die Integration zweier Disziplinen nicht naiv betrachtet werden darf. So verlassen sich Sportwissenschaftler oft unkritisch auf die Antworten der Informatik, ohne deren methodische Grundannahmen hinterfragen zu können. Andererseits nutzen Informatiker die mittlerweile gute Datenlage im attraktiven Anwendungsfeld Sport (Profifußball) oft nur als Showcase für ihre originären grundlagenwissenschaftlichen Fragestellungen. Diese Probleme könnten mit einer geeignet ausgestalteten institutionalisierten Zusammenarbeit zumindest verringert werden und so dem enormen Potenzial der Sportinformatik Entfaltungsmöglichkeiten bieten.

? Fragen für die Studierenden

Wie stellt sich die Entwicklung der Sportinformatik dar im Vergleich zu denjenigen anderer sportwissenschaftlicher Disziplinen?

Warum ist es wichtig, dass Projektgruppen in der Sportinformatik interdisziplinär besetzt sind und welche Rolle spielen dabei Wissenschaftsorganisationen?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springer-nature.com.

Literatur

- Allendorf, O. & Brettschneider, W.-D. (1976). Leistungsdatenerfassung und -auswertung im Sportspiel mit Hilfe des computergesteuerten optischen Lesestifts. In R. Andresen & G. Hagedorn (Hrsg.), *Zur Sportspielforschung* (Band 1: Theorie und Praxis der Sportspiele; S. 106–116). Bartels & Wernitz.
- André, E., Herzog, G. & Rist, Th. (1988). On the Simultaneous Interpretation of Real World Image Sequences and their Natural Language Description: The System SOCCER. Proceedings of the Eighth Conference on Artificial Intelligence, Munich, August 1–5, 1988. 449–454.
- Bolch, G. & Cerny, M. (1990). TOTO: Ein Programmsystem zur Analyse und Prognose der Ergebnisse von Mannschaftsspielen mit Hilfe eines IBM PC. In J. Perl (Hrsg.), *Sport und Informatik. 1. Workshop Sport & Informatik, Hochheim, 26.–27.4.89* (S. 25–35). Hofmann.

- Brefeld, U., Davis, J., Van Haaren, J. & Zimmermann, A. (Eds.). (2022). *Machine Learning and Data Mining for Sports Analytics – 8th International Workshop MLSA 2021, Virtual Event, September 13, 2021* (Springer Conference Proceedings, Communications in Computer and Information Science, Vol. 1571). Springer.
- Hagedorn, G., Ehrich, D. & Schmidt, G. (1980). Computerunterstützte Spielanalyse im Basketball. *Leistungssport*, 10 (5), 363–372.
- Hagedorn, G., Lorenz, H. & Meseck, U. (1980). Die Verteilung spieltypischer Aktivitäten im Basketball. *Leistungssport*, 11 (6), 442–449.
- Heckhausen, H. (1986). Interdisziplinäre Forschung zwischen Intra-, Multi- und Chimären-Disziplinarität. In Zentrum für interdisziplinäre Forschung der Universität Bielefeld (ZIF) (Hrsg.), *Jahresbericht 1985/86* (S. 29–40). ZIF.
- Krüger, M. (2015). Ommo Grupe und seine Vision des Sports. *Sportwissenschaft*, 45, 55–56.
- Link, D. & Lames, M. (2009). Matrix Reloaded - Struktur und Gegenstand der Sportinformatik. In M. Lames, C. Augste, O. Cordes, Ch. Dreckmann, K. Görsdorf & M. Siegle (Hrsg.), *Gegenstand und Anwendungsfelder der Sportinformatik. 7. Symposium der dvs-Sektion Sportinformatik vom 22.-24. Mai 2008 in Augsburg* (S. 11–32). Hamburg: Czwalina.
- Miethling, W.-D. & Perl, J. (1981). *Computerunterstützte Sportspielanalyse*. Czwalina.
- Perl, J. & Lames, M. (1995). Sportinformatik: Gegenstandsbereich und Perspektiven einer sportwissenschaftlichen Teildisziplin. *Leistungssport*, 25 (3), 26–30.
- Recla, J. & Timmer, R. (Hrsg.). (1976). *Kreative Sportinformatik*. Schorndorf: Hofmann.
- Willimczik, K. (1985). Interdisziplinäre Sportwissenschaft – Forderungen an ein erstarrtes Konzept. *Sportwissenschaft*, 15, 9–32.

Datensätze

Inhaltsverzeichnis

- Kapitel 2** **Künstliche Daten – 13**
Fabian Wunderlich
- Kapitel 3** **Reale Datensätze – Textdaten – 23**
Otto Kolbinger
- Kapitel 4** **Reale Datensätze – Videodaten – 31**
Eric Müller-Budack, Wolfgang Gritz und Ralph Ewerth
- Kapitel 5** **Reale Datensätze – Eventdaten – 39**
Marc Garnica Caparrós
- Kapitel 6** **Reale Datensätze – Positionsdaten – 47**
Daniel Memmert
- Kapitel 7** **Reale Datensätze Onlinedaten – 55**
Christoph Breuer



Künstliche Daten

Fabian Wunderlich

Inhaltsverzeichnis

- 2.1 Beispiel Sport – 14**
- 2.2 Hintergrund – 14**
 - 2.2.1 Die Limits von echten Daten – 14
 - 2.2.2 Die Idee von künstlichen Daten – 15
 - 2.2.3 Zufallszahlen und Monte-Carlo-Simulation – 16
 - 2.2.4 Vorteile und Nachteile von künstlichen Datensätzen – 16
- 2.3 Anwendungen – 17**
 - Literatur – 19**

Kernbotschaften

- Die Verfügbarkeit von echten Datensätzen aus dem Sportbereich kann stark limitiert sein, insbesondere in Bezug auf Aspekte wie Größe, Konsistenz oder Qualität.
- Mithilfe von Zufallszahlengeneratoren lassen sich Zufallszahlen simulieren, die bestimmte vorgegebene Eigenschaften erfüllen.
- Mithilfe dieser Zufallszahlen lassen sich komplexe Prozesse nachbilden und künstliche Datensätze erzeugen, ohne diese Prozesse tatsächlich in der Realität beobachten zu müssen.
- Einige Vorteile von künstlichen Datensätzen sind die fast unbegrenzte Verfügbarkeit und das präzise Wissen über die zugrunde liegenden Prozesse.
- Der Hauptnachteil ist, dass der Wert künstlicher Daten stark davon abhängt, wie präzise die bei der Erstellung getroffenen Annahmen die Realität abbilden.

2.1 Beispiel Sport

Bei der Anwendung von informatischen Methoden auf Sportdaten möchten wir verbesserte Klassifikationen erreichen, bessere Entscheidungen treffen, in den Daten verborgene Muster erkennen, aber vor allem auch die Prozesse im Sport besser verstehen. Welchen Einfluss hat die Aufschlagfähigkeit eines Tennisspielers auf die Gewinnwahrscheinlichkeit für das Match? Welche Defensivtaktik einer Fußballmannschaft steigert ihre Erfolgswahrscheinlichkeit? Wie wirkt sich die Trainingsbelastung eines American Football Teams auf das Verletzungsrisiko der Spieler aus? Die Beantwortung solcher Fragen kann auf der Datenseite durch die begrenzte Verfügbarkeit, Konsistenz und Qualität von echten Daten erschwert werden. Im Profisport wird dies zudem auch dadurch erschwert, dass Forscher echte Wettkämpfe nicht experimentell manipulieren können. Mithilfe von Simulation und künstlichen Daten können derartige Fragestellungen aber untersucht werden, ohne dabei auf experimentell erhobene oder in der Realität beobachtete Daten zurückgreifen zu müssen.

2.2 Hintergrund

2.2.1 Die Limits von echten Daten

In diesem Buch wird an zahlreichen anderen Stellen die Analyse von echten Datensätzen thematisiert. Natürlich ist die Nutzung solcher Datensätze der natürliche und logische erste Impuls, denn diese bilden ja gerade die Ergebnisse der komplexen Prozesse in der Realität ab, die mit informatischen Methoden analysiert werden sollen. Allerdings ist dabei zu bedenken, dass auch echte Datensätze nicht frei

von Problemen sind. Eine große Herausforderung besteht insbesondere darin, dass die echten Daten im Hinblick auf verschiedene Aspekte wie Größe, Konsistenz und Wettkampfregeln begrenzt sein können. In vielen Bereichen ist die Stichprobengröße unproblematisch, beispielsweise, wenn es um die Analyse einer großen Anzahl an Spielergebnissen (Angelini und Angelis 2019; Kovalchik 2016) oder Toren (Wunderlich et al. 2021a) geht. Natürliche Grenzen gibt es allerdings durch die Seltenheit gewisser Ereignisse, wie z. B. Spiele bei Fußballweltmeisterschaften (Armatas et al. 2007; Delgado-Bordonau et al. 2013). Bei Daten mit einer höheren Granularität wie Positionsdaten ist die Datenverfügbarkeit allerdings aktuell noch deutlich limitiert und es ist üblich, dass Studien auf einer „nur“ ein- oder zweistelligen Anzahl an Matches basieren (Clemente et al. 2014; Klemp et al. 2021).

Interne und externe Faktoren wirken sich zudem auf die Konsistenz der Daten aus, denn der Spitzensport kann inkonsistenten Regeln, Regeländerungen oder sozialen Einflüssen unterliegen. Beispiele hierfür sind die Tatsache, dass männliche Tennisspieler bei Grand-Slam-Turnieren über maximal fünf Sätze spielen, während bei Spielen der ATP-Tour über maximal drei Sätze gespielt wird (s. Clarke und Dyte 2000), die Umstellung von der Zwei-Punkte-Regel auf die Drei-Punkte-Regel im Fußball (Riedl et al. 2015), Änderungen der Basketballregeln in Bezug auf die Anpassung der Drei-Punkte-Linie (Štrumbelj et al. 2013) oder mögliche Auswirkungen der Geisterspiele während der COVID-19-Pandemie auf den Heimvorteil (Wunderlich et al. 2021b). Weitere datenbegrenzende Aspekte sind qualitativer Natur, beziehen sich also vor allem auf Vollständigkeit und Genauigkeit der verfügbaren Daten.

2.2.2 Die Idee von künstlichen Daten

Die Idee von künstlichen Daten lässt sich ein wenig mit der Idee statistischer Hypothesentests vergleichen. Bei den Tests wird davon ausgegangen, dass eine Nullhypothese zutrifft, und davon ausgehend berechnet, wie (bei Gültigkeit dieser Hypothese und Einberechnung des Zufalls) die Verteilung der möglichen Ausgänge eines Experiments aussehen würde. Sobald tatsächlich das Experiment durchgeführt wurde, kann anhand dieser theoretischen Verteilung abgeschätzt werden, wie plausibel die gefundenen Daten unter der gegebenen Hypothese sind. Oder anders ausgedrückt, ob die gefundenen Daten eher für die Hypothese oder gegen die Hypothese sprechen.

Während in diesem Fall eine Wahrscheinlichkeitsverteilung explizit angegeben werden kann, setzt die Idee von künstlichen Daten in der Regel in Situationen an, die zu komplex sind, um sie mit sinnvollem Aufwand direkt mathematisch zu beschreiben. Zunächst wird dabei der zugrunde liegende Prozess mathematisch modelliert, d. h., es wird beschrieben, nach welchen systematischen Gesetzmäßigkeiten der Prozess abläuft. Mittels Zufallszahlen und sogenannter Monte-Carlo-Simulation können dann die zufälligen Aspekte eingerechnet und somit ermittelt werden, welche Zwischenergebnisse und Ausgänge des Prozesses mit welcher Wahrscheinlichkeit zu erwarten sind.

2.2.3 Zufallszahlen und Monte-Carlo-Simulation

Zufallszahlen sind maschinell erstellte Zahlen, die einer bestimmten vorher festgelegten Wahrscheinlichkeitsverteilung entsprechen (James 1990). Auf diese Weise können z. B. 10.000 Zahlen erzeugt werden, deren Auftretenswahrscheinlichkeit einer Poisson-Verteilung mit einem vordefinierten Mittelwert entsprechen, die ansonsten aber einen zufälligen Charakter haben. Wenn die Charakteristiken eines simplen Prozesses bekannt sind, können somit wiederholt die zufallsbehafteten Ergebnisse dieses Prozesses generiert werden. Illustrieren lässt sich dies am Beispiel der Tore im Fußball, deren Anzahl gut durch eine Poisson-Verteilung angenähert werden kann (Karlis und Ntzoufras 2003). Durch Ziehen von Zufallszahlen aus einer Poisson-Verteilung können somit realistische Werte für die Anzahl der Tore einer großen Menge von Spielen künstlich simuliert werden, ohne tatsächlich eine derart große Menge an Spielen beobachten zu müssen. Um die Ergebnisse komplizierterer Prozesse zu simulieren, ist in der Regel die Generierung verschiedenster derartiger Variablen notwendig, die sich zusätzlich beeinflussen und miteinander interagieren können. Auf diese Weise entstehen durch die Modellierung des Prozesses und mittels Generierung von Zufallszahlen künstliche Daten, deren Erzeugung synonym auch als Simulation oder Monte-Carlo-Simulation bezeichnet wird (Harrison 2010).

2.2.4 Vorteile und Nachteile von künstlichen Datensätzen

Künstliche Daten helfen bei der Überwindung der oben thematisierten Limits von echten Daten, da sie es dem Forscher ermöglichen, Daten mit einer nahezu unbegrenzten Größe sowie mit vollständiger Konsistenz und Qualität zu simulieren. Ein Aspekt, der in diesem Kontext besonders zu nennen ist, ist der nachweisbar hohe Zufallseinfluss im Sportspiel (Wunderlich et al. 2021a; Brechot und Flepp 2020; Ben-Naim et al. 2006; Lames 2018). Gerade bei solch hohem Zufallseinfluss ist die Verfügbarkeit von großen Stichproben notwendig. Künstliche Daten, die in bestimmten Bereichen schneller und in größerer Menge erstellt werden können, als reale Daten zugänglich sind, können hier ein wertvolles Hilfsmittel darstellen. Ein weiterer Vorteil ist, dass im Gegensatz zu realen Prozessen die den künstlichen Daten innewohnenden Beziehungen absichtlich kontrolliert und variiert werden können, um so den Einfluss verschiedener Variablen auf das Prozessergebnis zu verstehen.

Der große Nachteil von künstlichen Daten ist in der fraglichen Übertragbarkeit auf echte Prozesse zu sehen. Die Ergebnisse eines Simulationsmodells sind natürlich massiv davon abhängig, wie der Prozess modelliert wurde und welche Annahmen über Wahrscheinlichkeitsverteilungen der einzelnen Variablen getroffen wurden. Insofern hängt der Wert der künstlichen Daten und daraus abgeleiteten Schlussfolgerungen stark davon ab, ob die bei der Erstellung getroffenen Annahmen die in der Realität vorliegenden Prozesse präzise genug abbilden. Je komplexer und schwerer beobachtbar ein Prozess in der Realität ist, desto größer ist das

Risiko, bei der Modellierung unpräzise Annahmen zu nutzen, und desto mehr bekommen die Simulationsergebnisse einen rein theoretischen Charakter. Optimalerweise sollte also immer ein Zusammenspiel aus künstlichen Daten und echten Daten angestrebt werden. Beispielsweise können in einem ersten Schritt durch die Nutzung von künstlichen Daten theoretische Erkenntnisse über die zugrunde liegenden Prozesse gefunden werden. In einem zweiten Schritt kann dann durch Transfer dieser Erkenntnisse auf echte Daten der tatsächliche Nutzen in der Praxis eindeutig bewiesen werden.

Die informatische Methode der Simulation – und damit die Erstellung von künstlichen Daten – ist fast universell anwendbar, und ihre Anwendungsbereiche beinhalten neben zahlreichen weiteren Beispielen das Gesundheitswesen (Zhang 2018; Jahangirian et al. 2012), die Produktion (Mourtzis et al. 2014) oder das Testen von Softwaresystemen (Misra 2015). Auch im Sportbereich werden Techniken der Simulation und künstliche Daten für verschiedenste Fragestellungen genutzt, die teilweise unten in diesem Kapitel noch näher beleuchtet werden (Bornn et al. 2019; Memmert et al. 2021; Newton und Aslam 2009; Wunderlich und Memmert 2020; Garnica-Caparrós et al. 2022; Štrumbelj und Vračar 2012; Leitner et al. 2010).

Definition

Unter künstlichen Daten verstehen wir in diesem Buch Daten, die durch Modellierung eines Prozesses und Monte-Carlo-Simulation erzeugt wurden. Diese bilden dabei in der Regel die Ergebnisse eines in der Realität existierenden Prozesses aus dem Sport nach und sollen helfen, ein verbessertes Verständnis für diesen oder verwandte Prozesse zu erlangen.

2.3 Anwendungen

► Beispiel 1

Bei dem ersten Anwendungsbereich geht es darum, Ausgänge von Sportereignissen anhand bestimmter Annahmen zu simulieren. Üblicherweise werden dafür als Annahmen einerseits eine Einschätzung der systematischen Spielstärke von Mannschaften oder Spielern und andererseits eine Modellierung des Spielablaufs der jeweiligen Sportart benötigt. Mit diesem Wissen können dann wiederholt Spiele oder ganze Wettbewerbe simuliert werden, und anhand einer Vielzahl solcher Simulationsdurchläufe ergibt sich die Wahrscheinlichkeit für jeden der möglichen Ausgänge. Die Studie von Newton und Aslam (2009) stellt einen exemplarischen Fall dieses Vorgehens dar. Anhand echter Daten aus dem Profitennis schätzen die Autoren die systematische Stärke der Spieler, gemessen als Wahrscheinlichkeit eines Punktgewinns bei eigenem Aufschlag bzw. Return. Zusätzlich schätzen sie die Leistungsschwankung der Spieler, gemessen als Variabilität dieser Wahrscheinlichkeiten. Anhand eines Modells, das das Regelwerk des Tennis mit

Punkt-, Spiel- und Satzgewinnen abbildet, lassen sich aus den Spielereigenschaften per Monte-Carlo-Simulation die Wahrscheinlichkeiten für verschiedene Spielausgänge ableiten. Auch ganze Turniere können durch zufälliges Ziehen der Sieger jedes Matches unter den vorgegebenen Wahrscheinlichkeiten simuliert werden. Die so entstehenden künstlichen Daten zu Turnierergebnissen können dann analysiert werden, um die wahrscheinlichsten Sieger und die Chancen jedes einzelnen Spielers auf das Erreichen einer bestimmten Runde zu analysieren. ◀

► Beispiel 2

Der zweite Anwendungsbereich zielt darauf ab, die Auswirkung und das Zusammenspiel von verschiedenen Einflussfaktoren besser zu verstehen. Hierbei können Simulation und künstliche Daten eingesetzt werden, um in einem Prozess die Auswirkung von einzelnen Variablen und deren Interaktion auf die daraus entstehenden Daten zu verstehen und so vor allem fehlerhafte Interpretationen zu vermeiden. Ein exemplarischer Fall ist die Studie von Bornn et al. (2019), die sich mit der Frage beschäftigt, ob die Belastung, gemessen als sogenannte *acute chronic workload ratio* (ACWR), ein Prädiktor für Verletzungsrisiko ist. Zahlreiche existierende Studien hatten dies zuvor nahegelegt, die Autoren vermuten allerdings, dass weitere Einflussfaktoren diesen Zusammenhang konfundieren können. Aus diesem Grund wurden künstliche Daten simuliert, bei denen Verletzungen nur von der Belastung der aktuellen Trainingseinheit und nicht von der ACWR abhängen. Bei der Analyse der entstehenden Daten lassen sich dann trotzdem signifikante Korrelationen zwischen der ACWR und auftretenden Verletzungen finden. Alleine anhand von theoretischen Überlegungen und künstlichen Daten konnte also bewiesen werden, dass die Belastung der aktuellen Trainingseinheit die Ergebnisse konfundieren kann und somit in echten Daten zuvor gefundene Ergebnisse möglicherweise ungenau oder sogar falsch interpretiert wurden. ◀

► Beispiel 3

Bei dem dritten Anwendungsfall geht es darum, durch künstliche Daten zwei Herausforderungen von echten komplexe Datensätzen aus dem Sport zu überwinden. Einerseits ist die Anzahl der Spiele, für die solche Daten verfügbar sind, üblicherweise begrenzt, sodass die gewünschten zu untersuchenden Situationen in den Daten nicht in großer Anzahl analysierbar sind. Andererseits sind bei professionellen Sportveranstaltungen keine experimentellen Manipulationen möglich, die das bewusste Erzeugen derartiger Situationen ermöglichen. In solchen Anwendungsfällen können künstliche Daten helfen, dennoch eine sinnvolle Analyse zu ermöglichen. Ein exemplarischer Fall ist die Studie von Memmert et al. (2021), bei der künstliche Daten genutzt wurden, um die Analyse von Positionsdaten im Fußball zu erweitern. Durch einen Simulationsansatz ist es möglich, systematisch verschiedenste Kombinationen der Formationsflexibilität von Angriffs- bzw. Verteidigungsmannschaft zu untersuchen. Insbesondere kann dadurch herausgefunden werden, welche taktische Flexibilität der Mannschaften am erfolgversprechendsten ist. Zwar werden als Simulationsgrundlage echte Positionsdaten genutzt, eine reine Analyse auf Positionsdaten echter Spiele ist allerdings nicht ohne Weiteres möglich, da nicht garantiert wäre, dass die zu analysierenden Kombinationen in diesen Spielen überhaupt vorhanden sind. ◀

Studienbox

Garnica-Caparrós et al. (2022) stellen in ihrer Studie ein Simulations-Framework vor, mit dessen Hilfe künstliche Daten generiert und analysiert werden können. Als Anwendungsbeispiel dienen prädiktive Modelle zur Vorhersage von Sportereignissen. Dabei wird konzeptionell der gesamte Vorhersageprozess nachgebildet, indem Mannschafts- oder Spielerstärken, Spelausgänge sowie durch Buchmacherfehler beeinflusste Wettquoten simuliert werden. Anhand der entstehenden künstlichen Datensätzen können dann existierende oder neuartige Ratingverfahren und prädiktive Modelle validiert werden. Der Vorteil der künstlichen Datensätze im Vergleich zu echten Datensätzen besteht dabei unter anderem darin, dass sie eine genauere Validierung von Genauigkeit und Profitabilität der prädiktiven Modelle ermöglichen.

? Fragen für die Studierenden

Was versteht man unter Monte-Carlo-Simulation?

Was sind die Hauptvorteile und Hauptnachteile von künstlichen Daten?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Angelini, Giovanni; Angelis, Luca de (2019): Efficiency of online football betting markets. In: *International Journal of Forecasting* 35 (2), S. 712–721. DOI: <https://doi.org/10.1016/j.ijforecast.2018.07.008>.
- Armatas, Vasilis; Yiannakos, Athanasios; Sileloglou, P. (2007): Relationship between time and goal scoring in soccer games: Analysis of three World Cups. In: *International Journal of Performance Analysis in Sport* 7 (2), S. 48–58. DOI: <https://doi.org/10.1080/24748668.2007.11868396>.
- Ben-Naim, Eli; Vazquez, Federico; Redner, Sidney (2006): Parity and Predictability of Competitions. In: *Journal of Quantitative Analysis in Sports* 2 (4). DOI: <https://doi.org/10.2202/1559-0410.1034>.

- Bornn, Luke; Ward, Patrick; Norman, Darcy (2019): Training schedule confounds the relationship between acute:chronic workload ratio and injury. In: *Sloansportsconference Com*.
- Brechot, Marc; Flepp, Raphael (2020): Dealing With Randomness in Match Outcomes: How to Rethink Performance Evaluation in European Club Football Using Expected Goals. In: *Journal of Sports Economics* 21 (4), S. 335–362. DOI: <https://doi.org/10.1177/1527002519897962>.
- Clarke, S. R.; Dyte, D. (2000): Using official ratings to simulate major tennis tournaments. In: *Int Trans Operational Res* 7 (6), S. 585–594. DOI: <https://doi.org/10.1111/j.1475-3995.2000.tb00218.x>.
- Clemente, M. Filipe; Martins, Fernando M. L.; Couceiro, S. Micael; Mendes, S. Rui; Figueiredo, António J. (2014): Inspecting teammates' coverage during attacking plays in a football game: A case study. In: *International Journal of Performance Analysis in Sport* 14 (2), S. 384–400. DOI: <https://doi.org/10.1080/24748668.2014.11868729>.
- Delgado-Bordonau, Juan Luis; Domenech-Monforte, Carlos; Guzmán, José Francisco; Méndez-Villanueva, Alberto (2013): Offensive and defensive team performance: relation to successful and unsuccessful participation in the 2010 Soccer World Cup. In: *Journal of Human Sport and Exercise* 8 (4), S. 894–904. DOI: <https://doi.org/10.4100/jhse.2013.84.02>.
- Garnica-Caparrós, Marc; Memmert, Daniel; Wunderlich, Fabian (2022): Artificial data in sports forecasting: A simulation framework for analysing predictive models in sports. In: *Information Systems and e-Business Management* 20 (3), S. 551–580. <https://doi.org/10.1007/s10257-022-00560-9>.
- Harrison, Robert L. (2010): Introduction To Monte Carlo Simulation. In: *AIP conference proceedings* 1204, S. 17–21. DOI: <https://doi.org/10.1063/1.3295638>.
- Jahangirian, Mohsen; Naseer, Aisha; Stergioulas, Lampros; Young, Terry; Eldabi, Tillal; Brailsford, Sally et al. (2012): Simulation in health-care: lessons from other sectors. In: *Oper Res Int J* 12 (1), S. 45–55. DOI: <https://doi.org/10.1007/s12351-010-0089-8>.
- James, Frederick (1990): A review of pseudorandom number generators. In: *Computer physics communications* 60 (3), S. 329–344.
- Karlis, Dimitris; Ntzoufras, Ioannis (2003): Analysis of sports data by using bivariate Poisson models. In: *J Royal Statistical Soc D* 52 (3), S. 381–393. DOI: <https://doi.org/10.1111/1467-9884.00366>.
- Klemp, Maximilian; Wunderlich, Fabian; Memmert, Daniel (2021): In-play forecasting in football using event and positional data. In: *Scientific reports* 11 (1), S. 24139. DOI: <https://doi.org/10.1038/s41598-021-03157-3>.
- Kovalchik, Stephanie Ann (2016): Searching for the GOAT of tennis win prediction. In: *Journal of Quantitative Analysis in Sports* 12 (3). DOI: <https://doi.org/10.1515/jqas-2015-0059>.
- Lames, Martin (2018): Chance involvement in goal scoring in football – an empirical approach. In: *Ger J Exerc Sport Res* 48 (2), S. 278–286. DOI: <https://doi.org/10.1007/s12662-018-0518-z>.
- Leitner, Christoph; Zeileis, Achim; Hornik, Kurt (2010): Forecasting sports tournaments by ratings of (prob)abilities: A comparison for the EURO 2008. In: *International Journal of Forecasting* 26 (3), S. 471–481. DOI: <https://doi.org/10.1016/j.ijforecast.2009.10.001>.
- Memmert, Daniel; Imkamp, Jonas; Perl, Jürgen (2021): Flexible Defense Succeeds Creative Attacks! – A Simulation Approach Based on Position Data in Professional Football. In: *JSEA* 14 (09), S. 493–504. DOI: <https://doi.org/10.4236/jsea.2021.149029>.
- Misra, Anuranjan (2015): Comparative Study of Test Data Generation Techniques. In: *JITS* 1 (2), S. 1–7.
- Mourtzis, D.; Doukas, M.; Bernidaki, D. (2014): Simulation in Manufacturing: Review and Challenges. In: *Procedia CIRP* 25, S. 213–229. DOI: <https://doi.org/10.1016/j.procir.2014.10.032>.
- Newton, Paul K.; Aslam, Kamran (2009): Monte Carlo Tennis: A Stochastic Markov Chain Model. In: *Journal of Quantitative Analysis in Sports* 5 (3). DOI: <https://doi.org/10.2202/1559-0410.1169>.
- Riedl, Dennis; Heuer, Andreas; Strauss, Bernd (2015): Why the Three-Point Rule Failed to Sufficiently Reduce the Number of Draws in Soccer: An Application of Prospect Theory. In: *Journal of sport & exercise psychology* 37 (3), S. 316–326. DOI: <https://doi.org/10.1123/jsep.2015-0018>.
- Štrumbelj, Erik; Vračar, Petar; Robnik-Šikonja, Marko; Dežman, Brane; Erčulj, Frane (2013): A decade of euroleague basketball: an analysis of trends and recent rule change effects. In: *Journal of human kinetics* 38, S. 183–189. DOI: <https://doi.org/10.2478/hukin-2013-0058>.

- Štrumbelj, Erik; Vračar, Petar (2012): Simulating a basketball match with a homogeneous Markov model and forecasting the outcome. In: *International Journal of Forecasting* 28 (2), S. 532–542. DOI: <https://doi.org/10.1016/j.ijforecast.2011.01.004>.
- Wunderlich, Fabian; Memmert, Daniel (2020): Are betting returns a useful measure of accuracy in (sports) forecasting? In: *International Journal of Forecasting* 36 (2), S. 713–722. DOI: <https://doi.org/10.1016/j.ijforecast.2019.08.009>.
- Wunderlich, Fabian; Seck, Alessandro; Memmert, Daniel (2021a): The influence of randomness on goals in football decreases over time. An empirical analysis of randomness involved in goal scoring in the English Premier League. In: *Journal of Sports Sciences* 39 (20), S. 2322–2337. DOI: <https://doi.org/10.1080/02640414.2021.1930685>.
- Wunderlich, Fabian; Weigelt, Matthias; Rein, Robert; Memmert, Daniel (2021b): How does spectator presence affect football? Home advantage remains in European top-class football matches played without spectators during the COVID-19 pandemic. In: *PloS one* 16 (3), e0248590. DOI: <https://doi.org/10.1371/journal.pone.0248590>.
- Zhang, Xiang (2018): Application of discrete event simulation in health care: a systematic review. In: *BMC health services research* 18 (1), S. 687. DOI: 10.1186/s12913-018-3456-4.



Reale Datensätze – Textdaten

Otto Kolbinger

Inhaltsverzeichnis

- 3.1 Einleitung – 24**
- 3.2 Anwendungen – 25**
 - 3.2.1 Evaluation von Technological Officiating Aids – 25
 - 3.2.2 Spielvorhersagen – 26
 - 3.2.3 Talentscouting – 27
- Literatur – 28**

Kernbotschaften

- Textdaten können Informationen über Sportler, Wettkämpfe und deren Auswirkungen auf die Gesellschaft enthalten, die nicht in anderen Daten abgebildet sind.
- Computergestützte Text-Mining-Verfahren erlauben eine ökonomische Verarbeitung und Auswertung von großen (Text-)Datenmengen.
- Textdaten werden derzeit hauptsächlich zur Bearbeitung von sportsoziologischen und sportökonomischen Fragestellungen herangezogen.
- Erste Studien zeigen Potenzial für die systematische Auswertung von Textdaten auch in den Bereichen, die sich primär mit der Leistung von Athleten beschäftigen, wie beispielsweise Trainingswissenschaft und Wettkampfdiagnostik.

3.1 Einleitung

Die Bearbeitung von Fragestellungen aus dem Sport und der Sportwissenschaft mit informatischen Verfahren beschäftigte sich lange nahezu ausschließlich mit numerischen Daten, wie z. B. Aktions- oder Positionsdaten. Allerdings liegt Wissen über Sportler, Wettkämpfe und deren Auswirkungen auch oftmals in Textform vor, wie beispielsweise unzählige Scouting-Berichte in Nachwuchsakademien von Vereinen und Verbänden. Heutzutage erlauben die Fortschritte im Bereich der Texterkennung und des maschinellen Lernens eine ökonomische Auswertung großer Textdatensätze. Entsprechend werden zunehmend sogenannte „Text-Mining“-Verfahren in Theorie und Praxis eingesetzt, speziell in Disziplinen, in denen traditionell viel mit Daten in Textform wie offenen Fragebögen oder standardisierten Interviews gearbeitet wird. So dominieren in der Sportwissenschaft Studien aus dem Bereich der Sportsoziologie. Bereits in mehreren Studien wurde untersucht, wie Fans auf politische Statements von Sportlern reagieren, beispielsweise Frederick et al. (2020) bezüglich politischen Statements von Megan Rapinoe oder Schmidt et al. (2019) zu Protesten während der Nationalhymne. Beide der aufgeführten Studien nutzten als Datenbasis Social Media Posts – ein weiterer Trend bei der Forschung auf Basis von Textdaten. Entsprechend werden bei den exemplarischen Anwendungen in diesem Kapitel insgesamt zwei Studien gezeigt, welche auf Social-Media-Daten beruhen.

Eine Studie beschäftigt sich mit dem Einfluss des Videoassistenten im Fußball, des sogenannten VAR (Video Assistant Referee), auf die Stimmung von Fans der englischen Premier League auf Twitter (Kolbinger & Knopp, 2020). Hier können Textdaten genutzt werden, um systematisch die Auswirkungen von technischen Neuerungen auf Interessensgruppen zu untersuchen. Ein Aspekt, der speziell bei der Einführung von technischen Hilfsmitteln für Schiedsrichter vernachlässigt wurde. Wie Beiträge aus sozialen Medien ebenso zur Vorhersage von Spielergebnissen herangezogen werden können, wird ebenfalls in diesem Kapitel anhand eines Beispiels aus dem American Football demonstriert (Schumaker et al., 2017).

Dass dies nicht die einzigen Textdaten sind, die wertvolle Informationen für Spielvorhersagen enthalten können, wird anhand einer Studie von Beal et al. (2021) diskutiert. Als letzter exemplarischer Anwendungsbereich wird abschließend anhand von zwei Beiträgen aufgezeigt, wie Textdaten beim Scouting von Talenten genutzt werden können (Seppa et al., 2017; Maymin, 2021).

Definition

Sämtliche strukturierten und unstrukturierten Textkörper können prinzipiell als Textdaten dienen. Im Kontext der Sportinformatik umfasst dies unter anderem, aber keinesfalls ausschließlich, Social-Media-Beiträge, Interviews und Experteneinschätzungen in Textform.

3.2 Anwendungen

3.2.1 Evaluation von Technological Officiating Aids

Mehr und mehr Sportarten führten über die letzten Jahrzehnte technische Hilfsmittel zur Unterstützung von Schiedsrichtern ein, sogenannte Technological Officiating Aids (Kolbinger, 2018). Während sich Sportpraxis und wissenschaftliche Publikationen vor allem mit der Technologie selbst und deren Auswirkungen auf die Entscheidungsqualität beschäftigten, wurde der Einfluss dieser Interventionen auf Interessensgruppen wie Fans vernachlässigt (Kolbinger & Lames, 2017). Hier bieten Textdaten in Form von Social-Media-Beiträgen eine leicht zugängliche Möglichkeit, genau diesen Einfluss zu untersuchen. Über drei Milliarden Menschen weltweit nutzen Plattformen wie Twitter, Facebook oder Instagram, um ihre Meinungen und Emotionen zu bestimmten Themen oder Ereignissen kundzutun (Kozinets, 2020). Das schließt natürlich polarisierende Themen im Sport mit ein, und der Videoassistent im Fußball kann zweifelsfrei als solches gesehen werden (vgl. hierzu auch Kolbinger, 2020).

Als Datenbasis für die Studie zum Einfluss des VAR auf das Stimmungsbild von Fußballfans auf Twitter nutzten Kolbinger und Knopp (2020) alle Tweets von 129 Spielen der Premier League Saison 2019/20, in denen der offizielle Match-Hashtag verwendet wurde (also zum Beispiel #LIVMUN für Liverpool FC gegen Manchester United FC). Von diesen insgesamt 643.251 Tweets beschäftigten sich 58.264 und damit 9,1 % mit dem Videoschiedsrichter. Für diese Tweets sowie den Rest der Stichprobe wurde anschließend eine sogenannte Sentiment-Analyse durchgeführt. Konkret wurde bewertet, ob ein Beitrag insgesamt eher ein negatives, neutrales oder positives Stimmungsbild ausdrückte. Auffällig war dabei, dass 76,2 % der Tweets über den VAR negative und nur 12,3 % positive Emotionen ausdrückten. Bei allen anderen Tweets während der betrachteten Fußballspiele waren hingegen 39,4 % der Beiträge positiv und nur 31,3 % negativ. Zudem betrachteten Kolbinger und Knopp (2020), wie sich Eingriffe des Videoschiedsrichters auf das

durchschnittliche Sentiment während Fußballspielen auswirkte, und konnten so zeigen, dass diese Eingriffe im Mittel zu einem deutlichen und über 20 min anhaltenden Stimmungseinbruch führten.

Sowohl für die Entscheidung, ob ein Tweet sich auf den VAR bezog, als auch für die Bewertung des Sentiments entwickelten und nutzen die Autoren automatische Text-Klassifikatoren. Es wurde also ein Algorithmus trainiert, um automatisch den Inhalt der Beiträge in die genannten Kategorien einzuordnen. Ein übliches Vorgehen bei der Analyse großer Textdatenmengen, welches auch in vielen der folgenden Studien angewandt wurde. Für alle diese Studien gilt, dass die Qualität des Text-Klassifikators von überragender Bedeutung ist. Ein Umstand, der – wie übrigens auch bei anderen Anwendungen von Machine-Learning-Verfahren – leider oft vernachlässigt wird. Entsprechend wichtig ist es für Leser*innen von Studien mit Textdaten, dass nicht nur Herkunft und Art der Daten nachvollziehbar sind, sondern auch das angewandte Klassifikationsverfahren und dessen Qualität (Kolbinger, 2022).

3.2.2 Spielvorhersagen

Ein weiterer Anwendungsbereich, in dem das Sentiment von Social-Media-Beiträgen bereits vielversprechend genutzt wurde, ist die Vorhersage von Spielergebnissen. Eine amerikanische Forschergruppe um Robert P. Schumaker demonstrierte dies in jeweils einer Studie zur englischen Premier League (Schumaker et al., 2016) und zur National Football League (NFL – American Football; Schumaker et al., 2017). Es handelt sich mehr oder weniger um einen Versuch, die sogenannte „Wisdom of the Crowd“ – ins Deutsche am ehesten als kollektive Intelligenz übersetzbar – zu nutzen, um den Ausgang von Spielen vorherzusagen. In diesem Abschnitt richten wir den Blick vor allem auf die Studie zur NFL, in dem die Autoren einen sehr interessanten Ansatz nutzten. Als Datenbasis dienten pro Spiel jeweils alle Tweets über eines der teilnehmenden Teams in den 96 h (vier Tagen) vor dem Kick-off. Dabei verglichen Schumaker et al. (2017), wie sich das durchschnittliche Sentiment dieser Posts am letzten Tag vor dem Spiel im Unterschied zu den drei Tagen zuvor veränderte. Dabei wurde schlicht das Team, für welches sich eine positivere Veränderung des Stimmungsbildes zeigte (oder eine weniger negative), als Sieger des Spiels vorhergesagt. Mit dieser simplen Methode erreichten die Autoren die gleiche Vorhersagequote wie Sportwettenanbieter, wobei sie insbesondere die Siege von Außenseitern besonders gut vorhersagen konnten.

Das gleiche Muster findet sich für eine Arbeit von Beal et al. (2021), wobei jedoch ein grundsätzlich anderer Typ von Textdaten genutzt wurde. Anstatt wie Schumaker et al. (2017) sehr viele unspezifische kurze Textkörper mit der Hoffnung auf Schwarmintelligenz zu nutzen, handelt es sich bei den Textdaten von Beal et al. (2021) um jeweils einzelne, elaborierte Texte zu einem vordefinierten Thema. Konkret: Vorberichte zu Spielen der Premier League aus einer englischen Tageszeitung. Hierbei wurden im Gegensatz zu den vorherigen Studien keine Klassifizierungen des Textes (mit Ausnahme der Zuordnung von Sätzen zu einem Team) vorgenommen. Auch mit diesem Ansatz wurden speziell unerwartete Ergebnisse

besser vorhergesagt als von auf numerischen Daten basierenden Modellen. Es scheint also, als würden im Text Informationen enthalten sein, die so (zumindest bisher) nicht über numerische Daten, wie vorherige Ergebnisse oder sogenannte Key Performance Indicators, abgebildet werden können.

3.2.3 Talentscouting

„Kobe weiß, wie man Basketball spielt – und was es braucht, um zu gewinnen“ – dieser Auszug aus dem Scouting-Bericht von Jason Sean Fuiman über den leider viel zu früh verstorbenen Kobe Bryant erwies sich als sehr zutreffend (Sumsky, 2020). Interessanterweise bezieht sich Fuiman hier auf Leistungsmerkmale von Kobe Bryant, die sich bisher nicht – und vielleicht niemals – über numerische Daten abbilden lassen. Solche Scouting-Berichte liegen in unzähligen Vereinen und Verbänden für eine unzählige Anzahl an Athletinnen und Athleten vor. Text-Mining-Verfahren können diese ökonomisch nutzbar machen, wie zwei Studien zeigen, die jeweils anhand von kommerziellen Scouting-Berichten versuchten, die zu erwartende Leistung in einer Profiligen vorherzusagen. Beide nutzten dabei sehr unterschiedliche Herangehensweisen.

Seppa et al. (2017) verknüpften für die Auswertung von Scouting-Berichten im Eishockey eine Sentiment-Analyse mit einer sogenannten wörterbuchbasierten Kategorisierung von Textdaten (im Englischen: *lexicon-based*). Letzteres bedeutet, dass sie versuchten, jeden Satz oder Abschnitt eines Scouting-Berichts über bestimmte Schlagwörter oder Wortketten einer Kategorie zuzuordnen. Zum Beispiel wurde ein Satz der Kategorie „Einsatz“ zugeordnet, wenn Wörter wie eben „Einsatz“ oder aber auch „faul“ oder Wortketten wie „Kampf annehmen“ auftraten. In Verbindung mit einer Analyse des Sentiments des entsprechenden Abschnitts versuchten sie die Spieler dann jeweils für diese Kategorien einzuordnen, also beispielsweise als Spieler mit „mangelndem Einsatz“ oder „gutem Puck-Gefühl“. Auf diese Weise konnten Seppa et al. (2017) besser die Assist- und Torrate der Spieler im Profibereich vorhersagen als auf Basis der erzielten Assists und Tore in den Jugendlichen. Noch besser waren die Vorhersagen, wenn beides kombiniert wurde. Einschränkend muss jedoch gesagt werden, dass die Vorhersagequalität für beide genutzten Verfahren und deren Kombination nicht sehr hoch war. Allerdings ist das Muster, dass die Berichte die Vorhersagequalität verbessern konnten, sehr interessant.

In einer Studie aus dem Basketball beschreibt Maymin (2021), dass ein von ihm entwickeltes Modell die Draft Performance von 29 der 30 NBA-Teams übertroffen hätte. Das Modell enthielt neben Spielstatistiken auch Scouting Reports, welche neben Scores für bestimmte Fähigkeiten auch vorstrukturierte Textdaten enthielten. Die Textkörper waren dabei in die Bereiche „Stärken“, „Schwächen“, „Insgesamt“ und „Anmerkungen“ unterteilt. Da sich Maymin (2021) vor allem auf den Vergleich seines Modells mit der Draft Performance von NBA-Teams beschäftigte, ging er nicht im Detail auf die Beiträge der einzelnen Komponenten seines Modells ein. Allerdings wird bereits aus der zusammenfassenden Übersicht über die Bedeutung der Komponenten ersichtlich, dass Inhalt und insbesondere sowohl Um-

fang als auch Sentiment der einzelnen Kategorien einen Vorhersagebeitrag leisten, der ähnlich hoch war wie der von einzelnen Matchstatistiken.

Entsprechend ist der Forschungsstand zur Nutzbarkeit von Textdaten für die Talentdiagnostik noch keinesfalls zufriedenstellend, zumal sich die wenigen Studien bisher auf kommerzielle Scouting-Berichte und ausschließlich auf das Sportssystem in Nordamerika bezogen. Allerdings sind die ersten Ergebnisse durchaus als vielversprechend zu beurteilen und deuten darauf hin, dass die Textdaten Informationen abbilden, die in anderen Daten (noch) nicht vorhanden sind.

? Fragen für die Studierenden

1. Nennen Sie zwei Verfahren, um Textdaten automatisch zu klassifizieren.
2. Beschreiben Sie anhand von zwei Beispielen, wie man Social-Media-Beiträge in der Sportwissenschaft nutzen kann.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Beal, R., Middleton, S. E., Norman, T. J., & Ramchurn, S. D. (2021). Combining machine learning and human experts to predict match outcomes in football: A baseline model. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(17), pp. 15447–15451.
- Frederick, E. L., Pegoraro, A., & Schmidt, S. (2020). „I’m not going to the f***ing White House”: Twitter users react to Donald Trump and Megan Rapinoe. *Communication & Sport*, in press. <http://doi.org/https://doi.org/10.1177/2167479520950778>
- Kolbinger, O. (2018). *Innovative technische Hilfsmittel zur Unterstützung von Schiedsrichtern in Sportarten als Gegenstand von Evaluationsforschung [Innovative Technological Officiating Aids as object of Evaluative Research]*. Doctoral dissertation, Technical University of Munich.
- Kolbinger O. (2020). VAR experiments in the Bundesliga. In: Armenteros M, Benítez AJ, Betancor MA, editors. *The use of video technologies in refereeing football and other sports* (pp. 228–245). Routledge.
- Kolbinger, O. (2022). Text Mining and Performance Analysis. In *International Conference on Security, Privacy, and Anonymity in Computation, Communication, and Storage* (pp. 3–8). Springer, Cham.

- Kolbinger, O. & Lames, M. (2017). Scientific approaches to technological officiating aids in game sports. *Current Issues in Sport Science*, 2:001. https://doi.org/10.15203/CISS_2017.001
- Kolbinger, O. & Knopp, M. (2020). Video kills the sentiment – Exploring fans’ reception of the video assistant referee in the English Premier League using Twitter data. *PLoS ONE*, 15(12): e0242728. <https://doi.org/10.1371/journal.pone.0242728>
- Kozinets, R. V. (2020). *Netnography: The essential guide to qualitative social media research*. Sage.
- Maymin, P. (2021). Using scouting reports text to predict NCAA→ NBA performance. *Journal of Business Analytics*, 4(1), 40–54. <https://doi.org/10.1080/2573234X.2021.1873077>
- Schmidt, S. H., Frederick, E. L., Pegoraro, A., & Spencer, T. C. (2019). An analysis of Colin Kaepernick, Megan Rapinoe, and the national anthem protests. *Communication & Sport*, 7(5), 653–677. <https://doi.org/10.1177/2167479518793625>
- Schumaker, R. P., Jarmoszko, A. T., & Labedz Jr, C. S. (2016). Predicting wins and spread in the Premier League using a sentiment analysis of twitter. *Decision Support Systems*, 88, 76–84. <https://doi.org/10.1016/j.dss.2016.05.010>
- Schumaker, R. P., Labedz Jr, C. S., Jarmoszko, A. T., & Brown, L. L. (2017). Prediction from regional angst – a study of NFL sentiment in Twitter using technical stock market charting. *Decision Support Systems*, 98, 80–88. <https://doi.org/10.1016/j.dss.2017.04.010>
- Seppa, T., Schuckers, M. E., & Rovito, M. (2017). Text mining of scouting reports as a novel data source for improving NHL draft analytics. In *Ottawa Hockey Analytics Conference* (pp. 1–11).
- Sumsky, A. (2020, July 2). Kobe Bryant’s Scouting Report is Worth the Read. *Basketball forever*. <https://basketballforever.com/2020/07/02/kobe-bryants-scouting-report-worth-read>.



Reale Datensätze – Videodaten

Eric Müller-Budack, Wolfgang Gritz und Ralph Ewerth

Inhaltsverzeichnis

- 4.1 Beispiel Sport – 32
- 4.2 Hintergrund – 33
- 4.3 Grundlagen und Definition – 34
- 4.4 Anwendungen – 34
- Literatur – 37

Kernbotschaften

- Videodaten erfassen Aktionen und Handlungen von Sportler*innen sowie Bewegungen von Spielgeräten.
- Mithilfe von KI-basierten Ansätzen können Videoaufzeichnungen automatisch ausgewertet werden, um zeitgenau Informationen über Bewegungen, Aktionen und Haltungen (Posen) für weitergehende Analysen zugänglich zu machen.
- Mithilfe von Informationen, die aus Videoaufzeichnungen extrahiert werden, können sowohl Video- als auch Positionsdaten mit zusätzlichen Metainformationen angereichert werden.
- Mithilfe von Verfahren der Spielfeldregistrierung können Positionsdaten aus Videos extrahiert werden.
- Echtzeitfähige Ansätze können in der Zukunft dazu beitragen, dass Aktionen in Einzel- und Mannschaftssportarten live ausgewertet werden können.

4.1 Beispiel Sport

Videoaufzeichnungen von Wettbewerben und Trainingsprozessen erfassen Aktionen, Handlungen und Bewegungen von Sportler*innen. Sie enthalten viele Informationen wie Körperhaltungen sowie biomechanische oder taktische Details, die allein durch Positionsdaten (s. ► Kap. 6) nicht oder nicht vollständig abgebildet werden können. Anhand von drei Beispielen aus der Domäne Fußball wird im Folgenden verdeutlicht, welche Informationen mithilfe von KI-basierten Ansätzen zur automatischen Analyse von Videodaten ausgewertet werden können.

1. Videoaufzeichnungen von Fußballspielen enthalten eine Vielzahl von atomaren (Fouls, Tore etc.) und komplexen (Pässe, Schüsse etc.) Aktionen. Zudem sind auch Details zur Ausführung der Aktionen sichtbar, wie beispielsweise das Körperteil, mit dem ein Pass oder Schuss im Fußball durchgeführt wird, oder die Art eines gespielten Passes (Flachpass, hoher Pass). Mithilfe einer automatischen Detektion von Aktionen können Video- und Positionsdaten mit Metainformationen angereichert werden. Das erlaubt Analyst*innen, beispielsweise nach Szenen mit bestimmten Aktionen in Videos und großen Videosammlungen zu suchen, um sportwissenschaftliche Fragen effizient zu beantworten.
2. Des Weiteren können die Körperhaltung (Pose) und die Bewegungsabläufe der Athlet*innen genauer analysiert werden. Es können z.B. Poseninformationen wie die Körper- und Kopfausrichtung einer passgebenden Fußballerin oder eines passgebenden Fußballers sowie möglicher Passempfänger*innen und der verteidigenden Spieler*innen in Betracht gezogen werden, um Passoptionen vorauszusagen. Mithilfe einer automatischen Objektverfolgung (Tracking) lassen sich Bewegungen in Form einer Zeitreihe von Posendaten beschreiben.
3. Die Bedeutung von Positionsdaten für diverse Fragestellungen von Spielanalyt*innen und Sportinformatiker*innen wird detailliert in ► Kap. 6 beschrieben. Allerdings sind Positionsdaten in der Regel nicht frei verfügbar und die Erstellung solcher Positionsdaten erfordert spezielle mobile Geräte oder

mehrere Kameras, bis hin zu vorinstallierten Kamerasystemen im Stadion, die nur im Profibereich eingesetzt werden können. Mittels einer Videoaufzeichnung aus einer einzelnen Kameraperspektive und Informationen über das Spielfeld (Spielfeldbegrenzungen) ist es jedoch möglich, Positionsdaten zu schätzen. Auf diese Weise können auch Analysen für den Amateurbereich oder von Trainingsprozessen ermöglicht werden.

4.2 Hintergrund

Positionsdaten helfen einerseits, Spiele durch eine abstrakte Repräsentation relativ schnell objektiv auszuwerten, andererseits gehen dabei naturgemäß viele Detailinformationen verloren. Dazu zählen Informationen über Aktionen (Kopfball, Grätsche etc.), Haltung bzw. Pose, Kopf-/Blickrichtung, sowie Bewegungsdetails. Zur Erfassung solcher Informationen können aktuelle Verfahren des maschinellen Sehens (engl. *computer vision*) auf Videodaten angewendet werden, die in der Regel auf Deep-Learning-Modellen (s. ► Kap. 20 und 21) basieren. In den letzten Jahren wurden einige Ansätze vorgestellt, die Aktionen in Sportvideos mit exakten Zeitpunkten detektieren (Biermann et al. 2021, Delière et al., 2021; Giancola & Ghanem, 2021). Ansätze zur Bestimmung der Körperpose (Kreiss et al., 2019; Cao et al., 2021) erkennen markante Punkte (engl. *key points*, z. B. Schultern, Hüfte, Knie, Gelenke etc.) für die abgebildeten Personen, um die Körperhaltung darzustellen. Diese Ansätze werden u. a. mit Videos aus Domänen des Mannschafts- und Individualsports trainiert und wurden bereits für verschiedene Sportarten erfolgreich angewendet, um beispielsweise mögliche Passoptionen zu bewerten (Sangüesa et al., 2020) oder Elfmeter zu analysieren (Sousa Pinheiro et al., 2022).

Positionsdaten erlauben eine Reihe zusätzlicher Anwendungen. Deshalb sind in den letzten Jahren immer mehr Ansätze zur Spielfeldregistrierung (Chen & Little, 2019; Sha et al., 2020; Theiner & Ewerth, 2023), die für die Extraktion von Positionsdaten aus Videos wichtig ist, vorgeschlagen worden. Diese Ansätze erlauben es, den sichtbaren Teil des Spielfeldes in den Bild- bzw. Videodaten in ein 2D-Modell des Spielfeldes zu überführen. In Kombination mit Ansätzen zur Objektdetektion (Zhou et al., 2020), haben Theiner et al. (2022) ein erstes System zur Extraktion von Positionsdaten aus Fernsehaufzeichnungen und Scouting-Feed-Aufnahmen von Fußballspielen vorgestellt.

Neben den zuvor genannten Forschungsthemen existieren noch weitaus mehr Forschungsfelder im Bereich der KI-basierten Sportvideoanalyse. Dazu zählen beispielsweise die automatische Generierung von Highlight-Videos (Decroos et al., 2017) sowie das Tracking und die (Re-)Identifikation (auch über verschiedene Kameraeinstellungen hinweg) von Personen und Spielgeräten (Rematas et al., 2018; Cioppa et al., 2022; Habel et al., 2022). Des Weiteren haben sich Forscher*innen mit Softwaretools (z. B. *SportSense* von Probst et al., 2018) und Informationsvisualisierungen (Fischer et al., 2019) für effektive Analyseprozesse mittels Sportvideos beschäftigt. Neben den zuvor genannten Forschungsansätzen existieren auch diverse kommerzielle Lösungen zur Analyse von Sportvideos, wie z. B. *SkillCorner* (► <https://skillcorner.com/>) und *Stats Perform* (► <https://www.statsperform.com>).

4.3 Grundlagen und Definition

Digitale Videos bestehen aus einer Reihe von Einzelbildern, die mit einer Frequenz von üblicherweise 25 bis 100 Bildern (engl. *frames*) pro Sekunde aufgezeichnet werden. Für die menschliche Wahrnehmung eines Bewegungseindrucks sind mindestens 15 Bilder pro Sekunde notwendig. Videodaten sind daher sehr speicherintensiv. Ein Video mit einer räumlichen Auflösung von 1920×1080 Pixeln mit drei Farbkanälen für die Primärfarben Rot, Grün und Blau mit je 8 Bit benötigt bei einer Bildwiederholfrequenz von 30 Hz ohne Kompression bereits ca. 178 MByte pro Sekunde. Daher kommen *verlustbehaftete* Kompressionsverfahren zum Einsatz, die die Redundanz zwischen rasch aufeinanderfolgenden Bildern ausnutzen und Bewegungen von Bild zu Bild schätzen können. Diese Kompressionsverfahren können bei weitgehender Erhaltung der Qualität die benötigte Datenmenge erheblich reduzieren. Zur Nachbearbeitung von Videos ist eine Video-Editing-Software notwendig (Schnittsoftware, Schnittprogramm), die z. B. erlaubt, einzelne Videosegmente auszuwählen, in anderer Reihenfolge aneinanderzufügen, die Bildqualität zu verbessern oder Textinformation einzufügen oder über den Bildinhalt zu legen.

Videos von Wettbewerben und Trainingseinheiten können aus verschiedenen Kameraeinstellungen mit unterschiedlichen Charakteristiken aufgezeichnet werden. In *SoccerNet* (► <https://www.soccer-net.org/>) von Delière et al. (2021), einer der größten Datensammlungen im Fußball, wird zwischen 13 Kameraeinstellungen unterschieden. Die Einstellungen reichen von einer Hauptkamera, die das Spielgeschehen zum größten Teil abdeckt, über Kameras für Nahaufnahmen (engl. *close-ups*) bis hin zu Torkameras. Darüber hinaus existieren auch Scouting-Feed-Aufnahmen von Fußballspielen, die üblicherweise (fast) das komplette Spielfeld abdecken und sich daher besonders für taktische Analysen eignen. Nahaufnahmen hingegen bilden bestimmte Bewegungsabläufe detaillierter ab und eignen sich deshalb beispielsweise für biomechanische Analysen.

4.4 Anwendungen

► Beispiel 1 (Aktionsdetektion)

Durch KI-basierte Ansätze zur automatischen Detektion von Aktionen in Videos können Video- und Positionsdaten mit weiteren Metainformationen angereichert werden. Der *SoccerNet*-Datensatz von Delière et al. (2021) enthält 500 Videos, die für 17 wichtige Aktionen im Fußball, darunter Tore, Fouls, sowie Schüsse auf und neben das Tor, annotiert sind. Aktuelle Deep-Learning-Ansätze wie von Giancola & Ghanem (2021) erzielen bereits vielversprechende Resultate beim Finden von Aktionen in den Videos. Mithilfe solcher Ansätze kann effizient nach bestimmten Aktionen in Videos und gro-

ßen Videosammlungen gesucht werden. Beispielsweise könnten Standardsituationen oder Situationen, die zum Torerfolg geführt haben, für ausgewählte Mannschaften, Spiele etc. genauer analysiert werden. Zum anderen ist es möglich, ausgehend von einer gewählten Szene, ähnliche Szenen in Bezug auf Anzahl und Typ der darin abgebildeten Aktionen in demselben oder in anderen Videos zu finden. Dies erlaubt es Spielanalysten*innen, gezielt nach bestimmten taktischen Mustern zu suchen. Eine bestehende Limitierung des *SoccerNet*-Datensatzes ist, dass wichtige Aktionen wie Pässe sowie Attribute (z. B., ob flacher oder hoher Pass) zur Beschreibung einer Aktion nicht annotiert sind. Eine entsprechende Taxonomie für eine möglichst vollumfängliche Abdeckung von Aktionen in Invasionssportarten haben Biermann et al. (2021) vorgestellt. Mithilfe von entsprechend annotierten Trainingsdaten können aktuelle Methoden (z. B. Giancola & Ghanem, 2021) zukünftig mit diesen Klassen erweitert werden. ◀

► Beispiel 2 (Poseninformationen)

Videoaufzeichnungen von Sportler*innen enthalten wichtige Details zu Körperpose und Bewegungen. Sangüesa et al. (2020) nutzen das Deep-Learning-Verfahren *OpenPose* (Cao et al., 2021), um Poseninformationen aus Videodaten von Fußballspielen zu extrahieren und daraus die Körperorientierung des Passgebers und möglicher Passempfänger zu bestimmen. Die Positionsdaten werden mit den Metainformationen zur Körperpose angereichert, um die wahrscheinlichsten Passoptionen unter Berücksichtigung der Positionierung verteidigender Spieler*innen voraussagen. Das Verfahren wurde auf Grundlage von elf Spielen des FC Barcelona mit insgesamt 6038 Pässen ausgewertet. Durch die Verknüpfung von Informationen zur Körperorientierung mit Positionsdaten konnten bessere Ergebnisse bei der Vorhersage der tatsächlichen Passempfängerin bzw. des tatsächlichen Passempfängers erzielt werden als mit einem Referenzverfahren, das ausschließlich Positionsdaten verwendet. Damit hat sich die Körperorientierung in einem multimodalen Modell zur Passvorhersage als ein Schlüsselmerkmal im Entscheidungsprozess der Spieler*innen erwiesen. ◀


► Beispiel 3 (Spielererkennung und -verfolgung)

KI-basierte Methoden zur Wiedererkennung erlauben es, Sportler*innen über Videoframes und Kameraeinstellungen hinweg zu verfolgen (*tracken*). Cioppa et al. (2022) haben einen Datensatz mit 200 Videosequenzen aus zwölf Fußballspielen mit jeweils einer Länge von 30 Sekunden veröffentlicht und damit verschiedene State-of-the-Art-Verfahren zur gleichzeitigen Verfolgung mehrerer Objekte (engl. *multi-object tracking*) optimiert. Durch das Tracking von Spieler*innen können Bewegungen in Form von Trajektorien aus Videodaten extrahiert werden, die beispielsweise zur Analyse von Laufmustern oder Spielzügen eingesetzt werden können. Insbesondere in Kombination mit Verfahren zur *Spielfeldregistrierung* (s. Studienbox) können die Bewegungen auch auf einem 2D-Spielfeldmodell abgebildet werden, um so auch biomechanische Leistungsindikatoren (z. B. Laufdistanzen, Laufgeschwindigkeiten) zu schätzen und weitere Analysen auf Grundlagen von Positionsdaten (s. ► Kap. 6) durchzuführen. ◀

Studienbox

Theiner et al. (2022) haben ein erstes System (■ Abb. 4.1) vorgestellt, das aktuelle Verfahren des maschinellen Sehens kombiniert, um Positionsdaten in Fernsehübertragungen und Southing-Feed-Aufzeichnungen von Fußballspielen automatisch zu schätzen. Hierfür werden Spielfeld und Spielfeldmarkierungen im Videobild segmentiert und mithilfe eines Deep-Learning-Ansatzes (Chen & Little, 2019) mit einer Referenzdatenbank von synthetischen Spielfeldaufnahmen mit bekannten Kameraparametern verglichen. Auf Basis der Kameraparameter des ähnlichsten Referenzbildes wird eine *Homographiematrix* bestimmt. Anschließend kann die Homographiematrix zur Transformation des Videobildes in ein 2D-Spielfeldmodell angewendet werden. Diese sogenannte *Spielfeldregistrierung* haben Theiner & Ewerth (2023) durch

eine Schätzung von Kameraparametern über eine iterative Optimierung der Reprojektionsfehlers geometrischer Primitive (Liniensegmente des Spielfeldes) zum 2D-Spielfeldmodell weiter optimiert. Schließlich werden Spieler*innen und Ball mithilfe eines Deep-Learning-Ansatzes (Zhou et al., 2020) in den Videobildern detektiert und zur Bestimmung von Positionsdaten durch die Homographiematrix ins 2D-Spielfeldmodell transformiert. Das System hat sehr gute Ergebnisse erzielt und bietet eine erste Grundlage für die Durchführung verschiedener Analysen auf Basis von Positionsdaten (s. ► Kap. 6), wie beispielsweise die automatische Erkennung von Fußballformationen (Müller-Budack et al., 2019), Raumkontrolle (Memmert et al., 2019) und weiteren Key-Performance-Indikatoren (KPIs).



■ Abb. 4.1 System zur Extraktion von Positionsdaten. (Theiner et al., 2022)

? Fragen für die Studierenden

1. Was sind die besonderen Charakteristika von Videodaten?
2. Welche Vor- und Nachteile haben Videodaten gegenüber Positionsdaten?
3. Welche Aufgabenstellungen können mit KI-basierten Ansätzen in Sportvideos gelöst werden?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Biermann, H., Theiner, J., Bassek, M., Raabe, D., Memmert, D., & Ewerth, R. (2021). A Unified Taxonomy and Multimodal Dataset for Events in Invasion Games. *International Workshop on Multimedia Content Analysis in Sports co-located with the ACM Multimedia, MMSports@MM 2021, Virtual Event, 2021*, 1–10. ACM.
- Cao, Z., Hidalgo, G., Simon, T., Wei, S.-E., & Sheikh, Y. (2021). OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43, 172–186. IEEE.
- Chen, J., & Little, J. J. (2019). Sports Camera Calibration via Synthetic Data. *IEEE Conference on Computer Vision and Pattern Recognition Workshops, CVPR Workshops 2019, Long Beach, CA, USA, 2019*, 2497–2504. IEEE.
- Cioppa, A., Giancola, S., Deliège, A., Kang, L., Zhou, X., Cheng, Z., Ghanem, B., & Droogenbroeck, M. V. (2022). SoccerNet-Tracking: Multiple Object Tracking Dataset and Benchmark in Soccer Videos. *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, CVPR Workshops 2022, New Orleans, LA, USA, 2022*, 3490–3501. IEEE/CVF.
- Decroos, T., Dzyuba, V., Haaren, J. V., & Davis, J. (2017). Predicting Soccer Highlights from Spatio-Temporal Match Event Streams. *AAAI Conference on Artificial Intelligence, San Francisco, California, USA, 2017*, 1302–1308. AAAI Press.
- Deliège, A., Cioppa, A., Giancola, S., Seikavandi, M. J., Dueholm, J. V., Nasrollahi, K., Ghanem, B., Moeslund, T. B., & Droogenbroeck, M. V. (2021). SoccerNet-v2: A Dataset and Benchmarks for Holistic Understanding of Broadcast Soccer Videos. *IEEE Conference on Computer Vision and Pattern Recognition Workshops, CVPR Workshops 2021, Virtual Event, 2021*, 4508–4519. IEEE.
- Fischer, M. T., Keim, D. A., & Stein, M. (2019). Video-based Analysis of Soccer Matches. *International Workshop on Multimedia Content Analysis in Sports co-located with the ACM Multimedia, MMSports@MM 2019, Nice, France, 2019*, 1–9. ACM.
- Giancola, S., & Ghanem, B. (2021). Temporally-Aware Feature Pooling for Action Spotting in Soccer Broadcasts. *IEEE Conference on Computer Vision and Pattern Recognition Workshops, CVPR Workshops 2021, Virtual Event, 2021*, 4490–4499. IEEE.
- Habel, K., Deuser, F., & Oswald, N. (2022). CLIP-ReIdent: Contrastive Training for Player Re-Identification. *International Workshop on Multimedia Content Analysis in Sports co-located with the ACM Multimedia, MMSports@MM 2022, Lisboa, Portugal, 2022*, 129–135. ACM.

- Kreiss, S., Bertoni, L., & Alahi, A. (2019). PifPaf: Composite Fields for Human Pose Estimation. *IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2019, Long Beach, CA, USA, 2019*, 11977–11986. IEEE.
- Memmert, D., Raabe, D., Schwab, S. & Rein, R. (2019). A tactical comparison of the 4-2-3-1 and 3-5-2 formation in soccer: A theory-oriented, experimental approach based on positional data in an 11 vs. 11 game set-up. *PLoS one*, 14.
- Müller-Budack, E., Theiner, J., Rein, R., & Ewerth, R. (2019). “Does 4-4-2 exist?” – An Analytics Approach to Understand and Classify Football Team Formations in Single Match Situations. *International Workshop on Multimedia Content Analysis in Sports co-located with the ACM Multimedia, MMSports@MM 2019, Nice, France, 2019*, 25–33. ACM.
- Probst, L., Kabary, I. A., Lobo, R., Rauschenbach, F., Schuldt, H., Seidenschwarz, P., & Rumo, M. (2018). SportSense: User Interface for Sketch-Based Spatio-Temporal Team Sports Video Scene Retrieval. *ACM Conference on Intelligent User Interfaces Workshops, ACM IUI Workshops 2018, Tokyo, Japan, March 11, 2018*, Vol. 2068. CEUR-WS.org.
- Rematas, K., Kemelmacher-Shlizerman, I., Curless, B., & Seitz, S. M. (2018). Soccer on Your Tabletop. *IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2018, Salt Lake City, UT, USA, 2018*, 4738–4747. IEEE.
- Sangüesa, A. A., Martín, A., Fernández, J., Ballester, C., & Haro, G. (2020). Using Player’s Body-Orientation to Model Pass Feasibility in Soccer. *IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR Workshops 2020, Seattle, WA, USA, 2020*, 3875–3884. IEEE/CVF.
- Sha, L., Hobbs, J. A., Felsen, P., Wei, X., Lucey, P., & Ganguly, S. (2020). End-to-End Camera Calibration for Broadcast Videos. *IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2020, Seattle, WA, USA, 2020*, 13624–13633. IEEE.
- de Sousa Pinheiro, G., Jin, X., Da Costa, V. T., & Lames, M. (2022). Body Pose Estimation Integrated With Notational Analysis: A New Approach to Analyze Penalty Kicks Strategy in Elite Football. *Frontiers in Sports and Active Living*, 4.
- Theiner, J. & Ewerth, R. (2023). Keypoint-less Camera Calibration for Sports Field Registration in Soccer. *IEEE/CVF Winter Conference on Applications of Computer Vision, WACV 2023, Waikoloa, HI, USA, 2023*, 1166–1175. IEEE/CVF.
- Theiner, J., Gritz, W., Müller-Budack, E., Rein, R., Memmert, D., & Ewerth, R. (2022). Extraction of Positional Player Data from Broadcast Soccer Videos. *IEEE/CVF Winter Conference on Applications of Computer Vision, WACV 2022, Waikoloa, HI, USA, 2022*, 1463–1473. IEEE/CVF.
- Zhou, X., Koltun, V., & Krähenbühl, P. (2020). Tracking Objects as Points. *European Conference on Computer Vision, ECCV 2020, Glasgow, UK, 2020*, 474–490. Springer.



Reale Datensätze – Eventdaten

Marc Garnica Caparrós

Inhaltsverzeichnis

- 5.1 Beispiel Sport – 40
- 5.2 Hintergrund – 41
- 5.3 Anwendung – 42
- Literatur – 45

Kernbotschaften

- Unter Eventdaten versteht man die zeitlich geordnete Sammlung aller Aktionen, die in einem Invasionssportspiel wie Fußball oder Basketball stattfinden.
- Eventdaten enthalten nicht nur zeit- und sportartspezifische Attribute, sondern ordnen auch alle Ereignisse im Feld zu und können benutzerdefinierte Attribute umfassen, um die Datenanalyse zu bereichern.
- Invasionssportarten sind ein komplexes Zusammenspiel mehrerer Spieler. Eventdaten können dabei helfen, die Abläufe eines Spiels zu verbreiten und das Ergebnis zu verstehen.
- Mithilfe von Eventdaten lassen sich fortgeschrittene Spielstatistiken erstellen, mit denen die Aktivitäten bestimmter Spieler in bestimmten Situationen kontextualisiert werden können.
- In den letzten Jahren wurden mehrere probabilistische Modelle vorgestellt, die darauf abzielen, die Kette von Events zu analysieren, die zu einem bestimmten Teamziel führen, wie z. B. die Metrik Expected Goals.
- Nicht alle Tore sind gleich erzielt. Eventdaten enthalten wichtige Informationen, um zu verstehen, was, wo und wie es passiert.
- Eine korrekte Verwaltung und Modellierung von Eventdaten kann zu einem besseren Verständnis der Mannschaftstaktik und des Beitrags der Spieler beitragen.

5.1 Beispiel Sport

Es ist noch gar nicht so lange her, dass Fußballspieler hauptsächlich nur nach ihrer Torfähigkeit bewertet wurden. Spielerauszeichnungen wurden dann mit den Spielern mit der höchsten Offensivaktivität und -effizienz in Verbindung gebracht. Vor dem explosionsartigen Anstieg des Interesses an Leistungsstatistiken und wichtigen Leistungsindikatoren für den Beitrag der Spieler wurden dem Assist (d. h. dem Pass, der einem anderen Spieler ein Tor ermöglicht) und der Passgenauigkeit mehr Aufmerksamkeit geschenkt. Heutzutage und in den Jahren, in denen die Analytik im Fußball und in anderen Sportarten am weitesten fortgeschritten ist, werden die Spieler sowohl in der Offensive als auch in der Defensive sehr detailliert bewertet. Die kurze Sequenz zwischen einem Tor und dem vorangegangenen Pass wurde erheblich erweitert: Wie wurde das Angriffsspiel eingeleitet? Wer hat den Ball in die Angriffszone gebracht, wo der Assist ausgeführt wurde? Der Trainingsstab misst die Leistung eines Spielers nicht mehr nur an den letzten Bewegungen vor einem Tor, sondern an einer größeren und aussagekräftigeren Abfolge von Ereignissen (Events), die zu einem Tor führen. Diese Abfolge von x-y-verorteten Ereignissen auf dem Spielfeld ist die Grundlage von Eventdaten, einer zeitbasierten Aufzeichnung aller während des Spiels stattfindenden Aktionen. Die Analyse von Eventdaten ist zu einem entscheidenden Aspekt jeder professionellen Fußball-

mannschaft geworden, wobei die wichtigsten Anwendungen aus dem „Pattern Mining“, der Sequenzanalyse und den Assoziationsregeln stammen. Im Fußball haben Eventdaten zur Entstehung fortschrittlicher Metriken wie Expected Goals (xG) (Caley, 2015) und anderen Erweiterungen geführt, aber nicht nur im Fußball, sondern auch in Sportarten wie Basketball, wo Eventdaten ebenfalls eine der im täglichen Betrieb am häufigsten verwendeten Datenquellen sind, mit erwarteten Metriken wie Expected Possession Value (Cervone et al., 2014).

5.2 Hintergrund

Das Aufkommen von hochgranularen Daten ist einer der Hauptmotoren der Big-Data-Analytik-Revolution, die die Sportindustrie in den letzten zehn Jahren erlebt hat. Beim Betrachten oder Spielen von Invasionssportarten (Hughes & Bartlett, 2002), also von Sportarten mit solchen gemeinsamen Merkmalen wie Fußball, gibt es mehrere Möglichkeiten, das Spiel anhand von Daten zu reproduzieren. Box-Score-Statistiken, oft als Match-Sheet-Daten bezeichnet, vermitteln ein sehr intuitives Bild der Aktionen, die während des Spiels stattgefunden haben, z. B. die Anzahl der Pässe einer bestimmten Mannschaft in einem Basketballspiel (Oliver, 2004) oder die Anzahl der Schüsse in einem Fußballspiel. Diese Daten stellen jedoch eine diskrete Zusammenfassung dar und vernachlässigen die Interaktionen, die zeitliche Abfolge und die Distribution des Spiels. Die zeitlichen Informationen, d. h., wann die Ereignisse stattfinden und in welcher Reihenfolge, wurden den sogenannten Play-by-Play-Daten hinzugefügt, einer geordneten Textsammlung aller Aktionen, die von beiden Mannschaften während eines Spiels durchgeführt werden. Diese Art von Datenquelle lieferte nicht nur eine genauere Beschreibung des Spiels, sondern ermöglichte auch eine sequenzbasierte Analyse von Ereignissen (Carling et al., 2008), wodurch die Aufmerksamkeit auf die Ereigniskette und nicht auf das Auftreten eines einzelnen Ereignisses gelenkt wurde.

Die Sammlung von Play-by-Play-Daten motivierte die Untersuchung zeitlicher Interaktionen bei Invasionssportarten. In einigen Fällen könnte die Verarbeitung dieses textuellen Logs Ad-hoc-Box-Scores mit zeitlichen Kriterien erzeugen. Zum Beispiel könnte die zeitliche Distribution der Ereignisse Informationen über die Struktur und die Merkmale des Sports liefern (Alberti et al., 2013). Trotz des Informationszuwachses in dieser Datenquelle waren die Textinformationen zu jeder Aktion im Spiel oft nicht hinreichend, was ihre Anwendung und Studien einschränkt. Dank der Fortschritte bei den Datenerfassungstechnologien und Computer-Vision-Systemen (Gudmundsson & Horton, 2018) entwickelten sich die Play-by-Play-Daten zu den sogenannten Eventdaten. Eventdaten ermöglichen ein besseres Verständnis des Invasionssportspiels, da sie räumlich-zeitliche Informationen über alle während des Spiels stattfindenden Aktionen sowie verschiedene Kontextmarker enthalten. Das Auftreten von raum-zeitlichen Eventdaten in Invasionssportarten ist oft mit einer anderen Datenquelle verbunden, den Tracking-

oder Positionsdaten (Goes et al., 2020; Bourbousson et al., 2010). Bei Positionsdaten handelt es sich um eine hochgranulare Datenquelle, die durch optische Tracking-Systeme oder sensorbasierte Technologien erfasst wird. Diese Datenquelle umfasst die Positionen aller Spieler und des Balls mit hoher Frequenz. Positionsdaten enthalten mehr Informationen als Eventdaten, sind aber oft schwieriger effizient zu analysieren. Eventdaten werden in der Regel für das Coaching, das Scouting oder die Leistungsanalyse verwendet und sind zu einem Kernbestandteil jeder datengesteuerten Sportorganisation, insbesondere von Vereinen und Verbänden, geworden. Obwohl die meisten der verwendeten Eventdaten derzeit durch eine Mischung aus manuell kommentierten Verfahren und automatischen Systemen erfasst werden, dehnen die Fortschritte bei der automatischen Notation von Sportspielen diese Datenquelle auf alle Ligen und Akademien aus (Biermann et al., 2021).

Definition

Eventdaten sind definiert als die zeitlich geordnete Sammlung aller Aktionen (Ereignisse), die in einem Invasionssportspiel stattfinden. Zu den Eventdaten gehören unter anderem systematische Informationen wie der Zeitstempel, wann das Ereignis eingetreten ist, der Hauptakteur des Ereignisses (z. B. der Spieler, der den Pass ausführt), die Mannschaft, die räumlichen Merkmale des Ereignisses (d. h. die x- und y-Koordinaten des Ereignisses im Spielfeld) und das Ergebnis des Ereignisses (z. B., ob der Pass akkurat war oder nicht) sowie sportspezifische Attribute. Im Fußball könnten Ereignisse beispielsweise mit dem Körperteil erweitert werden, mit dem die Aktion ausgeführt wurde (linker Fuß, rechter Fuß, Kopf), mit der Art des Ereignisses (z. B. diagonale Pässe, durchgehende Pässe, Pässe mit Chips) oder mit der Schwierigkeit des Ereignisses (z. B. die Anzahl der Verteidiger vor dem Tor, die Position des Torwarts beim Schuss usw.). Zu den aktuellen Fortschritten bei Eventdaten im Fußball gehört bei jedem Ereignis der Standort aller Spieler und des Balls als wichtiges Kontextattribut (StatsBomb, 2021). Eventdaten gibt es in vielen Invasionssportarten wie Fußball, Basketball, Handball, Hockey und Rugby.

5.3 Anwendung

■ *Eventdaten zur Erweiterung der Boxscore-Statistiken*

Beispiel 1: Der Aufstieg des Frauenfußballs hat sich in den letzten Jahren als Leitfaden für viele andere Sportorganisationen erwiesen, um die Gleichstellung im Sport zu fördern und zu motivieren. In einer aktuellen Studie wurden die techni-

schen und taktischen Unterschiede zwischen Männer- und Frauenfußball anhand von Eventdaten verglichen (Garnica-Caparrós & Memmert, 2021). Um die detailliertesten Statistiken zur Zusammenfassung eines Fußballspiels zu extrahieren und den Vergleich zu erweitern, nutzte die Studie Eventdaten aus zwei Wettbewerben (51 Spiele der UEFA-Europameisterschaft der Männer 2016 und 31 Spiele der UEFA-Europameisterschaft der Frauen 2017). Aus über 100.000 Ereignissen wurden 33 diskrete Merkmale erstellt, die nach dem Zeitraum des Spiels und der Spielerposition unterteilt wurden. Es wurde eine subjektive Vergleichsmethode unter Verwendung von Werkzeugen des maschinellen Lernens für die Interpretation vorgestellt. Insgesamt zeigte die Studie zentrale Faktoren auf, die die Leistung der einzelnen Geschlechter unterscheiden, sowie Muster, die mehrere Indikatoren umfassen.

■ *Eventdaten zur Bewertung von Aktionen im Spiel und Auswirkungen auf den Spieler*

Beispiel 2: Um die Ansätze zu erweitern, die von der Metrik Expected Goals (xG) angeführt werden, wurde das gesamte Potenzial der Eventdaten mit dem Ziel genutzt, die Auswirkungen jeder Aktion in einem Fußballspiel zu messen (Decroos et al., 2020). Der VAEP (Valuing Actions by Estimating Probabilities)-Framework versucht, jedem einzelnen Ereignis einen Beitrag zuzuordnen, indem er die Wahrscheinlichkeiten eines Treffers und eines Gegentreffers vor und nach dem Ereignis misst. Damit zielt dieser Ansatz darauf ab, bestehende Methoden zu verbessern, die sich nur auf seltene Ereignisse, wie z. B. Schüsse, stützen, um die Leistung eines Spielers oder einer Mannschaft zu bewerten. Insgesamt kann der VAEP-Framework verwendet werden, um die offensiven und defensiven Leistungen eines Spielers oder einer Mannschaft zu quantifizieren.

■ *Eventdaten zum Verständnis der Spielerinteraktionen*

Beispiel 3: Die in den Eventdaten enthaltenen Informationen ermöglichen die Analyse des Teamverhaltens als komplexes System von Interaktionen. (Duch et al., 2010) heben die Leistungsfähigkeit der Netzwerkanalyse hervor, um die Interaktion zwischen Spielern in einem Team zu verstehen. Passnetzwerke (Passing Networks) wurden als visuelle Definition von Teamarbeit vorgestellt und quantifizierten den Beitrag von Einzelpersonen und der Teamleistung. Ein Passnetzwerk kann aus einfachen Eventdatenquellen erstellt werden, wobei die Knoten des Netzwerks die Spieler einer Mannschaft und die Kanten ihre Verbindung während des Spiels (d. h. Pässe) darstellen. Die gewichteten Kanten geben einen Überblick über die häufigsten Interaktionen und über die für die Mannschaftstaktik entscheidenden Spieler. Falls verfügbar, können die Knoten auch der durchschnittlichen Position der Spieler auf dem Feld zugeordnet werden, was eine Gesamtaufteilung der Mannschaft auf dem Feld und einen x-y-basierten Überblick über ihre Taktik ermöglicht.

Studienbox

5

Die derzeitige Forschung zur Nutzung von Eventdatenquellen zum Verständnis von Invasionssportarten wird durch probabilistische Modelle vorangetrieben, die die Arbeit der xG-Metrik und des VAEP-Frameworks erweitern. Die vorherrschende Verwendung in Sportorganisationen schafft jedoch einen Bedarf an einer demokratischeren, interpretierbaren und anpassbaren Anwendung der sequenzbasierten Analyse von Eventdaten. Eine aktuelle Studie (Kröckel & Bodendorf, 2020) schlägt einen verallgemeinerbaren Rahmen für die Analyse von Spielerbeiträgen, Mannschaftstaktiken und Sequenzanalysen im Fußball vor, der auch auf an-

dere Invasionssportarten übertragen werden könnte. Process Mining als Werkzeug könnte als Einstiegspunkt dienen, um das Potenzial detaillierter Eventdatenquellen über die Berechnung fortgeschrittener Box-Score-Statistiken hinaus zu entfalten. Ein prozessbasiertes Management könnte auch die Reproduzierbarkeit von Abläufen in experimentellen Ansätzen durch Simulation ermöglichen. Oversampling und künstliche Modellierung von Ereignisabläufen könnten das vorhandene Wissen über Algorithmen für erwartete Metriken erweitern und ihre Interpretation verfeinern.

? Fragen für die Studierenden

1. Was ist der Hauptunterschied zwischen Play-by-Play und Eventdaten?
2. Wie verbessern die Eventdaten die Box-Score- oder Match-Sheet-Informationen?
3. Wie ist der VAEP-Framework in der Lage, den Beitrag der einzelnen Aktionen im Spiel zu messen?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Alberti, G., Iaia, F. M., Arcelli, E., Cavaggioni, L., & Rampinini, E. (2013, September). Goal scoring patterns in major European soccer leagues. *Sport Sciences for Health*, 9, 151–153. doi:<https://doi.org/10.1007/s11332-013-0154-9>
- Biermann, H., Theiner, J., Bassek, M., Raabe, D., Memmert, D., & Ewerth, R. (2021). A Unified Taxonomy and Multimodal Dataset for Events in Invasion Games. doi:<https://doi.org/10.48550/ARXIV.2108.11149>
- Bourbousson, J., Sève, C., & McGarry, T. (2010, February). Space–time coordination dynamics in basketball: Part 2. The interaction between the two teams. *Journal of Sports Sciences*, 28, 349–358. doi:<https://doi.org/10.1080/02640410903503640>
- Caley, M. (2015). *EPL projections and expected goals method: Spurs are good!* Retrieved October 4, 2022, from <https://cartilagefreecaptain.sbnation.com/2015/10/19/9295905/premier-league-projections-and-new-expected-goals>
- Carling, C., Bloomfield, J., Nelsen, L., & Reilly, T. (2008). The Role of Motion Analysis in Elite Soccer. *Sports Medicine*, 38, 839–862. doi:<https://doi.org/10.2165/00007256-200838100-00004>
- Cervone, D., D'Amour, A., Bornn, L., & Goldsberry, K. (2014). A Multiresolution Stochastic Process Model for Predicting Basketball Possession Outcomes. doi:<https://doi.org/10.48550/ARXIV.1408.0777>
- Decroos, T., Bransen, L., Haaren, J. V., & Davis, J. (2020, July). VAEP: An Objective Approach to Valuing On-the-Ball Actions in Soccer (Extended Abstract). *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization. doi:<https://doi.org/10.24963/ijcai.2020/648>
- Duch, J., Waitzman, J. S., & Amaral, L. A. (2010, June). Quantifying the Performance of Individual Players in a Team Activity. (E. Scalas, Ed.) *PLoS ONE*, 5, e10937. doi:<https://doi.org/10.1371/journal.pone.0010937>
- Garnica-Caparrós, M., & Memmert, D. (2021, May). Understanding gender differences in professional European football through machine learning interpretability and match actions data. *Scientific Reports*, 11. doi:<https://doi.org/10.1038/s41598-021-90264-w>
- Goes, F. R., Meerhoff, L. A., Bueno, M. J., Rodrigues, D. M., Moura, F. A., Brink, M. S., . . . Lemmink, K. A. (2020, April). Unlocking the potential of big data to support tactical performance analysis in professional soccer: A systematic review. *European Journal of Sport Science*, 21, 481–496. doi:<https://doi.org/10.1080/17461391.2020.1747552>
- Gudmundsson, J., & Horton, M. (2018, March). Spatio-Temporal Analysis of Team Sports. *ACM Computing Surveys*, 50, 1–34. doi:<https://doi.org/10.1145/3054132>
- Hughes, M. D., & Bartlett, R. M. (2002, January). The use of performance indicators in performance analysis. *Journal of Sports Sciences*, 20, 739–754. doi:<https://doi.org/10.1080/026404102320675602>
- Korte, F., Link, D., Groll, J., & Lames, M. (2019, July). Play-by-Play Network Analysis in Football. *Frontiers in Psychology*, 10. doi:<https://doi.org/10.3389/fpsyg.2019.01738>
- Kröckel, P., & Bodendorf, F. (2020, July). Process Mining of Football Event Data: A Novel Approach for Tactical Insights Into the Game. *Frontiers in Artificial Intelligence*, 3. doi:<https://doi.org/10.3389/frai.2020.00047>
- Oliver, D. (2004). *Basketball on Paper*. Potomac Books Inc.
- StatsBomb (2021). *StatsBomb*. Retrieved from <http://www.statsbomb.com/>



Reale Datensätze – Positionsdaten

Daniel Memmert

Inhaltsverzeichnis

- 6.1 Beispiel Sport – 48**
- 6.2 Hintergrund – 48**
- 6.3 Anwendungen – 49**
- Literatur – 52**

Kernbotschaften

- Positionsdaten beschreiben die Positionen/Bewegungen von Sportlern und Spielgeräten in Form von x-y-Koordinaten.
- Positionsdaten spiegeln die komplexe Wirklichkeit wider, sind reliabel, können objektiv sowie extrem schnell ausgewertet werden.
- Auf der Basis von Positionsdaten kann man leistungsrelevante Parameter aus Training und Wettkampf analysieren.
- Experimentelle Ansätze können in der Zukunft dazu beitragen, dass in verschiedenen Bereichen der Sportwissenschaft und Sportinformatik Theorien entwickelt und überprüft werden können.

6

6.1 Beispiel Sport

Anhand von drei Beispielen aus dem Sportspiel Fußball soll verdeutlicht werden, welche Fragen Spielanalysten – aber auch Sportinformatiker – in den unterschiedlichsten Mannschaftssportspielen haben, die auf der Basis von Positionsdaten beantwortet werden können. Erstens ist es wichtig zu wissen, welche Räume auf dem Fußballfeld von welchen Spielern wann besetzt werden. Neben solchen sogenannten Raumkontroll-Werten ist außerdem von Interesse, wie sich Kontrollanteile mit dem eigenen Passspiel verschieben: Wie groß ist der Raumgewinn im Spielaufbau oder bei Schnittstellenpässen vor dem gegnerischen Tor? Zweitens ist beim Umschaltverhalten einer Mannschaft wichtig zu wissen, wie schnell und wo die Spieler einer Mannschaft den Gegner nach eigenem Ballverlust anlaufen. Auf diese Weise kann nicht nur die Erfolgsquote im Pressing beziffert werden, sondern auch die Aggressivität, mit welcher eine Mannschaft nach Ballverlust umschaltet. Drittens kann man bestimmen, wie viele Gegenspieler einen ballführenden Spieler noch verteidigen können – sowohl bevor als auch nachdem dieser einen Pass gespielt hat. Die beiden Werte geben bereits Aufschluss darüber, wie viele Spieler eine Mannschaft beim Verteidigen hinter den Ball stellt (Rest-Verteidigung), aber ebenso interessant ist die Differenz: Sie zeigt an, wie viele Gegenspieler ein Pass letztlich überspielt und so aus dem Spiel nimmt. Dieser Wert erweist sich als gutes Mittel zur Beurteilung von Vertikalpässen und lässt sich beliebig verfeinern, indem man beispielsweise neben den überspielten Gegenspielern zusätzlich den Druck integriert, welchen die Gegenspieler auf Passgeber und -nehmer zum Zeitpunkt der Abgabe und Annahme ausüben.

6.2 Hintergrund

Zur Erfassung der oben dargestellten Leistungsparameter würde man bei der Beurteilung von Videomitschnitten viele Stunden benötigen. Auf der Basis von sogenannten Positionsdaten ist dies aber in Sekunden möglich (Memmert & Raabe, 2019). Die genaue Erfassung der Positionen jedes Akteurs und möglicherweise wei-

tere Materialien ermöglichen somit heutzutage deutlich komplexere Analysen mit neuartigen Leistungsindikatoren. Mittlerweile werden in verschiedenen Sportarten Positionsdaten erfasst. Während im (Beach-)Volleyball (Link & Ahmann, 2013), Hockey (Stöckl & Morgan, 2013), Handball (Hassan et al., 2017; Bassek et al., 2023), Tennis (Kovalchik & Reid, 2018; van Meurs et al., 2021), Badminton (Rojas-Valverde et al., 2020) oder Basketball (Kempe et al., 2015) diese Entwicklung erst am Anfang steht, werden im Fußball Positionsdaten bereits standardmäßig generiert. Es gibt bisher mehrere Leistungsparameter, sogenannte Key-Performance-Indikatoren (KPIs), die zur Analyse eingesetzt werden (vgl. Memmert, Lemmink & Sampaio, 2017; Low et al., 2019).

Mithilfe von Prozess-, Längsschnitt- und Querschnittanalysen kann man auf der Basis von Positionsdaten beispielsweise auch dynamische Zusammenhänge untersuchen, in dem man situative und somit kontextspezifische Bezüge sowie interindividuelle Unterschiede stärker berücksichtigt (vgl. Rein & Memmert, 2016). Dazu können in Zukunft auch stärker Trainings- und Wettkampfdaten miteinander verknüpft werden. Um die Positionsdaten zu interpretieren, sind fundierte Theorien oder Modelle zwingend notwendig (Rein et al., 2017; Memmert et al., 2019). Durch den immer größer werdenden Stellenwert von Positionsdaten in der Sportinformatik werden aktuell experimentelle Ansätze sichtbar, die Theorien aufstellen und empirisch prüfen (Memmert et al., 2019; Low et al., 2021, 2022).

Definition

Positionsdaten beschreiben die Positionen sowie Bewegungen von Sportlern und Spielgeräten in Form von x-y-Koordinaten. Sie setzen sich im Sportspiel aus den Positionen aller Spieler und des Balls in Form von x-y-Koordinaten (beim Ball teilweise auch z-Komponente) zusammen (Memmert & Raabe, 2019). Zur Erfassung dienen entweder spezielle Kamerasysteme im Stadion oder mobile Geräte, welche die Spieler unter ihrer Spielkleidung tragen.

6.3 Anwendungen

► Beispiel 1

In einer Big-Data-Feldstudie wurden insgesamt 50 Spiele der Fußball-Bundesliga der Männer aus der Saison 2014/15 (zwei Teams, zwei Halbzeiten, 200 Data-Sets) auf der Basis von Positionsdaten mit verschiedenen KPIs (Memmert et al., 2017; Memmert et al., 2016) automatisch ausgewertet und validiert. Im Mittelpunkt stand dabei das selbst-entwickelte Analyse-Tool SOCCER (Perl, Grunz, & Memmert, 2013), welches konventionelle Datenanalyse, dynamische Zustand-Ereignis-Modellierung und künstliche neuronale Netze (vgl. ► Kap. 21) kombiniert. Die siegreichen Teams überzeugen mit deutlichen höheren Raumkontroll-Anteilen sowie Raumgewinnen im eigenen Spiel-aufbau und überspielen hier auch durchschnittlich mehr Gegenspieler. Auch im Angriff zeichnen sie sich durch hohe Raumgewinne vor dem gegnerischen Tor aus. Über den

Verlauf der gesamten Saison wurden außerdem die Mannschaften des oberen und unteren Tabellendrittels (gemäß Abschlusstabelle) miteinander verglichen. Und auch hier zeigte sich die Raumkontrolle als großer Unterschied zwischen Top-Clubs und Abstiegs-kandidaten. Egal, ob Spielaufbau oder Angriffsspiel: In fast allen Bereichen zeigte sich ein signifikanter Unterschied der Raumdominanz in den kritischen Zonen des Spielfelds – zugunsten der Teams aus dem oberen Drittel. Zieht man den Vergleich zwischen siegreichen und unterlegenen Mannschaften, zeigt sich, dass das Gewinner-Team in den 90 min mehr Gegenspieler im Spielaufbau überspielt. Zudem stehen ihm im Vergleich zu den Verlierern bei Ballbesitz durchschnittlich weniger Gegenspieler gegenüber – sogar bei Vertikalpässen im Offensivbereich. Dennoch betrieben die unterlegenen Mannschaften mehr Aufwand im Umschaltspiel. ◀

6

► Beispiel 2

Um unterschiedliche physiologische und anatomische Merkmale zwischen Frauen und Männern auszublenken und geschlechtsspezifische Vorurteile bei der Beurteilung von Fußballspielen auf höchstem Spielniveau zu vermeiden, wurde auf der Basis von Positionsdaten die taktische Leistung beider Geschlechter bewertet (Memmert et al., 2020). Als objektive KPIs wurden u. a. künstliche neuronale Netze (s. ► Kap. 21) eingesetzt. Die Analyse von Pass-Druck-Effizienz-Maßen, verschiedene Pressing-Indizes sowie verschiedene Raumkontroll-Parameter offenbart, dass Frauen und Männer vergleichbare Werte in allen taktischen Variablen aufweisen. Zusammenfassend konnte gezeigt werden, dass im Gegensatz zu bisherigen videobasierten Analysen bei der Verwendung „verblindeter“ Positionsdaten, bei denen keine Rückschlüsse auf das Geschlecht möglich sind, sowie objektiver KPIs keine wesentlichen Unterschiede in der fußballspezifischen taktischen Leistung zwischen Frauen und Männern im Hochleistungs-Fußball erkennbar sind. Die Befunde können objektive Rückschlüsse auf die Ausbildung von Spieler:innen ermöglichen, zur Weiterentwicklung und Professionalisierung des Frauenfußballs im Bereich Taktik beitragen und helfen, die öffentliche Wahrnehmung und die Attraktivität des Frauenfußballs auf Basis objektiver Bewertungskriterien zu fördern. ◀

► Beispiel 3

Unter Einbeziehung neuer Kontextinformationen während der Spielphasen untersuchten Klemp et al. (2022) den Zusammenhang zwischen Laufleistung und Torerfolg im Profi-Fußball. In einer Stichprobe von 302 Spielen der 1. Bundesliga wurde das erste Tor als Funktion der Laufleistung, basierend auf Positionsdaten, und Mannschaftsstärke der Mannschaften mittels logistischer Regression modelliert. Das beste Modell zeigte eine mittlere Genauigkeit von 77 %, was eine starke Beziehung zwischen der Laufleistung und der Wahrscheinlichkeit, das erste Tor zu erzielen, widerspiegelt. Dieser Zusammenhang war am stärksten für die Gesamtlaufstrecke im Vergleich zur Sprint- oder Laufstrecke mit eigenem Ballbesitz. Die Autoren schlagen zwei verschiedene mögliche Mechanismen vor, um die in der vorliegenden Studie gefundene Beziehung zwischen Laufleistung und Torerfolg zu erklären. Einerseits könnte dafür eine bessere Erfüllung der taktischen Ziele der Spieler verantwortlich sein, andererseits könnte auch die zunehmende Müdigkeit der gegnerischen Spieler eine Rolle spielen. ◀

► Beispiel 4

Guerrero-Calderón et al. (2021) analysierten die physische Leistungen professioneller Fußballspieler während des Trainings unter Berücksichtigung der kontextuellen Faktoren Spielort, Saisondauer und Qualität des Gegners, um Vorhersagemodelle für die erbrachte Leistung während Trainingseinheiten zu erstellen. Trainingsdaten wurden von 30 professionellen Fußballspielern der spanischen La Liga auf der Basis von Positionsdaten ($n = 1365$) generiert. Während der Trainingswochen vor Heimspielen zeigte sich eine verringerte Belastung in Bezug auf verschiedene Kraft-, Schnelligkeits- und Ausdauerparameter. Auch die Qualität des Gegners wirkte sich auf die Trainingsbelastung aus. Das vorgeschlagene Vorhersagemodell stellt einen innovativen Ansatz zur Quantifizierung der Trainingsbelastung im Profi-Fußball unter Berücksichtigung neuartiger Kontextfaktoren dar. ◀

Studienbox

Das Feldexperiment von Memmert et al. (2019) ist das erste, das in einem Elf-gegen-Elf-Fußballspiel-Setup die Auswirkungen verschiedene Spielsysteme (hier 4-2-3-1 vs. 3-5-2) auf taktische KPIs anhand von Positionsdaten untersucht. Die KPIs wurden mithilfe von dynamischen KPIs wie der „effektiven Spielfläche“, dem „Längen-Breiten-Quotienten“, der Raumkontrolle und der Passeffizienz unter Druck gemessen. Innerhalb des Paradigmas der experimentellen Positionsdatenanalyse zeigten beide Mannschaftsformationen keine Unterschiede in Bezug auf den effekti-

ven Spielraum oder die Raumkontrolle. Hypothesenkonform übertraf ein 3-5-2-Spielsystem mit fünf Ebenen (3-1-2-2-2) für den „Längen-Breiten-Quotienten“ und die Passeffizienz unter Druck das 4-2-3-1-Spielsystem mit vier Ebenen, da im ersteren im Mittelfeld eine (Spieler-)Ebene mehr vorhanden war. Das experimentelle Paradigma zur Positionsdatenanalyse stellt einen nützlichen Ansatz dar, um die Entwicklung und Validierung von theorieorientierten Modellen bei der Leistungsanalyse von Sportspielen voranzutreiben.

? Fragen für die Studierenden

1. Was sind Positionsdaten?
2. Nennen Sie zwei konkrete Anwendungsbeispiele, wie man sie im Sport nutzbar machen kann.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>

2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springer-nature.com.

6

Literatur

- Bassek, M., Raabe, D., Memmert, D., & Rein, R. (2023). Analysis of Motion Characteristics and Metabolic Power in Elite Male Handball Players. *Journal of Sports Science & Medicine*, 22(2), 310.
- Guerrero-Calderón, B., Klemp, M., Morcillo, J. A., & Memmert, D. (2021). How does the workload applied during the training week and the contextual factors affect the physical responses of professional soccer players in the match? *International Journal of Sports Science & Coaching*, 16, 994–1003.
- Hassan, A., Schrapf, N., & Tilp, M. (2017). The prediction of action positions in team handball by non-linear hybrid neural networks. *International Journal of Performance Analysis in Sport*, 17, 293–302.
- Kempe, M., Grunz, A., & Memmert, D. (2015). Detecting tactical patterns in basketball: Comparison of merge self-organising maps and dynamic controlled neural networks. *European Journal of Sport Science*, 15, 249–255.
- Klemp, M., Memmert, D., & Rein, R. (2022). The influence of running performance on scoring the first goal in a soccer match. *International Journal of Sports Science & Coaching*, 17(3), 558–567.
- Kovalchik, S., & Reid, M. (2018). A shot taxonomy in the era of tracking data in professional tennis. *Journal of Sports Sciences*, 36, 2096–2104.
- Link, D., & Ahmann, J. (2013). Moderne Spielbeobachtung im Beach-Volleyball auf Basis von Positionsdaten. *Sportwissenschaft*, 43, 1–11.
- Low, B., Coutinho, D., Gonçalves, B., Rein, R., Memmert, D., & Sampaio, J. (2019). A systematic review of collective tactical behaviours in football using positional data. *Sports Medicine*, 50, 343–385.
- Low, B., Rein, R., Raabe, D., Schwab, S., & Memmert, D. (2021). The porous high-press? An experimental approach investigating tactical behaviours from two pressing strategies in football. *Journal of Sports Sciences*, 39(19), 2199–2210.
- Low, B., Schwab, S., Rein, R., & Memmert, D. (2022). Defending in 4-4-2 or 5-3-2 formation? Small differences in footballers' collective tactical behaviours. *Journal of Sports Sciences*, 40(3), 351–363.
- Memmert, D. & Raabe, D. (2019). *Revolution im Profifußball. Mit Big Data zur Spielanalyse 4.0* (2. aktualisierte und erweiterte Auflage). Berlin: Springer-Verlag.
- Memmert, D., Klemp, M., Caparrós M., & Imkamp, J., (2020). Frauen vs. Männer – Taktische Leistungsfähigkeit im Fußball. *Impulse*, 25, 36–44.
- Memmert, D., Lemmink, K. & Sampaio, J. (2017). Current approaches to tactical performance analyses in soccer using position data. *Sports Medicine*, 47, 1–10.
- Memmert, D., Raabe, D., Knyazev, A., Franzen, A., Zekas, L., Rein, R., Perl, J., & Weber, H., (2016). Big Data im Profi-Fußball – Analyse von Positionsdaten der Fußball-Bundesliga mit neuen innovativen Key Performance Indikatoren. *Leistungssport*, 46, 21–26.

- Memmert, D., Raabe, D., Schwab, S. & Rein, R. (2019). A tactical comparison of the 4-2-3-1 and 3-5-2 formation in soccer: A theory-oriented, experimental approach based on positional data in an 11 vs. 11 game set-up. *PLoS one*, 14.
- Perl, J., Grunz, A., & Memmert, D. (2013). Tactics analysis in soccer – an advanced approach. *International Journal of Computer Science in Sport*, 12, 33–44.
- Rein, R., & Memmert, D. (2016). Big data and tactical analysis in elite soccer: future challenges and opportunities for sports science. *SpringerPlus*, 5, 1–13.
- Rein, R., Perl, R. & Memmert, D. (2017). Maybe a tad early for a Grand Unified theory: Commentary on “Towards a Grand Unified Theory of sports performance” by Paul S. Glazier. *Human Movement Science*, 56, 173–175.
- Rojas-Valverde, D., Gómez-Carmona, C. D., Fernández-Fernández, J., García-López, J., García-Tormo, V., Cabello-Manrique, D., & Pino-Ortega, J. (2020). Identification of games and sex-related activity profile in junior international badminton. *International Journal of Performance Analysis in Sport*, 20, 323–338.
- Stöckl, M., & Morgan, S. (2013). Visualization and Analysis of Spatial Characteristics of Attacks in Field Hockey. *International Journal of Performance Analysis in Sport*, 13, 160–178.
- van Meurs, E., Buszard, T., Kovalchik, S., Farrow, D., & Reid, M. (2021). Interpersonal coordination in tennis: Assessing the positional advantage index with Australian Open Hawkeye data. *International Journal of Performance Analysis in Sport*, 21, 22–32.



Reale Datensätze Onlinedaten

Christoph Breuer

Inhaltsverzeichnis

- 7.1 Beispiel Sport – 56
- 7.2 Hintergrund – 56
- 7.3 Anwendungen – 58
- Literatur – 61

Kernbotschaften

- Durch die Digitalisierung sind immer mehr Sportdaten und andere sportwissenschaftlich relevante Daten als Onlinedaten verfügbar.
- Web Scraping bzw. Web Crawling stellt eine Methode dar, diese Daten systematisch für sportwissenschaftliche Untersuchungen nutzbar zu machen.
- Die Nutzung von Onlinedaten führt zu signifikanten Erkenntnisgewinnen für die Sportwissenschaft.

7.1 Beispiel Sport

7

Die zunehmende Online-Sportberichterstattung, Second-Screen- und Tactical-Feed-Angebote von TV-Anstalten und Streaming-Anbietern, umfassende Statistikangebote von Sportligen und Anbietern von Sportwetten, Preisentwicklungen für Sportwaren auf Online-Verkaufsplattformen, Aktienkurse von Sportunternehmen, Spielinformationen auf Fantasy-Sport- und eSport-Plattformen, oder aber unzählige Trainingsdaten in Gesundheits- und Running-Apps – die digitale Welt hält eine nicht enden wollende Masse an Sportdaten sowie sportwissenschaftlich relevanten Daten bereit.

Für die sportwissenschaftliche Forschung entstehen damit verbesserte und auch völlig neue Möglichkeiten für datenbasierte Erkenntnisse. Pionierarbeit leisteten dabei insbesondere Studien zur optimalen Bepreisung von Stadiontickets. So konnten Kemper und Breuer (2016b) zum ersten Mal eine empirische Antwort auf die Frage geben, ob der FC Bayern München ein dynamisches Ticketpreis-System (*dynamic pricing*) mit sich verändernden Ticketpreisen (wie es in den nord-amerikanischen Profiligen weit verbreitet ist) einführen sollte. Dies gelang, indem umfassende Daten für Zweitverkäufe von Heimspieltickets des FC Bayern München auf eBay betrachtet und diese für die Bestimmung von Nachfragekurven und -gleichungen genutzt wurden. Auf diese Weise konnten die Autoren zeigen, dass der FC Bayern München durch die Einführung eines dynamischen Ticketpreis-Systems wirtschaftlich deutlich profitieren würde.

7.2 Hintergrund

Bei Onlinedaten kann es sich inhaltlich betrachtet um höchst unterschiedliche Daten handeln, von ökonomischen Preisdaten über soziodemografische Daten bis hin zu Positionsdaten, Leistungsdaten oder physiologischen Daten. Technisch betrachtet handelt es sich jedoch zumeist um Textdaten, die auf Onlineportalen verfügbar sind.

Um diese Onlinedaten für eigene Analysen zu nutzen, können diese manuell kopiert werden (Manual Scraping) oder aber man extrahiert, kopiert, speichert und

wiederverwertet diese Daten automatisiert (Web Scraping). In der Literatur findet sich häufig hierfür auch der Begriff Web Crawling.

Urheberrechte und andere rechtliche Aspekte sind dabei unbedingt zu beachten. Vor dem Scraping ist somit stets die rechtliche Situation zu prüfen, insbesondere, wenn Ergebnisse oder gar der Datensatz selbst publiziert werden sollen. Als Faustregel gilt dabei, dass alle Informationen, die hinter einem Benutzernamen und einem Kennwort gespeichert sind, als privat gelten und nicht ausgewertet werden sollten (Bradely & James, 2019).

Waren zu Beginn zumindest Grundkenntnisse einschlägiger Programmiersprachen wie Python erforderlich, um Web Scraping anzuwenden, so erlauben mittlerweile Web-Scraping-Werkzeuge wie Octoparse, Parsehub, Scraper API oder ScrapeSimple das Erstellen von Web Scrapern auch Nutzern ohne oder mit nur geringen Programmierkenntnissen. Nichtsdestotrotz bleibt das automatisierte Auslesen von Informationen aus Webseiten mit Programmiersprachen wie Python flexibler. Eine weitere sehr nützliche Entwicklung sind die Möglichkeiten, Web Scraping direkt mit Befehlen im Statistikprogramm R vorzunehmen. Javascript kann Web Scraping erschweren. Aber auch hierfür gibt es Softwarelösungen wie PhantomJS.

Nicht alle Halter von Webseiten erlauben oder unterstützen gar Web Scraping. Mitunter gibt es auch Abwehrmechanismen, zumal massenhaftes Web Scraping die Performance von Webseiten negativ beeinflussen kann. Dennoch gibt es eine stark steigende Anzahl legal nutzbarer Onlinedaten.

Der Prozess des Web Scrapings besteht aus folgenden Elementen:

1. Zunächst wird dem Programm bzw. dem Algorithmus (der Web Scraper) die URL der Seite, von der die Daten gescrapt werden, mitgeteilt.
2. Anschließend ruft der Web Scraper den HTML-Code der Seite ab und speichert diesen.
3. Mit dem abgerufenen HTML-Code können nun die Schlüsselemente identifiziert werden, die in einer Tabelle oder einer Datenbank gespeichert werden sollen.
4. Entsprechend ist der Befehl anzupassen.

Noch wenig verbreitet im Sport ist gegenwärtig, dass Onlinedaten in einem strukturierten, maschinenlesbaren Format interessierten Nutzern direkt zur Verfügung gestellt und über spezielle Programmierschnittstellen, sogenannte Application Programming Interfaces (APIs), gesichert werden können. Dies stellt ein technisch wie rechtlich sichereres Verfahren dar und dürfte zukünftig an Bedeutung gewinnen. Ein prominentes Beispiel hierfür stellt die Basketballliga NBA mit ihrer Webseite ► [nba.com](https://www.nba.com) dar. Sie bietet mittlerweile eigene API-Schnittstellen an, um die Nutzung bereitgestellter Daten zu unterstützen. Für Statistikprogramme wie R stehen auch hier wiederum zugeschnittene Anwendungen zur Verfügung, die die Daten direkt für die statistische Analyse zugänglich machen, z. B. nbastatR (Bresler, 2021). Auch im Bereich des Fantasy Sports finden sich zahlreiche API-Angebote.

Definition

Onlinedaten sind im WWW publizierte Textdaten zu unterschiedlichsten Inhalten. Mittels Web Scraping lassen sich diese Onlinedaten automatisiert extrahieren, kopieren, speichern und wiederverwerten. API-Schnittstellen stellen eine juristisch sicherere Alternative der Nutzung von Onlinedaten dar, sind im Sport aber noch wenig verbreitet.

7.3 Anwendungen

► Beispiel 1

Empirische Studien über tatsächliche dynamische Ticketpreise (Dynamic Ticket Pricing) im Sport mussten sich lange Zeit mit einer begrenzten Anzahl von Messzeitpunkten begnügen. Mittels Onlinedaten konnte erstmals der Einfluss der Zeit über den gesamten Verkaufszeitraum eines Fußballclubs untersucht werden. Kemper und Breuer (2016a) haben hierzu die täglichen Ticketpreise für ausgewählte Spiele des englischen Fußballvereins Derby County während der Saison 2013/2014 erhoben. Die Ticketpreise wurden ab dem ersten Tag gescrapt, an dem der Kauf von Tickets auf der Homepage von Derby County möglich war. Die betrachteten Verkaufszeiträume lagen zwischen 19 und 27 Tagen vor dem Spieltag. Insgesamt wurden Daten für elf Spiele analysiert, die 5862 Preispunkte umfassten. Die Ticketpreise wurden für die Altersklassen Erwachsene, Senioren und U18 berücksichtigt. Spiel- und Ticketpreisinformationen wurden jeden Tag direkt von der offiziellen Homepage von Derby County eingeholt. Die Anzahl der verkauften Tickets wurde von ► <http://www.worldfootball.net> bezogen. Mithilfe einer hedonischen Preisregression konnte gezeigt werden, dass die Zeit einen erheblichen Einfluss auf die dynamischen Ticketpreise hat. Die Ticketpreise stiegen mit der Zeit monoton an. Das Preissystem unterscheidet sich jedoch von Modellen, die in der Luftfahrt- oder Hotelbranche angewandt werden. Sportmanager können diese Erkenntnisse bei der Ausarbeitung eines ausgefeilteren Preisgestaltungskonzepts anwenden. ◀

► Beispiel 2

Um Wirkungsmechanismen und Moderatoreffekte von Live-Spielen auf TV-Zuschauer und den jeweiligen Nutzen für Sponsoren aufzuschlüsseln, wurden in einer Studie (Breuer et al., 2021) physiologische und psychologische Daten der Zuschauer erhoben (Blickkontakte auf Werbeflächen, elektrodermale Aktivität, emotionale Gesichtsausdrücke). Ergänzt wurden diese Daten um In-Play-Wettquoten, also die sich zeitvariabel verändernden Wettquoten innerhalb des Spiels. Sie sind ein verlässlicher Indikator für die Intensität des Wettbewerbs bzw. für die Offenheit des Spielausgangs. Je kleiner die Differenz der Wettquoten für einen Sieg von Team A und für einen Sieg von Team B sind, desto unsicherer ist der Spielausgang. Für die Studie wurden die In-Play-Wettquoten mit der Frequenz von 1 Hz (eine Messung pro Sekunde) über die Spieldauer von mindestens 90 min von der Webseite eines Wettanbieters gescrapt. Zum Matching mit den anderen Daten war es erforderlich, die jeweiligen Wettquoten beim Web Scraping mit einem Zeitstempel zu versehen, anhand dessen erst die Sequenzdaten aus den anderen Messungen zugeordnet werden konnten. Auf diese Weise konnte erstmals ge-

zeigt werden, wie die Emotionen von TV-Zuschauern mit dem Spielverlauf variieren und welche Bedeutung dies für die Wahrnehmung von Werbebotschaften hat. ◀

► Beispiel 3

In einer ähnlich gelagerten Studie haben Herold et al. (2021) den Effekt von sogenannten Geisterspielen, also Spielen ohne Zuschauer, während der COVID-19-Pandemie auf den Nutzen von TV-Zuschauern und Sponsoren untersucht. Da auch hierbei Aspekte des Spielverlaufs und der Offenheit des Spielausgangs zu kontrollieren waren, bedienten sie sich hierzu des Web Scrapings, um an entsprechende Daten zu gelangen. Dazu dienten die sich während des Spiels verändernden Wettquoten (*in-play betting odds*). Hierin spiegeln sich alle Faktoren wider, die sich auf den Ausgang eines Spiels auswirken, z. B. Tore, und somit Aufschluss über den Grad der Spannung während eines Spiels geben. Die Wettquoten sind leicht zugänglich, da sie von den Buchmachern für alle Spiele der Fußball-Bundesliga automatisch im Sekundentakt erfasst und unmittelbar nach dem Spiel online zur Verfügung gestellt werden und gescrapt werden können. In den Daten ist die Spielminute enthalten, sodass die In-Play-Wettquoten mit den physiologischen Daten der Teilnehmer (Blickverläufe, Herzfrequenz) abgeglichen werden können. Unter Zuhilfenahme der gescrapteten Daten konnte erstmalig gezeigt werden, dass Geisterspiele zu einem geringeren Nutzen für TV-Zuschauer führen – aber nur dann, wenn das Spiel bereits vorentschieden ist. Umgekehrt erhöhen Geisterspiele den Nutzen für Sponsoren, aber auch nur, wenn das Spiel bereits vorentschieden ist. TV-Zuschauer schauen dann häufiger auf Werbemittel wie Banden, wenn sowohl das Spiel weniger spannend ist als auch keine Ablenkungsmöglichkeit durch Stadionzuschauer bestehen. ◀

► Beispiel 4

Um zu untersuchen, ob die Anwesenheit von Zuschauern in Arenen einen Einfluss auf die Höhe des Ergebnisses, genauer gesagt, auf die Punktedifferenz zwischen den beiden Teams hat, analysierten Steinfeldt et al. (2022) $n = 12.500$ NBA-Spiele aus elf Saisons von 2010/11 bis 2020/21. Durch die COVID-19-bedingten Auflagen in der Saison 2020/21 mit entsprechenden Zuschauerrestriktionen konnten Effekte der Anwesenheit von Fans geprüft werden. Alle Daten der Studie waren Onlinedaten und wurden entweder per Web Scraping oder über API-Schnittstellen gewonnen. Zum Einsatz kam das Statistikprogramm R unter Verwendung des beliebten Pakets `nbastatR` (Bresler, 2021), welches die Daten der NBA über die Anwendungsprogrammierschnittstelle (API) der Liga nutzt. Mithilfe des Pakets wurden Daten auf Ebene der regulären Saisonspiele sowie Daten auf Ebene der regulären Saison für die Spielzeiten 2010/11 bis 2020/2021 gesammelt. Der Datensatz enthält Informationen zu den Spielergebnissen, dem Spielort, den Aufzeichnungen der Mannschaften und eine Reihe anderer fortgeschrittener Basketballstatistiken, die jedoch nicht alle in die Analyse eingeflossen sind. Die Zuschauerdaten wurden von ► basketball-reference.com gescrapt, und die Wettquoten wurden von ► oddsportal.com entnommen und anschließend mit dem Datensatz zusammengeführt. Mit dem Datensatz konnten die Autoren nachweisen, dass Spiele, die vor eingeschränkten Zuschauerzahlen ausgetragen wurden, mit größerer Wahrscheinlichkeit mit einem Vorsprung von 15, 20 oder 25 Punkten gewonnen wurden als Spiele, die vor nicht eingeschränkten Zuschauern ausgetragen wurden. Der Effekt war am stärksten

ausgeprägt bei Spielen, die auf dem Heimplatz des schwächeren Teams ausgetragen wurden, was bedeutet, dass schwächere Teams am meisten unter der begrenzten Unterstützung durch die Zuschauer litten. ◀

Studienbox

7

Im Jahr 2009 waren die San Francisco Giants aus der amerikanischen Major League Baseball der erste Sportverein, der ein dynamisches Preissystem einführte, und seither sind viele nord-amerikanische Profisportteams diesem Beispiel gefolgt. Bislang hatte jedoch noch kein deutscher Sportverein ein dynamisches Preissystem eingeführt. Die Studie legte den Grundstein für eine solche Diskussion, indem die Determinanten der Zahlungsbereitschaft der Fans für Bundesliga-Tickets identifiziert wurden. Dies geschah nicht wie häufig durch eine Befragung von Fans. Stattdessen wurden validere Daten tatsächlicher Transaktionen genutzt. Es wurden Ticketverkäufe auf dem deutschen Zweitmarkt auf eBay untersucht. Die Ticketpreise von eBay-Auktionen wurden während der zweiten Hälfte der Bundesliga-Saison 2013/14 täglich erhoben. Täglich wurde mit dem Suchbegriff Fußballbundesliga-Tickets, gefolgt von den Namen der teilnehmenden Mannschaften, nach Tickets auf eBay.de gesucht. Anhand des Transaktionscodes konnten alle relevanten Auktionen nachverfolgt und die endgültigen Verkaufspreise ausgewertet werden. VIP-Tickets wurden nicht berücksichtigt, da diese Tickets zusätzliche Leistungen wie Essen, Getränke und Parken beinhalten. Eintrittskarten für ausgewählte Kundengruppen wie Studenten, Rentner und Behinderte wurden ebenfalls nicht berücksichtigt, da sie

preislich ermäßigt sind und am Spieltag im Stadion nachgekauft werden können. Der endgültige Datensatz umfasste insgesamt 6510 eBay-Auktionen, bei denen 11.637 Tickets verkauft wurden. Bei vielen Auktionen wurde mehr als ein Ticket verkauft. In diesem Fall wurde der Endpreis durch die Anzahl der verkauften Tickets geteilt, um den Preis pro Ticket zu berechnen. Neben den Daten, die direkt auf eBay.de gesammelt wurden, wurden verschiedene andere Quellen genutzt, um eine umfangreiche Datenbank aufzubauen. Daten zu Datum und Uhrzeit der einzelnen Spiele wurden von der offiziellen Homepage der ersten deutschen Bundesliga (► <https://www.bundesliga.de>) übernommen. Die Ergebnisse der Spiele und die Daten zu den Tabellenplätzen wurden auf ► <https://www.ergebnisslive.com> verfolgt. Der ursprüngliche Nennwert jeder einzelnen Eintrittskarte wurde von der Homepage der jeweiligen Fußballmannschaft abgefragt. Relevante Informationen zu Derbys/Rivalen wurden von ► <https://www.derbysieg.com> übernommen. Die Zuschauerzahlen wurden von der Homepage ► <https://fussballdaten.sport.de/bundesliga/2014> entnommen. Daten zur Bevölkerung und zum Pro-Kopf-Einkommen wurden aus MB-Research (2013) entnommen. Die Wetterdaten wurden vom Deutschen Wetterdienst (► <https://www.dwd.de>) übernommen. So entstand ein Datensatz von 6510 Auktionen, der mittels einer zweistufigen

Kleinste-Quadrate-Regression analysiert wurde. Die Ergebnisse zeigen, dass Eintrittskarten auf dem Sekundärmarkt für fast das Doppelte des ursprünglichen Nennwerts der Karte weiterverkauft werden. Das endgültige Modell enthält 23 signifikante Variablen

und erklärt 59,6 % der Varianz. Sportmanager können diese Ergebnisse nutzen, um ihre derzeitige Strategie der variablen Preisgestaltung für Eintrittskarten weiter zu differenzieren oder einen ausgefeilteren dynamischen Preisansatz zu implementieren.

? Fragen für die Studierenden

1. Was sind Onlinedaten?
2. Was ist beim Web Scraping zu berücksichtigen?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Bradley, A. & James, R.J.E. (2019). Web Scraping using R. *Advances in Methods and Practices in Psychological Science* 2(3), 264–270.
- Bresler, A. (2021). nbastatR: R's interface to NBA data. R package version 0.1.1505. Retrieved 24.11.2021 from <https://github.com/abresler/nbastatR>
- Breuer, C., Rumpf, C. & Boronczyk, F. (2021). Sponsor message processing in live broadcasts – A pilot study on the role of game outcome uncertainty and emotions. *Psychology & Marketing* 38(5), 896–907.
- Herold, E., Boronczyk, F. & Breuer, C. (2021). Professional clubs as platforms in multi-sided markets: The role of spectators and atmosphere in live football. *Sustainability* 13, 2312.
- Kemper, C. & Breuer, C. (2015). What factors determine the fans' willingness to pay for Bundesliga tickets? An analysis of ticket sales in the secondary market from ebay.de. *Sport Marketing Quarterly* 24(3), 142–158.

- Kemper, C. & Breuer, C. (2016a). Dynamic ticket pricing and the impact of time – an analysis of price paths of the English soccer club Derby County. *European Sport Management Quarterly* 16(2), 233–253.
- Kemper, C. & Breuer, C. (2016b). How efficient is dynamic pricing for sport events? Designing a dynamic pricing model for Bayern Munich. *International Journal of Sport Finance* 11(1), 4–25.
- Steinfeldt, H., Dallmeyer, S. & Breuer, C. (2022). The silence of the fans – the impact of restricted crowds in the margin of victory in the NBA. *International Journal of Sport Finance* 17, 165–177.

Modellbildung

Inhaltsverzeichnis

- Kapitel 8** **Modellbildung – 65**
Jürgen Perl und Daniel Memmert
- Kapitel 9** **Prädiktive Modelle – 73**
Fabian Wunderlich
- Kapitel 10** **Physiologische Modellierung – 83**
Manuel Bassek



Modellbildung

Jürgen Perl und Daniel Memmert

Inhaltsverzeichnis

- 8.1 Beispiel Sport – 66
- 8.2 Hintergrund – 67
- 8.3 Anwendungen – 69
- Literatur – 72

Kernbotschaften


Die Idee der Modellbildung im Sport besteht darin, komplexe dynamische Systeme auf ihre essenziellen Strukturen, Daten und Wechselwirkungen abzubilden, um damit beschreibende, prognostische oder planerische Analysen und Berechnungen durchführen zu können.

Die vier wesentlichen Schritte für Entwicklung und Anwendung eines Modells sind:


1. Die *Reduktion* des realen Systems auf seine wesentlichen Komponenten und Dynamiken.
2. Die *Abbildung* der Problemsituation auf (informatisch) handhabbare Objekte (Zahlen, Funktionen, Grafen etc.) unter Berücksichtigung einer entsprechenden Rückabbildung der erzielten Ergebnisse.
3. Die *Analyse/Berechnung* als Prozess der frageorientierten Informationsgewinnung – oder kurz: die Überführung der Problem- oder Eingabedaten in Ergebnis- oder Ausgabedaten.
4. Die *Visualisierung* der Ergebnisse auf einer systemnahen Ebene (z. B. grafische Darstellung).

8.1 Beispiel Sport

Die Erkennung technisch-taktischer Stärken und Schwächen oder die Entwicklung strategischer Konzepte auf der Basis von erfassten Positions- und Aktionsdaten ist im Fußball essenziell (Memmert, 2022). Im Folgenden wird als Einstiegsbeispiel der Fall der modellbasierten Analyse von Spieler-Ball-Interaktion dargestellt: „Hätte der Spieler den Ball noch erreichen können?“ ■ Abb. 8.1 zeigt dazu ein Repräsentations- oder Visualisierungsschema, in dem die beiden in der Reduktion ausgewählten Objekte Spieler und Ball mit ihren für das Modell relevanten Daten (Positionen des Spielers und des Balles mit deren Bewegungsrichtungen zu Beginn



■ Abb. 8.1 Visualisierung der Systemreduktion



■ **Abb. 8.2** a Ergebnis der Modellberechnung, b Vergleich mit der Realität


des Prozesses sowie Geschwindigkeitswerte für Spieler und Ball aus den Videodaten) dargestellt sind.

Die Aufgabe des Modells wäre es nun, aus diesen Daten durch entsprechende *Berechnung* die Eingangsfrage der Erreichbarkeit zu beantworten. Das Ergebnis dieser Modellberechnung (oder auch Simulation) als Antwort auf die Erreichbarkeitsfrage wäre im einfachsten Fall „ja“ oder „nein“. In beiden Fällen bleibt die Antwort aber unbefriedigend, weil sie nicht vermittelt, *wo* die Ball-Erreichung stattfindet bzw. *warum* sie nicht stattfindet. Als vierter Schritt der Modellbildung ist also eine adäquate *Visualisierung* der Ergebnisse notwendig.

Die berechnete Wegegrafik zeigt in ■ Abb. 8.2a, dass der Spieler den Ball *theoretisch* hätte erreichen können; aber nicht *praktisch*: Wie die Videoaufnahmen zeigen, wurde der Ball vor dem berechneten Treffzeitpunkt von einem Gegenspieler weggeschlagen (vgl. ■ Abb. 8.2b). Dieser Gegenspieler war aber nicht Bestandteil des Modells, d. h., das Modell hatte die Realität zu stark reduziert! Und damit sind wir wieder beim ersten und entscheidenden Aspekt der Modellbildung – der *Reduktion*: Die oben bei den Kernbotschaften unter (1) genannte „Reduktion des realen Systems...“ ist notwendig, um überhaupt mit vernünftigem Aufwand ein Ergebnis berechnen zu können. Sie darf aber nicht zu eng sein, um nicht wesentliche Objekte und Dynamiken, die das Ergebnis beeinflussen, unberücksichtigt zu lassen.

8.2 Hintergrund

Den essenziellen Aspekt der Reduktion für Wirkungsweise und Verwendbarkeit eines Modells erkennt man für das Fußballbeispiel aus ■ Abb. 8.2b (Perl & Memmert, 2019): Der Ball hat in seinem Verlauf eine abrupte Bewegungsänderung erfahren, die aus dem Modell nicht erklärbar, für den Betrachter aber sofort verständlich ist: durch den Eingriff eines gegnerischen Spielers. Dieser gegnerische Spieler war wegen zu starker Reduktion nicht Bestandteil des Modells, und daher konnte seine mögliche Wirkung auf die zu modellierende Bewegungsdynamik auch nicht erkannt und berechnet werden.




■ **Abb. 8.3** a Voronoi-Zellen der Spieler, b Erreichbarkeitsanalyse

■ **Abb. 8.3a** zeigt die typische Modellierung einer solchen Spieler-Gegenspieler-Situation: Unter der Voraussetzung, dass beide Spieler sich mit der gleichen Geschwindigkeit bewegen, zeigt die Trennlinie zwischen dem blauen und dem gelben Bereich alle Punkte, die vom blauen und vom gelben Spieler gleichzeitig erreicht werden. Zu allen Punkten des blauen Bereichs gelangt der blaue Spieler schneller, zu allen Punkten des gelben Bereichs sein gelber Gegenspieler. Man nennt diese Bereiche der schnelleren Erreichbarkeit nach ihrem „Entdecker“ auch die Voronoi-Zelle des Spielers. Die Analyse der Erreichbarkeit des Balles präzisiert sich so auf die Frage: „Wie läuft der Ball durch die Voronoi-Zellen der beiden Spieler?“

■ **Abb. 8.3b** zeigt: Selbst wenn sich der blaue Spieler in der optimalen Richtung bewegt hätte, hätte er keine Chance gehabt, die Aktion des gelben Gegenspielers zu verhindern – er konnte den Ball nicht vor seinem Gegenspieler erreichen. Spielanalysen auf der Basis von Voronoi-Zellen sind inzwischen im Fußball Standard und dienen der Analyse der Wirksamkeit taktischer Formationen im Hinblick auf Raumkontrolle (Perl & Memmert, 2015; Memmert & Raabe, 2019) (■ **Abb. 8.4**).

Nachdem sich so gezeigt hat, dass eine weniger starke Reduktion die Genauigkeit der Modellbildung auch verbessern kann, stellt sich die Frage: Sollte man noch mehr Aspekte der Realität, wie z. B. Geschwindigkeitsunterschiede und -änderung oder Wechsel der Bewegungsrichtungen in das Modell einfließen lassen? Diese in der Modellbildung zentrale Frage lässt sich nicht pauschal mit *ja* oder *nein* beantworten. Die Antwort hängt jeweils von den verfügbaren Daten, dem noch vertretbaren Aufwand und dem erwarteten Nutzen der Modellbildung und -berechnung ab. So liefern z. B. die genannten Ergänzungen die Möglichkeit einer technischen Visualisierung des Spielgeschehens parallel zur Videopräsentation – aber nur, wenn die Daten in genügendem Umfang und in genügender Präzision zur Verfügung stehen. Andernfalls visualisiert die Modellbildung eher die Daten-



■ **Abb. 8.4** Fußballfeld mit den Voronoi-Zellen der Spieler von „A-gelb“ und „B-blau“ (Memmert & Raabe, 2019).

defizite als das Spielgeschehen. Resümee: Die zentrale Kunst der Modellbildung besteht in der adäquaten Reduktion, die die essenziellen Dynamiken erhält, ohne sich in Spielereien zu verlieren (Perl, 2015).

Definition

Das Modell ist ein abstraktes Abbild eines Systems. Es dient der Diagnose des Systemzustands und der Prognose des Systemverhaltens (Perl & Uthmann, 1997).

Die vier essenziellen Schritte der Modellbildung sind (in Klammern das Fußballbeispiel):

Systemreduktion – (Erfassung und Darstellung der Spieler-Ball-Situation)

Problemabbildung – (Setzung der Positions- und Geschwindigkeitsdaten)

Analyse/Berechnung – (Berechnung der Laufwege und ggf. des Schnittpunktes)

Ergebnisvisualisierung – (Darstellung der Spieler-Ball-Situation als Grafik)

8.3 Anwendungen

► Beispiel 1

Physiologische Modelle zur Optimierung von Belastungs-Leistungs-Wechselwirkungen dienen der Simulation von

- Kurzzeitwirkungen der Wettkampfbelastung auf Leistung und Ermüdung;

- Langzeitwirkungen der Trainingsbelastung auf Leistungsfähigkeit und Erholungsbedarf (► Kap. 13).

Die zentrale Idee der Modellbildung besteht dabei darin, die komplexen physiologischen Wechselwirkungen auf die essenziellen Aspekte von Belastung und Leistung zu reduzieren. Dabei stehen die Verzögerungen, mit denen Belastung und Erholung wirksam werden, im Mittelpunkt der Betrachtung: Je kürzer die Erholungsverzögerung im Vergleich zur Belastungsverzögerung ist, desto stärker sind Leistung und Leistungsfähigkeit entwickelt. Auf der Grundlage dieser Analysedaten können Training und Wettkampf in ihrer Wirkung verbessert werden (Tampier et al., 2012). Passen die aus der Analyse erwarteten Daten nicht zu den gemessenen Daten, kann dies ein Indiz für eine irreguläre Trainingssituation wie z. B. eine nicht erkannte Krankheit oder unerlaubte Hilfsmittel (z. B. Doping) sein. ◀

► Beispiel 2

Taktisch-strategische Modelle zur Darstellung und Analyse von Spielerverhalten in Mannschaftsspielen wurden im Fußball eingesetzt:

- Formationen: Die Spielerverteilung einer Mannschaft oder ihrer taktischen Gruppierungen können von künstlichen neuronalen Netzen analysiert und so auf wenige prototypische Formationen reduziert werden (Perl et al., 2013; Grunz et al., 2012). Mithilfe einer simulativen Dynamikanalyse von Formationswechseln in spezifischen Spielsituationen können taktische Verhaltensmuster erkannt und dann z. B. optimiert, vermieden oder (beim Gegner) gestört werden (Perl & Memmert, 2017). Hierbei gelingt auch die Modellierung von Kreativität bzw. kreativen Lösungen im Sportspiel (Memmert & Perl, 2009a,b).
- Voronoi-Zellen: Wie oben gezeigt, helfen Voronoi-Zellen, die Raumkontrolle von Spielern, Mannschaften oder taktischen Gruppen zu analysieren. Zusammen mit der Ballkontrolle, die aus Positions- und Bewegungsdaten von Spielern und Ball analysiert werden kann, kann man so Modelle entwickeln, die aus der Koinzidenz von Raum- und Ballkontrolle relativ zum Aktionsaufwand der Spieler die Effizienz des Angriffsverhaltens berechnen (Perl & Memmert, 2015). ◀


? Fragen für die Studierenden

- (1) Wie könnte man mit einem physiologischen Belastungs-Leistungs-Modell einen Dopingverstoß erkennen?
- (2) Wie genau muss ein Voronoi-Modell eines Fußballspiels sein?
 - (a) Repräsentationspräzision im Videostandard?
 - (b) Pi mal Daumen, und nur für kritische Phasen?
 - (c) In Abstimmung mit den Analyseanforderungen?

Studienbox

Ziel von Key Performance Indicators (KPI; Memmert et al., 2017, Low et al., 2019) ist es, komplexes Systemverhalten auf einzelne Werte abzubilden, um Systeme oder Systemkomponenten zu skalieren, zu bewerten und zu ranken. Sehr oft reduziert diese Abbildung jedoch nur wichtige Informationen über taktisches Verhalten oder Spieldynamik, ohne sie durch sinnvollere Information zu ersetzen. Perl und Memmert (2017) haben in zwei Schritten die Lücke zwischen komplexer Dynamik und numerischen Kennzahlen beim Offensivspiel im Fußball geschlossen. Zunächst wurde ein Modell entwickelt, das offensives Handeln prozessorientiert visualisiert, indem KPIs zur Darstellung offensiver Leistungen verwendet werden. Zweitens ist dieses Modell in Bezug auf Zeitinter-

valle organisiert worden, was es ermöglicht, die Wirksamkeit sowohl für eine ganze Halbzeit als auch für Intervalle beliebiger Länge zu messen. Perl und Memmert (2017) haben dabei gezeigt, dass das Angriffseffizienz-Profil ein dynamischer Indikator für den Spielerfolg einer Mannschaft ist. In ■ Abb. 8.5 ist durch rote Profile dargestellt, wie sich die Werte der Angriffseffizienzen von „A-gelb“ und „B-blau“ für die Korrelations-Intervall-Länge $IL = 300$ sec über die Halbzeit entwickeln. Die Effizienzwerte (OS A, OS B) für die Sekunde $t_0 = 1721$ sind in die graue Box eingetragen. In der Grafik zeigen die grünen Profile die jeweiligen Raumkontrollanteile in der gegnerischen 30-m-Zone; die violetten Markierungen zeigen die Ballkontroll-Zeitpunkte.



■ Abb. 8.5 Verläufe der Angriffseffizienzen für die Intervall-Länge $IL = 300$

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

8

Literatur

- Low, B., Coutinho, D., Gonçalves, B., Rein, R., Memmert, D., & Sampaio, J. (2019). A systematic review of collective tactical behaviours in football using positional data. *Sports Medicine*, 50, 343–385.
- Grunz, A., Memmert, D. & Perl, J. (2012). Tactical pattern recognition in soccer games by means of special self-organizing maps. *Human Movement Science*, 31, 334–343.
- Memmert, D. (Hrsg.) (2022). *Spielanalyse*. Berlin: Springer-Verlag.
- Memmert, D. & Perl, J. (2009a). Analysis and Simulation of Creativity Learning by Means of Artificial Neural Networks. *Human Movement Science*, 28, 263–282.
- Memmert, D. & Perl, J. (2009b). Game Creativity Analysis by Means of Neural Networks. *Journal of Sport Science*, 27, 139–149.
- Memmert, D., & Raabe, D. (2019). *Revolution im Profifußball. Mit Big Data zur Spielanalyse 4.0* (2. Auflage). Springer-Verlag: Berlin.
- Memmert, D., Lemmink, K. & Sampaio, J. (2017). Current approaches to tactical performance analyses in soccer using position data. *Sports Medicine*, 47, 1–10.
- Perl, J. (2015). Modelling and Simulation. In A. Baca (ed.), *Computer Science in Sport*, (pp. 110–153). Routledge.
- Perl, J. & Memmert, D. (2015). Analysis of process dynamics in soccer by means of artificial neural networks and Voronoi-cells. In A. Baca & M. Stöckl (Hrsg.), *Schriften der Deutschen Vereinigung für Sportwissenschaft*, Band 244, (S. 130–135). Hamburg: Czwalina.
- Perl, J. & Uthmann, Th. (1997). Modellbildung. In J. Perl, M. Lames & W.-D. Miethling (Hrsg.), *Informatik im Sport. Ein Handbuch*. (pp. 65–80). Schorndorf 1997.
- Perl, J., & Memmert, D. (2017). A Pilot Study on Offensive Success in Soccer Based on Space and Ball Control – Key Performance Indicators and Key to Understand Game Dynamics. *International Journal of Computer Science in Sport*, 16(1), (pp. 65–75).
- Perl, J., & Memmert, D. (2019). *Soccer: Process and interaction*. In A. Baca & J. Perl, Modelling and Simulation in Sport and Exercise (pp. 73–94). Abingdon: Routledge.
- Perl, J., Grunz, A. & Memmert, D. (2013). Tactics in soccer: an advanced approach. *International Journal of Computer Science in Sport*, 12, 33–44.
- Tampier, M., Endler, S., Novatchkov, H., Baca, A., & Perl, J. (2012). Development of an Intelligent Real-Time Feedback System. *International Journal of Computer Science in Sport*, 11(3).



Prädiktive Modelle

Fabian Wunderlich

Inhaltsverzeichnis

- 9.1 Beispiel Sport – 74**
- 9.2 Hintergrund – 74**
 - 9.2.1 Der Blick in die Zukunft – 74
 - 9.2.2 Der Sport als Anwendungsfeld für prädiktive Modelle – 75
 - 9.2.3 Erstellung von prädiktiven Modellen und methodische Beispiele – 75
- 9.3 Anwendungen – 77**
 - Literatur – 79**

Kernbotschaften

- Prädiktive Modelle sind in nahezu allen Bereichen der Wissenschaft und Gesellschaft relevant, von Wetter und Klima über Politik und Demografie, bis hin zu Aktienpreisen oder Wirtschaftswachstum.
- Aufgrund des öffentlichen und medialen Interesses, der hohen Datenverfügbarkeit und der finanziellen Anreize bietet der Sport ein prädestiniertes Umfeld für prädiktive Modelle.
- Prädiktive Modelle verfolgen ein klar definiertes Ziel, basieren auf einer detaillierten und aussagekräftigen Datenbasis, nutzen geeignete methodische Ansätze zur Modellbildung sowie geeignete Kriterien zur Bewertung der prädiktiven Qualität.
- Methodisch bieten sich insbesondere statistische Modelle oder informatische Modelle (wie z. B. Machine-Learning-Modelle) an, deren Auswahl u. a. von der genauen Fragestellung und der Datenkomplexität abhängt.

9

9.1 Beispiel Sport

Im Sport sind Fragen zu zukünftigen Ereignissen allgegenwärtig: Wer gewinnt den Super Bowl? Welcher U-21-Nationalspieler wird sich langfristig durchsetzen? Wie wird das Bundesliga-Wochenende laufen? Hat die Nationalmannschaft eine Titelchance bei der Handball-WM? Welche taktische Aufstellung verspricht im nächsten Spiel den größtmöglichen Erfolg? Mit welcher Trainingssteuerung lassen sich Verletzungen vermeiden? Und wer gewinnt eigentlich Wimbledon? Dabei sind derartige Fragen nicht nur beliebter Gesprächsstoff für Medien und Sportfans, sondern gleichzeitig eine Grundlage des Geschäftsmodells von Buchmachern und wichtige Aspekte, um den sportlichen und finanziellen Erfolg von Sportmannschaften zu sichern. Kein Wunder also, dass prädiktive Modelle im Sport eine bedeutende Rolle spielen, insbesondere, wenn es um die interdisziplinäre Verbindung von Informatik, Mathematik und Sportwissenschaft geht.

9.2 Hintergrund

9.2.1 Der Blick in die Zukunft

Den Blick auf die Zukunft zu richten, ist in unserer Gesellschaft etwas völlig Normales und Alltägliches. Wir möchten als Menschheit überleben und daher Entwicklungen wie den Klimawandel vorhersehen, um unsere Lebensgrundlage zu sichern. Wir möchten sicher leben und daher terroristische Bedrohungslagen im Vorhinein erkennen. Wir möchten unseren finanziellen Erfolg sichern, indem wir Entwicklungen an den Aktienmärkten, wirtschaftliche Trends oder Konsumentenverhalten richtig antizipieren. Und schließlich möchten wir einfach nur vorher-

sehen, ob es morgen regnet, um im passenden Moment immer einen Schirm dabeizuhaben.

Das Thema prädiktive Modelle ist daher eines, das in nahezu allen Bereichen der Wissenschaft und Gesellschaft Beachtung findet. Nur einige der relevantesten Bereiche, in denen prädiktive Modelle eine wichtige Rolle spielen, sind Wirtschaft (Timmermann 2000), Wetter (Taylor und Buizza 2004), Klima (Green et al. 2009), Ausgänge von politischen Wahlen (Wolfers und Leigh 2002), die Entwicklung von politischen Konflikten (Brandt et al. 2014), Kriminalität (Gorr et al. 2003), Demografie (Booth 2006) oder Energiebedarf (Hong et al. 2016).

9.2.2 Der Sport als Anwendungsfeld für prädiktive Modelle

Auch der Sport ist ein beliebtes und relevantes Anwendungsfeld für prädiktive Modelle (McHale und Swartz 2019; Vaughan Williams und Stekler 2010; Wunderlich und Memmert 2020; Horvat und Job 2020), was durch einige besondere Charakteristiken des Sports unterstützt wird.

Durch das hohe mediale und öffentliche Interesse gibt es eine große Menge an frei verfügbaren Daten, wodurch prädiktive Modelle auf Datensätze mit großen Stichprobengrößen und/oder einem großen Detailgrad zurückgreifen können (Koopman und Lit 2019; Lessmann et al. 2010; Štrumbelj und Vračar 2012; Klemp et al. 2021; Angelini und Angelis 2019).

Zudem bestehen hohe Anreize für gute prädiktive Modelle. Dies bezieht sich einerseits auf den Sportwettenmarkt, der sowohl auf Seiten der Buchmacher als auch auf Seiten von professionellen Wettspielern einen starken finanziellen Anreiz für die profitable Vorhersage von Spielergebnissen bietet (Constantinou et al. 2012; Hubáček et al. 2019; Boshnakov et al. 2017). Andererseits bezieht es sich auf das Sportbusiness selbst, bei dem hohe sportliche und finanzielle Anreize bestehen, z. B. das Interesse von Zuschauern (van Reeth 2019; Mueller 2020), optimales taktisches Bewegungsverhalten auf dem Spielfeld (Le et al. 2017; Dick und Brefeld 2019) oder Verletzungsrisiken (Rossi et al. 2018) adäquat zu modellieren.

Nicht zuletzt besteht ein wissenschaftliches Interesse, da prädiktive Modelle im Sport dazu beitragen können, übergreifende wissenschaftliche Theorien und Konzepte wie Markteffizienz (Angelini und Angelis 2019; Direr 2011; Bernardo et al. 2019; Goddard und Asimakopoulos 2004) oder kooperatives menschliches Urteilsvermögen (Peeters 2018; Spann und Skiera 2009) zu untersuchen.

9.2.3 Erstellung von prädiktiven Modellen und methodische Beispiele

An dieser Stelle soll erklärt werden, welche Schritte bei der Erstellung eines prädiktiven Modells nötig sind, und anhand von zwei beispielhaften Modellen das mathematische bzw. informatische Vorgehen erläutert werden.

1. Erster Schritt: Ziel

Zunächst ist kein prädiktives Modell denkbar ohne ein konkretes Ziel zu adressieren. Hierbei sind nicht nur die in diesem Kapitel bereits zahlreich genannten Anwendungsbeispiele zu beachten, sondern auch zahlreiche weitere Fragen zu den Charakteristiken des Modells zu beantworten, wie z. B.

- Wird eine prozentuale oder eine binäre (ja/nein) Vorhersage benötigt?
- Soll das Modell einfach und intuitiv verständlich sein?
- Ist eine hohe Berechnungszeit des Modells kritisch?
- Zielt das Modell eher auf eine hohe Genauigkeit oder eine hohe Profitabilität ab?

2. Zweiter Schritt: Datengrundlage

Einer der wichtigsten und nicht selten limitierenden Aspekte der Modellwahl ist die Datengrundlage. Hier ist insbesondere zu bewerten, welche Daten verfügbar sind, ob diese genutzt werden dürfen, und wenn ja, in welcher Menge (Stichprobengröße) die Daten vorliegen. Wichtig ist zudem zu bedenken, dass für sinnvolle prädiktive Modelle der Datensatz in einen genügend großen Trainings- und Testdatensatz geteilt werden sollte (*in-sample* und *out-of-sample data*). Die Anwendung eines Modells ergibt zudem nur dann Sinn, wenn Datenqualität und Informationsgehalt ausreichend sind, denn kein Modell der Welt wird in der Lage sein, ein zufriedenstellendes Ergebnis zu liefern, wenn die zugrunde liegenden Daten unvollständig und fehlerhaft sind oder von Vorneherein gar nicht die benötigten Informationen enthalten können.

3. Dritter Schritt: Methodischer Ansatz

In diesem Schritt geht es um die Modellwahl an sich, d. h. um die Frage, wie aus den gegebenen Daten eine Vorhersage erstellt werden kann. An dieser Stelle gehen wir davon aus, dass dafür ein statistischer oder informatischer Ansatz gewählt wird. Dabei ist zu beachten, dass der gewählte Ansatz das Ziel des Modells, die Datenverfügbarkeit und -komplexität sowie bereits vorhandenes Wissen über existierende Modelle oder die den modellierten Prozessen zugrunde liegenden Mechanismen berücksichtigt. Zum Beispiel bieten sich Machine-Learning-Modelle insbesondere an bei einer hohen Datenkomplexität, fehlendem Wissen über die zu modellierenden Prozesse und einem geringen Bedarf nach intuitiver Verständlichkeit der Modelle.

4. Vierter Schritt: Auswertung der prädiktiven Qualität

Als abschließender Schritt muss definiert werden, welche Kriterien für die prädiktive Qualität eines Modells relevant sind. Dies bezieht sich sowohl auf die Kalibrierung eines Modells als auch auf die finale Bewertung der prädiktiven Qualität. Die Auswahl der Kriterien hängt dabei natürlich wesentlich vom Ziel des Modells ab. Dankbare Maße sind u. a. der Anteil richtiger Vorhersagen, statistische Maße zur Genauigkeit von prozentualen Vorhersagen oder Profitabilitätsmaße wie Wettgewinne. Prädiktive Modelle können sich auf den Ausgang von Sportereignissen beziehen, wobei sie methodisch unterschiedliche Ansätze (statistisch, informatisch) verfolgen können.

■ **Modell 1: Statistisches Modell zur Vorhersage von Fußballergebnissen (Hvattum und Arntzen 2010)**

Ziel des hier vorgestellten Modells von Hvattum und Arntzen (2010) ist die prozentuale Vorhersage von Ergebnissen (Heimsieg, Unentschieden, Auswärtssieg) von Fußballspielen, wobei primär die Genauigkeit der Modelle betont wird. Datengrundlage sind die Ergebnisse von über 30.000 Fußballspielen, weitere Statistiken werden nicht verwendet. Jeder Mannschaft wird ein Parameter – das sogenannte ELO-Rating – zugeordnet, das die Spielstärke quantifiziert. Vor jedem Spiel wird aus diesen Parametern ein erwartetes Ergebnis berechnet und anhand des echten Ergebnisses werden die Stärkeparameter angepasst. Auf diese Weise ergibt sich ein adaptiver Prozess, bei dem die Stärken der Teams kontinuierliche Updates bekommen. Um aus den Spielstärken beider Teams eine prozentuale Vorhersage zu erhalten, nutzen die Autoren in einem zweiten Schritt ein ordinales logistisches Regressionsmodell, das die Differenz der Stärken als Input nutzt und daraus die Wahrscheinlichkeit der drei Spielausgänge bestimmt.

■ **Modell 2: Informatisches Modell zur Vorhersage von Pferderennen (Lessmann et al. 2010)**

Ziel des hier vorgestellten Modells von Lessmann et al. (2010) ist die prozentuale Vorhersage von Gewinnwahrscheinlichkeiten bei Pferderennen, wobei primär die Profitabilität des Modells hervorgehoben wird. Datengrundlage ist ein Datensatz von 1000 Pferderennen, der eine Vielzahl von verschiedenen Parametern beinhaltet. Um systematische Einflussfaktoren auf die Rennergebnisse abzubilden, nutzen die Autoren insgesamt 41 verschiedene Variablen, die sich auf den Wettmarkt, die Gegebenheiten des Rennens sowie die Charakteristiken und vorherigen Ergebnisse von Pferden, Jockeys und Trainern beziehen. Um diese Einflussfaktoren in eine prozentuale Vorhersage zu überführen, wird das sogenannte Random-Forest-Verfahren genutzt. Dieses gehört zur Familie der Machine-Learning-Modelle, basiert auf der randomisierten Erstellung von Entscheidungsbäumen und wird an anderer Stelle in diesem Buch detaillierter beschrieben.

Definition

Unter prädiktiven Modellen verstehen wir in diesem Buch insbesondere sämtliche statistischen oder informatischen Modelle, die darauf abzielen, die Wahrscheinlichkeit für das Eintreffen von in der Zukunft liegenden Ereignissen abzuschätzen.

9.3 Anwendungen

► Beispiel 1

Bei diesem Anwendungsbereich geht es darum, die Wahrscheinlichkeit für Ergebnisse von Sportereignissen zu schätzen. Anhand des Beispiels Fußball kann dies z. B. das Endergebnis im Sinne von Heimsieg, Unentschieden, Auswärtssieg (Hvattum und Arnt-

zen 2010), die genaue Anzahl Tore beider Teams (Karlis und Ntzoufras 2003) oder die Gesamtzahl der Tore im Spiel (Wheatcroft 2020) sein. Besondere Relevanz erfährt dieses Anwendungsbeispiel durch die Sportwettenbranche, die Wetten auf eben diese Ergebnisse ermöglicht. Datengrundlage sind in der Regel vorherige Ergebnisse (Koopman und Lit 2019; Hvattum und Arntzen 2010) und/oder zusätzliche mannschafts- oder spieler-individuelle Matchstatistiken (Hubáček et al. 2019; Štrumbelj und Vračar 2012). Methodisch werden häufig klassische statistische Verfahren wie adaptive Ratings und Wahrscheinlichkeitsmodelle genutzt. ◀

► Beispiel 2

Bei diesem Anwendungsbereich geht es um prädiktive Ansätze zur Modellierung des taktischen Verhaltens von Mannschaften auf dem Spielfeld. Er ist daher eher den Bereichen Performance Analysis bzw. Spielanalyse zuzuordnen. Konkret wird dabei z. B. versucht, durch sogenanntes „Ghosting“ das kollektive Bewegungsverhalten von Mannschaften vorherzusagen (Seidl et al. 2018; Le et al. 2017) oder die Gefährlichkeit von Spielsituationen und Aktionen auf dem Spielfeld zu analysieren (Dick und Brefeld 2019; Wei et al. 2013; Link et al. 2016; Lucey et al. 2014). Datengrundlage sind dabei in der Regel umfangreiche Datensätze von Positionsdaten und Eventdaten, und methodisch sind aufgrund der Datenstruktur Machine-Learning-Modelle prädestiniert. ◀

9

► Beispiel 3

Ein relativ junges Anwendungsbeispiel sind bewegungsdatengestützte prädiktive Ansätze zur Vorbeugung von Verletzungen (Rossi et al. 2018), die somit eine Verknüpfung zu den Bereichen Belastungssteuerung und Sportmedizin herstellen. Datengrundlage können z. B. GPS-Bewegungsdaten, weitere physischen Belastungsdaten und, soweit verfügbar, zusätzliche persönliche und medizinische Daten sein (Rossi et al. 2018; Ehrmann et al. 2016). Auch hier können durch die Vielzahl verschiedener Datenquellen Machine-Learning-Modelle einen geeigneten Ansatz darstellen (Claudino et al. 2019). ◀

Studienbox

Kovalchik (2016) untersuchte die Qualität von elf verschiedenen prädiktiven Modellen zur Vorhersage von Tennisergebnissen. Basierend auf über 2000 Matches der ATP-Saison 2014, analysierte sie Regressionsmodelle, punktbasierte Modelle und auf paarweisen Vergleichen basierende Modelle sowie Wettquoten. Am besten schnitten dabei Regressionsmodelle sowie auf dem ELO-Rating basierende Modelle ab, wobei keines der getesteten Modelle die prädiktive Qualität von Wettquoten erreichen oder überbieten konnte.

? Fragen für die Studierenden

Welche Anwendungsbereiche für prädiktive Modelle gibt es im Sport?

Welche Schritte sind notwendig, um ein sinnvolles prädiktives Modell zu entwickeln?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Angelini, Giovanni; Angelis, Luca de (2019): Efficiency of online football betting markets. In: *International Journal of Forecasting* 35 (2), S. 712–721. DOI: <https://doi.org/10.1016/j.ijforecast.2018.07.008>.
- Bernardo, Giovanni; Ruberti, Massimo; Verona, Roberto (2019): Semi-strong inefficiency in the fixed odds betting market: Underestimating the positive impact of head coach replacement in the main European soccer leagues. In: *The Quarterly Review of Economics and Finance* 71, S. 239–246. DOI: <https://doi.org/10.1016/j.qref.2018.08.007>.
- Booth, Heather (2006): Demographic forecasting: 1980 to 2005 in review. In: *International Journal of Forecasting* 22 (3), S. 547–581. DOI: <https://doi.org/10.1016/j.ijforecast.2006.04.001>.
- Boshnakov, Georgi; Kharrat, Tarak; McHale, Ian G. (2017): A bivariate Weibull count model for forecasting association football scores. In: *International Journal of Forecasting* 33 (2), S. 458–466. DOI: <https://doi.org/10.1016/j.ijforecast.2016.11.006>.
- Brandt, Patrick T.; Freeman, John R.; Schrodt, Philip A. (2014): Evaluating forecasts of political conflict dynamics. In: *International Journal of Forecasting* 30 (4), S. 944–962. DOI: <https://doi.org/10.1016/j.ijforecast.2014.03.014>.
- Claudino, João Gustavo; Capanema, Daniel de Oliveira; Souza, Thiago Vieira de; Serrão, Julio Cerca; Machado Pereira, Adriano C.; Nassis, George P. (2019): Current Approaches to the Use of Artificial Intelligence for Injury Risk Assessment and Performance Prediction in Team Sports: a Systematic Review. In: *Sports medicine – open* 5 (1), S. 28. DOI: <https://doi.org/10.1186/s40798-019-0202-3>.
- Constantinou, Anthony C.; Fenton, Norman E.; Neil, Martin (2012): pi-football: A Bayesian network model for forecasting Association Football match outcomes. In: *Knowledge-Based Systems* 36, S. 322–339. DOI: <https://doi.org/10.1016/j.knosys.2012.07.008>.
- Dick, Uwe; Brefeld, Ulf (2019): Learning to Rate Player Positioning in Soccer. In: *Big Data* 7 (1), S. 71–82. DOI: <https://doi.org/10.1089/big.2018.0054>.
- Direr, Alexis (2011): Are betting markets efficient? Evidence from European Football Championships. In: *Applied Economics* 45 (3), S. 343–356. DOI: <https://doi.org/10.1080/00036846.2011.602010>.
- Ehrmann, Fabian E.; Duncan, Craig S.; Sindhusake, Doungkamol; Franzsen, William N.; Greene, David A. (2016): GPS and Injury Prevention in Professional Soccer. In: *Journal of strength and conditioning research* 30 (2), S. 360–367. DOI: <https://doi.org/10.1519/JSC.0000000000001093>.

- Goddard, John; Asimakopoulos, Ioannis (2004): Forecasting football results and the efficiency of fixed-odds betting. In: *J. Forecast.* 23 (1), S. 51–66. DOI: <https://doi.org/10.1002/for.877>.
- Gorr, Wilpen; Olligschlaeger, Andreas; Thompson, Yvonne (2003): Short-term forecasting of crime. In: *International Journal of Forecasting* 19 (4), S. 579–594. DOI: [https://doi.org/10.1016/S0169-2070\(03\)00092-X](https://doi.org/10.1016/S0169-2070(03)00092-X).
- Green, Kesten C.; Armstrong, J. Scott; Soon, Willie (2009): Validity of climate change forecasting for public policy decision making. In: *International Journal of Forecasting* 25 (4), S. 826–832. DOI: <https://doi.org/10.1016/j.ijforecast.2009.05.011>.
- Hong, Tao; Pinson, Pierre; Fan, Shu; Zareipour, Hamidreza; Troccoli, Alberto; Hyndman, Rob J. (2016): Probabilistic energy forecasting: Global Energy Forecasting Competition 2014 and beyond. In: *International Journal of Forecasting* 32 (3), S. 896–913. DOI: <https://doi.org/10.1016/j.ijforecast.2016.02.001>.
- Horvat, Tomislav; Job, Josip (2020): The use of machine learning in sport outcome prediction: A review. In: *WIREs Data Mining Knowl Discov* 10 (5). DOI: <https://doi.org/10.1002/widm.1380>.
- Hubáček, Ondřej; Šourek, Gustav; Železný, Filip (2019): Exploiting sports-betting market using machine learning. In: *International Journal of Forecasting* 35 (2), S. 783–796. DOI: <https://doi.org/10.1016/j.ijforecast.2019.01.001>.
- Hvattum, Lars Magnus; Arntzen, Halvard (2010): Using ELO ratings for match result prediction in association football. In: *International Journal of Forecasting* 26 (3), S. 460–470. DOI: <https://doi.org/10.1016/j.ijforecast.2009.10.002>.
- Karlis, D.; Ntzoufras, I. (2003): Analysis of sports data by using bivariate Poisson models. In: *Journal of the Royal Statistical Society: Series D (The Statistician)* 52 (3), S. 381–393.
- Klemp, Maximilian; Wunderlich, Fabian; Memmert, Daniel (2021): In-play forecasting in football using event and positional data. In: *Scientific reports* 11 (1), S. 24139. DOI: <https://doi.org/10.1038/s41598-021-03157-3>.
- Koopman, Siem Jan; Lit, Rutger (2019): Forecasting football match results in national league competitions using score-driven time series models. In: *International Journal of Forecasting* 35 (2), S. 797–809. DOI: <https://doi.org/10.1016/j.ijforecast.2018.10.011>.
- Kovalchik, S. A. (2016). Searching for the GOAT of tennis win prediction. *Journal of Quantitative Analysis in Sports*, 12(3), 127–138.
- Le, H.; Carr, Peter; Yue, Yisong; Lucey, Patrick (2017): Data-Driven Ghosting using Deep Imitation Learning. In: *Proceedings of the 11th Annual MIT Sloan Sports Analytics Conference 2017*. Boston, MA.
- Lessmann, Stefan; Sung, Ming-Chien; Johnson, Johnnie E.V. (2010): Alternative methods of predicting competitive events: An application in horserace betting markets. In: *International Journal of Forecasting* 26 (3), S. 518–536. DOI: <https://doi.org/10.1016/j.ijforecast.2009.12.013>.
- Link, Daniel; Lang, Steffen; Seidenschwarz, Philipp (2016): Real Time Quantification of Dangerousness in Football Using Spatiotemporal Tracking Data. In: *PloS one* 11 (12), e0168768. DOI: <https://doi.org/10.1371/journal.pone.0168768>.
- Lucey, Patrick; Bialkowski, Alina; Carr, Peter; Yue, Yisong; Matthews, Iain (2014): How to get an open shot: Analyzing team movement in basketball using tracking data. In: *Proceedings of the 8th annual MIT SLOAN sports analytics conference*. Citeseer.
- McHale, Ian; Swartz, Tim (2019): Editorial: Forecasting in sports. In: *International Journal of Forecasting* 35 (2), S. 710–711. DOI: <https://doi.org/10.1016/j.ijforecast.2019.01.002>.
- Mueller, Steffen Q. (2020): Pre- and within-season attendance forecasting in Major League Baseball: a random forest approach. In: *Applied Economics* 52 (41), S. 4512–4528. DOI: <https://doi.org/10.1080/00036846.2020.1736502>.
- Peeters, Thomas (2018): Testing the Wisdom of Crowds in the field: Transfermarkt valuations and international soccer results. In: *International Journal of Forecasting* 34 (1), S. 17–29. DOI: <https://doi.org/10.1016/j.ijforecast.2017.08.002>.
- Rossi, Alessio; Pappalardo, Luca; Cintia, Paolo; Iaia, F. Marcello; Fernández, Javier; Medina, Daniel (2018): Effective injury forecasting in soccer with GPS training data and machine learning. In: *PloS one* 13 (7), e0201264. DOI: <https://doi.org/10.1371/journal.pone.0201264>.

- Seidl, Thomas; Cherukumudi, Aditya; Hartnett, Andrew; Carr, Peter; Lucey, Patrick (2018): Bhost-gusters: Realtime interactive play sketching with synthesized NBA defenses. In: 12 th Annual MIT Sloan Sports Analytics Conference.
- Spann, Martin; Skiera, Bernd (2009): Sports forecasting: a comparison of the forecast accuracy of prediction markets, betting odds and tipsters. In: J. Forecast. 28 (1), S. 55–72. DOI: <https://doi.org/10.1002/for.1091>.
- Štrumbelj, Erik; Vračar, Petar (2012): Simulating a basketball match with a homogeneous Markov model and forecasting the outcome. In: International Journal of Forecasting 28 (2), S. 532–542. DOI: <https://doi.org/10.1016/j.ijforecast.2011.01.004>.
- Taylor, James W.; Buizza, Roberto (2004): A comparison of temperature density forecasts from GARCH and atmospheric models. In: J. Forecast. 23 (5), S. 337–355. DOI: <https://doi.org/10.1002/for.917>.
- Timmermann, A. (2000): Density forecasting in economics and finance. In: Journal of Forecasting 19 (4), S. 231–234.
- van Reeth, Daam (2019): Forecasting Tour de France TV audiences: A multi-country analysis. In: International Journal of Forecasting 35 (2), S. 810–821. DOI: <https://doi.org/10.1016/j.ijforecast.2018.06.003>.
- Vaughan Williams, Leighton; Stekler, Herman O. (2010): Sports forecasting. In: International Journal of Forecasting 26 (3), S. 445–447. DOI: <https://doi.org/10.1016/j.ijforecast.2009.12.005>.
- Wei, Xinyu; Lucey, Patrick; Morgan, Stuart; Sridharan, Sridha (2013): Sweet-spot: Using spatiotemporal data to discover and predict shots in tennis. In: 7th Annual MIT Sloan Sports Analytics Conference, Boston, MA.
- Wheatcroft, Edward (2020): A profitable model for predicting the over/under market in football. In: International Journal of Forecasting 36 (3), S. 916–932. DOI: <https://doi.org/10.1016/j.ijforecast.2019.11.001>.
- Wolfers, Justin; Leigh, Andrew (2002): Three Tools for Forecasting Federal Elections: Lessons from 2001. In: Australian Journal of Political Science 37 (2), S. 223–240. DOI: <https://doi.org/10.1080/10361140220148115>.
- Wunderlich, Fabian; Memmert, Daniel (2020): Forecasting the outcomes of sports events: A review. In: European journal of sport science 21 (7), S. 944–957. DOI: <https://doi.org/10.1080/17461391.2020.1793002>.



Physiologische Modellierung

Manuel Bassek

Inhaltsverzeichnis

- 10.1 Beispiel Sport – 84
- 10.2 Hintergrund – 84
- 10.3 Anwendungen – 85
- Literatur – 88

Kernbotschaften

- Physiologische Modelle werden verwendet, um die Anforderungen der körperlichen Aktivität zu beschreiben und die Belastung zu analysieren, die der Sportler*innen in seiner Sportart erfährt.
- Die Erfassung von Positionsdaten bietet die Möglichkeit, die objektive externe Belastung genau zu berechnen.
- Physiologische Modelle können verwendet werden, um von der externen Belastung auf die interne Beanspruchung zu schließen.
- Verschiedene physiologische Modelle eignen sich für unterschiedliche Aktivitäten, wie z. B. das Laufen mit konstanter Geschwindigkeit in der Leichtathletik oder nicht lineare Bewegungen im Handball.

10.1 Beispiel Sport

In diesem Kapitel werden drei verschiedene Ansätze zur physiologischen Modellierung der Belastung von Athlet*innen auf der Grundlage objektiver Datenquellen, wie etwa Positionsdaten, vorgestellt. Trainer*innen können von solchen Daten profitieren, insbesondere, wenn sie mit einer großen Anzahl von Athlet*innen zu tun haben, wie z. B. in Mannschaftssportarten. Hier ist die Überwachung der Belastung ein zentraler Aspekt für Trainer*innen im Training und im Wettkampf. Genaue Informationen über die Belastung und Regeneration eines Athlete*innen können dazu beitragen, das Leistungsniveau konstant auf ein Maximum zu steigern und gleichzeitig das Verletzungsrisiko zu minimieren. Sie können genutzt werden, um die Einhaltung von Trainingsvorgaben zu kontrollieren, zu überprüfen, ob bestimmte Übungen den gewünschten physiologischen Effekt hatten, individuelle Regenerationsphasen zu planen oder Erholungsprozesse nach Verletzungen zu überwachen. Die zentralen Vorteile der physiologischen Modellierung liegen zum einen in der sofortigen Bewertung der Belastung, da moderne Algorithmen Übungen, Trainingseinheiten oder Spiele in Sekundenbruchteilen auswerten können. Zum anderen ermöglicht sie eine Entscheidungsfindung im Training auf der Grundlage objektiver Daten und empirischer Erkenntnisse.

10.2 Hintergrund

Um das Training zu optimieren und Verletzungen vorzubeugen, ist die genaue Charakterisierung der Spieler*innenbelastung eine wichtige Aufgabe für Trainer*innen, Analyst*innen und Forscher*innen (Akenhead & Nassis, 2016; Bourdon et al., 2017). Die Belastung eines/einer Athlet*in wird im Allgemeinen definiert als die relativen biologischen Stressoren, denen der/die Athlet*in während des Trainings oder Wettkampfs ausgesetzt ist (Bourdon et al., 2017). Ein Stressor kann alles sein, was im Training eine biologische Reaktion des Körpers auslöst, wobei relativ bedeutet, dass die Reaktion auf eine objektive Belastung von den individu-

ellen Fähigkeiten der/des Athlet*in abhängt. Diese Stressoren können entweder intern (z. B. Herzfrequenz) oder extern (z. B. Laufdistanz) gemessen und subjektiv (z. B. gefühlte Anstrengung) oder objektiv (GPS-Daten) erfasst werden. Objektive und interne Messungen (z. B. der Sauerstoffverbrauch) wären zwar für die Beurteilung der Belastung von Vorteil, sind aber in der Regel nicht für die Verwendung außerhalb eines Labors geeignet.

Mittlerweile können Athlet*innen die objektive interne und externe Belastung bereits mit weithin verfügbaren Wearables wie Herzfrequenzmessgeräten, GPS-fähigen Uhren oder Smartphones messen (Lutz et al., 2019). Letztere liefern genaue Messungen von Distanzen, Geschwindigkeiten und Beschleunigungen (Scott et al., 2016). In professionellen Mannschaftssportarten, wie dem Fußball, ist die Erfassung von Positionsdaten ein Standardverfahren während des Trainings und des Wettkampfs (s. ► Kap. 6j) und ermöglicht eine kontinuierliche Überwachung der Aktivität der Spieler*innen. Allerdings sind die Rohdaten für Analyst*innen nicht geeignet, um angemessene Trainingsempfehlungen abzuleiten. Die Aufzeichnung eines kompletten Handballspiels mit einem lokalen Positionssystem ergibt zum Beispiel über eine Million Datenpunkte ($14 \text{ Spieler*innen} \times 60 \text{ min} \times 60 \text{ s} \times 20 \text{ Hz}$). Daher müssen die Daten zu interpretierbaren und vergleichbaren Maßen aggregiert werden, um die inter- und intraindividuellen Belastungen effektiv verfolgen zu können. Es sei daran erinnert, dass sich die Belastung der Spieler*innen auf *relative* und *biologische* Stressoren bezieht. Daher zielt die physiologische Modellierung der Spielerbelastung darauf ab, Parameter aus objektiven externen Messgrößen zu extrahieren, die in enger Beziehung zu objektiven internen Messgrößen stehen. Im Idealfall können diese in den Kontext der individuellen Kapazitäten des/der Sportler*in gestellt werden.

Definition

Die physiologische Modellierung der Spieler*innenbelastung beschreibt die Extraktion physiologischer Parameter aus nicht-physiologischen Daten. Sie kann verwendet werden, um die Arbeitsbelastung von Sportler*innen während des Trainings und des Wettkampfs zu überwachen, um Trainingsergebnisse zu optimieren und Verletzungen vorzubeugen (Akenhead & Nassis, 2016; Bourdon et al., 2017). Im professionellen Mannschaftssport können die gesammelten Positionsdaten zu diesem Zweck verarbeitet werden.

10.3 Anwendungen

► Beispiel 1

Trainingsimpuls (TRIMP). Banister (1991) schlug den TRIMP vor, um die interne Belastung während des Ausdauertrainings zu modellieren. Der TRIMP wird als Produkt aus Trainingsdauer und Intensität berechnet. Die Intensität wird aus den Herzfrequenzdaten abgeleitet und mit einer Exponentialfunktion modelliert, um die nicht lineare Beziehung zwischen Intensität und interner Belastung zu berücksichtigen, wie sie sich in Blutlaktatkurven zeigt (für eine detaillierte Formel s. Borresen & Lambert, 2009).

Außerdem werden die Ruhe- und die maximale Herzfrequenz als Repräsentanten der individuellen Kondition des/der Athlet*in einbezogen. Auch individuelle Laktatkurven können in das Modell aufgenommen werden (Manzi et al., 2014). Der TRIMP ermöglicht eine ökologische Messung der Belastung, da dafür nur Herzfrequenzmessungen benötigt werden. Er kann verwendet werden, um die Intensität kontinuierlichen Ausdauertrainings zu überwachen. Im Mannschaftssport kann er beispielsweise während der Saisonvorbereitung und Regeneration eingesetzt werden. Der TRIMP ist jedoch auf Einheiten mit konstanter Geschwindigkeit beschränkt und ist nicht für Intervalltraining oder sportartspezifische Übungen geeignet. ◀

► Beispiel 2

Geschwindigkeitszonen. Multidirektionale Mannschaftssportarten wie Handball sind durch das nicht lineare Bewegungsverhalten der Spieler*innen gekennzeichnet, was bedeutet, dass die Spieler*innen ihre Geschwindigkeit ständig ändern (Karcher & Buchheit, 2014). Ein Ansatz zur Messung der Belastung in Mannschaftssportarten besteht darin, die von den Spieler*innen zurückgelegte Distanz in Geschwindigkeitszonen zu unterteilen. Im Laufe der Zeit wurden viele Modelle mit einer unterschiedlichen Anzahl von Zonen und Grenzgeschwindigkeiten verwendet (s. Miguel et al., 2021, für eine detaillierte Übersicht). Alsan und Aç (2012) verwendeten beispielsweise acht Zonen: (1) Gehen: 0–6 km/h, (2) Joggen: 6,1–8 km/h, (3) Laufen mit niedriger Intensität: 8,1–12 km/h, (4) Laufen mit mittlerer Intensität: 12,1–15 km/h, (5) Laufen mit hoher Intensität: 15,1–18 km/h, (6) Sprint mit niedriger Intensität: 18,1–21 km/h, (7) Sprint mit mittlerer Intensität: 21,1–24 km/h, (8) Sprint mit hoher Intensität: > 24 km/h; während Clemente et al. (2019) vier Zonen identifizierten: (1) Gehen: 0–6,9 km/h, (2) Joggen: 7–13,9 km/h, (3) Laufen: 14–20 km/h, (4) Sprinten: > 20 km/h. Andere Ansätze individualisieren die Geschwindigkeitszonen auf der Grundlage der durch Laktatschwellen gemessenen Kapazitäten der Athleten (Aslan & Aç, 2012) oder in Prozenten der Höchstgeschwindigkeit (Bacon & Mauer, 2017).

Die in verschiedenen Geschwindigkeitszonen zurückgelegten Distanzen sind ein einfacher Ansatz zur Modellierung der Spieler*innenbelastung, wenn die Aktivität nicht linear verläuft. Dies kann genutzt werden, um die Distanz-pro-Zone-Profile von Sportler*innen mit wünschenswerten Benchmark-Werten zu vergleichen. Solche Werte können die eigene Leistung vor einer Verletzung sein, um sie während der Rehabilitation zu vergleichen, oder der durchschnittliche Profispieler*innen, um Talente zu identifizieren. Allerdings erschweren die unterschiedlichen Definitionen von Geschwindigkeitszonen den Vergleich der von verschiedenen Forscher*innen und Praktiker*innen verwendeten Modelle (Bradley & Ade, 2018). ◀

► Beispiel 3

Metabolic Power. Beide zuvor beschriebenen Ansätze beziehen Beschleunigungen und Verlangsamungen nicht in ihre Modellierung ein. Ein möglicher Weg sie einzubeziehen, ist das Konzept der Metabolic Power. Metabolic Power ist definiert als der Energieaufwand pro Zeiteinheit, der erforderlich ist, um sich mit einer bestimmten Geschwindigkeit fortzubewegen, und wird berechnet als Produkt der Energiekosten für den Transport pro Einheit Körpermasse und Distanz ($\text{J} \cdot \text{kg}^{-1} \cdot \text{m}^{-1}$) und Geschwindigkeit ($\text{m} \cdot \text{s}^{-1}$) (di Prampero & Osgnach, 2018). Das Maß wurde erstmals von di Prampero et al. (2005)

eingeführt, die die biomechanische Äquivalenz von beschleunigtem (oder gebremstem) Laufen auf flachem Gelände und konstantem Laufen bergauf (oder bergab) nutzen, um den Energiebedarf für eine bestimmte Fortbewegung zu schätzen. Seitdem wurde es in mehreren Studien zur Charakterisierung der Spieler*innenbelastung verwendet (Miguel et al., 2021).

Das Modell der Metabolic Power kann mehrere Parameter der Spieler*innenbelastung liefern. (1) Metabolic Power: die momentane Leistung, die zur Durchführung der aktuellen Fortbewegung benötigt wird; (2) Metabolic Work: die Energie, die benötigt wird, um die Fortbewegung in einem Zeitfenster auszuführen; (3) Equivalent Distance: die Strecke, die jemand mit der gleichen Energie hätte zurücklegen können, wenn er nicht beschleunigt oder gebremst hätte; (4) Equivalent Distance Index: das Verhältnis zwischen der Equivalent Distance und der tatsächlich zurückgelegten Distanz. Der Equivalent Distance Index kann als Indikator dafür verwendet werden, wie sehr eine Aktivität durch Beschleunigungen und Abbremsen geprägt war. Diese Maße ermöglichen einen detaillierteren Einblick in die Belastung auf der Grundlage der kombinierten Analyse von Distanz, Geschwindigkeit und Beschleunigung. Außerdem liefern sie umfassende und vergleichbare Werte für die Belastung der Spieler*innen (Polglaze & Hoppe, 2019). ◀

Studienbox

Bassek et al. (2023) analysierten die Belastung von 330 männlichen Elite-Handballern während 77 Spielen der deutschen Handball-Bundesliga. Sie berichteten Benchmark-Werte für die Belastung von Profi-Handball-Spielen als Distanzen in sechs Geschwindigkeitszonen sowie Metabolic Power, Metabolic Work, Equivalent Distance und Equivalent Distance Index. Außerdem verglichen Sie den Einfluss des physiologischen Modells auf die gemessene Belastung statistisch. Dafür berechneten sie für jeden Spieler die zurückgelegte Distanz und die Equivalent Distance des Metabolic-Power-Modells. Anschließend wurden die Unterschiede dieser Maße zwischen den handballspezifischen Spielerpositionen Außen, Kreisläufer und Rückraumspieler mittels einer Varianzanalyse untersucht. Die Ergebnisse zeigten einen signifikanten Inter-

aktionseffekt für die Unterschiede zwischen Distanz und Equivalent Distance und den Spielerpositionen. Außen hatten eine größere Differenz zwischen der Equivalent Distance und der zurückgelegten Distanz als Rückraumspieler und Kreisläufer, was bedeutet, dass ihr Spiel stärker durch häufige Beschleunigungen und Abbremsen charakterisiert ist. Dies deckt sich mit anderen Studien, die berichten, dass Außen am häufigsten in Konterangriffe involviert sind, in denen maximale Antritte ausschlaggebend sind (Karcher & Buchheit, 2014). Die Wahl des physiologischen Modells ist also maßgeblich für die Analyse von Belastungen. In Sportarten, die durch konstantes Beschleunigen und Abbremsen charakterisiert sind, sollten Modelle verwendet werden, die Beschleunigungen abbilden können.

? Fragen für die Studierenden

In welche Kategorien kann die Bewertung der Spieler*innenbelastung unterteilt werden?

Nennen Sie drei Schlüsselmaße, die aus Positionsdaten abgeleitet werden können und die Grundlage für die physiologische Modellierung bilden.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Akenhead, R., & Nassis, G. P. (2016). Training load and player monitoring in high-level football: Current practice and perceptions. *International Journal of Sports Physiology and Performance*, 11(5), 587–593. <https://doi.org/10.1123/ijsp.2015-0331>
- Aslan, A., & Aç, C. (2012). Metabolic demands of match performance in young soccer players. *Journal of Sports Science & Medicine*, 11, 170–179.
- Bacon, C. S., & Mauger, A. R. (2017). Prediction of overuse injuries in professional U18-U21 footballers using metrics of training distance and intensity. *Journal of Strength and Conditioning Research*, 31(11), 3067–3076. <https://doi.org/10.1519/JSC.0000000000001744>
- Banister, E. W. (1991). Modeling elite athletic performance. In MacDougall, D., Wenger, H. A., Green, H. J. (Eds.), *Physiological testing of the high-performance athlete* (2nd ed.). Human Kinetics Books.
- Bassek, M., Raabe, D., Memmert, D., & Rein, R. (2023). Analysis of motion characteristics and Metabolic Power in elite male handball players. *Journal of Sports Science and Medicine*, 22, 310–316. <https://doi.org/10.52082/jssm.2023.310>
- Borresen, J., & Lambert, M. I. (2009). The quantification of training load, the training response and the effect on performance. *Sports Medicine*, 39(9), 779–795.
- Bourdon, P. C., Cardinale, M., Murray, A., Gatin, P., Kellmann, M., Varley, M. C., Gabbett, T. J., Coutts, A. J., Burgess, D. J., Gregson, W., & Cable, N. T. (2017). Monitoring athlete training loads: Consensus statement. *International Journal of Sports Physiology and Performance*, 12(s2), S2-161-S2-170. <https://doi.org/10.1123/IJSP.2017-0208>
- Bradley, P. S., & Ade, J. D. (2018). Are current physical match performance metrics in elite soccer fit for purpose or is the adoption of an integrated approach needed? *International Journal of Sports Physiology and Performance*, 13(5), 656–664. <https://doi.org/10.1123/ijsp.2017-0433>

- Clemente, F. M., Owen, A., Serra-Olivares, J., & Nikolaidis, P. T. (2019). Characterization of the weekly external load profile of professional soccer teams from Portugal and the Netherlands. *Journal of Human Kinetics*, 66, 155–164. <https://doi.org/10.2478/hukin-2018-0054>
- Karcher, C., & Buchheit, M. (2014). On-court demands of elite handball, with special reference to playing positions. *Sports Medicine*, 44(6), 797–814. <https://doi.org/10.1007/s40279-014-0164-z>
- Lutz, J., Memmert, D., Raabe, D., Dornberger, R., & Donath, L. (2019). Wearables for integrative performance and tactic analyses: Opportunities, challenges, and future directions. *International Journal of Environmental Research and Public Health*, 17(1), 1–26. <https://doi.org/10.3390/ijerph17010059>
- Manzi, V., Impellizzeri, F., & Castagna, C. (2014). Aerobic fitness ecological validity in elite soccer players: A metabolic power approach. *Journal of Strength and Conditioning Research*, 28(4), 6.
- Miguel, M., Oliveira, R., Loureiro, N., García-Rubio, J., & Ibáñez, S. J. (2021). Load measures in training/match monitoring in soccer: A systematic review. *International Journal of Environmental Research and Public Health*, 18(5), 2721. <https://doi.org/10.3390/ijerph18052721>
- di Prampero, P. E., Fusi, S., Sepulcri, L., Morin, J. B., Belli, A., & Antonutto, G. (2005). Sprint running: A new energetic approach. *Journal of Experimental Biology*, 208(14), 2809–2816. <https://doi.org/10.1242/jeb.01700>
- di Prampero, P. E., & Osgnach, C. (2018). Metabolic power in team sports - Part 1: An update. *International Journal of Sports Medicine*, 39(08), 581–587. <https://doi.org/10.1055/a-0592-7660>
- Polglaze, T., & Hoppe, M. W. (2019). Metabolic power: A step in the right direction for team sports. *International Journal of Sports Physiology and Performance*, 14(3), 407–411. <https://doi.org/10.1123/ijsp.2018-0661>
- Scott, M. T. U., Scott, T. J., & Kelly, V. G. (2016). The validity and reliability of global positioning systems in team sport: A brief review. *Journal of Strength and Conditioning Research*, 30(5), 1470–1490. <https://doi.org/10.1519/JSC.0000000000001221>

Simulation

Inhaltsverzeichnis

- Kapitel 11 Simulation – 93**
Jürgen Perl und Daniel Memmert
- Kapitel 12 Metabolische Simulation – 103**
Dietmar Saupe
- Kapitel 13 Simulation physiologischer
Anpassungsprozesse – 113**
Mark Pfeiffer und Stefan Endler



Simulation

Jürgen Perl und Daniel Memmert

Inhaltsverzeichnis

11.1 Beispiel Sport – 94

11.2 Hintergrund – 94

11.3 Anwendungen – 98

Literatur – 101

Kernbotschaften

System – Modell – Simulation:


1. Systemverhalten wird durch Modelle berechenbar.
2. Modellberechnungen simulieren das Systemverhalten und machen es transparent.
3. Simulationen helfen damit, Systemverhalten zu verstehen, vorausszusagen und zu beeinflussen.

11.1 Beispiel Sport

Die Leistungsanalyse im Sport hat im Wesentlichen zwei Ziele: Zum einen die Erkennung und optimale Nutzung der individuellen Leistungsgrenzen im Wettkampf, speziell bei Dauerbelastungen. Zum anderen die Erreichung und ggf. Steigerung der physiologischen Leistungskapazitäten im Training. Durch die komplexen Wechselwirkungen der unterschiedlichsten physiologischen Komponenten des Körpers ist es schwierig, Wirkungen wie Unter- oder Überforderung zu prognostizieren. Ein auf wenige Parameter vereinfachendes Wechselwirkungsmodell macht es möglich, durch Variation dieser Parameter (in *PerPot*, vgl. ► Kap. 13 Wirkungsverzögerungen) die physiologischen Reaktionen zu simulieren und so zu optimieren. Die Methode der regelmäßigen Überprüfung und Nachoptimierung, die für das Training offensichtlich adäquat ist, lässt sich dann entsprechend durch Online-Datenerfassung und -optimierung auch im Wettkampf anwenden. Über diese Optimierung hinaus lassen sich durch derartige simulationsgestützte Analysen aber aus Diskrepanzen zwischen Erwartung und Realität auch Unstimmigkeiten erkennen: Zum einen kann der tatsächliche Leistungsverlauf deutlich unter dem simulierten Verlauf liegen und damit eine zusätzliche physiologische Belastungssituation (z. B. Erkrankung) signalisieren. Zum anderen könnte der Leistungsverlauf deutlich über der Erwartung liegen, was dann auf zusätzliche Leistungspotenziale (wie z. B. Doping) schließen ließe.

11.2 Hintergrund

Simulationsbasierte Ansätze zur Verhaltensoptimierung sind im Sport in so unterschiedlichen Bereichen wie Taktikoptimierung in Mannschaftsspielen, Technikoptimierung für Bewegungsmuster oder Belastungs-Leistungs-Optimierung in Training und Wettkampf zu finden. Für das letzte der Beispiele kann der Zusammenhang zwischen Realität, Modell und Simulation besonders plastisch dargestellt werden. Physiologische Leistungsanalysen können mit *PerPot* (vgl. Perl, 2002, 2004) durchgeführt werden, welches in den verschiedensten Bereichen der Leistungsanalyse und -optimierung Verwendung gefunden hat (■ Abb. 11.1). Entsprechend den Ausführungen im ► Kap. 13 ist im *PerPot*-Modell das menschliche




■ **Abb. 11.1** Das Performance-Potential-Modell PerPot (nach Perl, 2003)

physiologische System auf ein Minimum an (abstrakten) Basiskomponenten reduziert, deren Wechselwirkungen nichtsdestoweniger mit erstaunlicher Präzision die Belastungs-Leistungs-Dynamiken (nicht nur) im Sport wiedergeben und dadurch für prognostische Simulationen geeignet ist (vgl. Perl, 2003):


Eine Belastungsrate (z. B. Laufgeschwindigkeit) füllt in gleicher Weise die beiden internen Potenziale „Belastung“ und „Erholung“. Aus dem Potenzial „Erholung“ füllt sich mit einer Verzögerung DR (*delay in response*) das Leistungspotenzial (hier z. B. Herzfrequenz). Aus dem Potenzial „Belastung“ wird mit einer Verzögerung DS (*delay in strain*) über einen negativen Fluss Leistung abgezogen. Dadurch entsteht auf dem Leistungspotenzial ein Einschwingvorgang, der gegebenenfalls zu stabilen Zuständen oder auch – z. B. bei Überbelastungen – zu vollständigen Ausschöpfungen des Leistungspotenzials führen kann. Im Belastungspotenzial ist die „Reserve“ ein Indikator dafür, wie hoch das Belastungsniveau ist. Läuft durch eine sehr hohe Belastungsrate das Belastungspotenzial über, wird die Reserve also negativ, dann wird mit einer sehr kurzen Verzögerung DSO (*delay in strain overflow*) das Leistungspotenzial zusätzlich reduziert. Der Fall der negativen Reserve kann als Überlastindikator verwendet werden kann.

In den folgenden Abbildungen zeigen die obersten Grafiken ein jeweils gleiches Belastungsprofil (Laufgeschwindigkeit), die mittleren Grafiken zeigen Leistungsprofile (Herzfrequenz) und die unteren Grafiken zeigen die Reserveprofile als Indikatoren des Systemzustands.

In ■ **Abb. 11.2** ist erkennbar, wie die berechneten Herzfrequenzen (grün, direkt proportional) und die Reserve (grau, umgekehrt proportional) mit leichten Verzögerungen dem Geschwindigkeitsprofil nachlaufen. Diese Verzögerungen und damit der Gesamtverlauf werden im Wesentlichen bewirkt durch die Erholungsverzögerung DR: Je kleiner DR, d. h. je kürzer die Erholungsverzögerung, desto niedriger und glatter ist der Herzfrequenzverlauf, und desto höher sind die Reservewerte.



■ Abb. 11.2 Standardmäßige simulative Berechnung



■ Abb. 11.3 Vergleich von Ist- und Soll-Profilen


Zwei essenzielle Aspekte und Anwendungsformen für die Leistungssimulation sind:

- (1) Die Erkennung inadäquater Belastungsmuster (Überlast, Unterlast) und die simulative Optimierung der Belastung-Leistung-Dynamik

11

Um sportliche Leistungsfähigkeit z. B. im Hinblick auf Steigerungsfähigkeit zu analysieren, kann man die Delay-Parameter, im Folgenden speziell die Erholungsverzögerung DR, variieren und so in der Simulation die Steigerungsmöglichkeiten erkennen (vgl. Perl, 2003). ■ Abb. 11.3 zeigt den Herzfrequenzverlauf (grün) und den Reserveverlauf (grau) des Athleten aus ■ Abb. 11.2 mit einer Erholungsverzögerung von $DR = 7,2$. Ergänzend simuliert sind als Trainingsziel die Wunschprofile (Herzfrequenz: grau, deutlich niedriger und glatter; Reserve: schwarz, deutlich höher) eines besser trainierten Athleten, die aber nur mit einer schnelleren Erholung ($DR = 5,8$) erreicht werden können.

Die Simulation ermöglicht so, Belastungsprofile auszutesten und zu vergleichen, ohne dabei den Athleten in realen Tests mit zu hohen Trainingsbelastungen zu überlasten. Im obigen Beispiel wäre das Ergebnis der Simulation die Frage, ob sich für den betrachteten Athleten der DR-Wert durch Training überhaupt auf unter 6



■ Abb. 11.4 Vergleich von Erwartungs- und Ist-Profilen

senken ließe. Zur Beantwortung dieser Frage wäre es sinnvoll, im Trainingsprozess die Trainingseinheiten durch entsprechende Simulationen zu begleiten, um eventuelle Überlastsituationen rechtzeitig zu erkennen und zu vermeiden.

- (2) Die Erkennung unglaublicher Belastungs-Leistungs-Dynamiken, hervorgerufen z. B. von auffälligen Verzögerungswerten, die ihrerseits auf physiologische Manipulationen (z. B. Doping) hinweisen

Beispiel: In ■ Abb. 11.4 ist in der mittleren Grafik als rotes Profil der simulierte Herzfrequenzverlauf eines unzureichend trainierten Athleten ($DR = 12,5$) dargestellt: Das Pulsniveau ist sehr hoch, die Reservewerte (grau) sind eher niedrig, und die Reaktionen auf Belastungswechsel sind stark. Insgesamt sind die Erwartungen auf ein gutes Wettkampfergebnis sehr gering.

Im Widerspruch dazu stehen die aus dem Wettkampf erfassten Profile für Herzfrequenz (grün) und Reserve (schwarz), die auf ein ausgezeichnetes Leistungsniveau schließen lassen. Eine modellbasierte Analyse ergibt – im krassen Widerspruch zu den Voranalysen – einen sehr guten Wert von $DR = 5,8$ für die Erholungsverzögerung.

Definition

Unter Simulation versteht man die Berechnung von Systemverhalten. Ausgangspunkt für die Simulation ist das Modell eines Systems, dessen Parameter und Input-Daten variiert werden können und mit deren Hilfe Berechnungen des Modellverhaltens durchgeführt werden können (Perl, 2015).

Eine Simulation wird verwendet, um

- (1) durch Parametervariation das Verhalten des Systems besser zu verstehen;
- (2) zukünftiges Verhalten des Systems voraussagen zu können;
- (3) Auffälligkeiten im Verhalten des Systems zu erkennen.

11.3 Anwendungen

► Beispiel 1

Erkennung von möglichen Überlastphasen in Rückschlagspielen wie Tennis sind möglich (unveröffentlichte Analysen zum EU-Projekt ► <https://matchpoint.bgtennis.bg/>). Schlagwechsel in Rückschlagspielen können lang und durch Sprints zu den Annahmepunkten kraftraubend sein. ■ Abb. 11.5 zeigt links das Bewegungsprofil eines Tennisspielers und rechts die zugehörigen Verläufe von

- Belastung: Laufgeschwindigkeit mit kurzen Pausen nach den eigenen Schlägen;
- Leistung: Herzfrequenz, zunächst entspannt (grün), dann in den kritischen Bereich ansteigend (hellblau, rot) und schließlich im Kollapsbereich endend (schwarz);
- Reserve: in der ersten Ruhephase zunächst stark ansteigend, zum Ende in der Überlastphase in den negativen Kollapsbereich abfallend.


Diese Verläufe lassen sich ex post auf der Basis erfasster Daten diagnostizieren oder durch Simulation ex ante mithilfe der Belastungs-Leistungs-Simulation zum Zweck der Vermeidung prognostizieren. ◀

► Beispiel 2


Erkennung von unplausiblen Leistungssteigerungen zum Wettkampfzeitpunkt sind möglich (Perl, 2004). Höchstbelastungen im Wettkampf können nicht kontinuierlich gehalten werden, sondern werden durch ein entsprechend aufbauendes Trainingsprogramm mit entsprechendem Vorlauf vorbereitet.

■ Abb. 11.6 zeigt links ein wettkampforientiertes Trainingsprofil (rot), das ein Ansteigen der Leistung (blau) zum Wettkampftermin bewirkt. Der intendierte Leistungsverlauf (grün) konnte dabei allerdings nicht erreicht werden. Rechts dargestellt ist in ■ Abb. 11.6 die gleiche Ausgangssituation, in der nun aber bei nahezu unverändertem Trainingsprofil die geplante Spitzenleistung am Wettkampftermin erreicht wird. Der

11



■ Abb. 11.5 Belastungsentwicklung in einem langen schnellen Schlagwechsel im Tennis



■ **Abb. 11.6** Taktische Maßnahmen zur Leistungsoptimierung

Grund liegt in der Erholungsverzögerung, die zum Wettkampftermin deutlich abnimmt und dadurch, wie oben beschrieben, die Umsetzbarkeit von Belastung entsprechend deutlich verbessert. Eine solche Reduktion der Erholungsverzögerung ist u. a. das Ziel von Training, wirkt aber in der Regel über einen Zeitraum von Wochen bis zu Monaten. Eine deutliche Verbesserung innerhalb von drei Tagen ist dagegen höchst auffällig und sollte Anlass für eine genauere Analyse der getroffenen Maßnahmen sein. ◀

► Beispiel 3

Das Erkennen und Optimieren von Strategien in Mannschaftsspielen, bei denen mehrere Spieler „unabhängig“ voneinander agieren, ist schwierig (Memmert, 2022). Ein innovativer Ansatz besteht darin, die Teams in eine kleine Anzahl taktischer Gruppen zu aufzuteilen und die Interaktion dieser Gruppen zu analysieren. Die Positionen der Spieler taktischer Gruppen im Fußball können dann auf Formationsmuster abgebildet werden und spiegeln so strategisches Verhalten und Interaktion wider (Perl & Memmert, 2019). Basierend auf diesen Informationen ermöglicht die Monte-Carlo-Simulation, taktische Strategien zu generieren, die – zumindest aus mathematischer Sicht – optimal sind. In der Praxis kann sich das Verhalten an diesen optimalen Strategien orientieren, ändert sich aber normalerweise in Abhängigkeit von den Aktivitäten des gegnerischen Teams. Die Analyse des Spiels unter dem Aspekt solcher simulierten Strategien kann zeigen, wie strikt bzw. flexibel (vgl. Memmert, 2015) ein Team strategische Muster variiert. Um ein solches Mannschaftsverhalten von taktischen Gruppeninteraktionen im Profi-Fußball zu optimieren, haben Perl et al. (2021) mit der Software SOCCER© (Perl & Memmert, 2011; Grunz et al., 2012; Perl et al., 2013) eine Simulations- und Validierungsstudie auf Basis von 40 Positionsdatensätzen aus dem Profi-Fußball durchgeführt. Nachdem die Validierungsstudie die Anwendbarkeit des definierten taktischen Modells bestätigte, zeigte die Simulationsstudie, dass offensive Spielergruppen weniger taktische Flexibilität benötigen, um erfolgreich in Ballbesitz zu gelangen, während defensive Spielergruppen dafür eine größere taktische Flexibilität benötigen. Offensive Spieler sollten somit mit einer flexibleren taktischen Ausrichtung spielen, um im Ballbesitz zu bleiben, während defensive Spieler mit einer planvolleren Ausrichtung spielen sollten, um erfolgreich zu sein. ◀

? Fragen für die Studierenden

1. Marathonlauf: Belastende Laufphasen (z. B. Brücken, jubelnde Zuschauer) wirken sich häufig erst mit erheblicher Verzögerung aus. Wie könnte man solche belastenden Phasen vor oder während des Laufes erfassen und in der (weiteren) Laufplanung berücksichtigen?
2. Taktikoptimierung im Fußball: Die auf dem Spielfeld messbaren Positionen von Angriffs- und Abwehrspielern wechseln situationsbedingt sehr schnell (mehrere Tausend pro Spieler und Halbzeit). Wie kann man aus diesem Datenwust verwertbare Information über taktische Konzepte erfassen?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Studienbox

In Individualsportarten steht, wie oben beschrieben, die Simulation der physiologischen Leistung im Vordergrund. In Rückschlag- oder in Mannschaftsspielen ist dagegen die Optimierung taktischen Verhaltens Gegenstand der Simulation, wie im Folgenden am Beispiel Fußball dargestellt wird. Der Schlüssel zum Erfolg liegt darin, die perfekte Mischung aus wechselnden taktischen Mustern zu finden, die wesentlich vom Verhalten der gegnerischen Mannschaft abhängen (Memmert & Raabe, 2019). Memmert et al. (2021) haben Profi-Fußballspiele nach dem spezifischen taktischen Teamverhalten „Angriff vs. Abwehr“ auf der

Basis eines Simulationsansatzes untersucht. Die Formationsmuster aller Spiele (40 Positionsdatensätze) werden von SOCCER© (Perl & Memmert, 2011) für Verteidigung und Angriff kategorisiert. Die Monte-Carlo-Simulation kann die mathematisch optimale Strategie evaluieren. Die Interaktions-simulation zwischen Angriff und Verteidigung ergibt optimale Flexibilitäts-werte für beide taktischen Gruppen. Die Ergebnisse zeigten, dass sowohl Angriff als auch Verteidigung optimale Planungs-raten aufweisen, um erfolgreicher zu sein. Je komplexer die Erfolgs-anzeige, desto erfolgreicher werden an-

greifende Spielergruppen. Die Ergebnisse zeigen auch, dass es defensiven Spielergruppen immer gelingt, Gruppen unterhalb eines bestimmten Planungsrautenwertes anzugreifen. Die simulationsbasierte Positionsdatenanalyse zeigt erfolgreiche strategische Verhaltensmuster für Angriff und Verteidigung.

Angreifende Spielergruppen benötigen eine sehr hohe Flexibilität (zur Kreativität s. Memmert & Perl, 2009a, b), um erfolgreich zu sein (im Ballbesitz bleiben). Defensive Spielergruppen müssen dagegen nur unterhalb einer definierten Flexibilitätsrate liegen, um mehr Erfolg zu garantieren.

Literatur

- Grunz, A., Memmert, D. & Perl, J. (2012). Tactical pattern recognition in soccer games by means of special self-organizing maps. *Human Movement Science*, 31, 334–343.
- Memmert, D. (2015). *Teaching tactical creativity in sport: Research and practice*. Routledge.
- Memmert, D. (Hrsg.) (2022). *Spielanalyse*. Berlin: Springer.
- Memmert, D. & Perl, J. (2009a). Analysis and Simulation of Creativity Learning by Means of Artificial Neural Networks. *Human Movement Science*, 28, 263–282.
- Memmert, D. & Perl, J. (2009b). Game Creativity Analysis by Means of Neural Networks. *Journal of Sport Science*, 27, 139–149.
- Memmert, D., & Raabe, D. (2019). *Revolution im Profifußball. Mit Big Data zur Spielanalyse 4.0* (2. Auflage). Springer: Berlin.
- Memmert, D., Imkamp, J., & Perl, J. (2021). Flexible defends succeeds creative attacks! – A simulation approach based on position data in professional football. *Journal of Software Engineering and Applications*, 14(9). DOI: <https://doi.org/10.4236/jsea.2021.149029>
- Perl, J. (2002). Adaptation, Antagonism, and System Dynamics. In G. Ghent, D. Kluka & D. Jones (eds.), *Perspectives – The Multidisciplinary Series of Physical Education and Sport Science*, 4, (pp. 105–125). Oxford: Meyer & Meyer Sport.
- Perl, J. (2003). On the Long-Term Behaviour of the Performance-Potential-Metamodel PerPot: New Results and Approaches. *International Journal of Computer Science in Sport*, 2, 80–92).
- Perl, J. (2004). PerPot – a meta-model and software tool for analysis and optimisation of load-performance-interaction. *International Journal of Performance Analysis of Sport-e*, 4, 61–73).
- Perl, J. (2015). Modelling and Simulation. In A. Baca (ed.), *Computer Science in Sport* (pp. 110–153). Routledge.
- Perl, J. Imkamp, J. & Memmert, D., (2021). Key Strictness vs. flexibility: Simulation-based recognition of strategies and its success in soccer. *International Journal of Computer Science in Sport*, 20, 43–54.
- Perl, J. & Memmert, D. (2011). Net-Based Game Analysis by Means of the Software Tool *SOCCER*. *International Journal of Computer Science in Sport*, 10, 77–84.
- Perl, J., & Memmert, D. (2019). *Soccer: Process and interaction*. In A. Baca & J. Perl, Modelling and Simulation in Sport and Exercise (pp. 73–94). Abingdon: Routledge.
- Perl, J., Grunz, A. & Memmert, D. (2013). Tactics in soccer: an advanced approach. *International Journal of Computer Science in Sport*, 12, 33–44.



Metabolische Simulation

Dietmar Saupe

Inhaltsverzeichnis

- 12.1 Beispiel Sport – 104
- 12.2 Hintergrund – 105
- 12.3 Anwendungen – 106
- Literatur – 111

Kernbotschaften

- Mathematische Modellierung erfasst den funktionalen Zusammenhang zwischen den messbaren metabolischen Output-Variablen Laktat, Sauerstoffaufnahme, Kohlendioxidabgabe sowie auch der Herzfrequenz und der abgeforderten Leistung.
- Die Energiebereitstellung aus dem System energiereicher Phosphate und oxidativen Phosphorylierung kann auch aus einer komplexeren Meta-Modellierung als System von gekoppelten Prozessen erfolgen, die am Rechner mit geeigneten Algorithmen simuliert werden.
- Das PC-Modell (*critical power*) beschreibt die maximal erzielbare Dauer einer Arbeitsbelastung am Ergometer bei einer vorgegebenen Leistung.
- Modelle erlauben anhand von Leistungstests die Schätzung interpretierbarer Parameter, die Analyse von Performanz im Training und Wettkampf, das Monitoring von Rehabilitationsmaßnahmen sowie die Planung von Strategien zum optimalen Einsatz des Leistungspotenzials.

12.1 Beispiel Sport

Anhand von zwei Methodiken soll besprochen werden, wie Dynamik und Grenzen der metabolischen Energiebereitstellung quantitativ durch Modellierung, Simulation und Analyse in der Sportinformatik beschrieben und für die Praxis eingesetzt werden können. Die Beispiele beziehen sich primär auf Rennradспорт bzw. Radergometer-Tests, können aber durch geeignete Modifikationen für andere Ausdauersportarten wie Laufen, Schwimmen oder Rudern angepasst werden. In Leistungsdiagnostik, Trainingswissenschaft und Sportmedizin werden Methoden eingesetzt, mit denen die Auswirkungen einer variablen Belastungsanforderung auf messbare Indikatoren wie Herzfrequenz, Sauerstoffaufnahme und Laktatproduktion modelliert und vorhergesagt werden. Für Athleten können sich daraus wertvolle Rückschlüsse auf Fitnessparameter und Trainingserfolg ergeben. Im Wettkampf kommt es darauf an, den individuell verfügbaren Energievorrat bestmöglich einzusetzen. Athleten müssen in jeder Phase eines Rennens einschätzen können, wie viel Leistung sie maximal erbringen können, ohne sich vorzeitig zu erschöpfen, aber auch ohne mit noch ungenutzten Energiereserven am Ziel anzu kommen. Im Rennradспорт können sie sich dazu auf der Grundlage ihrer jahrelangen Trainings- und Wettkampferfahrung an der gemessenen Leistung in Watt und an ihrer Herzfrequenz orientieren. Allerdings ist es nicht ausreichend, einfach eine geeignete Leistung festzulegen und diese konstant einzuhalten. Forschungsarbeiten mit einem theoretischen Ansatz konnten zeigen, dass auf Strecken mit variablem Steigungsprofil bzw. mit wechselnden Windverhältnissen eine variable Leistungsverteilung gegenüber einer konstanten von Vorteil ist. Mathematische Modellierung und Simulation erlaubt es, entsprechende adaptive Pacing-Strategien zu entwickeln.

12.2 Hintergrund

Leistungsdiagnostik im Ausdauersport wendet Testverfahren an, um die Belastbarkeit und den Leistungsstand von Sportlern quantitativ zu erfassen. Sie liefert eine wertvolle Grundlage für die Planung und Steuerung des Trainings. Von zentraler Bedeutung ist dabei der Teil des Stoffwechsels oder Metabolismus, der die Energie erzeugt, die für die jeweilige sportliche Belastung benötigt wird. Dabei erzeugen chemische Reaktionen mechanische Energie für die Muskulatur.

Der wesentliche Energielieferant ist dabei Adenosintriphosphat (ATP), das jedoch in nur begrenzter Menge im Muskel zur Verfügung steht. Verbrauchtes ATP muss resynthetisiert werden, und die dazu erforderliche Energie wird durch Oxidation von Zucker (Glykolyse), Fetten und Eiweißen produziert. Das kann aerob oder anaerob geschehen, d. h. mit oder ohne Einsatz von Sauerstoff. Bei der anaeroben Energiebereitstellung unterscheidet man außerdem zwischen Laktazid und alaktazid, also mit oder ohne Produktion von Milchsäure in Form von Laktat. Bei steigender Belastung wird zunehmend Laktat produziert, das nicht mehr in gleichem Maße abgebaut werden kann. Dadurch wird die Glykolyse stark gehemmt – mit der Folge, dass eine solch hohe Leistung nicht mehr dauerhaft aufrechtzuerhalten ist. Die maximale Leistung, angegeben etwa durch Geschwindigkeit in km/h auf einem Laufband oder der physikalischen Leistung in Watt auf einem Ergometer, bei der die Produktion von Laktat und dessen Abbau noch im Gleichgewicht sind, wird als individuelle anaerobe Schwelle oder maximales Laktat-Steady-State (MLSS) bezeichnet.

Der Energiestoffwechsel ist somit insgesamt ein sehr komplexes Netzwerk von vielen einzelnen Reaktionen. Die direkte messtechnische Erfassung sämtlicher Komponenten ist nicht möglich, und lediglich äußere Indikatoren können indirekt Aufschluss geben über den aktuellen Zustand der Energiebereitstellung. Die wichtigsten sind die Laktatkonzentration in mmol/l aus Blutproben am Ohrläppchen, die Sauerstoffaufnahme in ml/min, gemessen durch Spiroergometrie, die Herzfrequenz in bpm und beim Radsport schließlich die erzeugte mechanische Leistung in Watt am Ergometer bzw. im Feld mithilfe von Leistungssensoren an der Kurbel, dem Zahnkranz, den Pedalen oder in der Nabe. Eine grundlegende Funktionalität der in diesem Kapitel betrachteten Modelle und Simulationen ist es, die Auswirkungen von Leistungsprofilen (konstante Leistung, Stufentest, intermittierendes Training oder beliebig variable Leistung im Feld) auf die physiologischen Messgrößen zu bestimmen.

Definition

Lineare Differenzialgleichungen (DGL) mit asymptotisch exponentiellen Lösungen beschreiben die physiologische Adaption von Sauerstoffaufnahme und Herzfrequenz an eine konstante Leistungsanforderung.

Das CP-Modell (*critical power*) beschreibt die maximale Zeitspanne, die bei einer gegebenen konstanten Leistung auf einem Ergometer bis zur vollständigen Ausbelastung (Erschöpfung) gehalten werden kann.

Beide Modelle können für den Fall einer variablen Leistungsanforderung verallgemeinert werden.

12.3 Anwendungen


► Beispiel 1 Modellierung und Simulation von Output-Größen metabolischer Prozesse

Modellierung und Simulation sind Schlüsseltechnologien zum Verständnis des Verhaltens solcher komplexen Systeme. Eine wichtige Anforderung an diese Modelle für die Anwendungen im Ausdauersport ist es, die genannten messbaren Größen als Resultat eines Anforderungsprofils, der Belastung, bereitzustellen. Anhand des Vergleichs mit den Daten aus Studien am Ergometer im Labor bzw. mit Messungen im Feld können die Parameter der Modelle geschätzt werden und die Vorhersagekraft der Modelle durch Simulation und Vergleich mit den Messgrößen beurteilt werden. Grundsätzlich können wir drei Ansätze der Modellierung unterscheiden:

1. Die metabolischen Prozesse sind in der Biochemie gut bekannt. Zum Beispiel kann die Glykolyse in zehn verschiedene chemische Reaktionen aufgeteilt werden. Diese wandeln Glukose in Pyruvat um und setzen dabei ATP frei. Aus diesen und weiteren Reaktionsgleichungen wurde in Schulte et al. (1999) ein komplexes Modell, bestehend aus Differenzialgleichungen und algebraischen Gleichungen, aufgestellt und simuliert. Intervalle für Parameter konnten zum Teil aus der Literatur zur Biochemie und Sportmedizin entnommen werden, die Parameter selbst wurden iterativ durch Simulation des Modells anhand von Messdaten aus Laborversuchen bestimmt.

■ Abb. 12.1 zeigt als Beispiel den Vergleich von Laktatmessungen mit den aus dem Modell hergeleiteten Laktatkonzentrationen.

Dieser Ansatz der Modellierung hat den Vorteil, dass die Variablen und Parameter direkte metabolische Entsprechungen haben, wobei allerdings deren sportwissenschaftliche Interpretation vielfach nicht so offensichtlich ist wie beim Laktat. Nachteile sind die sehr große Komplexität, das erforderliche Expertenwissen in Biochemie und in den mathematischen Methoden für die Aufstellung und numerische Lösung des resultierenden differenzial-algebraischen Gleichungssystems.



■ Abb. 12.1 Stufentest am Ergometer bis zur Ausbelastung und resultierende Blutlaktatwerte aus Messungen und Modellierung (aus Schulte et al., 1999)

2. Die weitaus üblichere Methode zur Modellierung stellt direkt Gleichungen für die Dynamik der Output-Größen Sauerstoffaufnahme ($\dot{V}O_2$), Laktatkonzentration ($[La]$) oder Herzfrequenz (HR) auf. Dabei werden bevorzugt lineare Differenzialgleichungen eingesetzt. Diese haben exponentielle Lösungen, die gut die Anpassung des metabolischen Systems an eine Leistungsanforderung repräsentieren können. Die Variablen und Parameter sind leicht interpretierbar, typischerweise als Amplituden von Anpassungsreaktionen und deren zugehörige Zeitkonstanten.


Grundlegend für die Dynamik von $\dot{V}O_2$ ist zunächst dessen Wert im Äquilibrium (*steady state*), also nach Vollendung der Anpassungsreaktion auf eine konstante Belastung, die am Ergometer eingestellt wird. Das ergibt eine individuelle, monoton wachsende Funktion von $\dot{V}O_2$ über ein Leistungsintervall von $P = 0$ (W) bis zu einer maximalen und andauernden kritischen Leistung $P = P_c$, bei der die maximale Sauerstoffaufnahme $\dot{V}O_{2max}$ erreicht wird (s. Jones & Poole, 2013). Der Steady-state-Wert von $\dot{V}O_2$ setzt sich im Wesentlichen aus drei Komponenten zusammen:

(1) einem Basiswert, der leicht über dem $\dot{V}O_2$ im Ruhezustand liegt, (2) einem mit P linear wachsenden Anteil A_1 und (3) einer kleineren, sogenannten langsamen Komponente A_2 , die erst ab einem gewissen Leistungs-Schwellwert hinzukommt (s. ■ Abb. 12.2).

Für beide Komponenten, A_1 und A_2 , kann die Anpassung von $\dot{V}O_2$ an eine einsetzende konstante Belastung P sehr gut durch eine exponentielle Funktion mit drei Parametern A , T und τ beschrieben werden,

$$A \left(1 - \exp \left(-\frac{t-T}{\tau} \right) \right),$$

wobei A die Amplitude der betreffenden Komponente im *steady state* und τ eine Zeitkonstante bezeichnet, die die Geschwindigkeit der Adaption an den *steady state* quantifiziert. Nach τ Zeiteinheiten sind etwa 63 % der Amplitude A erreicht, nach 3τ sind es 95 %. T ist eine Zeitverzögerung, ab der die betreffende Komponente einsetzt.



■ **Abb. 12.2** Steady-state-Modell für Sauerstoffaufnahme $\dot{V}O_2$ in Abhängigkeit der Belastung, einer konstanten Leistung P . Leistungen größer als die kritische Leistung P_c können nicht auf Dauer gehalten werden (aus Artiga Gonzalez et al., 2019)

Diese exponentielle Dynamik lässt sich äquivalent durch die lineare Differenzialgleichung $\dot{x} = \tau^{-1}(A - x)$ mit Anfangswert $x(T) = 0$ beschreiben. Das liefert den Ansatz zur Verallgemeinerung des dynamischen Modells für variable Belastungen, wie sie im Training und im Wettkampf im Feld auftreten, d. h. für Leistungen $P = P(t)$, die nicht konstant sind. Dazu muss in der DGL die konstante Amplitude A durch $A(P(t))$ ersetzt werden, also durch die Amplitude, die zu der Belastung P zum Zeitpunkt t gemäß dem Modell in  Abb. 12.2 vorgegeben ist. In Artiga Gonzalez et al. (2019) wurde das ausgeführt und an experimentellen spiroergometrischen Datenserien validiert.

Dieselbe Methode lässt sich für die Modellierung der Dynamik der Herzfrequenz HR bei variabler Belastung einsetzen. In diesem Fall kann auf die langsame Komponente verzichtet werden, sodass als Parameter der Ruhepuls HR_0 , die (konstante) Steigung $\beta = dHR/dP$ (*gain*), die Zeitkonstante τ , die Zeitverzögerung T und gegebenenfalls die kritische Leistung P_c bzw. die maximale Herzfrequenz HR_{max} ausreichen.

In Mongin et al. (2020) wurde damit die Herzfrequenz von 30 Probanden bei einem Ausbelastungstest auf dem Laufband gefittet. Die Leistung P wurde dabei durch die Geschwindigkeit des Laufbands ersetzt. Im Median konnte 91 % der Gesamtvarianz der Herzfrequenz durch das Modell aufgeklärt werden. Mit einer zusätzlichen Anpassung des *gains* in Abhängigkeit der Belastungsintensität konnte diese Rate sogar auf 99 % verbessert werden. Allerdings erfordert das eine größere Zahl an Parametern, die bei der Regressionsanalyse geschätzt werden müssen und leicht zu Overfitting führen können.

3. Die beiden obigen Modellansätze streben eine Charakterisierung der leistungsbezogenen physiologischen Reaktion durch explizite Gleichungen an, auf der Grundlage der metabolischen Komponenten und Prozesse bzw. der Phänomenologie der messbaren Variablen. Dagegen wird die Beziehung zwischen abhängigem Output (VO_2 , HR , $[La]$) und dem Input (Leistung oder Geschwindigkeit als Belastung) durch Black-Box-Verfahren eigenständig ermittelt. Hierzu haben sich Verfahren des maschinellen Lernens wie z. B. Support Vector Machines, neuronale Netze und Deep Learning durchgesetzt (s. ► Kap. 20 und 21). Diese lassen sich natürlich auch für die Analyse von Daten aus dem Stoffwechsel einsetzen (s. Zignoli et al., 2020). Die erzeugten Systeme zur Schätzung der Output-Variablen haben, wie erwartet, eine bessere Passgenauigkeit im Vergleich zu den expliziten Modellierungen. Die Nachteile sind jedoch, dass zum Training der neuronalen Netze erhebliche Datenmengen erforderlich sind und dass die trainierten Gewichtsparameter keine offensichtliche sportmedizinische Interpretation ergeben.

Für eine weitergehende detaillierte Einführung zu den Methoden und dem Hintergrund der Modellierung von Laktat und Sauerstoffaufnahme beim Radsport sei der kürzlich erschienene Aufsatz von Zignoli et al. (2019) empfohlen. ◀

► Beispiel 2 Das CP-Modell (*critical power*)


Die im ersten Beispiel besprochenen Methoden liefern Grundlagen für Planung und Kontrolle von Training, beim Wettkampf jedoch steht für den Radsportler die Frage im Vordergrund, wie viel Leistung er entlang der Rennstrecke jeweils anstreben sollte, um schnellst-

möglich die Ziellinie zu erreichen – insbesondere, wenn die Strecke durch variables Terrain mit unterschiedlichen Steigungen verläuft. Die Antwort erfordert das Wissen um die maximal dauerhaft haltbare Leistung P_c , die jeweils zusätzlich kurzfristig verfügbaren Energie-reserven für Sprints und die Erholungsrate, mit der der Energiespeicher bei moderaterer Leistung wieder aufgefüllt werden kann. Ein erstes mathematisches Modell für diese Analyse ist schon vor über 50 Jahren von Monod & Scherrer (1965) eingeführt worden.

Die Grundlage dieses Konzepts sind zwei verschiedene Energiequellen, aerob und anaerob. Die aerobe Energieversorgung ist im Umfang unbegrenzt, kann aber nur mit einer festen Rate abgerufen werden, der schon erwähnten kritischen Leistung P_c . Andererseits kann der anaerobe Energievorrat mit unbegrenzter Rate angezapft werden, aber seine Gesamtgröße E_{an} ist recht begrenzt. Demzufolge erschöpft sich ein Sportler nach gewisser Zeit T , wenn die abgerufene Leistung P oberhalb der kritischen Leistung P_c liegt. In dem heute sogenannten CP-Modell (*critical power*) von Monod und Scherrer wird demzufolge dafür die hyperbolische Funktion $T = E_{an}/(P - P_c)$ für $P > P_c$ angesetzt. Dieser Ansatz lässt sich gut als hydraulisches Modell visualisieren (■ Abb. 12.3, links). Energiereserven sind durch Behälter mit Wasser repräsentiert, die durch Rohre verbunden sind. Der durch einen Regler steuerbare Ausfluss unten bestimmt die angeforderte Leistung, gegeben durch den Fluss.

Sei als Beispiel ein Hobby-Rennradfahrer mit einer kritischen Leistung von 250 W und einem anaeroben Energiespeicher von 20.000 J angenommen. Wie lange kann er bei einer Leistung von 300 W fahren? Es ergibt sich $T = 20.000 \text{ Ws}/(300 \text{ W} - 250 \text{ W}) = 400 \text{ s}$, also 6 min und 40 s. Eine Leistung von weniger als $P_c = 250 \text{ W}$ dagegen kann dem Modell zufolge unbeschränkt lange gehalten werden, vorausgesetzt, es wird genügend Nahrung aufgenommen, um den aeroben Energiefluss aufrechterhalten zu können.

Bei konstanter Belastung schreibt das CP-Modell vor, dass die anfängliche Energie-reserve E_{an} mit konstanter Rate $P - P_c$ verbraucht wird, bis sie nach der Zeit T erschöpft ist. Um das Modell für variable Leistungsanforderung $P = P(t)$ einzusetzen, führen wir



■ **Abb. 12.3** Hydraulische Darstellung von drei physiologischen Modellen. Links das klassische Modell von Monod & Scherrer (1965), in der Mitte das Modell von Wilkie (1981) mit adaptiver Erholungsrate und rechts das von Morton (1986) und Margaria mit einem zusätzlichen Gefäß für die anaerob-laktazide Energiebereitstellung (aus Wolf, 2018)

den aktuellen Energievorrat $e_{\text{an}}(t)$ ein, mit der Vorgabe des Anfangswerts $e_{\text{an}}(0) = E_{\text{an}}$. Daraus ergibt sich folglich die Differenzialgleichung $de_{\text{an}}/dt = P_c - P(t)$. Diese Gleichung erweitert das Modell zugleich für den Fall der Erholung bei Leistungen unterhalb P_c : Jedes Watt unterhalb von P_c ergibt einen Zufluss von 1 J pro Sekunde.

Das einfache Modell für die maximal haltbare Leistung hat sich in der Praxis gut bewährt. Um für ein Individuum die kritische Leistung P_c zu bestimmen, braucht man allerdings mehrere Punkte (P,T) auf dem Graph der hyperbolischen Funktion von T. Für jeden dieser Punkte muss ein Ergometertest bis zur Erschöpfung geleistet werden, gefolgt von einer hinreichend langen Erholungsphase. Das ist in der Praxis kaum durchführbar, und daher wurden dafür einfachere Tests entwickelt (s. die Übersicht in Lipková et al., 2022).

Das Zwei-Parameter-CP-Modell von Monod und Scherrer lieferte das Fundament für eine Reihe von Verfeinerungen, um kleine Defizite zu beheben. Es wurde bemängelt, dass das Modell beliebig hohe Leistungen erlaubt, zumindest für kurze Zeit, und dass die direkte Fortschreibung des Modells für Erholung unterhalb der kritischen Leistung ($P < P_c$), wie oben ausgeführt, zu optimistisch schätzt. In dem Drei-Parameter-Modell von Morton (1996) wird die Leistung begrenzt und in Skiba et al. (2014) sowie Wolf (2018) wurde die Erholungsrate gedämpft. Zwei weitere Modifikationen von Wilkie, Margaria und Morton sind in ■ Abb. 12.3 aufgeführt.

Die physiologischen Modelle, kombiniert mit einem mechanischen Modell von erforderlicher physikalischer Leistung beim Radfahren auf einer Strecke mit gegebenem Höhenprofil, lassen sich mit numerischer Optimierung beste Pacing-Strategien berechnen, s. Fayazi et al. (2013), Sundström und Bäckström (2017) und Wolf et al. (2018).

Studienbox

12

Die mathematische Modellierung von Training und Leistung in der Sportinformatik ist ein wertvolles Werkzeug für Anwendungen in Coaching, Fitness/Personal Training, Rehabilitation und Trainingsphysiologie. Zwei Modelle, das (CP-)Modell (*critical power*) und das Banister-Impulse-Response (IR-)Modell, bieten dazu komplementäre Methodiken. Das CP-Modell beschreibt die Beziehung zwischen geleisteter Arbeit und den verbleibenden Energiereserven. Das IR-Modell beschreibt die Dynamik, mit der sich die individuelle Leistungsfähigkeit im Laufe der Zeit in Abhängigkeit vom Trai-

ning verändert. Beide Modelle abstrahieren auf elegante Weise die zugrunde liegende Physiologie. Der umfassende Beitrag von Clarke und Skiba (2013) bietet dazu eine detaillierte Einführung der zugehörigen physiologischen Grundlagen, Definitionen und der Geschichte, leitet die Annahmen und Gleichungen her und unterrichtet im Umgang mit diesen Ressourcen anhand von Software (*spreadsheets*¹) für praktische Computerübungen.

1 ► <https://journals.physiology.org/doi/suppl/10.1152/advan.00078.2011>.

? Fragen für die Studierenden

1. Bestimmen und diskutieren Sie eine Modellgleichung für die Herzfrequenz bei einer einsetzenden konstanten Leistungsanforderung sowie die entsprechende Differenzialgleichung für variable Leistung.
2. Ein Proband führt auf einem Ergometer zwei Stufentests mit konstanter Belastung durch. Bei 450 W bricht er den Versuch nach nur 1:20 min erschöpft ab, nach Erholung schafft er bei 275 W immerhin 10:40 min. Welche kritische Leistung P_c und anaerobe Gesamtenergie E_{an} können daraus geschätzt werden? Welche Werte ergeben sich, wenn eine dritte Messung bei $P = 330$ W eine Gesamtzeit von $T = 5$ min ergibt? Welches Verfahren ist für diese Rechnung geeignet?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Artiga Gonzalez, A., Bertschinger, R., Brosda, F., Dahmen, T., Thumm, P., & Saupe, D. (2019). Kinetic analysis of oxygen dynamics under a variable work rate. *Human Movement Science*, 66, 645–658.
- Clarke, D. C., & Skiba, P. F. (2013). Rationale and resources for teaching the mathematical modeling of athletic training and performance. *Advances in Physiology Education*, 37(2), 134–152.
- Fayazi, S. A., Wan, N., Lucich, S., Vahidi, A., & Mocko, G. (2013). Optimal pacing in a cycling time-trial considering cyclist's fatigue dynamics. In *American Control Conference* (pp. 6442–6447).
- Jones, A. M., & Poole, D. C. (2013). *Oxygen Uptake Kinetics in Sport, Exercise and Medicine*. Routledge.
- Lipková, L., Kumstát, M., & Struhár, I. (2022). Determination of Critical Power Using Different Possible Approaches among Endurance Athletes: A Review. *International Journal of Environmental Research and Public Health*, 19(13), 7589.

- Mongin, D., Chabert, C., Caparros, A. U., Guzmán, J. V., Hue, O., Alvero-Cruz, J. R., & Courvoisier, D. S. (2020). The complex relationship between effort and heart rate: a hint from dynamic analysis. *Physiological Measurement*, 41(10), 105003.
- Monod, H., & Scherrer, J. (1965). The work capacity of a synergic muscular group. *Ergonomics*, 8(3), 329–338.
- Morton, R. H. (1986). A three component model of human bioenergetics. *Journal of Mathematical Biology*, 24(4), 451–466.
- Morton, R. H. (1996). A 3-parameter critical power model. *Ergonomics*, 39(4), 611–619.
- Schulte, A., Kracht, P., Dörrscheidt, F., & Liesen, H. (1999). Modeling and simulation of the human exercise metabolism. In *Conference Volume Software and Hardware Engineering for the 21st Century*, (pp. 377–382).
- Skiba, P. F., Jackman, S., Clarke, D., Vanhatalo, A., & Jones, A. M. (2014). Effect of work and recovery durations on W' reconstitution during intermittent exercise. *Medicine and Science in Sports and Exercise*, 46(7), 1433–1440.
- Sundström, D., & Bäckström, M. (2017). Optimization of pacing strategies for variable wind conditions in road cycling. Proceedings of the Institution of Mechanical Engineers, Part P: Journal of Sports Engineering and Technology, 231(3), 184–199.
- Wilkie, D. R. (1981). Equations describing power input by human as function of duration of exercise. *Exercise Bioenergetics and Gas Exchange*, 75–80.
- Wolf, S. (2018). *Applications of Optimal Control to Road Cycling* (Doctoral dissertation, University of Konstanz, Germany).
- Wolf, S., Biral, F., & Saupe, D. (2018). Adaptive feedback system for optimal pacing strategies in road cycling. *Sports Engineering*, 22(1), 1–10.
- Zignoli, A., Fornasiero, A., Bertolazzi, E., Pellegrini, B., Schena, F., Biral, F., & Laursen, P. B. (2019). State-of-the art concepts and future directions in modelling oxygen consumption and lactate concentration in cycling exercise. *Sport Sciences for Health*, 15(2), 295–310.
- Zignoli, A., Fornasiero, A., Ragni, M., Pellegrini, B., Schena, F., Biral, F., & Laursen, P. B. (2020). Estimating an individual's oxygen uptake during cycling exercise with a recurrent neural network trained from easy-to-obtain inputs: A pilot study. *PLoS One*, 15(3), e0229466.



Simulation physiologischer Anpassungsprozesse

Mark Pfeiffer und Stefan Endler

Inhaltsverzeichnis

- 13.1 Beispiel Sport – 114**
- 13.2 Hintergrund – 115**
- 13.3 Anwendungen – 117**
- Literatur – 120**

Kernbotschaften

- Trainings- und Wettkampfleistungen hängen stark mit physiologischen Anpassungsprozessen zusammen.
- Modelle auf höherer Ebene (makroskopisch) bilden die Gesamtwirkung vieler einzelner Prozesse (nicht ausschließlich physiologische) auf den Körper ab.
- Die Parameter dieser Meta-Modelle lassen sich anhand von messbaren Merkmalen (Daten) individuell einstellen (kalibrieren).
- Mit kalibrierten Modellen sind kurzfristige Simulationen (einzelne Trainingseinheiten oder Wettkämpfe) oder auch langfristige Simulation (Fortschritt durch Trainingsprogramme) möglich.

13.1 Beispiel Sport

In verschiedenen Bereichen des Sports wird trainiert, um Ziele im oder durch den Sport zu erreichen. Ist das sportliche Training auf die sportliche Leistungsfähigkeit ausgerichtet, besteht das Ziel primär darin, Anpassungsreaktionen (Adaptation) hervorzurufen, die im Ergebnis zu einer physiologischen Optimierung beteiligter Funktionssysteme führen. Die Bewältigung sportlicher Aufgaben im Training stellt eine auf den Organismus wirkende *Belastung* dar, deren Ausmaß sich aus der Art und Schwierigkeit der Handlungsaufgabe und der dabei bestehenden Ausführungsbedingungen ergibt. Die Belastung führt beim Trainierenden zu einer *Beanspruchung*, deren individuelles Ausmaß von der Inanspruchnahme der aktuell verfügbaren physiologischen Kapazitäten abhängt (Hohmann, Lames, Letztelter & Pfeiffer, 2020). Diesem Belastungs-Beanspruchungs-Konzept folgend findet eine positive physiologische Adaptation statt, wenn sich der Sportler über ein bestimmtes Maß hinausgehend beansprucht (adaptationswirksamer Trainingsreiz). In diesem Fall führt die zunächst eintretende Ermüdung (Beanspruchungsfolge) im weiteren Verlauf der Erholung zu einer Anpassung der Funktionssysteme und damit zu einer Leistungsoptimierung. Während auf niedrigem Leistungsniveau geringe Belastungs- bzw. Beanspruchungssteigerungen große Steigerungen der *sportlichen Leistung* oder *Leistungsfähigkeit* bewirken können, sind bei höherer Leistungsausprägung immer größere Beanspruchungen notwendig, um noch Funktionssteigerungen zu erzielen oder das aktuelle Niveau zu halten. Die besondere Herausforderung im Training besteht nun darin, einerseits einen adaptationswirksamen Trainingsreiz auszulösen und gleichzeitig die Überbeanspruchung von Funktionssystemen zu vermeiden, weil diese zu Fehlanpassungen führen können (Meeusen et al., 2013). Der Verlauf physiologischer Anpassungsprozesse im Sport lässt sich wie folgt zusammenfassen: Körperliche Belastung führt zu einer Beanspruchung der belasteten Funktionssysteme, deren Kapazitäten sich bei optimaler Reizkonstellation in Phasen der Erholung erhöhen bzw. erhalten bleiben. Die wissenschaftliche Betrachtung derartiger Prozesse kann auf den Zusammenhang zwischen Belastung und Beanspruchung während des Trainings

(Beispiel 1) oder die Gestaltung von Beanspruchungsabfolgen bei aufeinanderfolgenden Trainingseinheiten, d. h. den Zusammenhang zwischen Belastung bzw. Beanspruchung und der veränderten Leistung (bzw. Leistungsfähigkeit) gerichtet sein (Beispiel 2). In den letzten Jahren sind eine Reihe informatischer Ansätze vorgestellt worden mit dem Ziel, das Verhältnis von Belastung und Beanspruchung bzw. die hierdurch ausgelösten Anpassungsreaktionen zu modellieren und die Effekte von Trainingsstrategien mittels Simulation zu untersuchen.

13.2 Hintergrund

Die physiologische Anpassung infolge sportlichen Trainings ist ein komplexes, nicht lineares Geschehen. Dabei zeigt sich, dass die inter- und intraindividuelle Variabilität sowohl hinsichtlich der physiologischen Reaktionen als auch der Effekte auf die sportliche Leistung bzw. die Leistungsfähigkeit enorm sind (Borresen & Lambert, 2009). Ein wiederholter Trainingsreiz kann bei ein und derselben Person sowohl während der Belastungssituation als auch bei den anschließenden Anpassungsreaktionen unterschiedliche Wirkungen hervorrufen, da die Anpassung eines biologischen Systems selbst zu veränderten Folgeanpassungen führt. Ferner sind physiologische Anpassungsprozesse in hohem Maße von einer Vielzahl weiterer Faktoren abhängig, wie der menschlichen Genetik, dem Trainingszustand und der Trainingsgeschichte, psychologischen Faktoren und vielen anderen mehr (Balague et al., 2020; Pol et al., 2020). Aus den genannten Gründen wird der Zusammenhang zwischen Training (Belastung) und den leistungsphysiologischen Reaktionen (Beanspruchung) sowohl während (Beispiel 1) als auch im Nachgang der Belastung sowie den Leistungsveränderungen im weiteren Verlauf (Beispiel 2) zunehmend für den Einzelfall mittels sogenannter Metamodelle analysiert. In ihrem Überblicksbeitrag stellen Rasche und Pfeiffer (2019) verschiedene Ansätze zur Analyse individueller Zeitreihen im Hinblick auf die mathematischen Grundlagen und die zugrunde liegenden physiologischen Annahmen vergleichend vor (■ Abb. 13.1).

Aus bisherigen Erkenntnissen werden Annahmen zu physiologischen Anpassungsprozessen hergeleitet, die in den Modellkonzepten in unterschiedlichem Maße abgebildet werden (vgl. ■ Abb. 13.1):

- Die sportliche Leistung bzw. Leistungsfähigkeit ist ein zeitabhängiger Zustand (Output), der durch trainingsinduzierte körperliche Belastungen bzw. Beanspruchungen (Input) veränderbar ist.
- Physiologische Anpassungen erfolgen zeitverzögert infolge sportlichen Trainings.
- Körperliche Belastung (Training) wirkt auf den Systemzustand über zwei Komponenten: eine negative, welche die Zustandsgröße (Output) reduziert und eine positive, welche diese erhöht (Antagonismus der Trainingswirkung) (Perl, 2002).
- Physiologische Anpassungen haben eine individuelle Kapazitätsgrenze.
- Negative und positive Komponente sind von identischem Ausmaß.

Ansätze zur Modellierung des Zusammenhangs von Training (Input) und Leistung (Output)							
Physiologische Annahmen und Methoden	Zeitabhängigkeit						
	I: Leistung ist ein zeitabhängiger Status						
	II: Physiologische Adaptationen / Effekte sind verzögert / verfallen mit der Zeit						
	Trainingseffekte						
	III: Antagonistische Trainingseffekte auf die Leistung						
	IV: Beschränkte physiologische Kapazitäten						
	V: Gleichwertige positive / negative Effekte						
Beispiele	Typ B Differenzengleichungen (Flußgleichungen)		Typ A Differentialgleichungen (Exponentieller Zerfall)		Statistische Analyse Trend-/Saisonkomponente (Nicht)Parametrisch (Nicht)Linear		
			2-komp +	2-komp		≥ 3-komp	1-komp
Beispiele	Performance-Potential Double-Model	Performance-Potential Meta-Model	Impulse-Response Model + (Hill-Funktion) (auch: Fitness-Fatigue / Banister-Model) Mod. Impulse-Response Model (+Kalman Filter) Mixed Linear Modelling		Auto-regressive / integrated / moving average-Modelle Auto- / Kreuz- Korrelation	Künstliche Neuronale Netze (z.B. Multilayer Perceptron)	
	#Input	bivariat (2)	univariat (1)	univariat (1)		uni- / multivariat (1/n)	multivariat (n)

■ **Abb. 13.1** Überblick zu ausgewählten Modellen und deren physiologischen Annahmen, mathematischen Grundlagen und Anzahl der Eingabeparameter (nach Rasche & Pfeiffer, 2019)

Fasst man den aktuellen Stand zur informatisch orientierten Simulation physiologischer Anpassungsprozesse zusammen, dann unterscheiden sich die Modellansätze hinsichtlich ihrer physiologischen Annahmen und der grundlegenden mathematischen Konzepte. Die bisherigen empirischen Befunde zeigen, dass die Modellanpassung an reale Daten je nach Qualität (Gesamtanzahl und Erhebungsfrequenz von In- und Output, Güte der Datenerhebungsmethoden usw.) und Erhebungssetting (Leistungs- oder Breitensport) zwar recht zufriedenstellend gelingt, jedoch die Prognosegüte meist problematisch ist. Letzteres begründet sich unter anderem darin, dass die im Rahmen der Kalibrierung ermittelten Modellparameter nicht „stabil“ sind, d. h., mit unterschiedlichen Parameterkombinationen eine nahezu identische Anpassungsgüte (Modell-Fit) erreicht werden kann (Hemingway et al., 2020). Damit lassen sich die Modellparameter nur bedingt als individueller physiologischer Fingerabdruck interpretieren, was für die Prognose zukünftiger Entwicklungsverläufe oder die Untersuchung von Trainingsstrategien (z. B. Taper) jedoch wichtig wäre (Vermeire et al., 2022).

Definition

Unter *physiologischer Simulation* im Sport versteht man die Berechnung des Verhaltens biologischer Funktionssysteme bei körperlicher Belastung (sportliches Training). Ausgangspunkt für die Simulation physiologischer Anpassungsprozesse ist ein Modell, wonach das System des Trainierenden einen aktuellen Zustand aufweist, der durch eine Größe von außen (Input) veränderbar ist. Beschrieben werden kann sowohl das System selbst als auch dessen Leistungsfähigkeit (Output). Das Systemverhalten lässt sich simulativ durch Variation der Modellparameter und Daten untersuchen.


Die Simulation physiologischer Anpassungsprozesse wird verwendet, um

1. durch Parametervariation das Verhalten des Trainierenden besser zu verstehen (u. a. Auffälligkeiten);
2. zukünftige Leistungsentwicklungen voraussagen zu können;
3. die Effekte virtueller Trainingsstrategien oder -szenarien abzuschätzen.

13.3 Anwendungen

► Beispiel 1

Das Meta-Modell PerPot (Perl, 2001) wurde von Endler (2013) speziell auf den ausdauerorientierten Laufsport angepasst (PerPot-Run). Dies umfasste zum einen die Anpassung des Modells selbst durch Vereinfachung von Modellgleichungen, die im allgemeinen Meta-Modell einzelne Prozesse abbilden, welche im Anwendungsszenario Laufsport in dieser Form nicht vorkommen (vgl. ■ Abb. 13.2). Zum anderen wurden für den Ausdauersport wichtige Eigenschaften, wie die Langzeitatrophie, also die Ermüdung über die Zeit, in PerPot-Run integriert. Angelehnt an den Stufentest der üblichen Leistungsdiagnostik hat Endler (2013) einen speziellen Kalibrierungslauf zur Bestimmung der individuellen Modellparameter entwickelt und implementiert. Mithilfe der individuell angepassten (kalibrierten) Modelle ist es möglich, Simulationen von Trainingseinheiten und Wettkämpfen durchzuführen. So kann durch mehrfache Simulation einer bestimmten Wettkampfstrecke mit verschiedenen (konstanten) Geschwindigkeiten die optimale Geschwindigkeit simulativ ermittelt werden. Die Simulation basiert darauf, dass der Athlet am Ende des Wettkampfs virtuell seine komplette „Energie“ ausgeschöpft hat. Die damit errechnete Zielzeit wurde in einer Studie bei 33 Marathon- und Halbmarathonläufen mit den tatsächlichen Zielzeiten verglichen. Die mittlere Abweichung betrug 3,62 %, wobei bei über einem Drittel der Wettkämpfe praktisch die exakte Zielzeit vorausgesagt werden konnte.



■ Abb. 13.2 Simulation eines optimalen Marathonlaufs mit konstanter Geschwindigkeit

Eine weitere Möglichkeit, die Simulation bereits im Training sinnvoll zu nutzen, ist die Optimierung von Intervalltrainingseinheiten. Dabei stellt sich häufig die Frage, wie viele Intervalle und in welcher Geschwindigkeit zu bestreiten sind. Auch die Pausenlänge zwischen den Intervallen kann unterschiedlich gewählt werden. Mithilfe von Simulationen lassen sich diese Aspekte untersuchen und individuelle optimale Intervalltrainingseinheiten identifizieren. ◀

► Beispiel 2

Im Hochleistungssport besteht die Zielstellung des Trainings darin, die sportliche Leistung zu verbessern, sie zu erhalten oder einem Rückgang (z. B. altersbedingt) entgegenzuwirken. Um dies zu erreichen, gilt es am Limit der individuellen Adaptationskapazität immer wieder trainingswirksame Reizkonstellationen zu arrangieren, welche leistungssteigernde oder -erhaltende Anpassungsreaktionen hervorrufen (adaptationswirksame Belastung). Dabei sind gezielte Phasen der Erholung notwendig (Halsen & Jeukendrup, 2004). Bei einem dauerhaften Missverhältnis von Trainingsbelastung und Erholung besteht die Gefahr eines Übertrainings, d. h., die sportliche Leistung (bzw. Leistungsfähigkeit) kann stagnieren oder sich zeitweise sogar verringern (*non-functional overreaching*), im schlimmsten Fall erholen sich die beanspruchten physiologischen Funktionssysteme erst nach Monaten und die Leistung sinkt dauerhaft (*overtraining syndrome*). Dieser Zustand kann krankhafte Fehlanpassungen in den verschiedenen biologischen Regulationsmechanismen verursachen und zu einem Anstieg der Verletzungs- bzw. Krankheitsanfälligkeit führen (Schwellnus et al., 2016; Soligard et al., 2016).

Um die Trainingsbelastung und -beanspruchung optimal im Sinne der Trainingszielreichung zu gestalten und trainingsinduzierte Überbelastungen zu vermeiden, werden die individuellen Trainings- und Leistungsdaten auf ihren Zusammenhang hin untersucht. Diese sogenannten Trainingswirkungsanalysen sind dann besonders hilfreich, wenn die Auswirkungen von Trainingsinterventionen auf die sportliche Leistung(sfähigkeit) nicht nur rückwirkend modelliert, sondern auch prognostisch simuliert werden können. Dieses Vorgehen bietet sich in Sportarten bzw. Disziplinen mit weniger komplexen Trainings- und Leistungsstrukturen besonders an. In Studien zum Rad- und Schwimmsport konnte gezeigt werden, dass mit antagonistischen Modellen (vgl. ■ Abb. 13.1) zum einen die Modellierung des Leistungsverlaufs retrospektiv gelingt (Modell-Fit) und zum anderen bei gegebenen Trainingsdaten die zukünftige Leistungsentwicklung insbesondere für kürzere Zeiträume zufriedenstellen simuliert werden kann (Prognosegüte) (Pfeiffer, 2008; Fuhrmann, Pfeiffer & Hohmann, 2014). In den letzten Jahren ist eine Vielzahl an modellvergleichenden Studien zur Güte der Modellanpassung und prognostischen Güte erschienen, wobei das Spektrum von statistischen Ansätzen bis zu Maschine-Learning-Methoden reicht (u. a. Imbach et al., 2022; Matabuena & Rodríguez-López, 2019; Pfeiffer & Hohmann, 2012). ◀

Studienbox

Das im Abschn. „Einsatzbereiche“ im Beispiel 1 vorgestellte Modell „PerPot-Run“ kann auch zur Simulation der sogenannten individuellen anaeroben Schwelle (IAS) verwendet werden. Dabei handelt es sich um die Belastung, bei der sich Laktataufbau und -abbau im Körper gerade die Waage halten. Um diesen Wert verlässlich bestimmen zu können, müssen Sportler an mehreren Tagen Ausdauereinheiten an ihrer subjektiven Belastungsgrenze absolvieren. Die Belastung wird dabei von Einheit zu Einheit leicht erhöht. Während der Einheiten wird Laktat gemessen. Die Schwelle ist dann gerade die Belastung, bei der die Laktatkonzentration während des gesamten Laufs konstant bleibt und nicht über die Zeit steigt (Laktat-Steady-State). Diese Methode wird in der Praxis aufgrund der hohen Anforderungen an die Sportler nicht durchgeführt. Stattdessen werden die Schwellen mithilfe eines Stufentests im Rahmen eines leistungsdiagnostischen Tests bestimmt. Allerdings sind diese Tests ebenfalls aufwendig und kostenintensiv, da medizinisch geschultes Personal zur Durchführung (Blutentnahme) notwendig ist.

Mit PerPot-Run wurde eine simulative Bestimmung der IAS entwickelt. Diese wurde im Rahmen einer Studie von Endler et al. (2017) mit den gängigsten leistungsdiagnostischen Verfahren

zur Bestimmung der IAS verglichen. Dazu absolvierten 13 männliche Handballspieler (Alter: $23,2 \pm 2,3$; Gewicht in kg: $88,3 \pm 11,4$) einen klassischen leistungsdiagnostischen Stufentest auf dem Laufband mit drei Minuten Stufenlänge und einer Steigerung von 2 km/h pro Stufe bei einer Startgeschwindigkeit von 6 km/h. Zwischen den Stufen wurde kapillares Blut am Ohrläppchen zur Bestimmung der Laktatkonzentration entnommen. Die Werte wurden mit verschiedenen Berechnungsmodellen ausgewertet, um die IAS zu bestimmen, u. a. mit der am häufigsten genutzten Methode von Dickhuth (1999). Die Herzfrequenz- und Geschwindigkeitsdaten desselben Stufentests wurden genutzt, um die Parameter des informatischen Modells PerPot-Run auf die Athleten zu individualisieren. Durch Simulieren des zuvor beschriebenen Goldstandards mit mehreren Dauerläufen kann daraufhin die IAS berechnet werden. Ein Vergleich zeigte eine sehr hohe Korrelation zwischen den mit der Dickhuth-Methode und den mit PerPot-Run bestimmten Herzfrequenzen an der IAS (ICC: .916; r: .889). Es konnte damit gezeigt werden, dass die simulativ bestimmten Schwellen eine kosten- und ressourcensparende Alternative bzw. Ergänzung zur klassischen laktatbasierten Leistungsdiagnostik darstellen.

? Fragen für die Studierenden

1. Zu welchem Zweck können Simulationen von physiologischen Prozessen eingesetzt werden?
2. Was sind antagonistische Modelle und warum werden sie besonders für die Simulation physiologischer Anpassungsprozesse verwendet?
3. Nennen Sie Beispiele, für die Simulationen physiologischer Anpassungsprozesse im Training verwendet werden können.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springer-nature.com.

Literatur

- Balagué, N., Hristovski, R., Almarcha, M. D. C., Garcia-Retortillo, S., & Ivanov, P. C. (2020). Network Physiology of Exercise: Vision and Perspectives. *Frontiers in Physiology*, 11, 1607.
- Borresen, J. & Lambert, M. (2009). The quantification of training load, the training response and the effect on performance. *Sports Medicine (Auckland, N.Z.)*, 39(9), 779–795.
- Dickhuth, H.-H., Yin, L., Niess, A., Rocker, K., Mayer, F., Heitkamp, H. C. & Horstmann, T. (1999). Ventilatory, lactate-derived and catecholamine thresholds during incremental treadmill running: Relationship and reproducibility. *International Journal of Sports Medicine*, 20(2), 122–127.
- Endler, S. (2013). *Anpassung des Metamodells PerPot an den ausdauerorientierten Laufsport zur Trainings- und Wettkampfoptimierung* [Dissertation, Johannes Gutenberg-Universität Mainz]. <https://doi.org/10.25358/openscience-3652>
- Endler, S., Hoffmann, S., Sterzing, B., Simon, P. & Pfeiffer, M. (2017). The PerPot simulated anaerobic threshold – a comparison to typical lactate-based thresholds. *International journal of human movement and sports sciences*, 5(1), 9–15. <https://doi.org/10.13189/saj.2017.050102>
- Fuhrmann, S., Pfeiffer, M. & Hohmann, A. (2014). Modellierung von Trainingsprozessen im Schwimmsport. In M. Witt (Hrsg.), *DVS-Schwimmsport-Symposium 2011* (S. 91–98). Deutsche Schwimmtrainer-Vereinigung.
- Halson, S. L. & Jeukendrup, A. E. (2004). Does overtraining exist? An analysis of overreaching and overtraining research. *Sports Medicine*, 34(14), 967–981. <https://doi.org/10.2165/00007256-200434140-00003>
- Hemingway, B., Burgess, K., Elyan, E. and Swinton P. (2020). The effects of measurement error and testing frequency on the fitness-fatigue model applied to resistance training: A simulation approach. *International Journal of Sports Science & Coaching*, 15(1), 60–71.

- Hohmann, A., Lames, M., Letzelter, M. & Pfeiffer, M. (2020). Einführung in die Trainingswissenschaft. Wiebelsheim: Limpert.
- Imbach F., Perrey S., Chailan R., Meline & T. Candau R. (2022). Training load responses modelling and model generalisation in elite sports. *Scientific reports*. 12(1):1586.
- Matabuena, M. & Rodríguez-López, R. (2019). An Improved Version of the Classical Banister Model to Predict Changes in Physical Condition. *Bulletin of Mathematical Biology* (2019) 81:1867–1884.
- Meeusen, R., Duclos, M., Foster, C., Fry, A., Gleeson, M., Nieman, D., et al. (2013). Prevention, diagnosis and treatment of the overtraining syndrome: Joint consensus statement of the European College of Sport Science (ECSS) and the American College of Sports Medicine (ACSM). *European Journal of Sport Science*, 13(1), 1–24.
- Perl, J. (2001). PerPot: A Metamodel for Simulation of Load Performance Interaction. *Electronic Journal of Sport Science*, 1(2).
- Perl, J. (2002). Adaptation, antagonism and system dynamics. In G. Ghent, D. Kluka & D. Jones (Hrsg.), *Perspectives – The multidisciplinary series of physical education and sport science* (Bd. 4, S. 105–125). Oxford: Meyer & Meyer Sport.
- Pfeiffer, M. (2008). Modeling the relationship between training and performance – a comparison of two antagonistic concepts. *International journal of computer science in sport*, 7(2), 13–32
- Pfeiffer, M., und Hohmann, A. (2012). Applications of neural networks in training science. *Human movement science*, 31(2), 344–359.
- Pol, R., Balagué, N., Ric, A., Torrents, C., Kiely, J., & Hristovski, R. (2020). Training or Synergizing? Complex Systems Principles Change the Understanding of Sport Processes. *Sports medicine – open*, 6(1), 28.
- Rasche, C., Pfeiffer, M. (2019). Training. In A. Baca (Hrsg.), *Modelling and simulation in sport and exercise* (S. 187–207). London:Routledge.
- Schwellnus, M., Soligard, T., Alonso, J. M., Bahr, R., Clarsen, B., Dijkstra, H. P., et al. (2016). How much is too much? (Part 2) International Olympic Committee consensus statement on load in sport and risk of illness. *British Journal of Sports Medicine*, 50(17), 1043–1052.
- Soligard, T., Schwellnus, M., Alonso, J. M., Bahr, R., Clarsen, B., Dijkstra, H. P., et al. (2016). How much is too much? (Part 1) International Olympic Committee consensus statement on load in sport and risk of injury. *British Journal of Sports Medicine*, 50(17), 1030–1041.
- Vermeire, K., Ghijs, M., Bourgois, J. G., and Boone, J. (2022). The Fitness–Fatigue Model: What’s in the Numbers? *International Journal of Sports Physiology and Performance*, 2022, 17, 810–813

Programmiersprachen

Inhaltsverzeichnis

Kapitel 14 **Eine Einführung in die Programmiersprache
R für Einsteiger – 125**
Robert Rein

Kapitel 15 **Python – 143**
Maximilian Klemp



Eine Einführung in die Programmiersprache R für Einsteiger

Robert Rein

Inhaltsverzeichnis

- 14.1 Geschichte und Philosophie – 126
- 14.2 Konzeption und Programmierparadigmen – 127
- 14.3 Ressourcen zu R – 128
- 14.4 R Community und Pakete – 128
- 14.5 Einstieg in den Umgang mit R – 129
- 14.6 Ein Beispielworkflow in R – 132
- 14.7 Literate Programming – 137
- Literatur – 141

Kernbotschaften

- Die Programmiersprache R ist gezielt für Datenanalysen konzipiert worden.
- R erlaubt den einfachen Einstieg in die Datenanalyse ohne große Programmier-vorerfahrungen.
- R eignet sich hervorragend als erste Programmiersprache.
- Durch die Verwendung von Paketen wird die Funktionalität von R ständig er-weitert, sodass verschiedenste Datenanalysen einfach durchgeführt werden kön-nen.
- Da R Open Source ist, ist die Benutzung kostenfrei und zukunftssicher.
- R ist für alle üblichen Betriebssysteme verfügbar und kann weitestgehend un-abhängig von diesen eingesetzt werden.
- Durch Zusatzpakete unterstützt R vollumfänglich den Ansatz des Literate Pro-gramming und erlaubt die einfache Erstellung selbst komplexer Reports in den unterschiedlichsten Formaten.

14.1 Geschichte und Philosophie

Die Programmiersprache R ist mit dem Ziel entwickelt worden, Datenanalysen so einfach wie möglich zu machen. Historisch ist R als eine freie Alternative zu der Sprache S entstanden (Ihaka, 1998). Die Sprache S wurde in den 1970er-Jahren in den Bell Laboratories, damals Teil von AT&T, entwickelt. Die Entwickler von S wollten eine Sprache kreieren, die Datenanalyse möglichst einfach macht. Der konzeptionelle Ansatz war, ein System zu entwickeln, das einen graduellen Übergang von Benutzer*innen zu Entwickler*innen ermöglicht. Dies wurde durch die Kombination einer interaktiven Kommandozeile mit Möglichkeiten zum Erstellen klassischer Programme erreicht (Venables & Ripley, 2000). Das ursprüngliche S-System (später S-Plus) war aber durch seinen proprietären Charakter in seiner Verbreitungsmöglichkeit eingeschränkt. Im Jahre 1991 begannen daher Ross Ihaka und Robert Gentleman an der University of Auckland (Neuseeland) mit der Entwicklung einer Alternative. Die neue Programmiersprache mit dem Namen R wurde 1993 erstmals vorgestellt und im Jahre 1995 unter der GNU General Public License lizenziert. Dadurch wurde R zu einer „freien“ Software, die eine Weiterentwicklung abseits von proprietären Einschränkungen ermöglicht. Diese Entscheidung stellte sich im Nachhinein als goldrichtig heraus und ist nach wie vor eine der treibenden Kräfte bei der Weiterentwicklung von R. Heutzutage ist R im Bereich der universitären Forschung die *franca lingua* für statistische Analysen und hat andere proprietäre Statistikpakete weitestgehend verdrängt.

Ein weiterer Sprung in der Verbreitung von R kam mit der Veröffentlichung von RStudio (jetzt Posit). RStudio ist eine integrierte Entwicklungsumgebung auf der Basis von R, welche den Umgang mit verschiedenen Funktionalitäten von R vereinfacht. Die Umgebung wird von RStudio PBC (*public benefit corporation*) entwickelt. Die Entwicklungsumgebung hat den Zugang zu R für Programmier-neulinge noch einmal deutlich erleichtert, ohne jedoch die Kernidee der inter-

aktiven Datenanalyse in Kombination mit längeren Skripten oder Programmen aufzugeben. Daher ist selbst mit RStudio eine Datenanalyse mittels mausgesteuerter Menüs nicht möglich, und Anwender*innen arbeiten nach wie vor mit Befehlen, was immer noch die effizienteste Art der Datenanalyse ist.

Heutzutage läuft R auf allen Standardbetriebssystemen (Linux, Windows, macOS) wie auch auf zahlreichen Nichtstandardsystemen. Die Weiterentwicklung von R wird durch die Non-profit Organization „The R Foundation“ gesteuert. Die R Foundation ist Teil der Free Software Foundation und sorgt dafür, dass es keine Einschränkungen durch proprietäre Hürden gibt, und sichert die kontinuierliche Weiterentwicklung von R. Mittlerweile gibt es verschiedene kommerzielle Anbieter im Umfeld von R, die für Firmen Supportdienste bereitstellen. Dazu haben viele kommerzielle Statistikpakete Anbindungen an R implementiert.

14.2 Konzeption und Programmierparadigmen

Bei R handelt es sich um eine interpretierte Programmiersprache. Das bedeutet, dass R Programmierbefehle direkt ausführt und nicht erst das ganze Programm von einem Compiler in Maschinenbefehle übersetzt werden muss, wie das beispielsweise bei der Programmiersprache C der Fall ist. Dies hat den Vorteil, dass die Arbeit interaktiv durchgeführt werden kann, d. h., als Anwender*in wird nach jedem ausgeführten Befehl ein Ergebnis durch R zurückgeliefert. Dies vereinfacht Datenanalyse in großem Maße, da Daten schnell angepasst, transformiert oder grafisch bzw. deskriptiv dargestellt werden können. Der Nachteil von interpretierten Programmiersprachen ist, dass durch die Abarbeitung der einzelnen Befehle bestimmte Compileroptimierungen nicht angewendet werden können, sodass die Ausführungszeit im Vergleich zu kompilierten Programmiersprachen länger sein kann. R kann jedoch durch die Einbindung von Paketen, die in anderen Programmiersprachen erstellt wurden, in vielen Fällen diesen Nachteil umgehen.

Konzeptionell ermöglicht R die Programmierung mit unterschiedlichen Programmierparadigmen. Ein Ursprung von R leitet sich aus der Sprache Scheme (Sussman & Steele, 1998) ab. Scheme hat die Besonderheit, dass – etwas vereinfacht – zwischen Daten und Code kein Unterschied besteht (Abelson & Sussman, 1996). Daher ermöglicht R das sogenannte Meta-Programming, d. h., die Programmierung auf der Sprache selbst. Dies erlaubt es, in R relativ einfach domänen-spezifische Untersprachen zu erstellen, um verschiedene Aufgaben zu vereinfachen (Wickham, 2019). Daneben sind im Laufe der Zeit zahlreiche Möglichkeiten zur klassischen objektorientierten Programmierung hinzugekommen. Die einfache Erweiterbarkeit von R ermöglicht dabei eine ständige Weiterentwicklung der einsetzbaren Programmierparadigmen, sodass beispielsweise auch die funktionale Programmierung oder auch neuere Paradigmen wie die reaktive Programmierung möglich sind (Wickham, 2021). Trotz der stetigen Weiterentwicklung und Erweiterung hat R es jedoch immer geschafft, die Einstiegshürde gleichbleibend niedrig zu halten. Daher gilt, dass immer noch eine Datenanalyse im Anschluss an eine zweiminütige Installation direkt starten kann.

14.3 Ressourcen zu R

War es zu Beginn von R noch schwierig, Hilfe bei Problemen zu bekommen, so hat sich dies in den letzten zehn bis 15 Jahren dramatisch geändert. Beispielsweise war durch die für Suchmaschinen etwas unglückliche Namensgebung R die Suche nach Problemlösungen zu Beginn noch wenig erfolgreich. Dies hat sich jedoch vollkommen zum Positiven verändert. Im Internet finden sich zahllose überaus aktive Communities rund um R, mit ausführlichen Blogs, Podcasts, Youtube-Sammlungen und Programmierhilfen bei konkreten Fragen (z. B. Stack Overflow). Dazu ist die Anzahl an Büchern um und über R in den letzten Jahren geradezu explodiert. Mit eigenen Serien zur Datenanalyse mit R (Springer: Use R!, CRC: The R-Series) und zahllosen weiteren wissenschaftlichen Büchern mit mindestens Code-Beispielen in R bis hin zu frei verfügbaren Sammlungen hochqualitativer, wissenschaftlicher Bücher zu R (► bookdown.org).

Daher ist der Einstieg in die Datenanalyse mit R so einfach wie wohl kaum bei einer anderen Programmiersprache. Dazu kommt, dass innerhalb der wissenschaftlichen Gemeinschaft im Bereich der Statistik R die dominierende Sprache zur Implementierung und Testung neuer Verfahren ist. Dies führt dazu, dass die neuesten statistischen Verfahren meist direkt in R im Rahmen von Paketen von den jeweiligen Wissenschaftler*innen selbst bereitgestellt werden und somit früh zur Verfügung stehen.

14.4 R Community und Pakete

Eine treibende Kraft bei der Weiterentwicklung und Weiterverbreitung von R ist die riesige Gemeinschaft von Anwender*innen und Programmierer*innen. Dadurch, dass R im Kern eine vollständige Programmiersprache ist, kann die Funktionalität von R ständig erweitert und individuellen Bedürfnissen angepasst werden. Neue Funktionalität wird in R im Rahmen von sogenannten Paketen (alternativ Bibliotheken) gebündelt. Durch diese Pakete können neue Befehle durch neu definierte Funktionen in R zugänglich gemacht werden.

R-Pakete werden über das Comprehensive R Archive Network (kurz CRAN) verteilt. CRAN ist ein internationales Netzwerk von Webservern, auf denen R-Pakete gespeichert werden und das einfache Herunterladen aus R heraus ermöglichen. Die auf CRAN gespeicherte Paketen folgen alle einer streng definierten Struktur und durchlaufen eine Qualitätskontrolle. Die Weiterentwicklung bzw. weitere Anpassung wird durch sogenannte *maintainer* sichergestellt. Während die Anzahl an Zusatzpaketen am Anfang von R noch relativ übersichtlich war, liegt die derzeitige Anzahl an R-Paketen auf CRAN bei 18.720 (Stand 10/2022) mit ständig steigender Tendenz. Da sich Datenanalysen über verschiedene Disziplinen und Anwendungsfälle im Grunde genommen immer wieder ähneln, besteht eine hohe Wahrscheinlichkeit, dass auch für ungewöhnliche Anwendungsfälle bereits bestehende Pakete und Zusatzfunktionen in R zur Verfügung stehen. Daher besteht für den Großteil der Anwender*innen oftmals gar nicht mehr die Notwendig-

keit, kompliziertere Programmieraufgaben selbst durchzuführen. Vielmehr können auftauchende Probleme durch die Suche nach einem geeigneten Paket schnell gelöst werden. Dies führt ebenfalls dazu, dass die Einstiegshürde für den Umgang mit R sehr niedrig ist.

14.5 Einstieg in den Umgang mit R

Wie bereits mehrmals betont, besteht der Umgang mit R darin, spezifische Befehle durch R auszuführen zu lassen. So kann R im einfachsten Fall als ein überproportionierter Taschenrechner angesehen werden. Beispielsweise führt auf der R-Kommandozeile der Befehl $2 + 2$ gefolgt von einem ENTER zu folgendem Ablauf:

```
> 2 + 2  
[1] 4
```

Hierbei steht $>$ für die Kommandozeile und $[1]$ kennzeichnet die erste Zeile der Ausgabe von R. Die Kommandozeile funktioniert nach dem Prinzip einer sogenannten REPL. REPL ist eine Abkürzung für die englischen Begriffe *readeval-print loop*. Die Eingabe wird durch R eingelesen (R), im Rahmen der Programmiersprache evaluiert (E), das Ergebnis wird ausgegeben (P), und anschließend geht die Kommandozeile zurück zum Ausgangszustand (L).

Die im Beispiel berechnete 4 steht jetzt allerdings für die weitere Bearbeitung nicht mehr zur Verfügung, da R die REPL ausgeführt hat und die Ausgabe nicht automatisch gespeichert wird. Um den Rückgabewert eines Ausdrucks weiter zu bearbeiten, muss dieser Wert in irgendeiner Form zugänglich gemacht werden. Um berechnete Werte weiter verwenden zu können, muss diesen Werten ein Bezeichner (Name) zugewiesen werden. Dies zieht das Konzept einer Variablen nach sich. Erfahrungsgemäß stellt dieses Konzept eine erste größere Hürde dar für den Umstieg von beispielsweise Tabellenkalkulationsprogrammen, bei denen die Berechnungen scheinbar direkt auf den zu sehenden Daten stattfinden. Um in R einem Ausdruck bzw. dessen Rückgabewert einen Namen zuzuweisen, wird der Zuweisungsoperator $<-$ benutzt. Möchte ich beispielsweise das Ergebnis der „komplexen“ Berechnung $2 + 2 * 4$ einem Namen geben, so würde dies wie folgt aussehen:

```
> x <- 2 + 2 * 4
```

In diesem Fall gibt R keinen Ausdruck zurück, sondern hat intern dem Ergebnis von $2 + 2 * 4$ den Bezeichner x gegeben. Ein Aufruf x von auf der Kommandozeile führt dann zu:

```
> x  
[1] 10
```

Das heißt, im internen Speicher von R ist der Wert 10 abgespeichert, und der Wert kann über den Bezeichner `x` aufgerufen bzw. ausgegeben werden. Darin besteht ein grundlegender Unterschied in der Arbeitsweise mit Tabellenprogrammen. In R werden Berechnungen, die Rückgabewerte von Ausdrücken, Bezeichnern zugewiesen und können dann in späteren Schritten wieder aufgerufen werden. Andersherum, wenn Zwischenergebnisse keinen Bezeichner haben, können sie auch nicht wiederverwendet werden.

Zwei weitere Erläuterungen zu den bisherigen Beispielen sind notwendig. In den bisherigen Ausdrücken sind Leerzeichen zwischen die einzelnen Teile der Ausdrücke gesetzt worden. Diese Leerzeichen dienen lediglich der Leserlichkeit und haben keinen Einfluss auf die Evaluierung des Ausdrucks durch R. Daher sind die Ausdrücke $2 + 2 * 4$ und $2+2*4$ äquivalent und führen zum gleichen Ergebnis. Bei der Ausgabe des Wertes ist wahrscheinlich auch aufgefallen, dass R nicht den Wert 16 berechnet hat, der korrekt wäre, wenn die Evaluierung des Ausdrucks streng von links nach rechts durchgeführt wird. R hat jedoch die korrekte mathematischen Regel „Punkt vor Strich“ angewendet und ist daher zum Ergebnis 10 gekommen.

Bei der weiteren Bearbeitung von Bezeichnern in R ist beachten, dass R zwischen Groß- und Kleinschreibung unterscheidet. Daher führt der Aufruf des Bezeichners:

```
> x
Error: object 'x' not found
```

zu einem Fehler. Das Auftreten von Fehlern führt bei R-Neueinsteiger*innen oft zu großer Verwirrung, ist aber im Programmieralltag ein vollkommen normales Ereignis und sollte daher niemanden aus der Ruhe bringen. Im vorliegenden Fall bemängelt R lediglich, dass es den Bezeichner `x` nicht finden kann und dementsprechend nicht weiß, wie es weiter verfahren soll.

Die Arbeit mit R beruht in großen Teilen auf der Anwendung von Funktionen auf Werten. In R werden Funktionen nach dem Muster `<NAME>(<PAR1>,<PAR2>,...,<PARk>)` gebraucht (Die Zeichen `<>` zeigen einen beliebigen Bezeichner). Das heißt, sobald ein rundes Klammerpaar auf einen Bezeichner folgt, geht R davon aus, dass eine Funktion aufgerufen werden soll. Über `<PAR1>,<PAR2>,...,<PARk>` können der Funktion durch Komma getrennte Parameter übergeben werden. Die Anzahl der Parameter hängt dabei von der Definition der Funktion ab. Ein einfaches Beispiel ist die Anwendung der Wurzel auf einen numerischen Wert.

```
> y <- 9
> sqrt(y)
[1] 3
```

Die mathematische Wurzelfunktion wird in R mittels der Funktion `sqrt()` abgebildet. Im Beispiel wird zunächst dem Wert 9 der Bezeichner `y` zugewiesen, und auf diesen Bezeichner wird dann die Wurzelfunktion `sqrt()` angewendet. Ein etwas näher an der Anwendung liegendes Beispiel wäre beispielsweise die Berechnung des Mittelwerts oder die Summe der Datenreihe (3, 5, 7). In R wird eine solche geordnete Reihe von Zahlen als Vektor repräsentiert. Um einen solchen Vektor zu erstellen wird wiederum eine Funktion (`c()` für *concatenation*) verwendet. Anschließend kann auf den erstellten Vektor die Mittelwertsfunktion `mean()` bzw. die Funktion `sum()` angewendet werden.

```
> z <- c(3, 5, 7)
> z
[1] 3 5 7
> mean(z)
[1] 5
> sum(z)
[1] 15
```

Der große Vorteil von R besteht nun darin, dass problemlos eigene Funktion definiert werden können. Beispielsweise eine Funktion, welche das Minimum und das Maximum eines Vektors als einen Vektor mit zwei Einträgen zurückgibt.

```
> my_min_max <- function(x) {
+   c(min(x), max(x))
+ }
> my_min_max(z)
[1] 3 7
```

Hier wird mittels des Schlüsselworts **function()** R angezeigt, dass eine neue Funktion definiert wird. Auf das Schlüsselwort folgen die beiden runden Klammern mit den benötigten Parametern. Im Beispiel wird nur ein Parameter benötigt, der den Bezeichner `x` bekommt. Die Namensgebung ist dabei vollkommen willkürlich und muss nur dann im folgenden Funktionskörper, der durch die geschweiften Klammern `{ }` Bereich, passend verwendet werden. Bei Aufrufen der Funktion wird der Parameter entsprechend des übergebenen Wertes in den Klammern im Funktionskörper ersetzt.

Wird eine Funktion aus einem R-Paket benötigt. Dann muss dieses zunächst in der R-Umgebung auf dem Rechner installiert werden, wenn dies nicht schon in einer vorhergehenden Session geschehen ist. Dazu wird wiederum eine Funktion verwendet. Um beispielsweise interaktive Karten mit R zu generieren, ist das Paket „leaflet“ notwendig. Der folgende Befehl installiert das Paket im R-System:

```
> install.packages("leaflet")
```

R kontaktiert im Hintergrund den CRAN-Server und lädt das entsprechende Paket und benötigte Abhängigkeiten herunter. Die Funktionalität des Pakets steht dann noch nicht direkt zur Verfügung, sondern das Paket muss zunächst mit einem weiteren Befehl in die derzeit aktive Arbeitsumgebung geladen werden.

```
> library(leaflet)
```

Diese Beispiele dienen nur dazu, einen allerersten Überblick über die Arbeit mit R zu gewinnen und die ersten Konzepte im Umgang mit R kennenzulernen. Wie bereits an diesem einfachen Beispiel ersichtlich, besteht eine der Herausforderungen darin, die notwendigen Befehle und Funktionen zu erlernen. Der Einstieg in R ähnelt daher dem Erlernen einer neuen Sprache. Diese Anfangshürde wird heutzutage durch die deutlich verbesserten Suchfunktionen der Internetsuchmaschinen sehr erleichtert. So reicht meistens eine Suche, die mit einem R startet und dem Problem, um Lösungsvorschläge zu finden. Auf diese Weise kann eine schnelle Produktivität in R erreicht werden, ohne dass tiefer gehende Programmierkenntnisse benötigt werden. Daher eignet sich R sehr gut als eine erste Programmiersprache, bei der nach und nach weiterführende Programmierkonzepte nach Bedarf erarbeitet werden können. Gute Anfangsquellen für den Einstieg sind: Chambers (2008), Dalgaard (2020), Peng (2016), Wickham & Golemund (2016).

Im Folgenden wird ein etwas umfangreicheres Beispiel mit nur kurzen Erklärungen exemplarisch vorgeführt. Eingehende Erläuterungen zu den verwendeten Befehlen können in R mittels der Hilfedokumentation aufgerufen werden. Dazu wird lediglich ein `?` vor den Funktionsnamen gestellt, und R öffnet die dazu gehörende Hilfedatei.

```
> ?mean
```

14.6 Ein Beispielworkflow in R

14

Es sei der folgende Datensatz aus Tabelle XY gegeben. In zwei unabhängigen Gruppen A und B wurde der Körperfettgehalt bestimmt, und nun soll untersucht werden, ob ein statistisch signifikanter Unterschied zwischen den beiden Gruppen besteht. Dies ist natürlich nur ein synthetisches Beispiel und sollte in dieser Form daher nicht im Rahmen einer tatsächlichen wissenschaftlichen Arbeit durchgeführt werden, sondern dient lediglich der Anschauung (■ Tab. 14.1).

Um eine Datenanalyse durchzuführen, müssen die Daten zunächst in R eingeladen werden. In der Rohform (Supplementary Material: XYZ) liegen die Daten in Form einer Textdatei vor. Die erste Spalte der Datei zeigt die Gruppenzugehörigkeit an, während die zweite Spalte den jeweiligen Fettgehalt beinhaltet. Die Spalten sind durch ein Komma voneinander getrennt und als Dezimaltrennzeichen

■ **Tab. 14.1** Prozentualer Körperfettgehalt in zwei Gruppen

A	B
13,3	22,0
6,0	16,0
20,0	21,7
8,0	210,0
14,0	30,0
19,0	26,0
	30,0

wird, der internationalen Konvention folgend, ein Punkt verwendet. Um die Daten in R zu laden, wird aus dem Paket „readr“ die Funktion `read_csv()` verwendet. Zunächst muss jedoch das derzeitige Arbeitsverzeichnis von R auf den entsprechenden Ordner, unter dem die Datei abgelegt wird, gesetzt werden. Dazu wird die Funktion `setwd()` (kurz für *set working directory*) verwendet. Da Pfadangeben in R immer relativ zu Arbeitsverzeichnis bestimmt werden, erleichtert dieser Schritt die weitere Arbeit, weil keine langen Dateipfade angegeben werden müssen.

```
> setwd(<PFAD>)
```

Nun wird das Paket „readr“ geladen und die Datei mittels der Funktion `read_csv` eingeladen.

```
> library(readr)
> bfp <- read_csv(file = 'bfp_data.txt')
```

Die Daten stehen nun unter dem Bezeichner `bfp` in R zur Verfügung. Der Name ist dabei wieder willkürlich gewählt und der Einfachheit halber kurz gehalten.

```
> bfp <- read_csv(file = 'bfp_data.txt')
# A tibble: 13 x 2
  Group   BFP
  <chr> <dbl>
1 A      13.3
2 A       6
3 A      20
4 A       8
```

```

5 A      14
6 A      19
7 B      22
8 B      16
9 B      21.7
10 B     210
11 B      30
12 B      26
13 B      30

```

Die Daten sind in einem sogenannten `data.frame`-Objekt (bzw. der neueren Version `tibble`) abgelegt und können nun weiter verarbeitet werden. Beispielsweise kann mittels der Funktion `summary()` ein Überblick über deskriptiven Statistiken der Daten erzeugt werden.

```

> summary(bfp)
   Group      BFP
Length:13    Min.   : 6.00
Class :character 1st Qu.: 14.00
Mode  :character Median : 20.00
                        Mean  : 33.54
                        3rd Qu.: 26.00
                        Max.   :210.00

```


Hier ist bereits zu sehen, dass einer der Datenpunkte wahrscheinlich fehlerhaft ist, da der Wert > 100 ist, was bei für einen prozentualen Körperfettanteil nicht möglich ist. Im nächsten Schritt sollen die Daten dann grafisch mittels eines Boxplots dargestellt werden. R stellt von Haus aus zahlreiche Funktion zur einfachen grafischen Darstellung bereit. Wir wollen hier aber auf das Paket `ggplot2` zurückgreifen, welches die Erstellung moderner Grafiken in Publikationsqualität ermöglicht (Healy, 2018; Wickham, 2016). Vor der Verwendung muss das Paket wiederum zunächst geladen werden.


14

```

> library(ggplot2)
> ggplot(bfp, aes(Group, BFP)) + geom_boxplot()

```


Im Boxplot in  Abb. 14.1 ist der problematische Datenpunkt noch klarer ersichtlich und er verhindert auch gleichzeitig eine Analyse der Daten. Da wir keine weitere Information haben, schließen wir den Datenpunkt aus. Dazu benutzen wir aus dem Paket „dplyr“ die Funktion `filter`.



■ **Abb. 14.1** Darstellung der Beispieldaten mittels eines Boxplots mit dem problematischen Datenpunkt

```
> library(dplyr)
> bfp_clean <- filter(bfp, BFP <= 100)
> bfp_clean
# A tibble: 12 x 2
  Group   BFP
  <chr> <dbl>
1 A      13.3
2 A         6
3 A      20
4 A         8
5 A      14
6 A      19
7 B      22
8 B      16
9 B     21.7
10 B     30
11 B     26
12 B     30
> ggplot(bfp_clean, aes(Group, BFP)) + geom_boxplot()
```

Die grafische Darstellung mittels einer Boxplots ist jetzt schon deutlich nachvollziehbarer (s. ■ Abb. 14.2). Ohne hier weiter auf statistische Voraussetzungen einzugehen, führen wir jetzt einen unabhängigen t-Test für Gruppen mit unterschiedlichen Varianzen. Dazu benutzen wir wieder eine Funktion aus R.



■ **Abb. 14.2** Darstellung der Beispieldaten mittels eines Boxplots nach Ausschluss des Ausreißers

```
> t.test(BFP ~ Group, data = bfp_clean)

Welch Two Sample t-test

data: BFP by Group
t = -3.4017, df = 9.9886, p-value = 0.006762
alternative hypothesis: true difference in means between
group A and group B is not equal to 0
95 percent confidence interval:
 -18.040619 -3.759381
sample estimates:
mean in group A mean in group B
    13.38333      24.28333
```

14

Wie dieses Beispiel zeigt, lässt sich in R mittels weniger Befehle eine Datenanalyse realisieren. Die Entwickler von R haben dabei darauf geachtet, dass die Namensgebung von Funktionen möglichst nahe an der gewünschten Tätigkeit liegt, sodass einen der englische Begriff meist schnell die Funktion herleiten lässt.

Im Beispiel haben wir alle Befehle direkt auf der Kommandozeile eingegeben und die Daten interaktiv analysiert. Bei einer tatsächlichen Analyse wird die Datenanalyse aus einer Kombination von interaktiven Arbeiten und permanenten Skripten bestehen. Beispielsweise würden diejenigen finalen Befehle, die auf die Daten angewendet werden sollen, in eine Skriptdatei geschrieben werden, sodass die Analyse zu einem späteren Zeitpunkt wieder aufgegriffen werden kann bzw. nachvollziehbar ist. So könnte der gezeigte Workflow in das folgende Skript münden:


```
setwd(<PFAD>)

# Notwendige Bibliotheken
library(readr)
library(ggplot2)
library(dplyr)

# Daten einlesen
bfp <- read_csv(file = 'bfp_data.txt')

# Daten bearbeiten
bfp_clean <- filter(bfp, BFP <= 100)

# Deskriptiv
summary(bfp_clean)

# Graphiken
ggplot(bfp_clean, aes(Group, BFP)) + geom_boxplot()

# Analyse
t.test(BFP~Group, data = bfp_clean)
```

Die verwendeten Befehle sind durch die Verwendung von Kommentaren, die in R mit einem # signalisiert werden, noch besser nachvollziehbar.

14.7 Literate Programming

Da die Nachvollziehbarkeit von Datenanalysen nicht nur für einen selbst, sondern auch durch externe Parteien im Rahmen von wissenschaftlicher Reproduzierbarkeit zunehmend in der wissenschaftlichen Praxis an Bedeutung gewinnt, bietet R umfangreiche Funktionalität an, um Datenanalysen zu dokumentieren und zu veröffentlichen (Xie, 2016, 2017). Begrifflich fällt dieser Bereich unter das sogenannte Literate Programming. So wurde im Jahre 2002 bereits ein spezielles Paket „Sweave“ veröffentlicht, welches die Kombination von R- und Latex-Code in einem einzigen Dokument erlaubte. Darauf aufbauend hat sich mittlerweile ein ganzer Standard in Form von RMarkdown-Dokumenten entwickelt, um Reports, wissenschaftliche Artikel, Bücher, Weblogs, Dashboards, interaktive Dokumente, randomisierte Klausuren, Präsentationen und vieles mehr direkt aus R heraus zu generieren. Dazu werden unterschiedlichste Ausgabeformate (docx, pdf, odf, pptx, html) unterstützt.

Im Kern basieren viele dieser Prozesse auf dem Markdown-Standard, der es ermöglicht, selbst komplexeste Dokumente einfach zu erstellen. Markdown ist eine vereinfachte Auszeichnungssprache, mit der ohne komplizierte Textverarbeitungssysteme Dokumente erstellt werden können und wo die finale Formatierung der

Dokumente nachgeordneten Systemen überlassen wird. Das RMarkdown-Format reichert das Markdown-Format um R spezifische Element an. Ein einfaches Beispieldokument, basierend auf unseren vorhergehenden Skripts, wäre:

```
---
author: "Robert Rein"
title: "RMarkdown-Beispiel"
output: pdf_document
---

# Notwendige Bibliotheken
```{r}
library(readr)
library(ggplot2)
library(dplyr)
```

# Daten einlesen
```{r}
bfp <- read_csv(file = 'bfp_data.txt')
```

# Daten bearbeiten
```{r}
bfp_clean <- filter(bfp, BFP <= 100)
```

# Deskriptiv
```{r}
summary(bfp_clean)
```

# Graphiken
```{r}
#| fig.cap="Boxplot der Daten",
#| fig.height=3
ggplot(bfp_clean, aes(Group, BFP)) + geom_boxplot()
```

# Analyse
```{r}
t.test(BFP~Group, data = bfp_clean)
```
```

Das RMarkdown-Dokument beginnt mit einem sogenannten YAML-Header mit Metadaten. Darauf folgt das eigentliche Dokument. In der Schreibweise von Markdown bedeutet ein Hash (#) eine Überschrift erster Ordnung. Die Bereiche zwischen ````{r}``` und ````kennzeichnen einen R-Codebereich der als „chunk“ bezeichnet wird. Das Dokument kann mittels des Pakets „knitr“ in einen PDF-Report übersetzt werden. R führt dabei die jeweiligen Codebereiche zunächst aus, und die entsprechenden Ausdrücke und Werte werden in den chunks ersetzt. Erzeugte Grafiken werden ebenfalls direkt in das Dokument eingefügt (■ Abb. 14.3).

Insgesamt erlaubt die R-Umgebung daher den kompletten Lebenszyklus einer Datenanalyse von der ersten Bearbeitung bis zur Veröffentlichung der Daten aus einer einzigen Umgebung heraus. Dadurch können wiederkehrende Workflows automatisiert werden und relativ problemlos Reportingsysteme für die verschiedensten Anwendungsfälle erstellt werden.



■ **Abb. 14.3** Aus einem RMarkdown-Dokument generierter PDF-Report. Die R-Codebereiche sind durch den evaluierten Code ersetzt worden

Studienbox

Datenanalysen sind in den seltensten Fällen als geradlinige Aufgabe anzusehen, bei der von vornherein alle Bearbeitungsschritte feststehen. Daher ist jede Datenanalyse durch interaktive Phasen gekennzeichnet, bei denen die Daten zunächst untersucht und bearbeitet werden müssen. Nach dieser Datenprozessierung erfolgt meist erst die eigentliche Datenanalyse. Diese beiden Schritte können dabei durchaus in iterativen Zyklen mehrmals durchlaufen werden, bevor eine endgültige Prozesspipeline erstellt wird, mit der die Daten final analysiert und veröffentlicht werden. Eine Softwareumgebung zur Datenanalyse muss daher diese Schritte optimal unterstützen. Die Programmiersprache R ist genau mit dem Ziel konzipiert worden, diese Phasen zu ermöglichen, und bietet daher Möglichkeiten

zur interaktiven wie auch stärker strukturierten Arbeitsweise. Durch die Möglichkeit, Zusatzpakete einzubinden, wird die Funktionalität von R ständig erweitert und für praktisch alle möglichen Anwendungsfälle gibt es, wenn nicht schon komplette, dann doch bereits fertige Teillösungen. R bietet umfangreiche Unterstützung für den kompletten Lebenszyklus einer Datenanalyse. Da R eine vollständige Programmiersprache ist, können alle Analyseschritte an die eigenen Bedürfnisse angepasst werden. R erlaubt je nach Bedarf die Anwendung auf verschiedenen Komplexitätsebenen. So kann im Laufe der Zeit eine Entwicklung von Neuanwender*innen ohne Programmiererfahrung zu vollumfänglichen Programmierer*innen durchlaufen werden.

Fragen für die Studierenden

1. Was unterscheidet die Arbeit mit R von Tabellenkalkulationsprogrammen?
2. Wie kann die Funktionalität von R einfach erweitert werden?
3. Was wird unter dem Begriff Literate Programming verstanden?

14

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Abelson, H., & Sussman, G. J. (1996). *Structure and interpretation of computer programs*: The MIT Press.
- Chambers, J. M. (2008). *Software for data analysis: Programming with R* (Vol. 2). New York, USA: Springer.
- Dalgaard, P. (2020). *Introductory statistics with R* (2 ed.). New York, USA: Springer.
- Healy, K. (2018). *Data visualization: a practical introduction*: Princeton University Press.
- Ihaka, R. (1998). R: Past and future history. *Computing Science and Statistics*, 392396.
- Peng, R. D. (2016). *R programming for data science*. Victoria, BC, Canada: Leanpub.
- Sussman, G. J., & Steele, G. L. (1998). Scheme: A interpreter for extended lambda calculus. *Higher-Order and Symbolic Computation*, 11(4), 405–439.
- Venables, W., & Ripley, B. D. (2000). *S programming*. New York, USA: Springer Science & Business Media.
- Wickham, H. (2016). *Programming with ggplot2*. New York, USA: Springer.
- Wickham, H. (2019). *Advanced R*: CRC press.
- Wickham, H. (2021). *Mastering shiny*: O'Reilly Media, Inc.
- Wickham, H., & Grolemund, G. (2016). *R for data science: import, tidy, transform, visualize, and model data*: O'Reilly Media, Inc.
- Xie, Y. (2016). *Bookdown: Authoring books and technical documents with R markdown*: Chapman and Hall/CRC.
- Xie, Y. (2017). *Dynamic Documents with R and knitr*: Chapman and Hall/CRC.



Python

Maximilian Klemp

Inhaltsverzeichnis

- 15.1 Beispiel Sport – 144
- 15.2 Hintergrund – 145
- 15.3 Anwendungen – 147
- Literatur – 149

Kernbotschaften

- Die Programmiersprache Python ist eine dynamische, objektorientierte, höhere Open-Source-Programmiersprache und eine der beliebtesten Sprachen für Data-Science-Aufgaben.
- Die im Sport generierten Datenmengen erfordern effiziente und flexible Analyse-routinen, welche von der Vorverarbeitung großer Datenmengen (wie z. B. aus Positions- und Eventdaten) bis hin zur Modellierung mittels maschinellem Lernen und künstlicher Intelligenz reichen.
- Python bietet über diverse Bibliotheken eine große Bandbreite von Funktionalitäten, welche bei der Datenanalyse im Sport für jeden anfallenden Verarbeitungsschritt eine Lösung bieten.
- Diverse State-of-the-Art-Frameworks in der Datenanalyse und Modellierung im Sport sind in Python implementiert und mittels frei zugänglicher Bibliotheken für Forschende, Lehrende und Studierende nutzbar.
- Aus den zahlreichen Anwendungsfällen wird ersichtlich, welche signifikante Präsenz Python in der Sportdatenanalyse aufweist.

15.1 Beispiel Sport

Die Relevanz von Programmiersprachen für die Sportwissenschaft fußt maßgeblich auf der digitalen Revolution im Sport, welche in den vergangenen Jahrzehnten durch die Entwicklung effizienter Erhebungsmethoden für unterschiedliche Datentypen in Gang gesetzt worden ist (Memmert & Raabe, 2018). Ein Fußballspiel beispielsweise generiert Positionsdaten mit etwa 7 Mio. Datenpunkten und Eventdaten zu etwa 1800 Ereignissen, welche in Abhängigkeit vom Datenanbieter Eigenschaften in bis zu 20 Dimensionen enthalten. Multipliziert man diese Zahlen mit der Anzahl potenziell zu analysierender Spiele (z. B. 380 Spiele pro Saison in den meisten europäischen Ligen), wird der Bedarf nach effizienten Datenverarbeitungsprozessen schnell ersichtlich. Die konkreten Verarbeitungs- und Auswertungsaufgaben enthalten dabei die Filterung oder Aggregation von Datenpunkten, die Berechnung zusätzlicher Variablen oder die anschließende Modellierung von Zusammenhängen (für detailliertere Ausführungen s. Abschn. 15.2). Dabei treten wiederkehrende Analyseschritte auf, die beispielsweise in regelmäßigen Abständen auf neu generierte Daten angewendet oder aufgrund des Gesamtvolumens der analysierten Daten separat auf diversen Teildatensätzen ausgeführt werden müssen. Aus diesem Grund ist die Erstellung robuster und reproduzierbarer Datenverarbeitungspipelines durch benutzerdefinierte Programme und hierfür die Verwendung von Programmiersprachen unvermeidbar. Die Programmiersprache Python erfreut sich aufgrund ihrer im nächsten Abschnitt thematisierten Eigenschaften großer Beliebtheit unter Datenanalyst*innen und Datenwissenschaftler*innen. Auch für die Anwendungsfälle im Sport hat sich Python als die wohl beliebteste und meistgenutzte Programmiersprache durchgesetzt.

15.2 Hintergrund

Aus den im vorhergehenden Abschnitt genannten Datenstrukturen und -volumina ergeben sich einige spezifische Anforderungen an Datenverarbeitungsprozesse in der Sportinformatik. So liegen häufig Rohdaten (z. B. in Form von Positions- oder Eventdaten) für mehrere Spiele, Trainingseinheiten oder Teilausschnitte vor, welche für die meisten Anwendungsfälle vor der eigentlichen Analyse vorverarbeitet werden müssen. Zu diesen Vorverarbeitungsschritten zählen Filteroperationen, Gruppierungs- und/oder Aggregierungsschritte sowie die Neuberechnung von Variablen durch Kombination oder Transformation bestehender Variablen. Häufig müssen außerdem Daten aus unterschiedlichen Datenquellen anhand eines gemeinsamen Index zusammengeführt werden. So kann es beispielsweise nötig sein, Informationen aus Videodaten und Positionsdaten auf der Ebene des Timecodes zu synchronisieren oder Informationen zu ganzen Spielen mit aus den Rohdaten berechneten Variablen zusammenzuführen (dem Vokabular der Datenbankabfragesprache SQL folgend werden diese Operationen als „Joins“ bezeichnet). Diese Bandbreite an möglichen Datenverarbeitungsschritten allein macht die Etablierung effizienter und robuster Vorverarbeitungspipelines bereits notwendig. Darüber hinaus fallen jedoch in der Verarbeitung und Analyse von Sportdaten häufig die gleichen Schritte wiederholt an. Dies kann entweder darin begründet sein, dass regelmäßig neue Daten erhoben werden und unmittelbar verarbeitet werden müssen, oder in der Größe der insgesamt zu analysierenden Daten. Ein Positionsdatensatz nimmt in Python etwa 500 MB des Arbeitsspeichers ein, sodass eine gesamte Saison an Positionsdaten (eine Datengrundlage, welche bestenfalls zur Untersuchung von Zusammenhängen verwendet werden sollte) unmöglich gleichzeitig geladen und verarbeitet werden kann. Dieser Umstand begründet vor allem den Bedarf nach reproduzierbaren Analyseroutinen. Abschließend müssen die Daten, sobald sie infolge der oben genannten Schritte in eine strukturierte Form gebracht worden sind, unter Nutzung von Methoden des maschinellen Lernens oder der künstlichen Intelligenz modelliert werden, um Zusammenhänge zu finden oder Klassifikationsprobleme im Bereich der Sportinformatik zu lösen (Generierung von Positionsdaten aus Videobildern, Detektion von Spielphasen etc.).

Python bietet für alle oben genannten Herausforderungen Lösungen und ist aufgrund dieser Vielseitigkeit sowie weiterer Eigenschaften optimal zur Datenverarbeitung und -analyse im Sportkontext geeignet. In der Gemeinschaft der Datenwissenschaftler*innen im Allgemeinen und der Sportdatenanalyst*innen im Speziellen ist Python besonders beliebt, da es sich dabei um eine kostenlos verfügbare, dynamische, objektorientierte, höhere Programmiersprache handelt, welche durch die bereitgestellten Module bzw. Bibliotheken hochgradig flexible und aktuelle Funktionalitäten bereitstellt. Im Hinblick auf die oben formulierten Bedarfe sind spezifisch die nachfolgenden Bibliotheken wertvoll: *pandas* (McKinney, 2011) stellt Funktionalitäten für den Datenimport aus unterschiedlichen Quellen, die Zusammenführung und Verarbeitung von Daten sowie die anschauliche Darstellung in grafischer und tabellarischer Form bereit. *NumPy* (Oliphant, 2006) ermöglicht effiziente Berechnungen, einschließlich umfangreicher Vektor- und

Matrixoperationen, während *SciPy* (McKinney, 2010) Methoden der Analysis und Zeitreihenanalyse zur Verfügung stellt. Neben den rudimentären Visualisierungsmöglichkeiten in *pandas* beinhaltet *Matplotlib* (Barrett, Hunter, Miller, Hsu, & Greenfield, 2005) eine weitaus umfangreichere Menge an Datenvisualisierungstechniken. Schließlich können über *Statsmodels* (Seabold & Perktold, 2010) „herkömmliche“ statistische Modelle wie das lineare Modell oder generalisierte lineare Modelle und mithilfe von *scikit-learn* (Pedregosa et al., 2011) Algorithmen des maschinellen Lernens implementiert werden. Die gleichzeitige Verfügbarkeit aller dieser Funktionalitäten in Kombination mit der dynamischen Natur von Python, welche ein interaktives Programmieren und dadurch schnelle und flexible Analysen ermöglichen, machen die Sprache besonders wertvoll für Datenanalyse- und -verarbeitungsaufgaben. Das hohe Abstraktionslevel erleichtert zusätzlich den Einstieg und das Erlernen grundlegender Funktionen.

Definition

Python ist eine dynamische, objektorientierte, höhere Open-Source-Programmiersprache. *Dynamisch* bezieht sich dabei auf den Prozess der Kompilierung. Die Kompilierung eines Programms beinhaltet die Übersetzung des Programms vom Quellcode (geschrieben in der jeweiligen Programmiersprache) in einen maschinenlesbaren Binärcode. Jede Programmiersprache muss auf diese Weise kompiliert werden, wobei für dynamische Programmiersprachen dieser Arbeitsschritt nicht explizit durch den/die Entwickler*in vorgenommen werden muss, sondern Zeile für Zeile vom sogenannten *Interpreter* übernommen wird. Die Konsequenz hieraus ist, dass in Python Befehle einzeln und unabhängig vom Rest des Programms ausgeführt werden können, was ein interaktives Programmieren und das zügige Testen einzelner Programmausschnitte sowie eine einfache Datenanalyse ermöglicht. *Objektorientierte* Programmiersprachen arbeiten mit sogenannten Klassen, welche Eigenschaften und Funktionen allgemeingültig definieren und somit reproduzierbare Analysen importierter Daten ermöglichen. *Höhere* Programmiersprachen stellen eine starke Abstraktion von den Details eines spezifischen Computers dar. Die verwendeten Befehle sind für Menschen vergleichsweise leicht lesbar und interpretierbar, wodurch Python anwender*innenfreundlicher ist als andere Sprachen. Der Nachteil dynamischer und höherer Programmiersprachen ist eine reduzierte Effizienz, welche sich in geringeren Rechengeschwindigkeiten niederschlägt. Ein weiterer Vorteil von Python in Bezug auf dieses Problem ist jedoch, dass neue Module angebunden werden können, welche in effizienteren Sprachen wie C++ oder C implementiert sind. Zuletzt ist Python als *Open-Source-Software* kostenlos verfügbar und durch die gemeinschaftsbasierte Instandhaltung einer ständigen Aktualitätsprüfung ausgesetzt. Hieraus resultiert weiterhin, dass im Internet flächendeckende Ressourcen zur Problembehandlung verfügbar sind, was die Nutzung stark vereinfacht.

15.3 Anwendungen

► Beispiel 1

Die genannten Vorverarbeitungsschritte (Filtern, Gruppieren, Aggregieren) werden in diversen Analysen großer Datenmengen erforderlich. So erarbeiteten Anzer und Bauer (2021) ein Expected-Goals-Modell, welches Informationen aus Positions- und Eventdaten berücksichtigen sollte. Hierzu waren komplexe Verarbeitungsschritte zur Synchronisation der beiden Datentypen erforderlich. Klemp, Wunderlich und Memmert (2021) erhoben diverse Leistungsindikatoren getrennt für die beiden Halbzeiten eines Spiels und filterten Variablen zum Teil in Bezug auf Ballbesitz oder Laufgeschwindigkeiten. Abschließend mussten die aus Positionsdaten berechneten Indikatoren mit jenen aus Eventdaten sowie einer weiteren Datenquelle für Wettquoten kombiniert werden. Die in diesen beiden Artikeln durchgeführten Operationen beinhalten diverse Datenvorverarbeitungsschritte, welche u. a. mit den Funktionalitäten von *pandas* und *NumPy* bearbeitet wurden. ◀

► Beispiel 2

Einen weiteren Anwendungsfall bildet die Berechnung komplexer Variablen wie die im Bereich der taktischen Analyse beliebten kollektiven Variablen. Diese modellieren die Beziehungen und Interaktionen zwischen Spielern und Mannschaften als geometrische oder algebraische Strukturen, weshalb hier beispielsweise die Bibliothek *SciPy* häufige Anwendung findet. Anwendungsbeispiele zeigen der Formationsvergleich von Memmert et al. (2019) oder die Untersuchung von Spielerwechseln durch Lorenzo-Martinez und Kollegen (2022). ◀

► Beispiel 3

Schließlich ermöglicht Python die statistische Modellierung sowohl im Sinne von Nullhypothesen-Signifikanztests (z. B. Bassek, Raabe, Memmert & Rein, 2022) als auch im Zuge der Implementierung von komplexeren Modellen aus dem Bereich des maschinellen Lernens. Eine der bekanntesten Anwendungen findet sich hier sicherlich in den Arbeiten von Decroos et al. (2019), welche auf Basis von Eventdaten ein Modell entwickelten, durch das sich der Status eines Spiels zu jedem Zeitpunkt quantifizieren lässt. Der Spielstatus beinhaltet dabei die Wahrscheinlichkeiten für Tore beider Mannschaften innerhalb eines definierten Zeitraums, wodurch sich Aktionen von Spielern anhand ihres Einflusses auf den Spielstatus flächendeckend bewerten lassen. Dieser Modellierungsansatz beinhaltet ebenfalls Datenverarbeitungs- und -visualisierungstechniken. Hervorzuheben ist er vor allem deshalb, weil die im Rahmen der Studie entwickelten Algorithmen in der Python-Bibliothek *socceraction* (► <https://github.com/ML-KULeuven/socceraction>) veröffentlicht wurden, sodass Interessierte die Arbeiten mit Daten diverser Anbieter nachvollziehen können. In diesem Zusammenhang ist abschließend die Veröffentlichung eines umfangreichen Datensatzes von Eventdaten durch Luca Pappalardo et al. (2019) zu nennen, für dessen Import und Analyse in Python durch die Autoren ebenfalls Ressourcen zur Verfügung gestellt wurden (► <https://github.com/Friends-of-Tracking-Data-FoTD/mapping-match-events-in-Python>). ◀

Studienbox

Wie in den vorigen Abschnitten deutlich wurde, sehen sich Datenanalyst*innen im Sportspiel mit wiederkehrenden Aufgaben konfrontiert, die im spezifischen Anwendungsfall jedoch häufig benutzerdefinierte Lösungen erfordern. Um diesem Umstand Rechnung zu tragen und eine Reihe generalisierter Lösungen vorzuschlagen, wurde die Python-Bibliothek *floodlight* von Raabe et al. (2022) veröffentlicht. Diese beinhaltet verschiedene Vorverarbeitungs- und Analyseroutinen für die Untersuchung von Sportdaten, bislang spezifisch für die Sportarten Fußball und Handball. Die Funktionalitäten von *floodlight* enthalten dabei Importfunktionen für

unterschiedliche Datenquellen von Positions-, Event- und Metadaten, Visualisierungsmethoden sowie spezifische Datenmodelle aus unterschiedlichen Disziplinen wie der Leistungsphysiologie (Metabolic-Power-Modell; di Prampero & Osgnach, 2018), dynamischen Systemen (Approximate Entropy; Pincus, 1991) oder dem kollektiven Verhalten (Bourbousson, Sève & McGarry, 2010). Das Ziel von *floodlight* besteht darin, wiederholt anfallende Prozesse des Imports oder der Vorverarbeitung zu standardisieren und zu externalisieren, sodass der Fokus von Forschenden stärker auf die eigentliche Analyse gelegt werden kann.

? Fragen für die Studierenden

1. Warum ist Python so beliebt für Data-Science-Aufgaben?
2. Nennen Sie einen spezifischen Anwendungsfall für die Bibliotheken *pandas* und *scikit-Learn* aus der Sphäre der Datenanalyse im Sport.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Anzer, G., & Bauer, P. (2021). A Goal Scoring Probability Model for Shots Based on Synchronized Positional and Event Data in Football (Soccer). *Frontiers in Sports and Active Living*, 3, 624475.
- Barrett, P., Hunter, J., Miller, J. T., Hsu, J.-C., & Greenfield, P. (2005). Matplotlib – A Portable Python Plotting Package. *Astronomical Data Analysis Software and Systems XIV*, 347, 91.
- Bassek, M., Raabe, D., Memmert, D., & Rein, R. (2022). Analysing Motion Characteristics and Metabolic Power in Elite Male Handball Players.
- Bourbousson, J., Sève, C., & McGarry, T. (2010). Space–time coordination dynamics in basketball: Part 2. The interaction between the two teams. *Journal of Sports Sciences*, 28(3), 349–358.
- Decroos, T., Bransen, L., Van Haaren, J., & Davis, J. (2019). Actions speak louder than goals: Valuing player actions in soccer. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*.
- di Prampero, P. E., & Osgnach, C. (2018). Metabolic Power in Team Sports – Part 1: An Update. *International Journal of Sports Medicine*, 39(08), 581–587.
- Klemp, M., Wunderlich, F., & Memmert, D. (2021). In-play forecasting in football using event and positional data. *Scientific Reports*, 11(1), 1–10.
- Lorenzo-Martínez, M., Rein, R., Garnica-Caparrós, M., Memmert, D., & Rey, E. (2022). The effect of substitutions on team tactical behavior in professional soccer. *Research quarterly for exercise and sport*, 93(2), 301–309.
- McKinney, W. (2010). Data structures for statistical computing in python. *Proceedings of the 9th Python in Science Conference*.
- McKinney, W. (2011). pandas: a foundational Python library for data analysis and statistics. *Python for high performance and scientific computing*, 14(9), 1–9.
- Memmert, D., & Raabe, D. (2018). *Data analytics in football: Positional data collection, modelling and analysis*: Routledge.
- Memmert, D., Raabe, D., Schwab, S., & Rein, R. (2019). A tactical comparison of the 4-2-3-1 and 3-5-2 formation in soccer: A theory-oriented, experimental approach based on positional data in an 11 vs. 11 game set-up. *PloS one*, 14(1), e0210191.
- Oliphant, T. E. (2006). *A guide to NumPy (Vol. 1)*: Trelgol Publishing USA.
- Pappalardo, L., Cintia, P., Rossi, A., Massucco, E., Ferragina, P., Pedreschi, D., & Giannotti, F. (2019). A public data set of spatio-temporal match events in soccer competitions. *Scientific Data*, 6(1), 1–15.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., . . . Dubourg, V. (2011). Scikit-learn: Machine learning in Python. *The Journal of Machine Learning Research*, 12, 2825–2830.
- Pincus, S. M. (1991). Approximate entropy as a measure of system complexity. *Proceedings of the National Academy of Sciences*, 88(6), 2297–2301.
- Raabe, D., Biermann, H., Bassek, M., Wohlan, M., Komitova, R., Rein, R., . . . Memmert, D. (2022). Floodlight – A high-level, data-driven sports analytics framework. *arXiv preprint arXiv:2206.02562*.
- Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with python. *Proceedings of the 9th Python in Science Conference*.

Datenanalyse

Inhaltsverzeichnis

- Kapitel 16** **Logistische Regression – 153**
Ashwin Phatak
- Kapitel 17** **Zeitreihen Data Mining – 159**
Rumena Komitova und Daniel Memmert
- Kapitel 18** **Process Mining – 169**
Marc Garnica Caparrós
- Kapitel 19** **Zentralität von Netzwerken – 177**
*João Paulo Ramos, Rui Jorge Lopes, Duarte Araújo
und Pedro Passos*
- Kapitel 20** **Künstliche neuronale Netze – 189**
Markus Tilp
- Kapitel 21** **Tiefe neuronale Netzwerke – 199**
Dominik Raabe
- Kapitel 22** **Convolutional Neural Networks – 207**
Yannick Rudolph und Ulf Brefeld
- Kapitel 23** **Transfer Learning – 217**
Henrik Biermann
- Kapitel 24** **Random Forest – 227**
Justus Schlenger

Kapitel 25 Statistisches Lernen – 235

Gunther Schauberger und Andreas Groll

Kapitel 26 Open-set Recognition – 243

Ricardo da Silva Torres und Daniel Memmert



Logistische Regression

Ashwin Phatak

Inhaltsverzeichnis

- 16.1 Beispiel – 154
- 16.2 Hintergrund – 154
- 16.3 Anwendung – 156
- Literatur – 158

Kernbotschaften

- Die logistische Regression ist eines der grundlegenden statistischen Klassifizierungsmodelle für die Modellierung binärer (ja/nein) Ergebnisse.
- Da im Sport eine große Menge an Notations-/Ereignisdaten zur Verfügung steht, ist die logistische Regression eines der einfachsten Tools zur Untersuchung eines breiten Spektrums binärer Probleme.
- Im Allgemeinen ist die logistische Regression unempfindlich gegenüber kleinen Datenungleichgewichten, sie ist interpretierbar und rechnerisch kostengünstig.

16.1 Beispiel

In der Sportbranche gibt es eine Vielzahl von Situationen, in denen die Modellierung eines Sportereignisses ein binäres Ergebnis ist (Mattera, 2021). Ein Beispiel dafür ist die Vorhersage der Gewinn- oder Verlustwahrscheinlichkeit bei einem Sportereignis, Tor oder kein Tor und Foul oder kein Foul in Invasionssportarten. Bei Einzelsportarten wie Tennis oder Badminton, ob der Ball oder Federball innerhalb oder außerhalb des Feldes war. Solche Probleme können durch eine binäre logistische Regression modelliert werden, die zu den einfachsten und am besten interpretierbaren Klassifizierungsalgorithmen gehört, die es gibt. In verschiedenen Sportarten wurde die binäre Klassifizierungsmodellierung erfolgreich eingesetzt, um die Rekrutierung, das Coaching, die Selbst-/Gegneranalyse und die Verletzungsvorhersage auf der Grundlage der in den jeweiligen Sportarten gesammelten Big Data zu untersuchen (Phatak et al., 2021).

16.2 Hintergrund

Der Aufstieg von Big Data in der Sportleistungsanalyse hat einen völlig neuen Ansatz verfolgt. Die Mechanismen zur Datensammlung und ihre Bereitstellung für die Sportindustrie haben ein großes Potenzial für die Nutzung der verfügbaren Daten in allen Sportarten und ihren jeweiligen Teilbereichen geschaffen (Rein & Memmert, 2016). Statistische Analysen und Machine Learning (maschinelles Lernen) sind die Werkzeuge, die Experten bei der Auswertung und Interpretation von Daten im Entscheidungsfindungs- und Wissensfindungsprozess helfen (Phatak et al., 2021).

Klassifizierungs- und Regressionsmethoden sind die primären Methoden, die für die Wissensentdeckung verwendet werden. Bei der Klassifizierung ist die logistische Regression der einfachste Algorithmus, der für die Modellierung binärer Probleme verwendet wird. Logistische Regression ist rechnerisch kostengünstig, interpretierbar und robust gegenüber Datenungleichgewichten. Programme wie SPSS und Excel und Sprachen wie Python und R verfügen über integrierte Bibliotheken zur Implementierung der logistischen Regression, wodurch sie einfach und


für Datenanalysten mit unterschiedlichen technischen Kenntnissen zugänglich ist (Persson, 2022).

Definition

Das logistische Modell ist in der Statistik ein statistisches Modell, das die Wahrscheinlichkeit eines Ereignisses modelliert. Dies geschieht, indem die logarithmische Wahrscheinlichkeit für das Ereignis als lineare Kombination einer oder mehrerer unabhängiger Variablen betrachtet wird (Wright, 1995). Im Wesentlichen handelt es sich um eine lineare Regression, die unter Verwendung einer Logit-Transformation zwischen 1 und 0 normalisiert wird (s. Gleichung unten). Der Höchstwert wird also auf 1 und der unterste Wert auf 0 festgelegt.

$$F(x) = \frac{1}{1 + e^{-(\beta_0 + \dots + \beta_n x_n)}}$$

Visuell kann die logistische Regression als Anpassung eines Schnörkels (■ Abb. 16.1) an die gegebenen Daten interpretiert werden, um eine binäre abhängige Variable vorherzusagen. Die logistische Regression und ihre Variationen wie die multiple logistische Regression und logistische Mischmodelle können mehrere unabhängige Variablen als Eingabe verwenden und auch Interaktionseffekte modellieren.



■ Abb. 16.1 Logistische Regressionskurve in zwei Dimensionen

16.3 Anwendung

► Beispiel 1

Betrachten wir eine Situation bei einem Einfallsspiel wie Fußball. Es gab eine große Debatte über videogestützte Schiedsrichter (VAR) (Tovar, 2021). Wir können ein automatisiertes System wie VAR mithilfe der logistischen Regression modellieren. In diesem Fall würden die Parameter wie folgt lauten:

- Abhängige Variable: Abseits = 1 und kein Abseits = 0
- Unabhängige Variable: Zu dem Zeitpunkt, zu dem der Pass gespielt wird:
 - vertikale Position des am weitesten entfernten Körperteils des vorletzten Spielers der verteidigenden Mannschaft.
 - vertikale Position des am weitesten entfernten Körperteils des höchsten (am Spiel beteiligten) Spielers der angreifenden Mannschaft „im Moment des Passspiels“.

Wir können den logistischen Regressionsalgorithmus trainieren, indem wir ihm ein Label geben, das darauf basiert, ob die gegebene Situation ein Abseits ist oder nicht. Anschließend können wir das Modell als rudimentäres VAR-System zur Erkennung von Abseits verwenden. ◀

► Beispiel 2

Die Gewinn- oder Verlustwahrscheinlichkeit kann auch mithilfe der logistischen Regression in mehreren Sportarten auf der Grundlage von Wettquoten modelliert werden (Wunderlich & Memmert, 2018; Wunderlich & Memmert, 2016). Es kann ein Modell erstellt werden, um die Wettquoten basierend auf den Ergebnissen der letzten drei Spiele zu verbessern. Nehmen wir eine beliebige Sportart an, in der Mannschaft A gegen Mannschaft B spielt, so wären die folgenden Eingabe- und Ausgabeparameter:

- Abhängige Variable: Gewinn = 1, Verlust = 0
- Unabhängige Variable:
 - Wettquoten für den Sieg von Mannschaft A
 - Wettquoten für den Sieg von Mannschaft B
 - Ergebnis der letzten drei Spiele für Mannschaft A
 - Ergebnis der letzten drei Spiele für Mannschaft B

Hinweis: Ein solches Modell kann theoretisch erstellt werden, aber es gibt Nuancen. In unserem Fall haben wir angenommen, dass die Wettquoten nicht bereits die letzten drei Spiele berücksichtigen. In diesem Fall müssten wir uns mit Multikollinearität in den abhängigen Variablen befassen, was ein ganz neues Thema ist. Wenn Sie daran interessiert sind, können Sie sich damit näher befassen. ◀

► Beispiel 3

In der NBA wird jede Saison ein Spieler aus der NCAA ausgewählt. Ein Modell mit logistischer Regression kann möglicherweise entwickelt werden, um zu entscheiden, ob der Spieler ausgewählt wird oder nicht (Liu et al., 2018). Die Parameter eines solchen Modells wären die folgenden:

- Abhängige Variable: Auswählen = 1, nicht auswählen = 0
- Unabhängige Variable:

- Angriffsstatistiken
 - Field Goal
 - Drei-Punkte-Würfe
 - Zwei-Punkte-Würfe
 - usw.
- Verteidigungsstatistik
 - Rebounds
 - Steals
 - Blocks
- usw.
- Physiologische Statistiken
 - Körpergröße
 - Sprunghöhe
 - usw. ◀

Studienbox

In einer Studie über Elite- und Sub-Elite-Torhüter (abgekürzt als GK für *goal keeper*) im Fußball wurde untersucht, welche Leistungskennzahlen (Key Performance Indices, KPIs) die Torhüter der Champions League (CL) von denen der Nicht-Champions League (NCL) unterscheiden (Jamil et. al, 2021). Die Analyse umfasste eine logistische Regression, bei der die CL-GKs als 1 kodiert wurden, während die NCLs als binäre abhängige Variable mit 0 kodiert wurden. Nach einigen Vorverarbeitungsschritten wurde ein Satz von 20 GK-Leistungsstatistiken (unabhängige Variablen) zur Modellierung der Unterschiede verwendet. Es wurde festgestellt, dass CL-GKs im Ver-

gleich zu den NCL-GKs besser „im Kurzpassspiel mit den Füßen“ waren. Bei der Fähigkeit, Schüsse zu stoppen, scheint es keine Unterschiede zu geben.

Diese Idee kann zur Analyse jeder Position im Fußball verwendet werden, und die Kodierung der Spieler als 1/0 (Erfolgskriterien) ist auch abhängig von der Forschungsfrage. Eine Frage wie die, was der Unterschied zwischen den KPIs von Mittelfeldspielern der Relegationsebene im Vergleich zu Mittelfeldspielern der Nicht-Relegationsebene ist, kann auch mit denselben Daten und logistischer Regression beantwortet werden, indem man einfach die Kodierungskriterien der Spieler „anpassen“.

? Fragen für die Studierenden

1. Welches sind die maximalen und minimalen Werte, die die abhängigen Variable in einer logistischen Regression annehmen können?
2. Nennen Sie ein Beispiel aus drei verschiedenen Sportarten, bei dem die logistische Regression zur Modellierung eines bestimmten Szenarios in den jeweiligen Sportarten verwendet werden kann. Hinweis: Führen Sie die abhängigen und unabhängigen Variablen für jedes Szenario auf.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Jamil, M., Phatak, A., Mehta, S., Beato, M., Memmert, D., & Connor, M. (2021). Using multiple machine learning algorithms to classify elite and sub-elite goalkeepers in professional men's football. *Scientific reports*, 11(1), 1–7.
- Liu, Y., Schulte, O., & Li, C. (2018, September). Model trees for identifying exceptional players in the NHL and NBA drafts. In *International workshop on machine learning and data mining for sports analytics* (pp. 93–105). Springer, Cham.
- Mattera, R. (2021). Forecasting binary outcomes in soccer. *Annals of Operations Research*, 1–20.
- Persson, I. (2022). Review of Applied Univariate, Bivariate, and Multivariate Statistics Using Python by Daniel Denis.
- Phatak, A. A., Wieland, F. G., Vempala, K., Volkmar, F., & Memmert, D. (2021). Artificial Intelligence-Based Body Sensor Network Framework – Narrative Review: Proposing an End-to-End Framework using Wearable Sensors, Real-Time Location Systems and Artificial Intelligence/Machine Learning Algorithms for Data Collection, Data Mining and Knowledge Discovery in Sports and Healthcare. *Sports Medicine-Open*, 7(1), 1–15.
- Rein, R., & Memmert, D. (2016). Big data and tactical analysis in elite soccer: future challenges and opportunities for sports science. *SpringerPlus*, 5(1), 1–13.
- Tovar, J. (2021). The Debate of VAR. In *On Fairness, Justice, and VAR* (pp. 29–39). Palgrave Macmillan, Cham.
- Wright, R. E. (1995). Logistic regression.
- Wunderlich, F., & Memmert, D. (2016). Analysis of the predictive qualities of betting odds and FIFA World Ranking: evidence from the 2006, 2010 and 2014 Football World Cups. *Journal of sports sciences*, 34(24), 2176–2184.
- Wunderlich, F., & Memmert, D. (2018). The betting odds rating system: Using soccer forecasts to forecast soccer. *PloS one*, 13(6), e0198668.



Zeitreihen Data Mining

Rumena Komitova und Daniel Memmert

Inhaltsverzeichnis

17.1 Beispiel Sport – 160

17.2 Hintergrund – 160

17.3 Anwendungen – 162

17.3.1 Data-Mining-Algorithmen – 162

17.3.2 Data Mining von Zeitreihen in der Medizin – 163

17.3.3 Data Mining im Sport – 163

Literatur – 166

Kernbotschaften

- Zeitreihen sind in Sportbereich weit verbreitet und erfordern besondere Analysetechniken.
- Die Gewinnung von Informationen über das Verhalten von Zeitreihen kann wichtig und nützlich für die Analyse von Sportdaten sein.
- Zeitreihen-Data-Mining-Techniken sind ein guter Kandidat für die Anwendung auf Sportdaten, um neues Wissen zu entdecken.
- Zeitreihen-Data-Mining-Techniken sind nützlich für die Entscheidungsfindung im Sportbereich, indem sie nach Mustern suchen sowie Motive und Anomalien erkennen.

17.1 Beispiel Sport

Ein wichtiger Faktor für die Analyse von Leistung und Erfolg im Fußball sind Positions- und Eventdaten (s. Kap. 5 und 6). In vielen Fällen können Positionsdaten als Zeitreihendaten betrachtet werden. Darüber hinaus gibt es Ansätze, Zeitreihen und Ereignisfolgen miteinander zu verknüpfen. So existieren Ansätze dafür, Events aus den Positionszeitreihen automatisch zu erkennen. Die Erkennung von Fußballaktivitäten kann auf diese Weise unter Verwendung der Positionsdaten von Spieler und Ball erfolgen. Die Schwierigkeit bei der Erkennung von Sportaktivitäten besteht darin, sinnvolle Aktionen aus den Zeitreihen zu erkennen und zu lokalisieren. So kann z. B. ein Pass-Ereignis als der Moment definiert werden, in dem der Ball den Fuß des Spielers verlässt. Auf ähnliche Weise kann in taktischen Szenarien die Verfügbarkeit von Zeitreihendaten über die Aktivitäten von Spielern von Vorteil für ihre Leistung sein, was auch für die Entscheidungsfindung im Training hilfreich sein kann. Durch die Möglichkeit, alle Aktivitäten eines Fußballspielers nur anhand von Positionsdaten in Form von Zeitreihen zu erkennen, ist es zudem möglich, die Aktivitäten von Spielern ohne Hilfe von Video-Annotationen zu erkennen.

17.2 Hintergrund

Data Mining hat das Ziel, interessante Muster und nützliche Informationen aus Daten zu extrahieren. Im Kontext der Anwendung gemeinsam mit Anwendungsexperten werden Data-Mining-Techniken im Bereich der Sportdatenanalyse immer beliebter (Stein et al., 2017). Die Weiterentwicklung von Tracking-Systemen bietet Forschern aus dem Sportbereich eine weitere Möglichkeit, neue Erkenntnisse über die Leistung von Spielern oder auch Bewegungsmuster zu gewinnen. Angesichts der großen Informationsmenge im Sportbereich sind die Möglichkeiten des Data Mining vielfältig (Bonidia et al., 2018).

Wiederkehrende und überraschende Ereignisse, die aus Sportdaten extrahiert werden, können beispielsweise bei der Erkennung von Sportaktivitäten, und Muster können bei der Vorhersage künftiger Ereignisse von Hilfe sein, etwa bei der Leistungsvorhersage, beim Coaching oder bei der Strategieplanung.

Es gibt eine große Anzahl von Data-Mining-Anwendungen, in denen Informationen oder Beobachtungen als Zahlenwerte zu diskreten Zeitpunkten vorliegen. Im Sportbereich beispielsweise kommt eine Folge von diskreten Messwerten oft aus Sensordaten, die als Zeitreihen (engl. *time series*) dargestellt werden kann. Die Anwendung von Zeitreihenmethoden im Data Mining wird als Time Series Data Mining (TSDM) bezeichnet (Esling & Agon, 2012; Fu, 2011; Mitsa, 2010). Die klassische Zeitreihenanalyse (Box, Jenkins & Reinsel, 2016) untersucht die Entwicklung von Werten im Zeitverlauf, die sich oft in bestimmte Komponenten gliedern lassen, wie z. B. Trend, saisonale Komponente oder Periodizität. TSDM hingegen befasst sich mit viel größeren Mengen von Zeitreihendaten und einer viel größeren Anzahl von Zeitreihen. Der Schwerpunkt von TSDM liegt jedoch weniger auf der Analyse der statistischen Eigenschaften von Zeitreihendaten, sondern viel mehr auf der Erkennung von Beziehungen zwischen Zeitreihen und der Extraktion potenziell nützlicher und sinnvoller Informationen, wobei hier die Begriffe „nützlich“ und „sinnvoll“ von der jeweiligen Anwendung abhängen. TSDM umfasst unter anderem Lernverfahren wie Klassifizierung und Clustering von Zeitreihen, Anomalie- und Mustererkennung in Zeitreihen.

Während der Sportbereich nur am Rande erwähnt wird, könnte der Einsatz von TSDM-Verfahren auch auf den Sport übertragen werden. State-of-the-Art-Verfahren, die z. B. häufig in der Medizin und im Individualsport verwendet werden, sind kaum anwendbar. So können beispielsweise innerhalb einer Messung physischer Aktivitäten mehrere Arten einer menschlichen Bewegung auftreten (Minnen et al., 2006; Tanaka, Iwamoto, & Uehara, 2005). TSDM-Verfahren wie Anomalie- und Motiverkennung für menschliche Bewegungen beruhen auf der Ähnlichkeit zwischen (ein- oder mehrdimensionalen) Zeitreihenfolgen von Aktivitäten in Form von Motiven. Ähnliche Aktivitäten sind durch ähnliche Handlungsabläufe gekennzeichnet, die auch im Sport häufig vorkommen.

Die Aktivitäten eines Spielers lassen sich im Allgemeinen in einfache Aktivitäten (oder Ereignisse) und komplexe Aktivitäten einteilen. Einfache Aktivitäten hängen nicht vom Kontext ab, d. h., sie können für sich allein existieren (z. B. bestimmte Aktionen einzelner Spieler). Komplexe Aktivitäten hingegen setzen sich aus einer Reihe von einfachen Aktivitäten zusammen und können darauf basieren, die Beziehung zwischen den Ereignissen oder die Interaktionen zwischen anderen Akteuren zu verstehen und sie als eine Abfolge von Ereignissen zu analysieren. So können beispielsweise Zeitreihendaten aus den Positionsdaten eines Spielers während eines Spiels in Ereignisse wie Pässe oder Schüsse zerlegt werden, aber auch komplexere Aktivitäten wie Dribblings können als Kombination mehrerer Einzelaktivitäten betrachtet werden. Die Erkennung von Aktivitäten bzw. Ereignissen im Sport, beispielsweise von Positionsdaten in Form von Zeitreihen, kann nützliches

Wissen und Kontext über die Aktionen eines Spielers liefern. Eine solche Aufgabe ist jedoch nicht einfach, da selten eine Standardtaxonomie der Spieleraktivitäten vorliegt (Biermann et al. 2021).

Definition

Eine *Zeitreihe* T stellt eine Folge zeitlich geordneter reeller Zahlen (Messungen) dar, d. h., $T = [t(1), \dots, t(n)]$, wobei $t(i) \in \mathbb{R}$, $i = 1, \dots, n$, das i -te Element der Zeitreihe T bezeichnet. Eine *multidimensionale Zeitreihe* ist eine Menge von einzelnen Zeitreihen. *Time Series Data Mining (TSDM)* ist ein Bereich der Data Science, der sich mit der Erkennung und Extraktion nützlicher Informationen aus Zeitreihen befasst.

17.3 Anwendungen

17.3.1 Data-Mining-Algorithmen

► Beispiel 1

Die Zeitreihenklassifikation und das Zeitreihen-Clustering stellen wichtige und anspruchsvolle Probleme beim TSDM dar (Esling & Agon, 2012; Liao, 2005; Mitsa, 2010). Zeitreihenklassifikation ist die automatische Zuordnung von gelabelten Zeitreihen in vordefinierten Kategorien. Ein Cluster ist eine Gruppierung von Objekten, die sogenannten *cluster*, die möglichst ähnlich zueinander sind. Das Input des Clusterings kann eine Menge von Zeitreihen (multidimensionale Zeitreihen) aus verschiedenen Quellen, wie z. B. Sensoren, oder eine Menge von Teilsequenzen einer einzigen (langen) Zeitreihenquelle sein. Betrachtet man mehrere Zeitreihen, so besteht die Hauptidee des Clusterings darin, Gruppen von Zeitreihen zu finden, die innerhalb des Clusters ähnlich sind, sich aber relativ stark von Zeitreihen anderer Cluster unterscheiden. ◀

► Beispiel 2

Eine Zeitreihen-Anomalie kann als ein unerwartetes und/oder ungewöhnliches Muster in Zeitreihen definiert werden, das stark von der Norm abweicht (Zolhavarieh, Aghabozorgi & Teh, 2014). Mit anderen Worten, Anomalien treten dann auf, wenn der zugrunde liegende Prozess von seinem definierten normalen Zustand abweicht. Das Erkennen solcher Anomalien wird als Anomalie-Erkennung bezeichnet. Anomalien lassen sich in drei Kategorien einteilen (Chandola et al., 2009). Eine punktuelle Anomalie liegt vor, wenn ein einzelner Punkt signifikant von allen Punkten in dem Datensatz abweicht (Braei & Wagner, 2020). Eine weitere Art von Anomalien sind kontextuelle Anomalien. Diese Datenpunkte werden in Bezug auf einen bestimmten Kontext bzw. Zusammenhang als abnormal gesehen. Die letzte und vielleicht die herausforderndste Art einer An-

omalie ist die sogenannte kollektive Anomalie. Dabei sind einzelne Datenpunkte nicht auffällig (anormal). Stattdessen ergibt sich erst in der Betrachtung einer Datenmenge eine Auffälligkeit. ◀

► Beispiel 3

Zu den Problemen bei der Auswertung von Zeitreihen in Kombination mit maschinellem Lernen gehören das Erkennen und Entdeckung von unbekannten, häufig vorkommenden Teilsequenzen einzelner (oder mehrerer) Zeitreihen, auch Motive genannt (Chiu, Keogh & Lonardi, 2003; Lin, Keogh, Lonardi & Patel, 2002). Zum Beispiel sollen in einer gegebenen Menge von Zeitreihen neue Motive gefunden werden. Die Motiverkennung ist die Technik, um diese zu finden, und stellte ein grundlegendes Problem beim TSDM dar (Mueen, 2014; Torkamani & Lohweg, 2017; Tanaka, Iwamoto & Uehara, 2005). Die Erkennung von Motiven ist jedoch eine schwierige Aufgabe, selbst wenn sie die gleichen oder sehr ähnliche Eigenschaften aufweisen. Ein Grund dafür ist, dass in den meisten Fällen die Anzahl des Auftretens von Motiven, ihre Form, die Länge sowie die Dauer des Auftretens unbekannt sein können (Mitsa, 2010). ◀

17.3.2 Data Mining von Zeitreihen in der Medizin

► Beispiel 4

Die Erkennung von Anomalien und die Entdeckung von Motiven im medizinischen Bereich sind kritische Probleme, die ein hohes Maß an Genauigkeit erfordern (Lin & Li, 2010; Liu, Li, Chen, Tan, Chen & Zhou, 2015; Sivaraks & Ratanamahatana, 2015). Im Allgemeinen werden EKG-Zeitreihen in der Medizin dazu verwendet, den Verlauf von elektrischen Impulsen des Herzens grafisch darzustellen. Anhand dieser Daten können Aussagen über den medizinischen Zustand des Patienten getroffen werden. Das Erkennen von Anomalien in EKG-Daten kann helfen, abnormale Herzschläge vor der Diagnose zu erkennen, und die Suche nach Motiven kann helfen, die ähnlichen und schnellen Herzschläge im EKG zu lokalisieren. Wankhedkar und Jain (2021) schlugen beispielsweise eine Methode zur Erkennung von Anomalien in EKG-Zeitreihen vor. Die einander ähnlichen Herzschläge sind die Motive, während die Schläge, die einen hohen Wert haben und sich voneinander unterscheiden, die Anomalien darstellen. ◀

17.3.3 Data Mining im Sport

► Beispiel 5

Im Vergleich zur Erkennung von Herzschlägen, die im Allgemeinen periodisch vorkommen, treten Motive (oder Ereignisse) wie Pässe, Schüsse oder Dribblings im Fußball nicht in regelmäßigen Abständen während eines Fußballspiels auf. Schuldhau

et al. (2015) haben einen inertialsensorbasierten Schuss-/Pass-Ansatz für Fußballmannschaften entwickelt, um Pässe und Torschüsse zu identifizieren, der hauptsächlich auf Motiverkennung und klassischen Algorithmen des maschinellen Lernens wie Support Vector Machine, Klassifizierung und Naïve Bayes basiert. Es wurden Peaks in den Beschleunigungssensordaten (Motive) vom linken und rechten Schuh des Fußballspielers erkannt, und diese Peaks wurden in Schuss, Pass usw. klassifiziert. Die Erkennung von atomaren Pass-Ereignissen, definiert als der Moment, in dem der Ball den Fuß des Spielers verlässt, wurde ebenfalls durchgeführt (Sanford et al., 2020). Die Autoren schlagen Algorithmen für maschinelles Lernen vor, die in der Lage sind, Pässe und andere Gruppenaktivitäten entweder aus den Video- oder den Positionsdaten zu erkennen. ◀

► Beispiel 6

Yeh, Kavantzias und Keogh (2017) verwenden beispielsweise einen Algorithmus, um die korrekte (mehrdimensionale) Motivposition des Schlags eines Boxers (als wiederholtes Verhalten) zu ermitteln. Der Algorithmus vergleicht einen einfachen Cross mit dem Cross einer Eins-zu-Zwei-Kombination und den drei Dimensionen: rechter Oberarm, rechter Unterarm und linker Oberarm. Zwei Verhaltensmuster an der dominanten Hand des Boxers sind fast identisch, befinden sich aber bei verschiedenem Auftreten des Motivs in einer anderen Position. ◀

Studienbox

Biermann et al. (2023) verwendeten einen Algorithmus zur automatischen Erkennung von Ereignissen wie Pässen in den Positionsdaten von Fußballspielen mithilfe von TSDM-Techniken. Zur Erkennung von Pass-Ereignissen stellten die Autoren eine Methode zur Motiverkennung aus der Spieler-Ball-Distanz und der Ballbeschleunigung in Form von Zeitreihen aus den Positionsdaten bereit. Motive treten auf, wenn die Zeitreihendaten eine bestimmte Form oder Veränderung zur gleichen Zeit aufweisen (s. ■ Abb. 17.1). Die Autoren schlagen daher eine Methode vor, die sowohl Zeitreihen aus den Positionsdaten als auch Eventdaten verwendet. Zunächst vergleichen sie Eventdaten mit den Positionsdaten. Wie sich herausstellt, sind die Pässe in den Eventdaten im Ver-

gleich zu den Positionsdaten leicht verzögert. Um diese Verzögerung zu kompensieren, führen die Autoren zunächst eine Methode zur Erkennung von Zeitreihenmotiven durch, um ein Modell zu erstellen, das Pässe in den Positionsdaten erkennt. Für die Erkennung von Ereignissen in den Zeitreihendaten verwenden die Autoren zusätzlich eine geeignete Feature-Space-Darstellung der Zeitreihen. Anschließend werden die (verzögerten) Pässe aus den bereits existierenden Eventdaten als Vorlage genommen und in einem bestimmten Fenster anhand des Modells zur Erkennung von Pässen optimiert. Es wurde gezeigt, dass dieser Algorithmus die Synchronisierung zwischen Positions- und Ereignisdaten erheblich verbessert.




Abb. 17.1 Eine exemplarische Sequenz für Spieler-Ball-Distanz (cyanfarbene Kurve) und Ballbeschleunigung (orange Kurve). Dabei bezeichnet k den Zeitpunkt, zu dem ein Pass (ein Ereignis) stattfindet

? Fragen für die Studierenden

1. Was ist Time Series Data Mining (TSDM)?
2. Wo können TSDM-Methoden in der Sportwissenschaft eingesetzt werden?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Biermann, H., Komitova, R., Raabe, D., Müller-Budack, E., Ewerth, R., Memmert, D. (2023, accepted). Synchronization of Passes in Event and Spatiotemporal Soccer Data. *Scientific Reports*.
- Biermann, H., Theiner, J., Bassek, M., Raabe, D., Memmert, D., Ewert, R. (2021). A Unified Taxonomy and Multimodal Dataset for Events in Invasion Games. *Proceedings of the 4th International Workshop on Multimedia Content Analysis in Sports*, 2021, 1–10.
- Bonidia, R., Rodrigues, L., Avila-Santos, A.P., Sanches, D., & Brancher, J. (2018). Computational intelligence in sports: a systematic literature review. *Advances Human-Computer Interaction*, 2018, 1–13.
- Box, G., Jenkins, G., & Reinsel, G. (2016). *Time series analysis: forecasting and control*. New Jersey: John Wiley & Sons, Inc., Hoboken, fifth ed.
- Braei, M., & Wagner, S. (2020). Anomaly detection in univariate time-series: a survey on the state-of-the-art. *arXiv preprint, arXiv:2004.00433*.
- Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: a survey. *ACM Computing Surveys*, 41(3), 1–58.
- Chiu, B., Keogh, E., & Lonardi, S. (2003). Probabilistic discovery of time series motifs. In *Proceedings of the 9th International Conference on Knowledge Discovery and Data Mining (KDD)*, (pp. 493–498).
- Esling, P., & Agon, C. (2012). Time series data mining. *ACM Computing Surveys (CSUR)*, 45(1), 1–34.
- Fu, T.-C. (2011). A review on time series data mining. *Engineering Applications of Artificial Intelligence*, 24(1), 164–181.
- Liao, T. (2005). Clustering of time series data – a survey. *Pattern Recognition*, 38(11), 1857–1874.
- Lin, J., Keogh, E., Lonardi, E., & Patel, S. (2002). Finding motifs in time series. In *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining 2nd Workshop on Temporal Data Mining*, (pp. 53–68).
- Lin, J., & Li, Y. (2010). Finding approximate frequent patterns in streaming medical data. In *IEEE 23rd International Symposium on Computer-Based Medical Systems (CBMS)*, IEEE, (pp. 13–18).
- Liu, B., Li, J., Chen, C., Tan, W., Chen, Q., & Zhou, M. (2015). Efficient motif discovery for large-scale time series in healthcare. *IEEE Transactions on Industrial Informatics*, 11(3), 583–590.
- Minnen, D., Starner, T., Essa, I., & Isbell, C. (2006). Discovering characteristic actions from on-body sensor data. In *Wearable computers, 2006 10th IEEE international symposium on wearable computers*. IEEE, (pp. 11–18).
- Mitsa, T. (2010). *Temporal data mining*. Chapman and Hall/CRC.
- Mueen, A. (2014). Time series motif discovery: dimensions and applications. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 4(2), 152–159.
- Ofoghi, B., Zeleznikow, J., MacMahon, C., & Raab, M. (2013). Data mining in elite sports: a review and a framework. *Measurement in Physical Education and Exercise Science*, 17(3), 171–186.
- Sanford, R., Gorji, S., Hafemann, L. G., Pourbabaee, B., and Javan, M. (2020). Group Activity Detection from Trajectory and Video Data in Soccer. *Proceedings of the IEEE/CVF Conference on Computer Vision, Graphics and Image Processing*, (pp. 1–7).
- Schuldhuis, D., Zwick, C., Körger, H., Dorschky, E., Kirk, R., & Eskofier, B.M. (2015). Inertial sensor-based approach for shot/pass classification during a soccer match. In *KDD workshop on large-scale sports analytics* (pp. 1–4).
- Schumaker, R., Soleiman, O., & Chen, H. (2010). Sports knowledge management and data mining. *Annual Review of Information Science and Technology*, 44(1), 115–157.
- Sivaraks, H., & Ratanamahatana, C. (2015). Robust and accurate anomaly detection in ECG artifacts using time series motif discovery. *Computational and mathematical methods in medicine*, 2015.
- Stein, M., Janetzko, H., Seebacher, D., Jäger, A., Nagel, M., Hölsch, J., Kosub, S., Schreck, T., Keim, D., & Grossniklaus, M. (2017). How to make sense of team sport data: from acquisition to data modeling and research aspects. *Data*, 2(1).

- Tanaka, Y., Iwamoto, K., & Uehara, K. (2005). Discovery of time series motif from multidimensional data based on MDL principle. *Machine Learning*, 58(2), 269–300.
- Torkamani, S., & Lohweg, V. (2017). Survey on time series motif discovery. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 7(2).
- Wankhedkar, R. & Jain, S.K. (2021). Motif discovery and anomaly detection in an ECG using Matrix Profile. *Progress in Advanced Computing and Intelligent Engineering*. Springer, Singapore, 88–95.
- Yeh, C., Kavantzaz, N., & Keogh, E. (2017). Matrix profile VI: meaningful multidimensional motif discovery. In *IEEE international conference on data mining (ICDM)*. IEEE, (pp. 565–574).
- Zolhavarieh, S., Aghabozorgi, S., & Teh, Y. (2014). A review of subsequence time series clustering. *The Scientific World Journal*, 2014.



Process Mining

Marc Garnica Caparrós

Inhaltsverzeichnis

18.1 Beispiel Sport – 170

18.2 Hintergrund – 171

18.3 Anwendungen – 173

18.3.1 Process Mining im Gesundheitswesen – 173

18.3.2 Process Mining in der Bildung – 174

18.3.3 Process Mining im Fußball – 174

Literatur – 175

Kernbotschaften

- Process Mining ist eine Disziplin, die sich aus dem Data Mining ableitet und sich auf die Analyse von End-to-End-Prozessen konzentriert, die normalerweise durch Ausführungslogs dargestellt werden.
- Ausführungslogs sind eine zeitlich geordnete Sammlung von Ereignissen, die in einem beliebigen System auftreten. Zum Beispiel die Verfahren, die ein Patient in einem Krankenhaus durchlaufen muss.
- Process Discovery ist eine Reihe von Algorithmen, die einen Prozess aus gesammelten Daten (beobachtetes Verhalten) konzeptionell definieren und visualisieren.
- Conformance Checking misst die Übereinstimmung zwischen dem Prozessentwurf (theoretisches Verhalten) und der in den Daten beobachteten tatsächlichen Ausführung.
- Die Prozessverbesserung untersucht den Prozess und seine konzeptionelle Definition mit dem Ziel, das Gesamtsystem zu verbessern.
- Process Mining ist in jedem Bereich anwendbar und eröffnet zahlreiche Möglichkeiten für die Sportwissenschaft, z. B. durch die Nutzung von Ereignis- und Positionsdaten aus Invasionssportarten.

18.1 Beispielsport

Basketball ist ein Mannschaftssport, auch wenn die Medien versuchen, bestimmte Aktionen oder Spieler zu individualisieren. Basketballmannschaften trainieren wöchentlich, um ihre Offensiv- und Defensivtaktiken zu üben. Oft können diese Taktiken je nach Gegner variieren. Analysen auf der Basis von Positionsdaten (die Bewegungen der Spieler und des Balles auf dem Spielfeld) und Eventdaten (die von den Spielern ausgeführten Aktionen) geben Taktiktrainern einen Überblick darüber, wie sich eine Mannschaft auf dem Spielfeld verhält. Im Angriff verfügen Mannschaften in der Regel über vordefinierte Angriffsspielzüge, sodass die Spieler wissen, wie sie den Angriff starten, den Ball bewegen und nach Korbchancen suchen müssen. Diese vordefinierten Angriffssysteme können als theoretischer Prozess mit einem Anfang, einer Reihe von Aktivitäten und Ressourcen und mehreren Endoptionen betrachtet werden. Diese Prozesse sind auch in den gesammelten Daten vorhanden, wobei die Aktionen des Spielers mit Ball in den Eventdaten und die Aktionen abseits des Balles in den Positionsdaten enthalten sind. Process Mining bietet das Instrumentarium, um diese Prozesse in den gesammelten Event- und Positionsdaten zu entdecken, das beobachtete Mannschaftsverhalten mit dem theoretischen Entwurf der Trainer zu vergleichen und schließlich zu versuchen, diese Prozesse zu verbessern, indem beispielsweise ignorierte Korbchancen in den gesammelten Daten

identifiziert werden. Die Implementierung von Process Mining könnte sich positiv auf die sportliche Leistung auswirken und die Entscheidungsfindung in der Sporttaktik unterstützen.

18.2 Hintergrund

Das Process Mining (PM) leitet sich aus dem Data Mining ab, einer Forschungsdisziplin, die Mathematik, Statistik und Informatik zur Wissensgewinnung aus Datensätzen umfasst. Oft haben diese Datensätze mit großen Datenherausforderungen zu tun, wie z. B. großem Volumen, Vielfalt in ihrer Syntax und Semantik oder hoher Geschwindigkeit der Erzeugung. In den 1990er-Jahren kam es zur Implementierung zahlreicher IT-Systeme in allen Bereichen der modernen Industrie, die jedes Unternehmen revolutionierten. Die Entwicklung der Unternehmensdigitalisierung brachte Softwaresysteme wie Enterprise Resource Planning (ERP) und Business Process Management (BPM) Tools und -Methoden zusammen. In diesen frühen Tagen war die Definition von Geschäftsprozessen Teil der Entwurfsphase eines jeden Unternehmens. Experten ermittelten die Anforderungen und entwarfen den effizientesten Prozess zur Durchführung einer bestimmten Aufgabe, an der zahlreiche Ressourcen, Aktivitäten und Akteure beteiligt waren (Tiwari, Turner & Majeed, 2008).

Neben dem Data Mining tauchten verschiedene andere Ansätze auf, um mit solch komplexen Implementierungen umzugehen. Data Warehousing, Datenbankmanagementsysteme und Fortschritte in der Hardware ermöglichten die massive Erfassung aller Kernaspekte eines Geschäftsprozesses, wobei jeder Schritt und jede während des Prozesses verwendete Ressource im sogenannten Ausführungslog vermerkt wurde. Motiviert durch diese massive Sammlung von Geschäftsprozessen wurde in der Arbeit von van der Aalst, Weijters & Maruster (2004) die Idee vorgestellt, datengesteuerte Prozessmodelle oder Workflows zu erstellen, die direkt aus den gesammelten Daten beobachtet, analysiert und verbessert werden können. Process Mining nutzt also die Ausführungslogs eines beliebigen Systems, um die tatsächlichen Geschäftsprozesse zu rekonstruieren.

Obwohl diese Ausführungslogs, die oft als Ereignislogs bezeichnet werden, in vielen Branchen allgegenwärtig sind, fehlen den Unternehmen eine gute Definition und ein gutes Verständnis ihrer tatsächlichen Prozesse. PM beseitigt daher die Unterschiede zwischen Ereignislogs (beobachtetes Verhalten) und Prozessmodellen (entweder theoretische Modelle darüber, wie Systeme funktionieren sollten, oder datengesteuerte Modelle des Systemverhaltens). Zu den Anwendungen solcher Analysen gehören u. a. die Analyse der Behandlung von Patienten in Krankenhäusern, die Verbesserung der Benutzerfreundlichkeit von E-Commerce-Websites, die Analyse des Gepäckmanagements in einem Flughafensystem oder die Steuerung einer automatischen Industrie eines Automobilherstellers. Während die

Hauptarbeit im Bereich PM noch Teil des akademischen Wissens ist, haben einige Unternehmen begonnen, diese Analysetechnik anzuwenden, um ihre Prozesse vollständig zu verstehen und zu kontrollieren.

Erst 2011 wurde das Process Mining Manifesto (van der Aalst et al., 2012) der Forschungsgemeinschaft vorgestellt. In diesem Dokument wird PM als eine Technik zur Extraktion von Wissen aus Ereignislogs definiert, die von Informationssystemen erzeugt werden, mit dem Ziel, Prozesse in verschiedenen Geschäftsbereichen zu entdecken, zu überwachen und zu verbessern. In dieser Arbeit werden auch die drei wichtigsten PM-Typen genannt: Discovery (Entdeckung), Conformance (Übereinstimmung) und Enhancement (Verbesserung). Die von den genannten Typen am meisten erforschte Art, Process Discovery umfasst die Generierung von Prozessen und visuellen Darstellungen direkt aus Ereignislogs ohne zusätzliche Daten (van der Aalst W., Process Mining, 2016), es ermöglicht eine automatisierte Definition Ihres Geschäftsprozesses aus Ihren gesammelten Daten. Techniken zu Conformance Checking analysieren die Abweichungen zwischen den datengesteuerten, automatisch entdeckten Modellen und dem theoretischen Prozess (wie der Prozess funktionieren sollte) (Rozinat & van der Aalst, 2008; Bergami, Maggi, Marrella & Montali, 2021). Schließlich zielen die Methoden zur Prozessverbesserung darauf ab, die bestehenden Prozesse anhand der Informationen aus den Ereignislogs zu verbessern (Process Enhancement), indem die Aktivitäten geändert oder die beteiligten Ressourcen neu organisiert werden (de Leoni, 2022).

In einigen Fällen werden Ereignislogs aus Sensordaten erzeugt, die ein natürliches System beobachten (z. B. Wettervorhersagestationen), und der Prozess ist eigentlich eine konzeptionelle Definition, die versucht, das beobachtete Verhalten zu beschreiben. In diesen Fällen kann das Endziel von PM immer noch angewendet werden. Im Sport werden verschiedene Datenerfassungstechniken auf allen möglichen Ebenen angewandt. Professionelle Sportteams und -verbände überwachen mithilfe von Sensoren die Herzfrequenz, die zurückgelegte Strecke oder den durchschnittlichen Ermüdungsgrad ihrer Sportler. In Sportarten, die unter den Begriff „Invasionssport“ fallen (Hughes & Bartlett, 2002), werden Spiele ebenfalls überwacht, wobei zwei Hauptdatenquellen entstehen: Ereignisdaten und Positionsdaten. Ereignisdaten werden ursprünglich dazu verwendet, Spielstatistiken zu erstellen, die Anzahl der Aktionen eines bestimmten Spielers zu zählen, die Genauigkeit von Pässen zu melden usw. Ereignisdaten sind jedoch von Natur aus das Ausführungslog einer Mannschaft im Spiel, die zeitlich geordnete Abfolge aller im Spiel stattfindenden Aktionen. In ähnlicher Weise erfassen Positionsdaten die Position aller Spieler und des Balles mit hoher Frequenz während des Spiels. Während es sich bei diesen Daten per Definition um eine räumlich-zeitliche Reihe von Positionen handelt, könnten diskrete Methoden eine Abfolge von Positionsphasen, Trajektorien oder Bewegungsmustern erzeugen, die unter die Definition eines Prozesses fallen könnten. In beiden Fällen könnte das PM diese Datenquellen nutzen, um den Prozess, der der Leistung einer Mannschaft in einem Spiel zugrunde liegt, methodisch zu definieren. Die Forschung in diesem Bereich könnte sich damit befassen, wie PM-Techniken zur Definition von Mannschaftstaktiken oder Spielerfunktionen eingesetzt werden können.

Definition

Process Mining ist eine relativ junge Forschungsdisziplin im Schnittpunkt von Data Mining und Business Management, die sich mit der Entdeckung, Anpassung und Verbesserung von Geschäftsprozessen beschäftigt. Die prozessorientierte Analyse verwaltet Betriebsstudien unter der Annahme, dass die Daten auf einem dynamischen Verhaltensprozess beruhen. Rollen und Akteure interagieren im Hinblick auf ein bestimmtes Ziel oder eine bestimmte Funktion in der Zeit und führen bestimmte Muster, Aufträge und Arbeitsabläufe aus. Einige Data-Mining-Techniken, wie z. B. Sequenz- oder Episoden-Mining, können Daten als Sequenz modellieren, berücksichtigen aber keine End-to-End-Prozesse. PM identifiziert die Prozessmodelle und bietet eine visuelle Darstellung von Strukturen oder unstrukturierten Ereignislogs (Diamantini, Genga & Potena, 2016). Process Discovery umfasst die Identifizierung von Prozessmodellen und die visuelle Darstellung von Struktur- oder unstrukturierten Prozessdaten, die aus einer beliebigen Umgebung stammen. Conformance Checking liefert ein Maß für die Übereinstimmung zwischen der Strategie eines Prozesses (dem theoretischen Verhalten) und der tatsächlichen Ausführung. Die Prozessverbesserung schließlich erweitert oder verbessert die aktuellen Prozessmodelle mithilfe des aus der Analyse gewonnenen Wissens.

18.3 Anwendungen

PM ist ein hochgradig anwendbares Gebiet, hat sich in allen möglichen Bereichen als äußerst aufschlussreich erwiesen und ist zu einem Kernaspekt jeder Systemimplementierung geworden.

18.3.1 Process Mining im Gesundheitswesen

► Beispiel 1

Die Notaufnahme eines Krankenhauses ist ein komplexes System, in dem eine schnelle Entscheidungsfindung erforderlich ist. Indikatoren wie Wartezeiten, Überlastung der Patienten oder Qualität der Versorgung haben immer Priorität. PM hat sich als nützlich erwiesen, um die Interaktionen, Aktivitäten und Prozesse, die in einer Notaufnahme stattfinden, zu beobachten und zu analysieren (Rojas et al., 2019). Ziel dieser aktuellen Studie war es, PM als Instrument für die Leistungsanalyse in diesem Bereich zu nutzen und Engpässe im gesamten Verfahren zu identifizieren, die eventuell vermieden werden könnten, um die Qualität der Gesundheitsversorgung zu verbessern. ◀

► Beispiel 2

Eine weitere großartige Anwendung von PM im Gesundheitswesen wurde in einer Forschungsarbeit zur Verhaltensanalyse im Krankenhaus vorgestellt (Arnolds & Gartner, 2017). In dieser Studie standen die klinischen Pfade, also die Abläufe, die ein Patient

im Krankenhaus durchläuft, im Mittelpunkt der prozessorientierten Analyse. Die Vorhersage bestimmter klinischer Pfade wie Diagnostik, Operation oder Therapie und der Übergänge zwischen ihnen ist für die Krankenhausplanung von großer Bedeutung. Durch die Analyse erreichten die Autoren eine Verringerung der von den Patienten zurückgelegten Wege. ◀

18.3.2 Process Mining in der Bildung

► Beispiel 3

Seit 2020 sind Online-Kommunikation und -Zusammenarbeit ein wesentlicher Bestandteil jedes Teams oder jeder Organisation geworden. Sogar Bildungssysteme bewegen sich in Richtung eines flexibleren Dienstleistungsmodells, das Online-Ressourcen mit Präsenzunterricht kombiniert. In einer Studie aus dem Jahr 2016 (Alvarez, Fabra, Hernandez & Ezpeleta, 2016) wurde PM verwendet, um die Übereinstimmung zwischen den Zielen der Lehrkräfte und den Aktivitäten der Schüler in einer E-Learning-Umgebung zu messen. Die Autoren nutzten die Logs, die von den Studierenden bei der Durchführung ihrer Aktivitäten erstellt wurden, und den Kursplan des Lehrers (beobachtetes vs. theoretisches Verhalten). ◀

18.3.3 Process Mining im Fußball

► Beispiel 4

PM wurde bereits im Sport getestet, in diesem Fall anhand von Fußballereignisdaten (Kröckel & Bodendorf, 2020). In dieser explorativen Studie wurden die Möglichkeiten von PM als Instrument für die taktische Analyse von Fußballspielen analysiert. PM zeigt ein vielversprechendes Potenzial, um die Leistung von Mannschaften und Spielern im Fußball zu bewerten und eine Standarddefinition der Mannschaftstaktik zu liefern, indem das in den Ereignisdaten gesammelte typische Verhalten erkannt wird. PM ermöglicht auch die Untersuchung der organisatorischen Perspektive des Spielstils einer Mannschaft. So können Metriken darüber gewonnen werden, wie die Spieler miteinander interagieren, um ein gemeinsames Ziel zu erreichen. ◀

Studienbox

Invasionssportarten sind Sportarten, die sich in ihrer Spielweise ähneln sowie in der Art und Weise, wie die Konfrontation zwischen den beiden Mannschaften ausgetragen wird. In Sportarten wie Fußball, Basketball, Handball oder Rugby haben die Mannschaften das gemeinsame Ziel, in das gegnerische Terri-

torium einzudringen und Punkte zu erzielen, während sie gleichzeitig die gegnerische Punktzahl innerhalb eines bestimmten Zeitraums so niedrig wie möglich halten. Trotz der Ähnlichkeiten wird die Forschung zu Invasionssportarten hauptsächlich in eindimensionalen Studien zur Analyse einer einzigen

Sportart präsentiert. Der Grund für diese Diskretisierung der Studien könnte mit der Datenverfügbarkeit oder einer einfacheren Formulierung der Studienanforderungen zusammenhängen. In diesem Szenario bietet sich Process Mining als Kandidat für eine sportart-unabhängige Analyse an, bei der die Prozessmodelle auf jede Sportart verallgemeinert werden können. Zum Beispiel die Abstraktion der gemeinsamen Merkmale zwischen einem Fußballtor und einem Rugbyversuch. Das Ver-

ständnis allgemeiner Konzepte von Invasionssportarten in Bezug auf die ortsbezogene Kontrolle des Spielfelds oder die Zusammenarbeit zwischen Spielern bei gemeinsamen Aufgaben könnte neue Taktiken in den jeweiligen Sportarten eröffnen und einen wesentlichen Beitrag zur Sportwissenschaft leisten. Jüngste Studien haben in der Tat die positive Wirkung von Multisportpraktiken auf junge Athleten für ihre potenzielle langfristige Entwicklung und Spezialisierung festgestellt (Barth & Güllich, 2020).

? Fragen für die Studierenden

1. Wo gibt es Beispiele für Ausführungslogs in der Sportanalyse?
2. Definieren Sie die drei Arten von Process Mining.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Alvarez, P., Fabra, J., Hernandez, S., & Ezpeleta, J. (2016, September). Alignment of teacher's plan and students' use of LMS resources. Analysis of Moodle logs. *2016 15th International Conference on Information Technology Based Higher Education and Training (ITHET)*. IEEE. doi:<https://doi.org/10.1109/ithet.2016.7760720>
- Arnolds, I. V., & Gartner, D. (2017, April). Improving hospital layout planning through clinical pathway mining. *Annals of Operations Research*, 263, 453–477. doi:<https://doi.org/10.1007/s10479-017-2485-4>

- Barth, M., & Güllich, A. (2020, December). Non-linear association of efficiency of practice of adult elite athletes with their youth multi-sport practice. *Journal of Sports Sciences*, 39, 915–925. doi:<https://doi.org/10.1080/02640414.2020.1851900>
- Bergami, G., Maggi, F. M., Marrella, A., & Montali, M. (2021). Aligning Data-Aware Declarative Process Models and Event Logs. In *Lecture Notes in Computer Science* (pp. 235–251). Springer International Publishing. doi:https://doi.org/10.1007/978-3-030-85469-0_16
- de Leoni, M. (2022). Foundations of Process Enhancement. In *Lecture Notes in Business Information Processing* (pp. 243–273). Springer International Publishing. doi:https://doi.org/10.1007/978-3-031-08848-3_8
- Diamantini, C., Genga, L., & Potena, D. (2016, February). Behavioral process mining for unstructured processes. *Journal of Intelligent Information Systems*, 47, 5–32. doi:<https://doi.org/10.1007/s10844-016-0394-7>
- Hughes, M. D., & Bartlett, R. M. (2002, January). The use of performance indicators in performance analysis. *Journal of Sports Sciences*, 20, 739–754. doi:<https://doi.org/10.1080/026404102320675602>
- Kröckel, P., & Bodendorf, F. (2020, July). Process Mining of Football Event Data: A Novel Approach for Tactical Insights Into the Game. *Frontiers in Artificial Intelligence*, 3. doi:<https://doi.org/10.3389/frai.2020.00047>
- Rojas, E., Cifuentes, A., Burattin, A., Munoz-Gama, J., Sepúlveda, M., & Capurro, D. (2019, April). Performance Analysis of Emergency Room Episodes Through Process Mining. *International Journal of Environmental Research and Public Health*, 16, 1274. doi:<https://doi.org/10.3390/ijerph16071274>
- Rozinat, A., & van der Aalst, W. M. (2008, March). Conformance checking of processes based on monitoring real behavior. *Information Systems*, 33, 64–95. doi:<https://doi.org/10.1016/j.is.2007.07.001>
- Tiwari, A., Turner, C. J., & Majeed, B. (2008, February). A review of business process mining: state-of-the-art and future trends. *Business Process Management Journal*, 14, 5–22. doi:<https://doi.org/10.1108/14637150810849373>
- van der Aalst, W. (2016). *Process Mining*. Springer Berlin Heidelberg. doi:<https://doi.org/10.1007/978-3-662-49851-4>
- van der Aalst, W., Adriansyah, A., de Medeiros, A. K., Arcieri, F., Baier, T., Blicke, T., . . . Wynn, M. (2012). Process Mining Manifesto. In *Business Process Management Workshops* (pp. 169–194). Springer Berlin Heidelberg. doi:https://doi.org/10.1007/978-3-642-28108-2_19
- van der Aalst, W., Weijters, T., & Maruster, L. (2004, September). Workflow mining: discovering process models from event logs. *IEEE Transactions on Knowledge and Data Engineering*, 16, 1128–1142. doi:<https://doi.org/10.1109/tkde.2004.47>



Zentralität von Netzwerken

João Paulo Ramos, Rui Jorge Lopes, Duarte Araújo und Pedro Passos

Inhaltsverzeichnis

19.1 Eine Netzwerkwissenschaft im Fußball – 178

19.2 Hintergrund – 178

19.3 Anwendungen – 183

Literatur – 186

Kernbotschaften

- Leistungsrelevante Parameter aus Training und Wettkampf können durch die Netzwerkforschung erfasst werden.
- Netzwerkanalyse (NA) hilft, die Leistungsergebnisse zu verstehen.
- Es wird unterschieden zwischen der Dynamik der Netzwerke und der Dynamik auf den Netzwerken (Strukturen vs. Prozesse).
- Es gibt einen Unterschied zwischen Metriken auf Spielebene und Metriken auf Spielzeugebene.

19.1 Eine Netzwerkwissenschaft im Fußball

Die Dynamik des interaktiven Verhaltens von Spielern impliziert, dass sich die relevanten Momente eines Spiels über den Lauf der Zeit entwickeln. Die Art der Interaktionen zwischen Mannschaftsspielern und Gegnern ist ein komplexer Prozess, der über Pässe, Positionierung und Abstände zwischen den Spielern hinausgeht. Um diese Komplexität zu erfassen, ist der Hypernetzwerk-Ansatz ein vielversprechendes Instrument. Frühere Arbeiten zur Leistungsanalyse (engl. Performance Analysis, PA) in Mannschaftssportarten haben sich auf Zentralitätsmaße konzentriert. In den letzten zwei Jahrzehnten wurden die Theorie dynamischer Systeme (Davids, Glazier et al. 2003, Araujo, Davids et al. 2004, Davids, Araújo et al. 2005, Reilly, Cabri et al. 2005) und später die ökologische Dynamik als Hintergrund für die Beschreibung und Erklärung interaktiver Verhaltensweisen in Mannschaftssportarten verwendet (Vilar, Araújo et al. 2012). Daraus ergaben sich Fragen zu kooperativen Interaktionen zwischen Spielern desselben Teams, z. B. welcher Spieler interagiert am meisten mit seinen Teamkollegen? Darüber hinaus gewinnt die Frage der Zentralität innerhalb kooperativer und kompetitiver Interaktionen an Relevanz, was zu spezifischeren Forschungsfragen führt, wie z. B.: Welche Spielerkonstellationen (1 vs. 1; 2 vs. 1; 1 vs. 2; 2 vs. 2; usw.) sind unter Berücksichtigung der relativen Positionierung und Entfernung der Spieler in den Spielen am häufigsten (zentral)? Wo finden diese statt? Welche Spieler sind beteiligt bzw. welche Verfahren werden von den Spielern und Mannschaften angewandt, um die lokale Dominanz (z. B. 2 gegen 1) in den verschiedenen Bereichen des Spielfelds zu fördern oder sich Vorteile bei den Torchancen zu verschaffen?

19.2 Hintergrund

Der Ansatz komplexer Systeme an die Leistung von Mannschaftssportarten mithilfe der Netzwerkwissenschaft betrachtet und beschreibt Mannschaften so, dass ihre Teile (Gruppen und Spieler) miteinander verbunden sind (Bar-Yam 1997). Daher kann der Grad der Systemkomplexität erhöht werden, und zwar einerseits über die Struktur, also indem die Anzahl der Teile erhöht wird, und andererseits über die Funktionalität, also indem ihre Interaktionen erhöht werden (Bar-Yam

2004). In Mannschaftssportarten ist die Anzahl der Spieler (Anteile) in einem Spiel geregelt, was die Komplexität der Menge und Variabilität der Interaktionen zwischen Gruppen und Spielern unterstreicht (Bar-Yam 2003).

Mit dem Ziel, Interaktionen zu untersuchen, wurde in einer zunehmenden Zahl von Studien (Duch, Waitzman et al. 2010, Dutt-Mazumder, Button et al. 2011, Passos, Davids et al. 2011, Duarte, Araujo et al. 2012, Grund 2012, Clemente, Couceiro et al. 2014, Clemente, Couceiro et al. 2015, Clemente, Martins et al. 2015, Clemente, Martins et al. 2015, Ramos, Lopes et al. 2017a) die Soziale Netzwerkanalyse (SNA) als geeignete Methode verwendet, um die wechselseitigen Abhängigkeiten im Mannschaftssport zu erfassen. Der Ansatz bestand darin, die kooperative Interaktion zwischen Zweiergruppen (Dyaden) von Spielern desselben Teams oder ihre Aktionen mit dem Ball zu modellieren. Die kommunikative Stärke der SNA-Visualisierung durch die Darstellung der aggregierten Passdaten während eines Fußballspiels (Ramos, Lopes et al. 2018) zwischen den Dyaden bestärkte die Verwendung dieser Metriken für die Leistungsanalyse zur Modellierung der mannschaftsinternen Koordination als häufige Passinteraktion zwischen Spielern in Mannschaftssportarten (Duch, Waitzman et al. 2010, Passos, Davids et al. 2011, Brandes, Freeman et al. 2012, Grund 2012).

Die Analyse dieser Pass-Netzwerke offenbart einige kollektive Eigenschaften (z. B. Muster) der Teamleistung sowie den zugrunde liegenden individuellen Beitrag zu diesen Eigenschaften (Ramos 2019). Für Praktiker ist jedoch immer noch unklar, in welcher Weise die Analyse sozialer Netzwerke zu einer effektiven Verbesserung der individuellen und der Teamleistung beiträgt. Es besteht nach wie vor eine gewisse Unsicherheit darüber, wie individuelle Unterschiede und Rollen (einflussreiche Akteure) kombiniert werden, um die Teamleistung zu verbessern (Duch, Waitzman et al. 2010). Wichtig ist, dass jede Netzwerkanalyse eines Systems oder Prozesses davon ausgeht, dass es eine Struktur, d. h. ein Netzwerk, gibt, in dem diese Interaktionen stattfinden (Brandes, Robins et al. 2013).

Wir wenden uns nun den strukturellen Eigenschaften von Netzwerken zu, d. h. den Eigenschaften, die allen Netzwerken gemeinsam sind. Bei einem bestimmten zu untersuchenden System gibt es Eigenschaften, die das Netzwerk wissenschaftlich ausdrückt. In erster Linie besteht das System aus interagierenden Elementen, d. h. ein Netzwerk ist eine „Sammlung von Eckpunkten, die durch Kanten verbunden sind“ (Newman 2010), wie in ■ Abb. 19.1 dargestellt. In den vielen verschiedenen Ansätzen zur Untersuchung von Mannschaftsballsportarten werden Spieler und Pässe jeweils durch die Eckpunkte (Akteure) und Kanten (Interaktionen) des Netzwerks dargestellt. In den einfachsten Netzwerkmodellen (sogenannte einfache Netzwerke oder einfache Graphen) gibt es mindestens eine Kante zwischen jedem Paar von Eckpunkten, während komplexere Modelle (Multigraphen) mehrere Kanten aufweisen (Ramos 2019). Die grundlegendsten globalen Struktureigenschaften eines Netzwerks sind Ordnung und Größe, ausgehend von der Anzahl der Eckpunkte und Kanten. Das globale Intensitätsniveau der Interaktionen im Netzwerk kann über die Dichte eigenschaft gemessen werden, die als Verhältnis zwischen der Netzwerkgröße (Anzahl der Pässe oder anderer Aktionen mit dem Ball – Kanten) und der Anzahl der Kanten, die im Netzwerk existieren könnten, berechnet wird (Guillaume & Latapy 2006). Eine hohe Dichte im




Abb. 19.1 Deutschland – Ghana: FIFA Fußballweltmeisterschaft 2014. Jeder Kreis stellt einen Spieler in seiner relativen Position dar; der Radius und die Farbe jedes Kreises stehen für die Anzahl der Spieler, mit denen ein Spieler interagiert, bzw. für seine Passgenauigkeit (rot: mehr Präzision; gelb: weniger Präzision); die Pfeile stellen die Richtung der Pässe zwischen den Spielern dar; die Breite und die Schattierung jedes Pfeils stehen für die Anzahl der Interaktionen (Pässe) zwischen den Spielern (hellere Pfeile bedeuten weniger Pässe, dunklere Pfeile bedeuten mehr Pässe). Die Zahlen in Klammern stehen für die von den einzelnen Spielern gespielten Minuten (z. B. 0–90', 90 min gespielt) oder für den Zeitpunkt, zu dem ein Spieler das Spiel begonnen hat (z. B. +78'), d. h. in Minute 78 ins Spiel gekommen ist und *golo* 54' bedeutet, dass er in Minute 54' ein Tor erzielt hat

Netzwerk wird tendenziell mit einer besseren Teamleistung in Verbindung gebracht (Grund 2012, Ramos 2019).

Die genannten Metriken bewerten die Dynamik des Netzes und konzentrieren sich auf die Ströme innerhalb der Netzstruktur, z. B. auf die Pässe zwischen den Spielern. Auf diese Weise ist ein ganzes Spiel das Aggregat aller Pässe, die als statische Daumenkinos (kumulative Momentaufnahmen des Netzwerks in Abhängigkeit von der Zeit) jeder Spieleraktion auftreten, wobei die Position des Spielers konstant bleibt, die Interaktionen jedoch im Laufe der Zeit kumulieren (Moody, McFarland et al. 2005, Ramos, Lopes et al. 2018). Die untersuchten Struktureigenschaften waren vor allem die Netzwerkzentralität und die Dichte der Interaktionen zwischen den Teammitgliedern und den Leistungsergebnissen (Katz, Lazer et al. 2004, Balkundi und Kilduff 2006, Grund 2012). Durch Zählen der Anzahl der Kanten (z. B. Pässe), die mit einem Knotenpunkt (z. B. Spieler) verbunden sind, erhält man den Grad eines Knotenpunkts, der auch als „degree centrality“ bezeichnet wird (Newman 2010). Die Studien zu Mannschaftssportarten haben sich hauptsächlich mit dem „ball flux“ (z. B. Pässe) befasst, der gerichtete Netzwerke von einem Spieler zum anderen bildet. In dieser Art von Netzwerken haben die

Eckpunkte (Spieler) zwei Grade: den „*in-degree*“ (z. B. die Anzahl der eingehenden Pässe zu diesem Spieler oder der abgefangenen Bälle) und den „*out-degree*“ (z. B. die Anzahl der ausgehenden Pässe oder der zugelassenen Interaktionen) (Newman 2010). Wenn eine Mannschaft nur wenige Spieler mit hohen Zentralitätswerten hat, bedeutet dies, dass diese Spieler für die meisten der ausgeführten Pässe verantwortlich sind und die Mannschaft dazu neigt, stark von ihnen abhängig zu sein, mit einem vorhersehbareren Verhalten, das mit einer weniger effizienten Mannschaftsleistung verbunden ist (Grund 2012, Ramos 2019).

Durch Zählen der Anzahl der Kanten und der Anzahl der Eckpunkte wird die Intensität des Netzwerks berechnet. Aus dem Verhältnis zwischen der Netzwerkgröße (Anzahl der Pässe oder anderer Aktionen mit dem Ball – Kanten) und der Anzahl der Kanten, die innerhalb des Netzwerks existieren könnten, wird die Dichte des Netzwerks berechnet (Guillaume und Latapy 2006). Eine hohe Dichte im Netzwerk wird tendenziell mit einer besseren Mannschaftsleistung in Verbindung gebracht (Grund 2012, Ramos 2019, Pina et al. 2017). Die genannten Metriken bewerten die Dynamik des Netzwerks und konzentrieren sich auf die Ströme in der Netzwerkstruktur, z. B. Ballwechsel zwischen Spielern. Zentralitätsstudien könnten Fachleuten bei der Verbesserung der Mannschaftssportleistung helfen, indem sie Fragen beantworten wie: „Wer ist der interaktivste Spieler?“ oder „Welche Spieler haben eine vermittelnde Rolle?“ oder „Wie zentral ist ein Spieler?“ oder „Wie trägt jeder Spieler zur Leistung der anderen bei?“ (Ramos, Lopes et al. 2018).

Bei der Frage nach dem interaktivsten Spieler liegt der Schwerpunkt auf der lokalen Strukturanalyse der Interaktionen. Das bedeutet, dass die Interaktionen/Pässe zwischen dem Spieler und den benachbarten Spielern durch den „*in-degree*“ oder den „*out-degree*“ angegeben werden. Um andere Fragen anzugehen, müssen wir die globale Analyse der Netzwerkstruktur verstehen, da sie nicht nur die benachbarten Knotenpunkte berücksichtigt, sondern auch die Tatsache, dass ein zweiter, ein dritter und/oder weitere Schritte in diesen Sequenzen von Durchgängen stattgefunden haben. Eine Einschränkung bei der Verwendung dieser Metriken, die aus der Analyse anderer komplexer Systemnetzwerke, wie z. B. (sozialer) Internetnetzwerke, übernommen wurden, besteht darin, dass einige Metriken auf dem Konzept des kürzesten Pfades oder eines geodätischen Pfades beruhen. Dieses Konzept wird auf den Pfad zwischen zwei Knotenpunkten angewandt, für den es keinen anderen Pfad im Netzwerk gibt, der zwischen diesen beiden Knotenpunkten kürzer ist (die geodätische Distanz oder kürzeste Distanz, die die kürzeste Netzwerkdistanz darstellt, Newman 2010). Bei der Analyse von Fußballspielen werden alle Pässe/Aktionen oder relevante Zeitspannen oder sogar die Dauer einiger wichtiger Ereignisse wie Tore oder Torchancen aggregiert. In diesen Fällen müssen wir eine globalere Netzwerkanalyse in Betracht ziehen, die alle Verbindungen umfasst, welche im Verlauf eines Spiels oder einer Zeitspanne aufgetreten sind. Dieses Aggregationsmerkmal in Mannschaftsballsportarten folgt nicht dem Konzept des kürzesten Weges (typisch für soziale Interaktionen im Internet), sondern dem Konzept der Zufallswege (ein Weg, der in zufälligen Schritten durch das Netzwerk führt, z. B. könnte ein Spieler mehr als einmal Teil der Passsequenz sein). Dieses Konzept repräsentiert die Ereignisse während eines Mannschaftssportspiels besser

(Ramos et al. 2017), wie z. B. das Passen eines Balles (Newman 2010). Metriken wie die „*betweenness centrality*“, die den Grad ausdrückt, in dem ein Knoten auf dem kürzesten Pfad zwischen zwei anderen Knoten liegt, oder die „*closeness-centrality*“, die ein Zentralitätsmaß ist, das die Länge der kürzesten Pfade zwischen dem fokalen Knoten und allen anderen Knoten berücksichtigt. Diese Metrik kann bei der Beantwortung von Fragen zu den Zwischen- bzw. zentralen Spielern helfen, geht aber davon aus, dass die Interaktionen über die kürzesten Pfade erfolgen müssen (Ramos 2019).

Definition

Die Netzwerkanalyse (NA) begann mit einer Theorie über das System (Brandes et al. 2013), einer sozialen Theorie im Fall der sozialen Netzwerkanalyse. NA ist die Berechnung von Netzwerk- oder Knoteneigenschaften (wie Netzwerkordnung oder Knotengrade), die nur ein Teil des breiteren Prozesses der Netzwerkwissenschaft ist.

„*Flow centrality*“ (Freeman 2000) kann die Einschränkung der „*betweenness centrality*“ (basierend auf kürzesten Pfaden) überwinden, da sie den Anteil der Spaziergänge zählt, der zu einem Ereignis führt, an dem der fokale Spieler beteiligt ist, anstatt die kürzesten Pfade zwischen den Spielern zu berücksichtigen (Duch, Waitzman et al. 2010). Fewell und Kollegen (2012) wandten dies in der Basketballforschung an, wo das Konzept die individuelle Dominanz auf Spielebene bewerten kann, indem es sich auf die Gesamtbeteiligung während aller Spiele in einem Match konzentriert (Fewell, Armbruster et al. 2012). Durch die Berechnung der „*flow centrality*“ ist es möglich, die Beteiligung jeder Spielposition an allen Spielzügen in einem Spiel zu erfassen. Aufbauend auf dieser Metrik und der „*random walk betweenness*“ (Newman 2005) war es auch möglich, eine neue Metrik namens „*flow betweenness*“ zu berechnen, die den Anteil der Spiele misst, in denen ein Spieler als Vermittler im Verhältnis zu allen Spielen seines Teams fungiert (Korte, Link et al. 2019). Darüber hinaus kann der „*weighted betweenness score*“ für jede Spielposition berechnet werden und bewertet, wie oft ein Spieler zwischen zwei anderen Spielern seiner Mannschaft steht, gemessen an ihren stärksten Passverbindungen (oder anderen Variablen der Interaktion) während eines Spiels, sodass der Spieler innerhalb von Spielzügen als Überbrückungseinheit fungiert. Diese Metriken können zur Identifizierung der Spielmacher und zur Beantwortung der Frage nach dem vermittelnden Spieler verwendet werden, wenn die Metriken auf Spielebene (Gesamtheit aller Spielzüge im Spiel) durch Metriken auf Spielzugebene (Gesamtheit einiger Augenblicke vor einem bestimmten Ereignis im Spiel, z. B. einer Torchance) ersetzt werden. Außerdem ist eine Unterscheidung zwischen Metriken auf Spielzugebene erforderlich. Diese Metriken betonen unterschiedliche Aufgaben auf den Spielpositionen. Ramos und Kollegen (2018) schlugen erstmals vor, dass die „*flow centrality*“ ein geeigneter Spielmacher-Indikator sein könnte, der zwischengeschaltete Spieler auf Spielzugebene hervorhebt (Ramos, Lopes et al. 2018).

19.3 Anwendungen

► Beispiel 1

Während sich die meisten Studien mit SNA im Sport auf die Angriffsmuster konzentrierten, zielten Sasaki und Kollegen (Sasaki, Yamamoto et al. 2017) darauf ab, die Netzwerke zu klären, die innerhalb der Verteidigungsmuster entstehen, welche während eines Rugbyspiels eine entscheidende Rolle spielen. Der Grundgedanke war, dass die Kooperation, die strukturelle Einheiten (z. B. Verteidiger) verbindet, immer dynamisch ist. Daher weist ein unterschiedliches Kooperationsformat auf unterschiedliche Merkmale einer Einheit hin. Auch hier wurde erwartet, dass die interaktivere Struktur (höhere Komplexität) weniger vorhersehbar und anpassungsfähiger ist. ◀

► Beispiel 2

Einige Studien haben die Zusammenarbeit durch direkten Körperkontakt untersucht, z. B. das Tackling im Rugby (Koh, Yamamoto et al. 2013). Die Autoren berechneten die absolute Häufigkeit von Tacklings pro Position während eines Rugbyspiels, was zu einer Balleroberungsleistung der Verteidigung beiträgt, die folglich die offensive Aktivität des Gegners neutralisiert. Das Ziel dieser Studie war es, die Bedeutung von Zentralität einer defensiven Mannschaft im Rugby zu erklären. Jedes Mal, wenn eine Verteidigungshandlung von mehreren Spielern stattfand, wurde ein einzelnes Netzwerk erstellt. Die Eckpunkte stellten die Positionen der Spieler dar, und die Kanten repräsentierten die Zusammenarbeit zwischen den Mannschaftsteilen im Verlauf eines Spiels (Doppeltackling), wenn ein Tackling mit zwei Spielern zu einem Ballgewinn im Spiel führte. Die Kanten wurden nach der Anzahl der sich wiederholenden kooperativen Aktionen in der Gesamtheit des Spiels gewichtet. ◀

► Beispiel 3

Zwischen der SNA und den Leistungsergebnissen klafft immer noch eine Lücke, die die praktischen Auswirkungen des Ansatzes beeinträchtigt. Bei den derzeitigen temporalen Ansätzen wurde die tatsächliche Abfolge des Passspiels nicht berücksichtigt, um die Spieler zu erkennen, die ihre Mannschaftskameraden durch das Passspiel tatsächlich miteinander verbinden. Dies impliziert, dass Passsequenzen separat ausgewertet werden sollten, anstatt die aggregierten Passdaten über ein Spiel hinweg zu untersuchen (Ramos, Lopes et al. 2018). Somit muss das Zusammenspiel bei jedem Ballbesitz separat analysiert werden, anstatt eine aggregierte Passmatrix auf Spielebene auszuwerten. Diese Art von Ansatz befasst sich mit der Dynamik des Netzwerks, indem die Veränderungen in der Netzwerkstruktur selbst bewertet werden, wie z. B. i) der Beziehungsraum (d. h. Interaktionen, die in einem geografischen Raum betrachtet werden), ii) ihre Zeitstruktur (d. h. Änderungsrate, Reihenfolge der Sequenz oder Gleichzeitigkeit von Interaktionen) und iii) ihre Beziehungen zu verschiedenen Arten von Knotenpunkten (d. h. Mitspieler oder Gegner), wodurch sowohl kooperative als auch kompetitive Interaktionen berücksichtigt werden (Moody, McFarland et al. 2005, Ramos, Lopes et al. 2018). ◀


► Beispiel 4

Komplexe Netzwerke wie temporale und zweigeteilte Netzwerke, wie die sogenannten Hypernetzwerke (Johnson 2006), stellen Interaktionen und Beziehungen dar, die im Verlauf eines Mannschaftssportspiels auftreten. In einem Hypernetzwerk kann eine Hyperkante mehr als zwei Knoten verbinden (z. B. zwei Spieler einer Mannschaft und einer der anderen Mannschaft: 2 vs. 1), wodurch n -fache Beziehungen direkt als Mengen σ dargestellt werden (Johnson 2006, Johnson 2008, Criado, Romance et al. 2010, Johnson 2013, Boccaletti, Bianconi et al. 2014, Johnson 2016, Ramos, Lopes et al. 2017).

Diese Verallgemeinerung ermöglicht die Darstellung mehrerer kooperativer und konkurrierender Interaktionen in ihrer genauen Positionierung und ihrem Zeitrahmen im Spiel (■ Abb. 19.2). Die resultierenden Darstellungen und Statistiken können beschreiben:

1. Wenn es zentrale Sätze jeder Art (z. B. 1 vs. 1; 2 vs. 1; 1 vs. 2; 2 vs. 2) gibt, die im Spiel oder in bestimmten Zeitspannen (z. B. die zehn Sekunden vor einer Torchance) vorkommen.
2. Wer sind die zentralen Spieler in den Gruppen und gibt es eine bestimmte zentrale Gruppe, die häufiger vorkommt als die anderen?
3. Wenn es eine zentrale spezifische Region gibt, in der die Gruppen auftreten, dargestellt in Histogrammen wie *heat maps*.
4. Wie sich Gruppen auflösen oder zu neuen Gruppen zusammenschließen (z. B. Geschwindigkeitsänderungen bei den Spielzügen) und welche Spieler diese Veränderungen in den Gruppen maßgeblich fördern.

Die Dynamik dieser Zentralitäten kann durch Hypernetze auf verschiedenen Skalen oder Analyseebenen bewertet werden, z. B.: einzelne Spieler, bestimmte Gruppen und Gruppen von Gruppen. In einigen Studien wurde dieser Hypernetwork-Mehrebenen-Ansatz verwendet, der die komplexe Systemverbindung zwischen Mikro-, Meso- und Makroebene berücksichtigt (Ramos, Lopes et al. 2017a, Ramos, Lopes et al. 2017b, Ramos 2019). ◀



■ Abb. 19.2 Aufbau eines Hypernetzes auf der Grundlage der Nähe zwischen den Spielern, die durch Kanten (Polygone) miteinander verbunden sind und deren Position auf dem Fußballfeld zu einem bestimmten Zeitpunkt dargestellt wird

► Beispiel 5

Frühere Untersuchungen haben statistische Signifikanzen zwischen Spielpositionen in erfolgreichen und erfolglosen Spielen im Fußball in Bezug auf „*flow centrality*“ und „*flow betweenness*“ ergeben (Korte, Link et al. 2019). Verteidiger und defensive Mittelfeldspieler fungieren in 70–75 % aller Spielzüge, an denen sie beteiligt sind, als Überbrücker, die Anteile für Torhüter und Stürmer betragen nur 40–50 %. ◀

► Beispiel 6

Die Metrik auf Spielebene misst den Anteil am Gesamtpassspiel einer Mannschaft, während die Metrik auf Spielerebene die Häufigkeit von Spielzügen während eines Spiels bewertet. Mit der „*flow betweenness*“ wird beispielsweise ermittelt, wie oft sich ein Spieler während eines Spiels tatsächlich zwischen zwei anderen Spielern befindet und als Vermittler fungiert. ◀

► Beispiel 7

Die Quantifizierung der Netzwerkzentralität innerhalb eines Teams oder zwischen Teams liefert eine Bewertung der Beitragsmechanismen der einzelnen Spieler. Genauer gesagt würde die „*Eigenvektor centrality*“ die spezifischen Netzwerkstrukturen der benachbarten Knotenpunkte widerspiegeln. Sasaki und Kollegen verwendeten nicht die „*betweenness-centrality*“, sondern die „*Eigenvektor centrality*“, die nach Ansicht der Autoren die „*vertex centrality*“ stark widerspiegelt (Sasaki, Yamamoto et al. 2017). ◀

Studienbox

Der Hypernetwork-Ansatz für PA in Mannschaftssportarten hat sich mit Zentralitäten in Kooperations- und Wettbewerbsinteraktionen befasst (Ramos et al. 2017a; Ramos et al. 2017b; Ramos 2019; Ribeiro et al. 2019; Ribeiro et al. 2020). Die vielversprechenden Ergebnisse basierten hauptsächlich auf Distanzinteraktionen zwischen Spielern und ermöglichten die Identifizierung einiger Zentralitäten:

1. die häufigsten Gruppen von Spielern, die durch die Nähe zueinander gebildet wurden, waren 1 vs. 1

(25 %), gefolgt von 1 vs. 2 (10,31 %), 2 vs. 1 (8,8 %) und 2 vs. 2 (6,81 %);

2. die Interaktionen bei der Positionierung der Gruppen (z. B. durch „*heatmaps*“) sind in der Regel ein Reflex der Strategie (Design) für die Rollen der Spieler im Spiel;
3. die Synchronisationsprozesse zwischen Spielern und Gegnern, die in den Spielen auftraten;
4. die dynamischen Veränderungen in den Gruppen wurden durch Veränderungen der Laufliniengeschwindigkeit der Spieler gefördert.

? Fragen für die Studierenden

1. Wie können wir die Spielmacher während eines Invasionsspiels im Mannschaftssport identifizieren?
2. Welche Arten von Interaktionen werden mithilfe von Netzwerkmetriken untersucht?
3. Betrachten Sie das Netzwerk, das die Pässe zwischen Spielern im Spiel Deutschland – Ghana (Fußballweltmeisterschaft 2014) darstellt. Berechnen und/oder identifizieren Sie:
 - a. die Ordnung des Netzes;
 - b. die Mannschaft, die ein dichteres Passnetz hat;
 - c. den zentralsten Spieler jeder Mannschaft (Angabe der verwendeten Kriterien);
 - d. welches Paar von Spielern (in jeder Mannschaft) eine mehr oder weniger wechselseitige Pass-Beziehung hat.
 - e. In den vorherigen Punkten (3a. bis 3d.) habe ich durchgeführt: _____
4. Wie lassen sich die Beziehungen zwischen den Spielern auf der Grundlage von räumlicher Nähe beschreiben (s. ■ Abb. 19.2)? Wie würde sich dies ändern, wenn Spieler r_2 den Spieler r_1 unterstützen würde?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Araujo, D., Davids, K., Bennett, S., Button, C., & Chapman, G (2004). Emergence of sport skills under constraints. *Skill Acquisition in Sport*. Routledge, Taylor & Francis e-Library, 409–434.
- Balkundi, P. and M. Kilduff (2006). The ties that lead: A social network approach to leadership. *The Leadership Quarterly*, 17(4), 419–439.
- Bar-Yam, Y. (1997). *Dynamics of complex systems*. Addison-Wesley Reading, MA.
- Bar-Yam, Y. (2003). *Complex systems and sports: complex systems insights to building effective teams*. Cambridge (MA): NECSI.

- Bar-Yam, Y. (2004). Making things work: solving complex problems in a complex world, *Knowledge Industry*.
- Boccaletti, S., et al. (2014). The structure and dynamics of multilayer networks. *Physics Reports* 544(1), 1–122.
- Brandes, U., et al. (2012). *Social Networks. Handbook of Graph Drawing and Visualization*. R. T. (ed.). CRC Press.
- Brandes, U., Robins, G., McCranie, A., & Wasserman, S. (2013). What is network science? *Network Science*, 1(1), 1–15. doi:<https://doi.org/10.1017/nws.2013.2>
- Clemente, F. M., et al. (2014). Using network metrics to investigate football team players' connections: A pilot study. *Motriz: Revista de Educação Física* 20(3), 262–271.
- Clemente, F. M., et al. (2015). Using network metrics in soccer: A macro-analysis. *Journal of human kinetics* 45(1), 123–134.
- Clemente, F. M., et al. (2015). General network analysis of national soccer teams in FIFA World Cup 2014. *International Journal of Performance Analysis in Sport* 15(1), 80–96.
- Clemente, F. M., et al. (2015). Midfielder as the prominent participant in the building attack: A network analysis of national teams in FIFA World Cup 2014. *International Journal of Performance Analysis in Sport* 15(2), 704–722.
- Criado, R., et al. (2010). Hyperstructures, a new approach to complex systems. *International Journal of Bifurcation and Chaos* 20(03), 877–883.
- Davids, K., et al. (2005). Applications of dynamical systems theory to football. *Science and football V*, 537–550.
- Davids, K., et al. (2003). Movement systems as dynamical systems. *Sports medicine* 33(4), 245–260.
- Duarte, R., et al. (2012). Sports teams as superorganisms: implications of sociobiological models of behaviour for research and practice in team sports performance analysis. *Sports Med* 42(8), 633–642.
- Duch, J., et al. (2010). Quantifying the Performance of Individual Players in a Team Activity. *PLoS ONE* 5(6), e10937.
- Dutt-Mazumder, A., et al. (2011). Neural network modelling and dynamical system theory. *Sports medicine* 41(12), 1003–1017.
- Fewell, J. H., et al. (2012). Basketball Teams as Strategic Networks. *PLoS ONE* 7(11), e47445.
- Freeman, L. C. (2000). Visualizing social networks. *Journal of social structure* 1(1), 4.
- Grund, T. U. (2012). Network structure and team performance: The case of English Premier League soccer teams. *Social Networks* 34(4), 682–690.
- Guillaume, J.-L. and M. Latapy (2006). Bipartite graphs as models of complex networks. *Physica A: Statistical Mechanics and its Applications* 371(2), 795–813.
- Johnson, J. (2006). Hypernetworks for reconstructing the dynamics of multilevel systems. In: European Conference on Complex Systems. 25–29, Oxford. <http://ecss.csregistry.org/tiki-index.php?page=ECC>
- Johnson, J. (2008). Multidimensional Events in Multilevel Systems. In Albeverio, D. Andrey, P. Giordano and A. Vancheri. *The Dynamics of Complex Urban Systems: An Interdisciplinary Approach*. S. Heidelberg, Physica-Verlag HD: 311–334.
- Johnson, J. (2013). *Hypernetworks in the science of complex systems*. Imperial College Press London.
- Johnson, J. H. (2016). Hypernetworks: Multidimensional relationships in multilevel systems. *The European Physical Journal Special Topics* 225(6), 1037–1052.
- Katz, N., et al. (2004). Network Theory and Small Groups. *Small Group Research* 35(3), 307–332.
- Koh, S., et al. (2013). Defence performance analysis of rugby union in Rugby World Cup 2011: network analysis of the turnover contributors. *Performance Analysis of Sport IX*, Routledge, 120–125.
- Korte, F., et al. (2019). Play-by-play network analysis in football. *Frontiers in psychology* 10, 1738.
- Moody, J., et al. (2005). Dynamic network visualization. *American journal of sociology* 110(4), 1206–1241.
- Newman, M. (2005). A measure of betweenness centrality based on random walks. *Social Networks* 27(1), 39–54.
- Newman, M. E. J. (2010). *Networks : an introduction*. Oxford; New York, Oxford University Press.

- Passos, P., et al. (2011). Networks as a novel tool for studying team ball sports as complex social systems. *Journal of Science and Medicine in Sport* 14(2), 170–176.
- Passos, P., Amaro E Silva, R., Gomez-Jordana, L., & Davids, K. (2020). Developing a two-dimensional landscape model of opportunities for penetrative passing in association football—Stage I. *Journal of Sports Sciences*, 38(21), 2407–2414.
- Pina TJ, Paulo A and Araújo D (2017). Network Characteristics of Successful Performance in Association Football. A Study on the UEFA Champions League. *Front. Psychol.* 8:1173. doi: <https://doi.org/10.3389/fpsyg.2017.01173>
- Ramos, J., et al. (2018). What's next in complex networks? Capturing the concept of attacking play in invasive team sports. *Sports medicine* 48(1), 17–28.
- Ramos, J., et al. (2017a). Hypernetworks Reveal Compound Variables That Capture Cooperative and Competitive Interactions in a Soccer Match. *Frontiers in Psychology* 8, 1379.
- Ramos, J., et al. (2017b). Hypernetworks: capturing the multilayers of cooperative and competitive interactions in soccer. International Congress Complex Systems in Sport, Frontiers.
- Ramos, J. P. D. (2019). Complex Networks Analysis in Team Sports Performance: Multilevel Hypernetworks Approach to Soccer Matches, ISCTE-Instituto Universitario de Lisboa (Portugal).
- Reilly, T., et al. (2005). Applications of Dynamical Systems Theory to Football. Science and Football V, Routledge, 570–572.
- Ribeiro, J., et al. (2019). The Role of Hypernetworks as a Multilevel Methodology for Modelling and Understanding Dynamics of Team Sports Performance. *Sports Medicine*, 1–8.
- Ribeiro, J., et al. (2020). A multilevel hypernetworks approach to capture meso-level synchronisation processes in football. *Journal of Sports Sciences* 38(5), 494–502.
- Sasaki, K., et al. (2017). Network centrality analysis to determine the tactical leader of a sports team. *International Journal of Performance Analysis in Sport* 17(6), 822–831.
- Vilar, L., et al. (2012). The role of ecological dynamics in analysing performance in team sports. *Sports Med* 42(1), 1–10.



Künstliche neuronale Netze

Markus Tilp

Inhaltsverzeichnis

- 20.1 Beispiel Sport – 190
- 20.2 Hintergrund – 191
- 20.3 Anwendungen – 192
- Literatur – 197

Kernbotschaften

- Künstliche neuronale Netze sind in ihrem Aufbau und ihrer Funktion dem biologischen Nervensystem nachempfunden.
- Sie bestehen aus sogenannten Neuronen, die in mehreren Schichten angeordnet sind. Zwischen den Neuronen der einzelnen Schichten bestehen Verbindungen, die Signale zwischen den Neuronen weiterleiten und diese dabei verstärken oder abschwächen.
- Eingangsinformationen werden in ein Ausgangssignal umgewandelt, ohne dass man die konkreten Zusammenhänge kennen muss.
- Es gibt verschiedene Arten, wie künstliche neuronale Netze arbeiten, z. B. unterscheidet man zwischen Netzen, die Zusammenhänge überwacht (*supervised*) oder unüberwacht, also komplett selbstständig (*unsupervised*), lernen.
- Es hat sich gezeigt, dass künstliche neuronale Netze im Sport genutzt werden können, um z. B. Muster zu erkennen oder Prognosen zu erstellen.
- Es ist zu erwarten, dass künstliche neuronale Netze in verschiedenen Bereichen der Sportwissenschaft in Zukunft verstärkt erfolgreich eingesetzt werden.

20.1 Beispiel Sport

Das biologische Nervensystem verändert sich beim Erlernen einer Bewegung oder beim wiederkehrenden Erkennen einer taktischen Situation. Wird eine komplexe Bewegung mithilfe der Ansteuerung der Muskulatur durch viele Nervenzellen in ähnlicher Weise oft wiederholt, merkt sich das Nervensystem das Zusammenspiel der entsprechenden Nervenzellen (des Marées, 2003). Die Nervenzellen bekommen dabei Informationen über die sogenannten Dendriten und geben, falls ein Schwellenwert erreicht wird, der die Nervenzelle aktiviert, ihrerseits Informationen über ihr Axon weiter. Diese Strukturen und die Synapsen, d. h. die Verbindungen zwischen den Zellen, verstärken sich, wenn sie oft genutzt werden, oder verkümmern, wenn sie nicht genutzt werden. Nach einer Trainingsphase wird die Bewegung dadurch immer besser und ökonomischer. Treten andererseits bestimmte Spielsituationen immer wieder auf, werden diese vom sensorischen Nervensystem immer in ähnlicher Weise erfasst. Mit der Zeit lernt das Nervensystem, die auftretenden Muster zu identifizieren, und kann die Situationen, z. B. eine Finte in einem Sportspiel, erkennen.

Künstliche neuronale Netze arbeiten auf ähnliche Weise. Ihre Neuronen bekommen Informationen von anderen Neuronen und geben diese weiter. Anstatt der Veränderung der Synapsen, die im Laufe der Zeit die Signalweitergabe anpassen und dabei verstärken oder abschwächen, werden bei künstlichen neuronalen Netzen die Rechenvorschriften zwischen zwei Neuronen angepasst. Die Phase dieser Anpassung wird ebenfalls Training genannt. Hat ein neuronales Netz mithilfe von Eingangsdaten ausreichend trainiert/gelernt, können z. B. Spielmuster eines Sportspiels erkannt werden (vgl. Grunz, Memmert & Perl, 2012; Memmert & Perl, 2009a, b; Perl, Grunz & Memmert, 2013).


20.2 Hintergrund

Es gibt verschiedene Arten von Netzwerkstrukturen, von denen hier die einfachsten dargestellt werden sollen. Werden z. B. Informationen immer nur in einer Richtung weitergegeben (von einer Eingangsschicht in Richtung einer Ausgangsschicht), spricht man von einem Feedforward-Netz. Kann das Netz hingegen auf frühere Berechnungen zurückgreifen, indem Rückkopplungen zugelassen werden, spricht man von einem Feedback-Netz (Backpropagation).

Die Grundstruktur eines neuronalen Feedforward-Netzes besteht aus einer Eingabeschicht (Input Layer), die ihrerseits aus mehreren Neuronen besteht, einer oder mehreren verdeckten Schichten (Hidden Layer) und einer Ausgabeschicht (Output Layer). Die einzelnen Neuronen einer Schicht sind mit allen Neuronen der nächsten Schicht in Verbindung (s. ■ Abb. 20.1). Umgekehrt bekommt jedes Neuron Informationen von allen Neuronen der vorherigen Schicht. Die Verbindungen legen fest, wie stark ein Wert eines Neurons zum nächsten weitergegeben wird, man spricht hier von dem Gewicht der Verbindung. Das Gewicht (engl. *weight*) der Verbindung z. B. des Neurons 2 und Neuron 5 aus der nächsten Schicht (■ Abb. 20.1) wird dabei mit w_{25} bezeichnet. Der Eingangswert eines Neurons ergibt sich aus den gewichteten Werten aller vorgeschalteten Neuronen. Dabei können diese Werte durch lineare oder nicht lineare Rechenvorschriften kombiniert werden. Diese Rechenvorschrift nennt man Propagierungsfunktion; sie ist im einfachsten Fall die Summe aller gewichteten Werte der eingehenden Neuronen (s. Rechenbeispiel 1).

Der Eingangswerte eines Neurons aus der Propagierungsfunktion werden nun über eine sogenannte Aktivierungsfunktion weiterverarbeitet. Ähnlich wie in der Natur ein Neuron nur dann aktiv wird, wenn ein gewisses Spannungspotenzial überschritten wird, gibt es Rechenvorschriften, die aus dem Eingangswert einen Aktivitätswert des Neurons berechnen. Es gibt unterschiedliche Arten von Aktivierungsfunktionen (z. B. Stufenfunktion, die einen konstanten Wert ab einem bestimmten Schwellenwert ergibt). Der sich ergebende Aktivitätswert kann dann zur nächsten Schicht weitergeleitet werden oder stellt im Falle eines Neurons der Outputschicht den Ausgabewert dar.

■ **Abb. 20.1** Grundstruktur eines neuronalen Netzes mit Eingabeschicht (Neuronen 1–3), verdeckter Schicht (Neuronen 4 und 5) und Ausgabeschicht (Neuron 6)



Die Gewichte zwischen den Neuronen sind variabel und können sich an die Daten anpassen. Die Phase dieser Anpassungen, in der dem neuronalen Netz eine Menge an Eingangsdaten zur Verfügung gestellt wird, nennt man Trainings- oder Lernphase. Während dieser Phase werden die Gewichte zwischen den Neuronen gemäß vorgegebenen Lernregeln verändert. Dabei unterscheidet man in überwachtes (*supervised*) oder unüberwachtes (*unsupervised*) Lernen. Beim überwachten Lernen werden dem Netz sowohl Eingangsdaten als auch die zugehörige Ausgangsdaten zur Verfügung gestellt, so wie ein/e Lehrer*in dem/r Schüler*in die Aufgabe und die Lösung sagt. Beim Lernen vergleicht das Netz die berechneten und die vorgegebenen Ausgangswerte und passt die Gewichtungen auf Basis der Differenzen fortlaufend an, bis die Differenzen einen vorgegebenen Schwellenwert unterschreiten. Die Art, wie die Differenzen berechnet werden, wird in einer sogenannten Fehlerfunktion festgelegt. Netztypen für überwachtes Lernen sind z. B. Perzeptron, Multi-Layer-Perzeptron (MLP) oder Radiale-Basisfunktion-Netze (RBF-Netze). Beim unüberwachten Lernen werden nur Eingangsdaten zur Verfügung gestellt. Das Netz versucht dann, die Eingabedaten aufgrund ihrer Ähnlichkeit auf benachbarten Neuronen abzubilden. So werden ähnlichen Eingabedaten nach der Trainingsphase ähnliche Ausgabedaten zugeordnet. Ein Netztyp für unüberwachtes Lernen ist z. B. eine Kohonen-Feature-Map (KFM). Der verwendete Netztyp hängt also von der Aufgabe ab, die ein Netz lösen soll. Für die verschiedenen Netztypen, Lernregeln, Propagierungs-, Aktivierungs- und Fehlerfunktionen wird auf die weiterführende Literatur verwiesen (z. B. Backhaus et al., 2006; Sanderson, 2017)

Definition

Künstliche neuronale Netze sind informationsverarbeitende Systeme, die der Vernetzung von Nerven in Lebewesen nachempfunden sind. Sie bestehen aus sogenannten Neuronen, die in einzelnen Schichten aufgebaut sind. Über die Verbindungen zwischen den Neuronen werden Eingabeinformationen mit Ausgabeinformationen miteinander verbunden. Künstliche neuronale Netze sind ein Teilgebiet der künstlichen Intelligenz und werden für Klassifikations-, Prognose- und Optimierungsaufgaben eingesetzt.

20.3 Anwendungen

► Rechenbeispiel 1

Ein künstliches neuronales Netz soll helfen vorherzusagen, ob ein/e gegnerische/r Angreifer*in im Beachvolleyball eher einen harten Angriffsschlag oder einen gezielten Shot spielen wird. Wir gehen davon aus, dass die Spielpositionen während der Annahme, des Zuspiels und des Angriffs diese Entscheidung beeinflussen. Als Netzeingangsdaten dienen deshalb die Entfernung der Annahmeposition des Angreifers vom Netz (in Metern), die Entfernung des Zuspielers vom Netz zum Zeitpunkt des Zuspiels (in Metern) sowie die Entfernung der Angriffsposition vom Netz (in Metern). Da es sich

um einen überwachten Lernprozess handelt (*supervised*), wird dem Netz die Angriffsvariante (0 = Angriffsschlag, 1 = Shot) als Ausgangsinformation ebenfalls mitgeteilt. Das künstliche neuronale Netz besteht in diesem Fall aus einer Eingabeschicht mit drei Neuronen (Distanzen zum Netz von Annahmeposition, Zuspieldisposition, Angriffsposition) und einer Ausgabeschicht mit einem Neuron (Angriffsvariante). Die Gewichte zwischen den Neuronen werden zu Beginn zufällig ausgewählt und im Laufe des Lernprozesses angepasst. Als Lernregel könnten die Gewichte z. B. immer um 5 % der Eingabewerte der aktuellen Situation (Lernrate) erhöht oder verringert werden, je nachdem, ob das Ergebnis zu niedrig oder zu hoch war. Entspricht das dem Ergebnis, bleiben die Gewichte unverändert (■ Abb. 20.2).

Aus einem Beispieldatensatz (s. ■ Tab. 20.1), in welchem die aus einem Spiel erhobenen Daten angeführt werden, soll die Funktionsweise eines künstlichen neuronalen Netzes nun erläutert werden. Nimmt man die Daten der ersten Zeile aus dem Beispieldatensatz (■ Tab. 20.1), ergibt sich aus den Eingabedaten und den zugehörigen Gewichten $w_{14} = -0,1$, $w_{24} = 0,3$ und $w_{34} = 0,2$ ein Wert von $0,6$ ($4 \cdot (-0,1) + 3 \cdot 0,3 + 0,5 \cdot 0,2$) (s. ■ Tab. 20.2). Dieser Wert wird dann von einer Aktivierungsfunktion weiterverarbeitet. Im Beispiel würde sich eine Schwellenwertfunktion anbieten, die z. B. bei Werten $< 0,5$ den Wert 0 (Angriff) und bei Werten $\geq 0,5$ den Wert 1 (Shot) annimmt. Die Anwendung der Aktivierungsfunktion würde im konkreten Fall den Wert 1 (Shot) ergeben, da $0,6$ größer als $0,5$ ist. Da der/die Spieler*in in der realen Situation aber einen Angriff (Wert 0) gespielt hat (s. ■ Tab. 20.1), würden die Gewichte vor der Berechnung der zweiten Spielsituation angepasst werden. In diesem Fall würden die Gewichte um 5 % der Eingabewerte aus Situation 1 verringert werden. Die neuen Gewichte wären $w_{14} = -0,1 - 0,05 \cdot 4 = -0,3$, $w_{24} = 0,3 - 0,05 \cdot 3 = 0,15$ und $w_{34} = 0,2 - 0,05 \cdot 0,5 = 0,175$. Nun wird mit den neuen Eingabedaten aus Situation 2 (Annahmeposition = 6 m, Zuspieldisposition = 1 m, Angriffsposition = 1 m) und den neuen Gewichten der neue Eingabewert berechnet. Es ergibt sich ein Wert von $-1,475$ ($= 6 \cdot 0,3 + 1 \cdot 0,15 + 1 \cdot 0,175$). Da dieser Wert $< 0,5$ ist, würde die Aktivierungsfunktion den Wert 0 (Angriff) ergeben. Dieser Wert stimmt wieder nicht mit dem beobachteten Verhalten (Shot) überein, weshalb die Gewichte wieder angepasst werden. Dieser Vorgang wird mit einer möglichst großen Menge an Eingangsdaten so oft wiederholt, bis die Vorhersagen eine vorgegebene ausreichende Genauigkeit erreichen. Dann hat das Netz den Zusammenhang gelernt und kann aufgrund von Daten aus einem (neuen) Eingabedatensatz (Annahmeposition, Zuspieldisposition, Angriffsposition) eine Vorhersage treffen, ob der Spieler den Ball hart schlägt oder einen Shot spielt. ◀



■ **Abb. 20.2** Rechenbeispiel 1: links: allgemeine Struktur des Netzes zur Vorhersage der Angriffsvariante; rechts: Berechnung des Eingabewertes des Ausgangsneurons aufgrund der Eingabedaten und der Gewichte

■ **Tab. 20.1** Beispieldatensatz

| | Distanz Annahme | Distanz Zuspield | Distanz Angriff | Angriffsverhalten |
|-------------|-----------------|------------------|-----------------|-------------------|
| Situation 1 | 4 | 3 | 0,5 | (0) Angriff |
| Situation 2 | 6 | 1 | 1 | (1) Shot |
| Situation 3 | 4,5 | 2 | 0,5 | (0) Angriff |
| ... | ... | ... | ... | ... |

■ **Tab. 20.2** Eingabedaten (e_i), Gewichte (w_{ij}), gewichtete Ausgabewerte und Summen (= Eingabewerte) aus dem Beispieldatensatz. Die Gewichte erhöhen oder verringern sich immer um 5 % der Eingabedaten

| | Annahme
$= e_1$ | Zuspield
$= e_2$ | Angriff
$= e_3$ | w_{14} | w_{24} | w_{34} | $e_1 \cdot w_{14}$ | $e_2 \cdot w_{24}$ | $e_3 \cdot w_{34}$ | Summe |
|--------|--------------------|---------------------|--------------------|----------|----------|----------|--------------------|--------------------|--------------------|--------|
| Sit. 1 | 4 | 3 | 0,5 | -0,1 | 0,3 | 0,2 | -0,4 | 0,9 | 0,1 | 0,6 |
| Sit. 2 | 6 | 1 | 1 | -0,3 | 0,15 | 0,175 | -1,8 | 0,15 | 0,175 | -1,475 |
| Sit. 3 | 4,5 | 2 | 0,5 | 0 | 0,2 | 0,225 | 0 | 0,4 | 0,1125 | 0,5125 |
| ... | | | | | | | | | | |

► Beispiel 2 Mustererkennung

Im Handball studieren Mannschaften Spielzüge ein, die günstige Torwurfsituationen ergeben sollen. Die Spieler*innen und der Ball legen dabei festgelegte Lauf- und Passwege zurück. Nun ist es von Interesse, die Spielzüge einer gegnerischen Mannschaft zu identifizieren, d. h., es sollen Muster im Spiel identifiziert werden. Künstliche neuronale Netze haben die Fähigkeit, Muster in Daten zu erkennen. Auf Basis von Positionsdaten der Passstationen aus Handballspielen haben Schrapf und Tilp (2013) ein künstliches neuronales Netz (Kohonen-Feature-Map) genutzt, um die Spielzüge der Mannschaften zu identifizieren. Es wurden Positionsdaten aus 612 Spielzügen, jeweils bestehend aus der Position des Wurfes und den vorausgehenden fünf Passstationen, verwendet. Um einen größeren Datensatz von 3060 Spielzügen zu erreichen, wurden die Daten verrauscht (d. h. mit einem zufälligen Datenrauschen versehen). Mit diesem Datensatz konnte das neuronale Netz 42 verschiedene Angriffsvarianten ermitteln. Über die Kontrolle der zugehörigen Videosequenzen bestätigten Experten*innen, dass die Angriffsvarianten des neuronalen Netzes tatsächlichen Spielzügen entsprachen. Interessanterweise bestanden 49 % aller Angriffe nur aus acht Angriffsvarianten, d. h., eine kleine Auswahl an Angriffsvarianten wurde bevorzugt benutzt. Zur Validierung konnten im Anschluss die echten Daten mit den durch das Netz identifizierten Angriffsvarianten verglichen wer-

den. Die durchschnittliche Abweichung war mit 1,2 m ausreichend gering. Ein Vorteil der Nutzung eines neuronalen Netzes im Vergleich zu klassischen statistischen Analysen ist, dass neben der Wurfposition auch die Passpositionen, aus denen sich die Wurfposition erst ergibt, in die Analysen mit eingehen. Dies ermöglicht, auch die Entstehung von Wurfsituationen zu analysieren. ◀

► Beispiel 3 Situationsvorhersage/Prognose

Bodenreaktionskräfte bei der Lokomotion geben Auskünfte über die Belastung und Leistung beim Gehen und Laufen. Die Messung von Bodenreaktionskräften ist allerdings sehr aufwendig, teuer und meist nur in Labors möglich. Komaris et al. (2019) haben künstliche neuronale Netze (überwacht, Feedforward mit Eingangs-, Ausgangs- und einer verdeckten Schicht) verwendet, um über Bewegungsdaten die Bodenreaktionskräfte der drei Raumrichtungen (x, y, z) bei drei unterschiedlichen Geschwindigkeiten (2,5 m/s, 3,5 m/s, 4,5 m/s) zu berechnen. Für jede Raumrichtung wurde ein künstliches neuronales Netz benutzt. Als Eingangsdaten dienten die Beschleunigungsdaten der Unterschenkel aus 3D-Bewegungsanalysen (= Eingangsdaten) sowie die zugehörigen Kraftkurven (= Ausgangsdaten) von einem Laufband mit Kraftmessplatten von 28 professionellen Läufern. Die Beschleunigungs- und Kraftkurvenverläufe wurden so skaliert, dass jeder Datensatz 100 Datenpunkte (1–100 % des Bewegungszyklus) enthielt. Entsprechend bestanden die Eingangs- und Ausgangsschichten ebenfalls aus jeweils 100 Neuronen. Die verdeckte Schicht bestand aus zehn Neuronen. In der Trainingsphase wurden die Datensätze von 16 zufällig ausgewählten Personen, in einer Validierungs- und Testphase jeweils die Datensätze von sechs Personen verwendet. Die Differenzen zwischen den berechneten und echten Bodenreaktionskräften waren unabhängig von den Geschwindigkeiten und ausreichend gering, sodass die Methode verwendet werden kann, um die Bodenreaktionskräfte aus den Beschleunigungen der Unterschenkel abschätzen zu können. Diese können relativ einfach, z. B. über inertielle Messeinheiten (Kombination mehrerer Inertialsensoren, z. B. Beschleunigungssensoren und Drehratensensoren), erhoben werden. ◀

Studienbox

Gerade in Sportspielen ist die Antizipation (Vorhersage von Spielaktionen) ein wichtiger Faktor für den Erfolg. Es ist bekannt, dass Expert*innen in einem Sportspiel, z. B. aufgrund von Beobachtungen der Position oder Körperhaltung des Gegners/der Gegnerin, Aktionen ihrer Gegner*innen frühzeitig erkennen können. Schrapf et al. (2022) nutzten ein künstliches neuronales Netz (Multi-Layer-Perzeptron) für die Vorhersage von Angriffs-

positionen im Hallenvolleyball. Im Hallenvolleyball ist es speziell für die Blockspieler wichtig, die Position des Angriffs möglichst früh zu kennen, um eine gute Position für den Block einzunehmen. Die Forscher*innen trainierten ihr neuronales Netz mit den Positionen der Annahmespieler*innen zum Zeitpunkt der Annahme sowie des Zuspielers/der Zuspielerin zum Zeitpunkt der Annahme und des Zuspiels, der Flugbahn der Annahme (Zeit), der Art

des Zuspiels (unteres oder oberes Zuspiel), der Bewegung während des Zuspiels (stehend, im Sprung, im Lauf, im Hechtbagger). Zusätzlich wurden dem Netz in der Trainingsphase noch die Angriffsposition (Positionen 2, 3, und 4 am Netz sowie Hinterfeld) und die Zuspielzeit ($< 0,8$ sec, $0,8\text{--}1,2$ sec, $> 1,2$ sec) als Ausgangsdaten zur Verfügung gestellt. Die Vorhersagen des neuronalen Netzes wurden im Anschluss mit Vorhersagen von Expert*innen (Trainer*innen auf Nationalteamniveau) verglichen. Diese mussten die Angriffsposition und Zuspielzeit aus einem Video schätzen, das kurz vor dem Zuspiel gestoppt wurde. Obwohl das neuronale Netz im Vergleich zu den Expert*innen nur eine beschränkte Information an Eingangsdaten zur Ver-

fügung hatte, waren die Vorhersagen der Angriffsposition etwa gleich gut (68,1 % vs. 65,3 % korrekte Vorhersage) und bei der Zuspielzeit sogar signifikant besser (79,2 % vs. 64,6 % korrekte Vorhersage) als die der Expert*innen. Das Ergebnis zeigt, dass neuronale Netze fähig sind, Aktionen in Sportspielen mit ähnlichen Erfolgsraten wie Expert*innen zu prognostizieren. Durch die Variation der Eingangsdaten könnte das Ergebnis vermutlich noch verbessert werden und im Rahmen von Wahrnehmungstraining auf die wesentlichen Vorhersageparameter hingewiesen werden. Ein entsprechendes Antizipationstraining ist auch für Athlet*innen in anderen Sportarten wie z. B. Handball (Hassan et al., 2017) möglich.

? Fragen für die Studierenden

1. Wie nennt man die verschiedenen Schichten eines künstlichen neuronalen Netzwerks?
2. Woraus ergibt/berechnet sich der Wert eines Neurons?
3. Wie lernt ein neuronales Netz während der Trainingsphase?
4. Nennen Sie zwei konkrete Anwendungsbeispiele, wie man neuronale Netze im Sport nutzbar machen kann.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Backhaus, K., Erichson, B., Plinke, W., & Weiber, R. (2006) Neuronale Netze. In *Multivariate Analysemethoden* (pp. 750–806), 11. Auflage. Springer, Berlin, Heidelberg, New York.
- Des Marées, H. (2003) *Sportphysiologie*, 9. Auflage, Sportverlag Strauß, Hellenthal.
- Grunz, A., Memmert, D. & Perl, J. (2012). Tactical pattern recognition in soccer games by means of special self-organizing maps. *Human Movement Science*, 31, 334–343.
- Hassan, A., Schrapf, N., & Tilp, M. (2017). The prediction of action positions in team handball by non-linear hybrid neural networks. *International Journal of Performance Analysis in Sport*, 17, 293–302.
- Komaris, D.S., Pérez-Valero, E., Jordan, L., Barton, J., Hennessy, L., O’Flynn, B., & Tedesco, S. (2019) Predicting Three-Dimensional Ground Reaction Forces in Running by Using Artificial Neural Networks and Lower Body Kinematics. *IEEE Access*, vol. 7, 156779–156786.
- Memmert, D. & Perl, J. (2009a). Analysis and Simulation of Creativity Learning by Means of Artificial Neural Networks. *Human Movement Science*, 28, 263–282.
- Memmert, D. & Perl, J. (2009b). Game Creativity Analysis by Means of Neural Networks. *Journal of Sport Science*, 27, 139–149.
- Perl, J., Grunz, A. & Memmert, D. (2013). Tactics in soccer: an advanced approach. *International Journal of Computer Science in Sport*, 12, 33–44.
- Sanderson, G. (2017, August 1). Neural networks. [Video]. YouTube. https://www.youtube.com/watch?v=aircAruvnKk&list=PLZHQObOWTQDNU6R1_67000Dx_ZCJB-3pi
- Schrapf & Tilp (2013) Action sequence analysis in team handball. *Journal of Human Sport and Exercise*, 8(3), 615–621.
- Schrapf, N., Hassan, A., Wiesmeyr, S., & Tilp, M. (2022) An Artificial Neural Network Predicts Setter’s Setting Behavior in Volleyball Similar or Better than Experts. *IFAC-PapersOnLine*, 55–20, 612–617.



Tiefe neuronale Netzwerke

Dominik Raabe

Inhaltsverzeichnis

- 21.1 Beispiel Sport – 200
- 21.2 Hintergrund – 201
- 21.3 Anwendungen – 202
- Literatur – 206

Kernbotschaften

- Tiefe neuronale Netzwerke sind neuronale Netze mit mehreren Schichten und potenziell Millionen von Parametern sowie potenziell Milliarden von Verbindungen.
- Sie werden erfolgreich für besonders komplexe Lernprobleme in der Forschung und industriellen Anwendung in diversen Feldern wie beispielsweise der Bilderkennung oder Sprachverarbeitung eingesetzt.
- Die Fähigkeit, komplexe Lernprobleme zu meistern, geht in der Regel mit einem hohen Bedarf an Trainingsdaten, intensiven Rechenzeiten und einer niedrigen Transparenz des trainierten Modells einher.
- Im Bereich Sport gibt es unzählige Einsatzfelder für tiefe neuronale Netze, von der Datenakquise über die Extraktion semantischer Ereignisse bis hin zur Analyse von komplexen taktischen Mustern.

21.1 Beispiel Sport

Tiefe neuronale Netzwerke sind eine Erweiterung und Entwicklung der klassischen neuronalen Netzwerke (s. ► Kap. 20) im Bereich der künstlichen Intelligenz. Während die Netzwerke in den Anfangsjahren ihrer Entwicklung oft nur aus wenigen Neuronen und maximal einer verdeckten Schicht (sog. Hidden Layer) bestanden, können moderne „tiefe“ neuronale Netze aus mehreren Hundert Millionen Neuronen, angeordnet in einer Vielzahl von verdeckten Schichten und Milliarden von Verbindungen zwischen den Neuronen bestehen. Der Unterschied zu den klassischen Netzen besteht demnach in der Anzahl der Schichten und Neuronen. Mitunter wird der Begriff „tiefes Lernen“ heutzutage jedoch auch inflationär für andere Methoden verwendet, um die besondere Komplexität eines Modells hervorzuheben. Eng verbunden mit der Größe dieser Netzwerke ist aber auch die sprunghaft gestiegene Leistungsfähigkeit, denn mittlerweile sind tiefe neuronale Netze ihren kleineren Vorfahren bei zahlreichen Problemen auf standardisierten Datensätzen (sog. Benchmark-Datensätze) deutlich voraus.

Aufgrund dieser Leistungsfähigkeit sind tiefe neuronale Netze heutzutage äußerst populär und werden für Anwendungs- oder Forschungsprobleme in unterschiedlichsten Domänen wie der Bilderkennung und -verarbeitung (sog. Computer Vision), Spracherkennung, Textverarbeitung, Medizin, Bioinformatik, Klimaforschung, aber auch im Sport eingesetzt. So haben beispielsweise erst die Fortschritte im Bereich der Computer Vision die Entwicklung von optischen (also kamerabasierten) Trackingverfahren zur Akquise von Positionsdaten mit akzeptabler Genauigkeit begünstigt. Denn bei diesen Verfahren werden die Spieler*innen und somit auch ihre Positionen mithilfe von tiefen neuronalen Netzen im Kamerabild detektiert. Die allerneuesten Verfahren können sogar aus einer Fernsehübertragung die Positionen extrahieren oder die genaue Silhouette der Spieler*innen schätzen (s. ► Kap. 4). Auch im Bereich der Analyse von Sportdaten finden sich zunehmend Methoden, welche dem tiefen Lernen zugeordnet werden können.

21.2 Hintergrund

Obwohl einige historische Vorläufer der modernen tiefen Netzwerke bereits zum Ende des 20. Jahrhunderts entwickelt wurden, lässt sich der Durchbruch dieser Methoden auf das Jahr 2012 datieren. In diesem Jahr konnten tiefe neuronale Netzwerke zum ersten Mal konventionellen Methoden im Bereich der Spracherkennung Paroli bieten (Hinton et al., 2012). Außerdem wurden in der Bilderkennung mehrere neue Rekorde auf den gängigen Benchmark-Datensätzen erzielt, was einer Kombination aus Netzwerkarchitektur, -größe, sowie Rechenpower zu verdanken war (Ciresan et al., 2012; Krizhevsky et al., 2017). Hier kamen sogenannte Convolutional Neural Networks (CNNs) zum Einsatz, welche in ihrem Aufbau der Funktionsweise des menschlichen visuellen Kortex nachempfunden sind und die Charakteristika des tiefen Lernens anschaulich darstellen.

Diese CNN-Architekturen bestehen aus mehreren Schichten, welche modulartig aufgebaut sind und sequenziell aneinanderhängen. Daten – in diesem Fall Bilder, kodiert als Matrizen von Pixelfarbwerten – werden über eine Eingangsschicht in das Netzwerk gespeist und dann Schritt für Schritt durch die einzelnen Schichten gereicht, wobei jeder Schicht eine eigene Aufgabe zukommt. Frühere Schichten sollen demnach untergeordnete Merkmale (sog. Features) des Bildes erkennen, wie Kontraste oder einzelne Farbbereiche, während spätere Schichten komplexere Features wie zunächst Linien und Formen bis hin zu Körperteilen oder Gegenständen detektieren sollen. Diese Logik folgt der Annahme, dass „höhere“ Konzepte, wie beispielsweise ein Gesicht, sich aus „niedrigeren“ Konzepten, wie beispielsweise den Augen und der Nase, zusammensetzen, welche sich wiederum aus Linien oder Punkten zusammensetzen. Dieser hierarchische Aufbau von Konzepten ist eine der Grundlagen großer Netzwerkarchitekturen (LeCun et al., 2015).

Dementsprechend hat sich die Komplexität moderner Netzwerkarchitekturen in den letzten Jahren drastisch vervielfacht. Obwohl diese nach wie vor weitestgehend aus Neuronen, Aktivierungs- und Propagierungsfunktionen bestehen, wird ihre Verschachtelung immer fortgeschrittener. Die direkte, komplette Verknüpfung von zwei aufeinanderfolgenden Schichten, welche frühere neuronale Netzwerke auszeichnet, ist mittlerweile nur noch eines von unzähligen Modulen. Stattdessen gibt es beispielsweise Module, welche Neuronen zu vorherigen Netzwerkschichten rückkoppeln (sog. rekurrente neuronale Netze) oder einzelne Datenpunkte innerhalb des Netzes zufällig löschen, um ein robusteres Training zu ermöglichen (sog. Dropout). Die Suche nach neuen Modulen sowie das Verbinden dieser Module zu Architekturen bilden einen wesentlichen Teil der aktuellen Forschung.

Tiefe neuronale Netzwerke besitzen jedoch auch einige Nachteile, welche mit ihrer schieren Größe einhergehen. Diese Netzwerke bestehen aus mehreren Hundert bis Milliarden von „trainierbaren“ Parametern – beispielsweise Gewichte der einzelnen Propagierungsfunktionen –, welche im Lernprozess angepasst werden, was sowohl praktische als auch theoretische Probleme mit sich bringt. Um die einzelnen Parameter anzupassen, also die Lösung zu „erlernen“, erfordern diese Methoden in der Regel viele Trainingsdaten (beim überwachten Lernen), lange Rechenzeiten und damit verbunden Ressourcen wie Hardware oder Energie. Eines der größten bisher

konstruierten Netzwerke, das GPT-3 im Bereich der Textverarbeitung, wartet mit 175 Mrd. Parametern auf (Brown et al., 2020). Das Training mit insgesamt 45 Terabyte an komprimiertem Textmaterial (ca. 400 Mrd. Zeichen) lief auf einem Supercomputer mit 10.000 Recheneinheiten über ungefähr einen Monat. Die geschätzten Kosten liegen im Bereich von mehreren Millionen US-Dollar, die Laufzeit, hochgerechnet auf eine einzelne Recheneinheit, bei mehreren Hundert Jahren. Obwohl dies ein Extrembeispiel ist, zeigt es, dass die Durchführbarkeit sowohl für Probleme mit kleineren Datensätzen (welche teilweise per Hand erstellt werden müssen) als auch durch finanzielle Rahmenbedingungen limitiert ist.


Darüber hinaus ist es aufgrund der Komplexität dieser Modelle nicht möglich, die finalen Vorhersagen eines trainierten Netzwerkes nachzuvollziehen. Aufgrund der hohen Anzahl von Parametern sind diese Modelle in der Regel eine „Blackbox“ mit intransparenten Wirkmechanismen. Wieso ein Netzwerk eine bestimmte Vorhersage trifft, bleibt zum Großteil sein Geheimnis. Davon abgesehen sind, aus der wissenschaftlichen Perspektive, simple und transparente Modelle den komplexeren und intransparenten Modellen vorzuziehen. Aufgrund dieser Nachteile befasst sich die Forschung heute intensiv mit Modellen, welche auf Basis sehr weniger Trainingsdaten lernen sowie für Menschen nachvollziehbare Vorhersagen liefern.

Definition

Tiefe neuronale Netze bzw. tiefes Lernen (häufig wird auch der englische Begriff „Deep Learning“ genutzt) bezeichnen eine Gruppe von Verfahren des maschinellen Lernens und insbesondere neuronale Netze, welche sich durch ihre Vielschichtigkeit und Größe auszeichnen. Solch große Netzarchitekturen bestehen häufig aus mehreren Teilmodulen mit unterschiedlichem Aufbau und Funktionsweise, welche modular miteinander verknüpft und gekoppelt werden. Dieser Ansatz folgt der Annahme, dass sich das zu erlernende Konzept in der realen Welt aus mehreren, hierarchisch aufgebauten Teilkonzepten zusammen setzt. In einer tiefen Lernmethode sollen diese sequenziell bis hin zum finalen Konzept durch die verschiedenen Netzwerkschichten erlernt werden – daher der Begriff „tiefes“ Lernen.

21.3 Anwendungen

Ein klassisches Beispiel für die Verwendung von tiefen neuronalen Netzwerken im Sportkontext ist die Generierung von Positionsdaten über sogenannte optische, also kamerabasierte Trackingsysteme. Diese Systeme zeichnen sich durch ihre Nicht-Invasivität aus, da die Spieler*innen keine zusätzliche Sensorik am Körper tragen müssen. Mithilfe der Netzwerke können die Spieler auf dem Kamerabild erkannt werden, und unter Verwendung von bis zu 20 Kameras mit unterschiedlichem Blickwinkel können die genauen Positionen ermittelt werden.



■ **Abb. 21.1** Schematischer Aufbau einer beispielhaften Verarbeitungspipeline zur Extraktion von Positionsdaten aus einer Fernsehübertragung. Übernommen von Theiner et al. (2022)

Während diese Kameras normalerweise in der Stadioninfrastruktur fest verbaut und kalibriert sind, ist die Technik heute so weit fortgeschritten, dass bereits ein dynamisches Kamerabild (beispielsweise einer TV-Übertragung) genutzt werden kann, um Spielerpositionen zu extrahieren. Dafür müssen allerdings mehrere Schritte neben der Identifikation der Spieler*innen durchgeführt werden, um genaue Positionen zu erhalten. Theiner et al. (2022) zeigen beispielhaft eine gesamte Pipeline, welche diese Aufgabe lösen kann (s. ■ Abb. 21.1). Diese besteht aus Schritten zur Identifikation der einzelnen Kameraschnitte, Auswahl aller Sequenzen, welche aus der Totalen gefilmt werden, Erkennung des Spielfeldes und Schätzung der Spielfeldkalibrierung, Erkennung der Spieler*innen, Extraktion der Positionen sowie Zuordnung von Identitäten. Bei fast allen diesen Teilschritten kommen Verfahren des tiefen Lernens zum Einsatz und zeigen höhere Präzision als herkömmliche Methoden.


Die Studie von Wagenaar et al. (2017) hingegen benutzt bereits verarbeitete Positionsdaten und befasst sich mit der Frage, ob Torchancen mithilfe von tiefen neuronalen Netzwerken (den oben beschriebenen CNNs) vorhergesagt werden können. Dazu wurden in einem Experiment mehrere Netzwerkarchitekturen mit ansteigender Komplexität verwendet. Aus Positionsdaten von Fußballspielen extrahierten die Autoren kurze Sequenzen von zehn Sekunden Länge, welche entweder in einem Torabschluss endeten oder nicht. Basierend auf diesem Datensatz wurde ein binäres Klassifikationsproblem formuliert, und die Aufgabe für die Netzwerke bestand darin, bei einer gezeigten Sequenz zu entscheiden, ob ein Torabschluss erfolgt – oder eben nicht. Da, wie beschrieben, CNNs aus der Bildverarbeitung stammen, wurden die rohen Positionsdaten zunächst in 256×256 Pixel große Bilder transformiert, welche die jeweilige Spielszene schematisch in einer zweidimensionalen Pixelgrafik darstellen (s. a. ► Kap. 23). Diese Repräsentation der Rohdaten wurde als Eingangsdaten für die verschiedenen Netzwerke genutzt. Zum Einsatz kamen ein vergleichsweise kleines und schlichtes CNN, ein zum damaligen Zeitpunkt äußerst performantes GoogLeNet sowie ein K-nächste-Nachbarn-Ansatz als Baseline. Gegenüber der Baseline mit im Schnitt 57,3 % Klassifizierungsgenauigkeit konnten die tiefen neuronalen Netzwerke deutlich bessere Ergebnisse erzielen: Die beste GoogLeNet-Variante erreichte eine durchschnittliche Genauigkeit von 67,1 %.

Studienbox

Die oben beschriebene Studie ist eine der ersten, welche spieltaktische Ereignisse wie Torabschlüsse auf der Basis von Positionsdaten und mithilfe von tiefem Lernen vorherzusagen versucht (Wagenaar et al., 2017). Es stellt sich jedoch die Frage, inwiefern eine Repräsentation von Positionsdaten in Pixelgrafiken für das spezifische Problem angemessen ist. Etwas allgemeiner ergibt sich die Frage, welche Datenrepräsentation und welche Netzwerkmodule bzw. -architekturen besonders passend für die Verarbeitung von Positionsdaten sind. Die Wahl selbiger hat nämlich entscheidenden Einfluss sowohl auf das Abschneiden in sportspezifischen Lernproblemen als auch auf die dazugehörige Modellkomplexität und die benötigten Stichprobengrößen im Lernprozess. In einer ähnlichen Studie schlagen Raabe, Nabben et al. (2022) daher eine graphenbasierte Datenrepräsentation und ein passendes tiefes neuronales Netz, bestehend aus mehreren Teilmodulen, vor (s. ■ Abb. 21.2). Die Rohpositionen der Spieler*innen werden hier als Knoten in einem Graph dargestellt, welche durch ihre jeweilige Interaktionen miteinander verknüpft sind. Diese Darstellung soll domänenspezifische Charakteristika von Sportarten ausnutzen und so die

Leistungsfähigkeit des Netzes verbessern. Des Weiteren haben Graphen interessante mathematische Eigenschaften (so genannte Invarianzen), welche die Notwendigkeit von Trainingsdaten reduziert. Graphenbasierte neuronale Netzwerke sind eine neue Entwicklung im Bereich des tiefen Lernens, welche die Verarbeitung von nicht-euklidischen Eingangsdaten ermöglicht.

In einem experimentellen Vergleich wurde anschließend diese neuronale Netzwerkarchitektur mit anderen Architekturen getestet. Als Lernproblem wurde eine binäre Klassifikationsaufgabe konstruiert, bei der kurze Sequenzen von Positionsdaten hinsichtlich der Frage beurteilt werden sollten, ob die Sequenzen in einem Ballgewinn der verteidigenden Mannschaft resultierten – oder eben nicht. Zum Vergleich kamen eine simple Baseline und vier unterschiedliche Datenrepräsentationen zum Einsatz. Zum einen ein reiner featurebasierter Ansatz, bei dem aus den rohen Positionsdaten zahlreiche gängige Key-Performance-Indikatoren (KPIs) berechnet und diese anschließend in einer logistischen Regression verwertet wurden. Des Weiteren wurden tiefe



■ **Abb. 21.2** Die genutzte, graphenbasierte tiefe neuronale Netzwerkarchitektur aus Raabe, Nabben et al. (2022)

neuronale Netzwerke basierend auf den rohen Positionsdaten, also eines langen Vektors mit den Spielerpositionen, sowie basierend auf einer Darstellung als Pixelgrafiken wie in der Studie von Wagenaar et al. (2017)

verwendet. Schließlich kam auch die vorgeschlagene graphenbasierte Architektur zum Einsatz.

Die Ergebnisse dieses Vergleichs sind in der folgenden Tabelle zusammengefasst:

| Modell | Datenrepräsentation | Anzahl Parameter | Klassifizierungsgenauigkeit |
|------------------------|---------------------|------------------|-----------------------------|
| Baseline | - | 1 | 74,5 % |
| Logistische Regression | KPIs | 10 | 76,8 % |
| SVGRU | Rohdaten | 499.970 | 71,6 % |
| CNN | Bilder | 437.506 | 61,4 % |
| GoogLeNet | Bilder | 9.936.038 | 80,4 % |
| TGNet | Graphen | 109.212 | 80,5 % |

Zusammenfassend lässt sich sagen, dass sowohl das komplexeste GoogLeNet mit fast 10 Mio. Parameter als auch das vorgeschlagene graphenbasierte Modell TGNet die mit Abstand besten Klassifizierungsergebnisse erzielen konnten. Allerdings ist das TGNet deutlich schlanker und kommt mit einem Bruchteil der Parameter aus, zudem sind die benötigten Trainings-, Inferenz- und Anpassungszeiten deutlich geringer (Raabe, Nabben et al., 2022). Es lässt sich also festhalten, dass die Entwicklung und Auswahl von passenden tiefen neuronalen Netzwerkarchitekturen auch im Sport zentrale Auf-

gaben sind, um das maximale Potenzial des tiefen Lernens für sportspezifische Fragestellungen zu nutzen. Um dies zu ermöglichen, sind jedoch noch weitere Rahmenbedingungen essenziell. Insbesondere für die Weiterentwicklung des tiefen Lernens im Bereich des Sports sind geeignete, öffentlich zugängliche Benchmark-Datensätze sowie transparente Darstellungen von genutzten Architekturen unabdingbar, welche in dieser Domäne deutlich schwächer ausgeprägt sind als in jenen Feldern, in denen das tiefe Lernen bereits bahnbrechende Erfolge erzielen konnte (Raabe, Biermann et al., 2022).

? Fragen für die Studierenden

1. Was unterscheidet tiefe neuronale Netzwerke von „klassischen“ neuronalen Netzwerken?
2. Was sind die Nachteile tiefer neuronaler Netzwerken und wodurch entstehen sie?
3. Wie lauten drei beispielhafte Klassen von tiefen neuronalen Netzwerken?
4. Was zeichnet den grundlegenden Aufbau tiefer neuronaler Netzwerken aus?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springer-nature.com.

Literatur

- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., ... Amodei, D. (2020). Language Models are Few-Shot Learners (arXiv:2005.14165). *arXiv*. <http://arxiv.org/abs/2005.14165>
- Ciresan, D., Meier, U., & Schmidhuber, J. (2012). Multi-column deep neural networks for image classification. *2012 IEEE Conference on Computer Vision and Pattern Recognition*, 3642–3649. <https://doi.org/10.1109/CVPR.2012.6248110>
- Hinton, G., Deng, L., Yu, D., Dahl, G., Mohamed, A., Jaitly, N., Senior, A., Vanhoucke, V., Nguyen, P., Sainath, T., & Kingsbury, B. (2012). Deep Neural Networks for Acoustic Modeling in Speech Recognition: The Shared Views of Four Research Groups. *IEEE Signal Processing Magazine*, 29(6), 82–97. <https://doi.org/10.1109/MSP.2012.2205597>
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2017). ImageNet classification with deep convolutional neural networks. *Communications of the ACM*, 60(6), 84–90. <https://doi.org/10.1145/3065386>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Raabe, D., Biermann, H., Bassek, M., Wohlan, M., Komitova, R., Rein, R., Groot, T. K., & Memmert, D. (2022). floodlight – A high-level, data-driven sports analytics framework. *Journal of Open Source Software*, 7(76), 4588. <https://doi.org/10.21105/joss.04588>
- Raabe, D., Nabben, R., & Memmert, D. (2023). Graph representations for the analysis of multi-agent spatiotemporal sports data. *Applied Intelligence*, 53(4), 3783–3803. <https://doi.org/10.1007/s10489-022-03631-z>
- Theiner, J., Gritz, W., Müller-Budack, E., Rein, R., Memmert, D., & Ewerth, R. (2022). Extraction of positional player data from broadcast soccer videos. *Proceedings of the IEEE/CVF winter conference on applications of computer vision (WACV)*, 823–833.
- Wagenaar, M., Okafor, E., Frencken, W., & A. Wiering, M. (2017). Using Deep Convolutional Neural Networks to Predict Goal-scoring Opportunities in Soccer. *International Conference on Pattern Recognition Applications and Methods*. <https://doi.org/10.5220/0006194804480455>



Convolutional Neural Networks

Yannick Rudolph und Ulf Brefeld

Inhaltsverzeichnis

22.1 Beispiel Sport – 208

22.2 Hintergrund – 209

22.3 Anwendungen – 211

Literatur – 214

Kernbotschaften

- Convolutional Neural Networks (CNNs) sind wichtige Modelle für das maschinelle Lernen auf der Grundlage von Bildern oder Daten mit vergleichbarer Gitterstruktur.
- Im Bereich des überwachten Lernens extrahieren CNNs z. B. Merkmale für Klassifizierung und Entdeckung.
- CNNs zeichnen sich durch Parameter Sharing und ihre Eigenschaften bezüglich verschobener Eingaben aus.
- CNNs eignen sich auch dazu, Merkmale räumlicher Situationen zu lernen, die durch Positionsdaten von Teamsportarten gegeben sind.

22.1 Beispiel Sport

Im Bereich der Sportanalyse können Bilder, Videos oder Positionsdaten (s ► Kap. 6) wesentliche Informationen zu bestimmten Eigenschaften, zu guten oder schlechten Aktionen von einzelnen Akteur*innen oder eines Teams liefern. In der Regel werden diese Informationen von eigens geschulten Analysten aus den jeweiligen Quellen gewonnen. Dieser Prozess ist jedoch zeitaufwendig, da die Analysten das komplette Material sichten müssen, um relevante Situationen zu entdecken.

Mithilfe von maschinellem Lernen kann die Arbeit der Analysten teilautomatisiert werden, indem der Computer die Daten nach Relevanz filtert. Durch die Verarbeitung sehr großer Datenmengen können oftmals auch bisher unbekannte statistische Zusammenhänge entdeckt werden.

Betrachten wir ein fiktives Expected-Goals-Modell (xG-Modell) im Fußball als motivierendes Beispiel. Die Idee hinter xG ist die Bewertung von Torchancen durch Wahrscheinlichkeiten. Die Wahrscheinlichkeit gibt an, wie oft vergleichbare Torchancen zu einem Tor führen. Je höher der xG, desto wahrscheinlicher ist es, dass eine Situation zu einem Tor führt. Als Modell eignet sich hier z. B. eine probabilistische Klassifikation durch eine logistische Regression, die mithilfe der beobachteten Ereignisse („Tor“ oder „kein Tor“) gelernt wird.

Dazu müssen die Torchancen aufbereitet werden und in einer computerlesbaren Repräsentation vorliegen, die sich für die Klassifikationsaufgabe eignet. Beim maschinellen Lernen extrahieren wir daher Merkmale, die die Situationen beschreiben und die es dem Computer erlauben, eine gute Repräsentation der in den Daten enthaltenen Konzepte zu finden. Für unser xG-Beispiel eignen sich Merkmale wie Distanz und Winkel von Spieler oder Spielerin zum Tor, die Anzahl beteiligter Gegenspieler*innen, ein Indikator, ob beispielsweise die Torfrau im Tor ist, ob eine oder mehrere Spieler*innen die Schussbahn blockieren usw. Die Bestimmung solcher Merkmale erfordert allerdings oft substanziellen Aufwand und ist häufig nicht trivial.

Convolutional Neural Networks (CNNs) bieten hier eine Alternative. Zunächst müssen dazu die Torchancen mithilfe von Positionsdaten in eine bildähnliche Gitterstruktur konvertiert werden, in der z. B. jeder Pixel im Gitter einem Quadratmeter auf dem Spielfeld entspricht und die Positionen der Spieler*innen und des

Balles entsprechend markiert sind. Die so transformierten Torchancen können nun direkt als Eingabe in das CNN verwendet werden, um die Wahrscheinlichkeit eines Tores maschinell zu lernen. Die aufwendige Extraktion von hilfreichen Merkmalen für die Aufgabe entfällt, da das CNN selbst die Merkmale generiert, die sich für die erfolgreiche Bearbeitung der Lernaufgabe am besten eignen. Das CNN lernt dabei Merkmale und Klassifikation gleichzeitig (Stichwort: End-to-End-Lernen). Gerade, wenn es schwierig ist, relevante Merkmale manuell zu definieren, erzielen Modelle, welche End-to-End gelernt werden können, meistens die besten Ergebnisse. Wie bei anderen End-to-End-Methoden gehen diese Erfolge mit dem Nachteil der schlechten Interpretier- und Erklärbarkeit der Modelle einher.

22.2 Hintergrund

Am üblichsten ist die Anwendung von Convolutional Neural Networks (CNNs) im Zusammenhang mit dem maschinellen Lernen auf Bildern. Grundsätzlich eignen sich CNNs jedoch für alle Daten mit ein- oder zwei- und sogar höherdimensionaler Gitterstruktur. Andere neuronale Netze, die sich vom Grunde her auch dazu eignen würden, Merkmale aus Bildern oder bildähnlichen Daten zu extrahieren (Fully-Connected Neural Networks) sind in der Regel entweder zu flach, oder aber mit sehr vielen Parametern ausgestattet. In beiden Fällen lassen sich die Modelle oft nicht effizient lernen.

Vorgänger von modernen CNNs (Fukushima, 1980) und frühe CNNs wie das LeNet-Modell (LeCun et al., 1998, s. a.  Abb. 22.2) konnten bereits handgeschriebene Ziffern anhand von Bildern klassifizieren. Parallel dazu wurden in der klassischen Computer Vision visuelle Merkmale wie Kanten oder Verläufe anhand von Pixelwerten in Bildern heuristisch bestimmt. Eine häufig eingesetzte Technik nutzte z. B. eine skaleninvariante Merkmalstransformation (SIFT), um die so berechneten Merkmale in einem zweiten Verarbeitungsschritt für eine Klassifikationsaufgabe zu verwenden.

Seit der Vervielfachung von Daten und Rechenleistung extrahieren CNNs effizient Merkmale, die zu deutlich besseren Ergebnissen führen als klassische Verfahren. Eine auf Grafikprozessoren (GPUs) trainierte CNN-Architektur (AlexNet; Krizhevsky et al., 2012) hat z. B. im Jahr 2012 einen Klassifikationswettbewerb auf dem bedeutenden ImageNet-Datensatz (Deng et al., 2009) mit sehr großem Abstand gegenüber klassischen Verfahren gewonnen.

In der Regel werden in CNNs mehrere Convolutional Layer kombiniert, um die Daten zu verarbeiten. In einem Convolutional Layer operieren meist mehrere Convolutional Filter mit lernbaren Parametern auf den Daten. Man kann sich diese Operationen so vorstellen, dass die Filter (im zweidimensionalen Fall eine Matrix mit lernbaren Einträgen) über die Eingabe bewegt werden und durch die Summe der punkweisen Multiplikation mit der darunter liegenden Eingabe für jede Position des Filters eine Ausgabe berechnen. Da ein Convolutional Filter mehrmals auf einer Eingabe angewendet wird, haben Convolutional Layer vergleichsweise weniger Parameter als traditionelle Fully-Connected Layer. Man spricht in diesem Zusammenhang auch von Parameter Sharing.

■ **Abb. 22.1** Beispielhafte Darstellung einer Filteroperation; die Summe der punktweisen Multiplikation (in Farbe) berechnet sich wie folgt: $1 \cdot 2 + 7 \cdot 0 + 8 \cdot 1 + 3 \cdot 3 = 19$

| | | |
|---|---|---|
| 1 | 7 | 5 |
| 8 | 3 | 2 |
| 9 | 4 | 6 |

*

| | |
|---|---|
| 2 | 0 |
| 1 | 3 |

=


| | |
|----|----|
| 19 | 23 |
| 37 | 28 |

Zur Veranschaulichung einer Filteroperation s. a. ■ Abb. 22.1. Zu sehen sind eine Eingabe, ein Convolutional Filter und die sich aus der Anwendung des Filters resultierende Ausgabe. In der Visualisierung sind die Werte zur Berechnung des linken oberen Ausgabewerts hervorgehoben (die Berechnung ist in dem Abbildungstext gegeben). Wenn die Eingabe mehr als zwei Dimensionen hat (z. B. haben Farbbilder neben den Dimensionen Höhe und Breite mehrere Farbkanäle), haben Eingabe und Filter auch mehr Dimensionen. Die Ausgabe einer Filteroperation bleibt dabei eine Matrix. Bei mehreren Convolutional Filtern in einem Layer werden die jeweiligen Ausgaben (auch Channels oder Feature Maps genannt) kombiniert und bilden einen mehrdimensionalen Tensor.

Die Beispielrechnung in ■ Abb. 22.1 eignet sich dazu, eine Eigenschaft von CNNs zu veranschaulichen: Wenn wir die Eingabe um eine Spalte nach rechts verschieben (und links z. B. mit Nullen auffüllen) und erneut denselben Convolutional Filter anwenden, würden wir die gleiche Rechnung für die rechte obere Ausgabe durchführen. Der Ausgabewert verschiebt sich in diesem Fall also auch nach rechts. Diese Eigenschaft von CNNs, für verschobene Eingabe eine gleichsam verschobene Ausgabe zu generieren, wird oft als Translationsäquivalenz – oder in Bezug auf die finale Repräsentation als Translationsinvarianz – beschrieben. Anschaulich bedeutet Translationsinvarianz, dass ein CNN, welches gelernt hat, Bälle in einem bestimmten Bereich eines Bildes zu klassifizieren, auch Bälle in anderen Bildbereichen erkennen kann. Das Netz kann dadurch generalisieren, also allgemein gültige Zusammenhänge erlernen, und diese auch auf neuen Daten erfolgreich anwenden. Für echte Translationsäquivalenz oder -invarianz müssen allerdings spezielle Konditionen vorliegen (vgl. dazu auch Kayhan und van Gemert, 2020).

Meist werden in CNN-Architekturen mehrere Convolutional Layer verwendet, von denen das erste Layer auf der Eingabe operiert und die nachfolgenden Layer auf den jeweiligen Ausgaben der früheren Layer. Dabei werden Merkmale in Layern tiefer (das heißt: näher an der finalen Ausgabe) liegen, in der Regel von einer größeren Region der Eingabe beeinflusst. In Anlehnung an die Biologie des menschlichen Auges nennen wir diese Region auch das rezeptive Feld, da es der Bereich der Eingabe ist, den das Merkmal sehen kann. Auch dadurch, dass das rezeptive Feld mit der Tiefe eines Layers wächst, können CNNs umso komplexere Merkmale extrahieren, desto weiter die Eingabe durch das Netzwerk propagiert werden.

■ Abb. 22.2 veranschaulicht eine – nach heutigen Standards – relativ einfache CNN-Architektur. In der Abbildung sind neben Convolutional- auch Subsampling-Operationen abgebildet. Tatsächlich beinhalten viele CNN-Architekturen neben Convolutional Layern auch weitere Layer, wie z. B. Pooling Layer für Subsampling oder sogenannte Residual Layer (He et al., 2016). Unter anderem Residual Layer



■ **Abb. 22.2** Die LeNet-5-CNN-Architektur zur Klassifikation von handschriebenen Ziffern. (LeCun et al., 1998)

ermöglichen es dabei, sehr tiefe CNN-Architekturen (das heißt: Modelle mit vielen Layern) erfolgreich zu trainieren. Dabei bleibt der Anwendungsbereich von modernen CNNs nicht auf Klassifikation oder Entdeckung beschränkt: CNNs werden auch in Modellen zum Erzeugen von künstlichen Bildern eingesetzt (z. B. Ramesh et al., 2021).

Definition

Convolutional Neural Networks (CNNs) sind künstliche neuronale Netzwerke, die insbesondere aus zweidimensionalen Daten mit Gitterstruktur effizient Repräsentationen lernen und Merkmale extrahieren können. Das Hauptmerkmal von CNN-Architekturen sind Convolutional Layer, bei denen die punktweisen Produkte von Filtern mit mehreren Bereichen der Eingabe zu entsprechenden Ausgabewerten aufsummiert werden. Eine Eigenschaft, die sich daraus ergibt, ist die der (bedingten) Translationsinvarianz: Die Ausgabe eines CNNs ist (bis zu einem gewissen Grad) unabhängig von Verschiebungen der Eingabe.

22.3 Anwendungen

► Beispiel 1

Bereits frühe CNNs konnten erfolgreich (handschriebene) Ziffern klassifizieren (s. Hintergrund). Gerke et al. (2015) konnten zeigen, dass sich CNNs auch für die automatische Erkennung von Nummern auf Trikots eignen. Dabei erstellten die Autoren einen Datensatz mit mehr als 8000 Bildern von Fußballer*innen mit lesbaren Trikotnummern und verglichen die Klassifikation mit einer CNN-Architektur mit einer Baseline-Klassifikation, die mit Merkmalen aus der klassischen Bildverarbeitung trainiert wurde. Die Studie kommt zu dem Ergebnis, dass ein relativ flaches CNN mit drei Convolutional Layern die Nummern sehr viel besser klassifiziert als die Baseline-Methode: Während die Baseline nur 40 % von ungesesehen Testbildern richtig zuordnet, kann das CNN bei 83 % der Testbilder die korrekten Nummern erkennen. Die Entdeckung der Spieler*innen in den Videobildern erfolgt bei Gerke et al. (2015) allerdings noch mithilfe von Methoden aus der klassischen Bildverarbeitung. ◀

► Beispiel 2

Auch für die Entdeckung von Entitäten auf Bildern können CNNs eingesetzt werden. Dass ein solcher Einsatz auch Auswirkungen auf die Sportanalytik haben kann, veranschaulicht z. B. eine Studie von Wei et al. (2016): In der Studie schlagen die Autoren sogenannte Convolutional Pose Machines vor, die die Erkennung von menschlichen Körperhaltungen auf Bildern (bekannt als Pose Prediction) durch den Einsatz von CNNs verbessert. Die Erkennung der Körperhaltung erfolgt dabei durch die Lokalisierung von bestimmten Körperteilen, die zusammengekommen die Körperhaltung beschreiben. Die Lokalisierung von Körperteilen nach Wei et al. (2016) erfolgt wiederum durch den sequenziellen Einsatz von CNN-Modellen. Während das erste CNN dabei lediglich auf den Bilddaten operiert, wird in nachfolgenden CNNs auch die Ausgabe der vorhergegangenen Modelle berücksichtigt. Die Idee dabei ist, dass Informationen zu relativ einfach zu erkennenden Körperteilen (z. B. Kopf und Schultern) mittels der ersten CNN-Modelle gewonnen werden können. Die Weitergabe dieser Informationen in die nachfolgenden CNNs kann dann die Entdeckung von schwieriger zu erkennenden Körperteilen (wie z. B. den Ellenbogen) erleichtern. Auf einem Datensatz mit Körperhaltungen aus acht Sportarten (Johnson und Everingham, 2011) konnten die Autoren dabei das zu der Zeit beste Ergebnis in Bezug auf richtig lokalisierte Körperteile erzielen. ◀

► Beispiel 3

Bei der automatischen Verarbeitung von Positionsdaten im Teamsport können CNNs auch als Bestandteil von komplexeren Modellen eingesetzt werden. Beispiele hierfür finden sich in der Studie von Fassmeyer et al. (2021), in der die Autoren die automatische Klassifikation von Spielsituationen im Fußball anhand von Positionsdaten untersuchen. Als Datengrundlage dienen dabei sequenzielle Positionsdaten mit 25 Positionen pro Sekunde, wobei jede einzelne Position in eine bildähnliche Gitterstruktur konvertiert wird. Die Umwandlung folgt dabei der Datentransformation in Dick und Brefeld (2019; s. Studienbox). Die von Fassmeyer et al. (2021) vorgeschlagenen Modelle verarbeiten sowohl die räumliche als auch die zeitliche Dimension der Daten: Pro Zeitschritt werden Merkmale der jeweiligen Positionen durch ein CNN extrahiert und als Eingabe in ein rekurrentes neuronales Netz (Recurrent Neural Network, RNN) gegeben. RNNs sind Modelle, die sich besonders gut für sequenzielle Daten eignen. Um auch Positionen ohne zugeordnete Klasse zum Training verwenden zu können (Stichwort: halbüberwachtes Lernen), werden die Modelle dabei angehalten, eine Repräsentation der Daten zu lernen, aus denen die Daten selbst wieder rekonstruiert werden können. Die Autoren schlagen zu diesem Zweck eine spezifische Autoencoder-Struktur vor. Fassmeyer et al. (2021) berichten für die so gewonnenen Repräsentationen sehr gute Ergebnisse bei der Klassifikation von Ecken und Flanken in den Daten. ◀


Studienbox

Auch Positionsdaten (vgl. ► Kap. 6) eignen sich für die Verarbeitung durch CNNs. In Dick und Brefeld (2019) schlagen die Autoren ein Modell vor, welches Positionen im Profi-Fußball mithilfe einer CNN-Architektur automatisch bewertet. Das CNN operiert dabei auf einer räumlichen Repräsentation von einzelnen Positionen. Die gewählte Repräsentation basiert auf der Idee, das Fußballfeld in ein zweidimensionales Gitter einzuteilen, in welches die zweidimensionalen Positionsangaben von Spieler*innen und Ball eingetragen werden. Dadurch werden Daten in eine bildähnliche Datenstruktur gebracht. Allerdings ist die Datenstruktur nicht durch die Eigenschaften von Bildern beschränkt. Anstelle von drei RGB-Farbkanälen werden mehrere Channels angelegt, in denen die Autoren verschiedene Informationen kodieren können. Konkret schlagen Dick und Brefeld (2019) neun Channels vor,

wobei alle Channels mit Nullen initialisiert werden. Siehe dazu auch das Beispiel in ■ Abb. 22.3.

In dem ersten Channel werden die Positionen der Spieler*innen des ersten Teams mit einem Wert von „1“ kodiert. Analog werden im zweiten und dritten Channel die Positionen des gegnerischen Teams und des Balles erfasst. In den Layern vier bis neun werden die Geschwindigkeiten von Spieler*innen und Ball erfasst. Dabei wird an der jeweiligen Position die Geschwindigkeit in sowohl Längs- als auch Querrichtung eingetragen.

Diese Repräsentation kann dann von einem CNN mit drei Layern verarbeitet werden. Die Ausgabe des CNN wird in ein Fully-Connected Layer gegeben, welches den Wert der jeweiligen Position schätzt (als zusätzliche Eingabe bekommt das Fully-Connected Layer dabei die Information über den Ballbesitz). Verglichen



■ **Abb. 22.3** Die Datenrepräsentation von Fußball-Positionsdaten zur Verarbeitung mit einem CNN nach Dick und Brefeld, (2019)

mit den Spielergebnissen, die sich aus den Positionen ergeben haben, können die Autoren auf die Nützlichkeit der gelernten Bewertung für die Sportanalyse schließen.

Unter anderem hilft die räumliche Repräsentation dabei, einem Permutationsproblem zu begegnen: Würde man die Daten direkt mit einem Fully-Connected Neural Network verarbeiten, würde die Ordnung der Spieler*innen in den Daten die Bewertung

einer Position beeinflussen. Die Repräsentation der Informationen von Spieler*innen eines Teams in nur einem Channel wirkt diesem Problem entgegen. Alternativ zu dem hier beschriebenen Ansatz hat sich die Repräsentation von Positionsdaten als Graphen und die Verarbeitung mit permutationsäquivalenten Modellen, wie z. B. Graph Neural Networks (z. B. Yeh et al., 2019) oder Transformern (vgl. Rudolph und Brefeld, 2022) etabliert.

? Fragen für die Studierenden

1. Warum eignen sich Fully-Connected Neural Networks in der Regel nicht für das maschinelle Lernen auf Bildern oder bildähnlichen Daten?
2. Unter welchen Bedingungen führt die Verarbeitung von zwei sich unterscheidenden Bildern durch dasselbe CNN zu der gleichen Repräsentation?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K. & Fei-Fei, L. (2009). Imagenet: A large-scale hierarchical image database. *IEEE Conference on Computer Vision and Pattern Recognition*, 248–255.
- Dick, U. & Brefeld, U. (2019). Learning to Rate Player Positioning in Soccer. *Big Data*, 7, 71–82.
- Fassmeyer, D., Anzer, G., Bauer, P. & Brefeld, U. (2021). Toward Automatically Labeling Situations in Soccer. *Frontiers in Sports and Active Living*, 3.

- Fukushima, K. (1980). Neocognitron: A Self-organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position. *Biological Cybernetics*, 36, 193–20.
- Gerke, S., Müller, K. & Schäfer, R. (2015). Soccer Jersey Number Recognition Using Convolutional Neural Networks. *IEEE International Conference on Computer Vision Workshop*.
- He, K., Zhang, X., Ren, S. & Sun, J. (2016). Deep Residual Learning for Image Recognition. *IEEE Conference on Computer Vision and Pattern Recognition*, 770–778.
- Johnson, S. & Everingham, M. (2011). Clustered Pose and Nonlinear Appearance Models for Human Pose Estimation. *IEEE Conference on Computer Vision and Pattern Recognition*.
- Kayhan, O. S. & van Gemert, J. C. (2020). On Translation Invariance in CNNs: Convolutional Layers can Exploit Absolute Spatial Location. *IEEE Conference on Computer Vision and Pattern Recognition*.
- Krizhevsky, A., Sutskever, I. & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. *Advances in Neural Information Processing Systems*.
- LeCun, Y., Bottou, L., Bengio, Y. & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86, 2278–2324.
- Ramesh, A., Pavlov, M., Goh, G., Gray, S., Voss, C., Radford, A., Chen, M. & Sutskever, I. (2021). Zero-Shot Text-to-Image Generation. *International Conference on Machine Learning*.
- Rudolph, Y. & Brefeld, U. (2022). Modeling Conditional Dependencies in Multiagent Trajectories. *International Conference on Artificial Intelligence and Statistics*.
- Wei, S.-E., Ramakrishna, V., Kanade, T. & Sheikh, Y. (2016). Convolutional Pose Machines. *IEEE Conference on Computer Vision and Pattern Recognition*.
- Yeh, R. A., Schwing, A. G., Huang, J. & Murphy, K. (2019). Diverse Generation for Multi-Agent Sports Games. *IEEE Conference on Computer Vision and Pattern Recognition*.



Transfer Learning

Henrik Biermann

Inhaltsverzeichnis

- 23.1 Beispiel Sport – 218
- 23.2 Hintergrund – 219
- 23.3 Anwendungen – 220
- Literatur – 224

Kernbotschaften

- Klassisches maschinelles Lernen (z. B. mit tiefen neuronalen Netzwerken, s. ► Kap. 21) erfordert generell sehr große Datenmengen (Big Data) sowie leistungsstarke Computersysteme (Rechencluster).
- Mittels Transferlernen können bereits vortrainierte Modelle (z. B. aus der Bildverarbeitung) für ein neues Problem genutzt werden.
- Dafür ist unter Umständen eine Transformation der Datenrepräsentation (Domäne) erforderlich.
- Dies kann unter anderem auch neue Einsichten in Problemstellungen eröffnen.


23.1 Beispiel Sport

Unabhängig von automatisiertem maschinellem Lernen besitzt das Konzept des Transfers zwischen verschiedenen Aufgaben (oder Fähigkeiten) im Sport eine besondere Bedeutung. So wurde beispielsweise bereits die menschliche Fähigkeit untersucht, Leistungen im Krafttraining in gute Performance in verschiedenen Sportarten zu übersetzen. Im Feld der Computerwissenschaften wird dieses Prinzip verwendet, um maschinell gelernte Modelle auf neue Aufgaben anzuwenden. Um dieses Vorgehen zu verdeutlichen, wird ein Beispiel aus der Fußball-Taktikanalyse vorgestellt. Basis für das Transferlernen sind oft leistungsstarke Modelle aus der Bildverarbeitung. Diese können zuverlässig viele verschiedene im Bild enthaltene Objekte erkennen. Wir wollen nun eines dieser Modelle mittels Transferlernen für eine Analyse (Rating) von Ballbesitzphasen verwenden. Um das gesamte Potenzial des Basismodells auszuschöpfen, benötigt das Modell als Eingang eine grafische Repräsentation der Daten (ein Bild oder Video). Hier können verschiedene Repräsentationen der Ballbesitzphase verwendet werden. Im einfachsten Fall kann man ein Videobild (z. B. Fernsehaufnahmen) der Ballbesitzphase verwenden. Allerdings gibt es auch Verfahren, um z. B. Positionsdaten (s. ► Kap. 6) in eine grafische Repräsentation umzuwandeln. So können die Positionen der Spieler etwa direkt als Punkte oder Kreise in einem abstrakten zweidimensionalen Bild angezeigt werden, welches dann als Eingang verwendet werden kann. Nachdem diese Transformationen vorgenommen sind, kann nun das Rating der Ballbesitzphasen vorgenommen werden. Hier ist es besonders interessant, die Ergebnisse der verschiedenen Repräsentationen einmal untereinander und einmal mit klassischen (featurebasierten) Verfahren zu vergleichen. So weisen z. B. schlechte Ergebnisse der Videobilder darauf hin, dass die große in den Videos enthaltene Redundanz die Modelle behindert. Andererseits belegen gute Ergebnisse der abstrakten zweidimensionalen Bilder, dass die Großzahl der interessanten Informationen aus den Positionsdaten in dieser Repräsentation enthalten ist. Zuletzt kann der Vergleich zu featurebasierten Verfahren mögliche Vorteile des Transferlernens zeigen.

23.2 Hintergrund

In den letzten Jahren haben sich in den verschiedensten Bereichen vermehrt Verfahren des maschinellen Lernens durchgesetzt, bei denen Modelle mit einer großen Zahl von (mehreren Millionen) Parametern auf bestimmte Aufgaben zugeschnitten werden. Dafür ist es erforderlich, die Modelle für diese Aufgabe zu trainieren. Dieses Training benötigt zum einen eine sehr große Menge an Daten (Big Data), damit die Modelle auch auf ungesehene Daten angewendet werden können, sowie zum anderen leistungsstarke Rechner (Rechencluster), um das Training in einer praktikablen Dauer durchführen zu können. Diese Voraussetzungen sind in der Regel nur bei großen Firmen gegeben. Für kleinere Gruppen (Forschungsteams), welche meist weder eine sehr große Menge von aufgabenspezifischen Daten noch Zugriff auf leistungsstarke Rechner haben, ist das Training dieser sehr großen Modelle daher meist nicht möglich. Während die Datenmengen und die Rechenkapazitäten von den Firmen nicht für den öffentlichen Gebrauch verfügbar gemacht werden, gibt es allerdings die Möglichkeit, die bereits vortrainierten Modelle aus dem Internet herunterzuladen. Ein Beispiel für ein solches Modell ist ein ImageNet (Russakovsky et al., 2015), ein tiefes neuronales Netzwerk (s. ► Kap. 21), welches über 1000 Objektkategorien in über 1 Mio. Bildern zuverlässig erkennen kann.

Hier kommt nun das Transferlernen ins Spiel. Basierend auf diesem Prinzip kann ein bereits für eine bestimmte Aufgabe designtes (und trainiertes) Modell für eine neue Aufgabe verwendet werden. Dafür kann der geschichtete Aufbau der Modelle, die aus verschiedenen unabhängigen Ebenen (Layern) bestehen, ausgenutzt werden. Im Beispiel von ImageNet bekommt das erste Layer des Netzwerks ein Bild (z. B. einer Orange), welches es verarbeitet und sein Ergebnis dann an die nächste Ebene des Netzwerks weitergibt. So wird das Bild sukzessive durch das Netz geschleust, bis im letzten Layer dann eine Objektklasse ausgegeben wird. In der Konsequenz wird im letzten Layer des Netzes also basierend auf dem Ausgang des vorletzten Layers die Objektklasse bestimmt. In der Konsequenz kann der Ausgang des vorletzten Layers als eine (hochdimensionale) Repräsentation (Merkmalsvektor) des ursprünglichen Eingangsbildes (Orange), welche alle notwendigen Informationen enthält, betrachtet werden. Da man eine einzelne Ebene (Layer) eines tiefen neuronalen Netzes in etwa mit einer Regression vergleichen kann (Dreiseitl und Ohno-Machado, 2002) (Regression, bei der Datenpunkte in einem [hochdimensionalen] Raum in verschiedene Subgruppen unterteilt werden), kann man in gewisser Weise davon ausgehen, dass die von den ersten Ebenen erstellten Merkmale domänenunabhängig sind. Für das Beispiel des ImageNets kann man also davon sprechen, dass die ersten Layer eine Bildverarbeitung vornehmen, die mit Operationen der „klassischen“ Bildverarbeitung (Kantenerkennung, Faltung etc.) vergleichbar ist. So kann das vortrainierte neuronale Netz also nicht nur in der Lage sein, die 1000 Objektkategorien zuverlässig zu erkennen, sondern auch (domänenunabhängig) die relevanten Informationen aus einem Bild zu extrahieren.



■ **Abb. 23.1** Übersicht über die Idee des Transferlernens

Daraus entsteht, neben der Möglichkeit sehr große Modelle kostengünstig zu verwenden, des Weiteren die Möglichkeit, aus dem Transfer zwischen den Domänen tiefgründige Erkenntnisse über die Struktur des Problems zu erfahren. Hierbei spielt die Transformation der Datenrepräsentation naturgemäß eine große Rolle. Dies ist besonders für komplexere Zusammenhänge interessant, wie sie z. B. in der Sportspielanalyse vorliegen (■ Abb. 23.1).

Definition

Transferlernen beschreibt das Vorgehen, ein maschinell trainiertes Modell für eine neue Aufgabe umzumünzen. Dies ermöglicht es, sehr große und leistungsstarke Modelle für bestimmte Aufgaben zu verwenden, auch ohne dass leistungsstarke Rechensysteme und große Datenmengen für die Aufgabe verfügbar sind.

23.3 Anwendungen

► Beispiel 1

Wie bereits dargestellt, werden üblicherweise tiefe neuronale Netzwerke aus der Bildverarbeitung als Ausgangsmodell verwendet. Von daher existieren naturgemäß Beispiele, bei denen Transferlernen genutzt wird, um den Inhalt von visuellen Daten automatisch zu erkennen. In einer Studie von Russo et al. (2019) wurde ein auf dem ImageNet-Datensatz (Russakovsky et al., 2015) vortrainiertes Netzwerk für die automatische Erkennung von Sportvideos eingesetzt (Russo et al., 2019). Dafür beziehen sich die Autoren auf einen Videodatensatz, bei dem Fernsehbilder von insgesamt 15 möglichen Sportarten (Fußball, Rugby, Tischtennis, Volleyball, Basketball, Cricket etc.) enthalten sind. Anhand dieses Datensatzes soll dann ein Modell trainiert werden, welches den Videos automatisch die richtige Sportart zuordnet. Die Ergebnisse der Studie zeigen, dass durch das Transferlernen des vortrainierten Modells der vorherige Goldstandard von 96 %

Genauigkeit auf eine perfekte Erkennung (100 % Genauigkeit) verbessert werden kann. Dies belegt eindrucksvoll die leistungsstarken bildverarbeitenden Elemente des vor-trainierten Modells und die Vorteile des Transferlernens. ◀

► Beispiel 2

Ein weiteres Beispiel zur Anwendung von Transferlernen in Videobildern stammt aus einer Studie von DeCampos et al. (2013). Hier wird ein Modell vorgestellt, welches Ereignisse in Videos automatisch erkennen kann. In diesem Modell ermöglicht ein hierarchischer Aufbau eine Abstraktion auf verschiedene semantische Ebenen. Die Autoren demonstrieren dies anhand einer Anwendung auf Fernsehbilder von Tennisspielen. Hier werden in der untersten (*low level*) Ebene zunächst einzelne Schläge erkannt. Dem folgen dann in oberen Ebenen schrittweise die Feldmarkierungen, die Spieler- und die Ballerkennung. Zuletzt besteht die oberste hierarchische Ebene in der Detektion von Ereignissen. Dies ermöglicht im Tennis eine automatische Annotation von z. B. Aufschlägen, Schlägen oder dem Ticken des Balles, was in der obersten hierarchischen Ebene bis zu einer automatischen Erkennung des aktuellen Spielstands geht. Diese besondere Struktur des Modells kann weiterhin auch für das Transferlernen angewendet werden. Demnach definieren die Autoren Anomalien, die in jeder hierarchischen Ebene detektiert werden können. So besteht eine Anomalie in einer der unteren hierarchischen Ebenen darin, dass die gezeigte Videoaufnahme nicht von einem Tennisspiel stammt, während eine Anomalie in einer oberen Ebene z. B. darin besteht, dass zu viele Spieler auf dem Feld erkannt werden. Wenn demnach in der untersten Ebene eine Anomalie (andere Sportart) erkannt wurde, löst dies automatisch lineare Transformationen aus, die dafür sorgen, dass das Modell sich an die neue Umgebung anpasst. Durch dieses Verfahren können die Autoren erfolgreich einen Transfer auf die Sportart Badminton durchführen. ◀

► Beispiel 3

Es existieren verschiedene Verfahren des Transferlernens, welche sich mit der Taktikanalyse im Sport beschäftigen. Als eine neue Möglichkeit der grafischen Repräsentation von Positionsdaten im Fußball wurden visuelle Rhythmen (Rodrigues et al., 2017) vorgestellt. Bei diesem graphenbasiertem Verfahren werden zunächst aus den Positionsdaten Graphen erstellt, aus denen dann wiederum bestimmte Merkmale (Features) extrahiert werden. Da diese Merkmale über die Zeit variieren (vgl. Zeitreihen, s. ► Kap. 25), können sie in visuelle Repräsentationen umgewandelt werden. Konkret kann man sich diese sogenannten visuellen Rhythmen als eine Aneinanderreihung von Pixeln vorstellen, bei der die Länge des Bildes die Dauer einer Situation kodiert. In diesen Aneinanderreihungen kann die Ausprägung (der Wert) des Merkmals dann z. B. durch sich verändernde Farben kodiert werden (vgl. Heatmap). Darüber hinaus können verschiedene visuelle Rhythmen für verschiedene Merkmale übereinandergestapelt werden, um so ein zweidimensionales Bild zu erstellen, das den Verlauf verschiedener Merkmale über einen Zeitraum widerspiegelt. So ergibt sich ein leistungsstarkes und übersichtliches Analysetool für individuellen Situationen in Fußballspielen, welches im Sinne des Transferlernens eine visuelle Repräsentation der Positionsdaten bieten kann. Damit können verschiedene taktische Konzepte detailliert evaluiert werden, wobei die konkrete Anwendung der visuellen Rhythmen für die maschinelle Fußballanalyse allerdings bisher noch nicht weiter untersucht ist. ◀

► Beispiel 4

Ein anderes Beispiel bietet eine Adaption des mittlerweile gut bekannte Algorithmus AlphaGo von Google DeepMind (Silver et al., 2016). Dessen Sieg gegen den professionellen Go-Spieler Lee Sedol (Anmerkung: Go entspricht in etwa einer Version von Schach und wird in China seit 3000 Jahren gespielt) wurde zu der Zeit von der Community als sehr bedeutend wahrgenommen. Allerdings wurde bereits zwei Jahre später eine Adaption des vorgestellt, der sogenannte AlphaZero-Algorithmus (Zhang & Yu, 2020). Dieser auf dem originalen AlphaGo basierende Algorithmus kann nun auch zusätzlich die Spiele Schach und Shogi spielen (Anmerkung: Shogi ist eine japanische Schachvariante). Eine weitere besondere Eigenschaft von AlphaGo ist, dass es ausschließlich durch Spiele gegen sich selbst trainiert wird und daher (abgesehen von den Spielregeln) keine externen Daten benötigt. In einem Schaukampf gegen den damaligen Goldstandard von Schachrobotern Stockfish 8 siegte AlphaGo in 100 Spielen klar mit 64:36. Dies zeigt die Wandelbarkeit des ursprünglichen Algorithmus sowie die Ähnlichkeit der Spiele Go und Schach. ◀


► Beispiel 5

Auch in anderen Bereichen wird Transferlernen vermehrt angewandt. Ein Beispiel aus der Domäne der Medizin besteht in dem Transfer von Netzen aus der ImageNet Challenge (Russakovsky et al., 2015), z. B. in der Domäne der Medizin. Dazu wurde hier die Challenge „Medical Segmentation Decathlon“ ausgerufen (Antonelli et al., 2021), bei der ein medizinischer Bilddatensatz mit zugehörigen Labeln veröffentlicht wurde. Mittels angewandtem Transferlernen sollen in dieser Challenge die medizinische Krankheitserkennung und Prävention maßgeblich verbessert werden. Konkret soll zum Beispiel für ein Bild entschieden werden, ob ein gesundes Gefäß oder ein schädlicher Tumor gezeigt wird. Besondere Schwierigkeiten sind bei diesem Problem die vergleichsweise geringe Anzahl der Daten und die verhältnismäßige Ähnlichkeit der Zielklassen. ◀

Studienbox

In einer Studie zur Anwendung von Transferlernen in der Fußballanalyse haben sich Wagenaar et al. (2017) die Frage gestellt, wie Angriffssequenzen im Fußball zuverlässig bewertet werden können. Dafür beobachteten sie Angriffssequenzen, welche entweder in einer Torchance oder in einem Ballverlust endeten. Als Ausgangsmodell für das Transferlernen diente hier ein so-

genanntes GoogLeNet, mit über 4 Mio. Parametern, welches in verschiedenen Konfigurationen entweder auf dem ImageNet-Datensatz (Russakovsky et al., 2015) vortrainiert oder nur auf dem vorliegenden Datensatz trainiert wird. Um die Positionen dann mit diesem Netzwerk zu analysieren, wird eine visuelle Repräsentation definiert. Im Detail werden für jeden Zeitpunkt aus den



■ **Abb. 23.2** Visuelle Repräsentation der Positionsdaten nach Beispiel von Wagenaar et al., (2017)

Positionsdaten dreikanalige (zweidimensionale) RGB-Bilder mit der Größe von 256×256 Pixeln erzeugt. Das Feld wird in dieser Darstellung als schwarzes Quadrat angezeigt, in das einige wichtige Feldmarkierungen (Außenlinien, Mittellinie und die beiden Sechzehnmeterlinien) enthalten sind. Die Spieler und der Ball werden entsprechend ihrer Koordinaten in den Positionsdaten als „Blobs“ (farbige Pixel) angezeigt. Außerdem werden beide Tore als farbige Striche dargestellt. Hier bekommt der Ball die Farbe Grün, das Heimteam die Farben Dunkelblau (Spieler), Cyan (Torwart) und Blau (Tor)

sowie das Auswärtsteam die Farben Rot (Spieler), Gelb (Torwart) und Orange (Tor). Um die Bewegungen während der Angriffssequenz darzustellen, sind weiterhin die Trajektorien der Spieler innerhalb der letzten zwei Sekunden als den Blobs angrenzende Linien angezeigt. Für die konkrete Rating-Aufgabe der Angriffssequenzen vergleichen die Autoren die besten Ergebnisse des GoogLeNet mit denen eines klassischen *K-nearest-neighbour*-Ansatzes (KNN-Ansatz). Hier zeigt sich, dass das Transferlernen eine um 10 % verbesserte Genauigkeit (67,1 %) im Vergleich zum KNN-Ansatz (57,3 %) aufweist (■ Abb. 23.2).

? Fragen für die Studierenden

1. Wo liegen die Vorteile des Transferlernens gegenüber einem „klassischen“ Maschinenlern-Ansatz?
2. Warum wird beim Transferlernen die letzte Ebene (Layer) des neuronalen Netzes entfernt?

23

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springer-nature.com.

Literatur

- Antonelli, M., Reinke, A., Bakas, S., Farahani, K., Landman, B. A., Litjens, G., ... & Cardoso, M. J. (2021). The medical segmentation decathlon. *arXiv preprint arXiv:2106.05735*.
- De Campos, T. E., Khan, A., Yan, F., FarajiDavar, N., Windridge, D., Kittler, J., & Christmas, W. (2013). A framework for automatic sports video annotation with anomaly detection and transfer learning. *Machine Learning and Cognitive Science, collocated with EUCOGIII*.
- Dreiseitl, S., & Ohno-Machado, L. (2002). Logistic regression and artificial neural network classification models: a methodology review. *Journal of Biomedical Informatics*, 35(5–6), 352–359.
- Rafiq, M., Rafiq, G., Agyeman, R., Choi, G. S., & Jin, S. I. (2020). Scene classification for sports video summarization using transfer learning. *Sensors*, 20, 1702.
- Rodrigues, D. C. U. M., Moura, F. A., Cunha, S. A., & Torres, R. D. S. (2017, February). Visualizing temporal graphs using visual rhythms – a case study in soccer match analysis. In *International Conference on Information Visualization Theory and Applications* (Vol. 4, pp. 96–107). SciTePress.
- Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., ... & Fei-Fei, L. (2015). ImageNet large scale visual recognition challenge. *International Journal of Computer Vision*, 115, 211–252.
- Russo, M. A., Kurnianggoro, L., & Jo, K. H. (2019, February). Classification of sports videos with combination of deep learning models and transfer learning. In *2019 international conference on electrical, computer and communication engineering (ECCE)* (pp. 1–5). IEEE.

- Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., Van Den Driessche, G., ... & Hassabis, D. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature*, 529, 484–489.
- Wagenaar, M., Okafor, E., Frencken, W., & Wiering, M. A. (2017, February). Using deep convolutional neural networks to predict goal-scoring opportunities in soccer. In *International Conference on Pattern Recognition Applications and Methods* (Vol. 2, pp. 448–455). SCITEPRESS.
- Zhang, H., & Yu, T. (2020). AlphaZero. In *Deep Reinforcement Learning* (pp. 391–415). Springer, Singapore.



Random Forest

Justus Schlenger

Inhaltsverzeichnis

- 24.1 Beispiel Sport – 228
- 24.2 Hintergrund – 229
- 24.3 Anwendungen – 230
- Literatur – 233

Kernbotschaften

- Random Forest ist ein Algorithmus des maschinellen Lernens, welcher auf der Verwendung einer Vielzahl von Entscheidungsbäumen für Vorhersagen beruht.
- Das Verfahren lässt sich ohne große Feinjustierung und Einstellungen (*out of the box*) verwenden.
- Der Random Forest kombiniert die simple und intuitive Eigenschaft von Entscheidungsbäumen mit der Komplexität und Flexibilität von Ensemble-Methoden.
- Besonders bei der Untersuchung von Performance-Indikatoren im Sport bietet sich der binäre Entscheidungscharakter an.

24.1 Beispiel Sport

Der Random-Forest-Algorithmus (RF), entwickelt von Breiman (2001), ist ein Machine-Learning-Verfahren, welches sich in den Datenwissenschaften hoher Beliebtheit erfreut. Dies lässt sich u. a. durch seinen fundamentalen Baustein, den Entscheidungsbaum, begründen. Die Struktur eines Entscheidungsbaumes spiegelt den Aufbau von Entscheidungsprozessen wider, wie sie z. B. auch im Sport eine wichtige Rolle spielen. Dies könnte die Entscheidung eines Fußballtrainers über einen Spielerwechsel, eine Spielerrekrutierung (Koenigstorfer und Wemmer, 2019) oder die taktische Entscheidung eines Tennisspielers bezüglich des gewählten Schlages sein.

Im Bereich der Computer- und Datenwissenschaften wird der RF-Algorithmus zu den Methoden des maschinellen Lernens bzw. der künstlichen Intelligenz gezählt. Das liegt daran, dass RF so wie andere Verfahren dieser Kategorie versuchen wird, anhand von bekannten Daten ein Modell zu generieren, welches daraufhin ermöglicht, Vorhersagen mit unbekannten oder zukünftigen Daten zu treffen. Der Sportinformatiker kann von diesen Vorhersagen z. B. in Bezug auf die Untersuchung von Sportwetten Gebrauch machen. Bei der beispielhaften Betrachtung eines einzelnen Basketballspiels müssen dafür Daten beider Teams bezüglich bestimmter Parameter erhoben werden. Das könnten mögliche Performance-Indikatoren sein, wie z. B. die Körpergrößen, die Laufdistanzen in vergangenen Spielen oder die Marktwerte der Spieler. Die Vielzahl an Entscheidungsbäumen wird nun mit den entsprechenden Parametern anhand von Ergebnissen vergangener Spiele trainiert (gebaut). Im Anschluss kann das Modell auf die Daten des zukünftigen Spiels angewendet werden, wodurch die Entscheidungsbäume einzelne Stimmen für das Endresultat des Spiels abgeben. Durch ein Mehrheitsrecht kann der Sportinformatiker nun nicht nur Vorhersagen für das Basketballspiel abgeben, sondern auch die Wichtigkeit der einzelnen im Modell verwendeten Parameter (eventuell KPIs) untersuchen.


24.2 Hintergrund

Die Funktionsweise des RF-Algorithmus lässt sich am besten an einem einzelnen binären Entscheidungsbaum verdeutlichen. Dabei beginnt man meist per Konvention oben an der „Wurzel“ und arbeitet sich durch die Verzweigungen bis an eines der „Blätter“ am unteren Ende des Baumes. Bei den Abzweigungen handelt es sich um sogenannte „Knoten“, und die dazwischenliegenden Linien werden als „Äste“ bezeichnet. In [Abb. 24.1](#) ist eine stark vereinfachte Variante eines Entscheidungsbaumes dargestellt. An der Wurzel und an den Knoten sind bestimmte Entscheidungsregeln platziert, welche entweder diskrete Kategorien oder Schwellenwerte beinhalten. Falls das Modell des Entscheidungsbaumes bereits trainiert wurde, kann dieser verwendet werden, um bei betrachteten Einheiten eine Klasse oder einen numerischen Wert vorherzusagen. Bei Erstem handelt es sich um einen Klassifizierungsbaum und beim Zweitem um einen sogenannten Regressionsbaum (Myles et al., 2004). Deshalb werden Entscheidungsbäume, begründet durch Breiman et al. (1984), auch „CARTs“ (Classification and Regression Trees) genannt.

Im Beispiel aus [Abb. 24.1](#) werden die binären Gruppen 0 und 1 anhand von Entscheidungsregeln bezüglich der Parameter x und z zugewiesen. Mit den Bezeichnungen aus der Statistik stellen die Klassen 0 und 1 die abhängigen Variablen und die Parameter x und z die unabhängigen Variablen dar. Somit handelt es sich in diesem Fall um einen Klassifizierungsbaum. Wie jedoch bereits erwähnt, muss ein Entscheidungsbaum erst gebaut werden, um für Klassifizierungs- oder Regressionsaufgaben sinnvoll eingesetzt zu werden. Um dies zu tun, müssen gelabelte Trainingsdaten vorhanden sein, also jene Daten aus vergangenen Events, in welchen die Endergebnisse bereits bekannt sind. Diese Art von Machine-Learning-Algorithmen gehören zu den Methoden des „überwachten Lernens“. Im Gegensatz dazu sind Methoden des unüberwachten Lernen durch fehlende Label gekennzeichnet.

Der Algorithmus für die Erstellung eines Entscheidungsbaumes läuft so ab, dass der gesamte Trainingsdatensatz (an der Wurzel startend) an jedem Knotenpunkt so aufgeteilt wird, dass möglichst homogene Gruppen entstehen. Dieser Prozess kann beliebig oft wiederholt werden, bis der Datensatz optimal in Bezug

Abb. 24.1 Skizze eines simplen Klassifizierungsbaumes



auf die gegebenen Labels aufgeteilt wurde oder die maximale Anzahl an Verzweigungen erreicht wurde. Diese maximale Anzahl an Verzweigungen kann vom Datenwissenschaftler bestimmt werden und wird als „Tiefe“ des Entscheidungsbaumes bezeichnet.

Wie sich allerdings zeigt, hat ein einziger Entscheidungsbaum eine sehr geringe Flexibilität gegenüber unbekannten Daten und tendiert dazu, die zufällige Varianz der Daten für die Entscheidungsfindung einzubeziehen (Biau und Scornet, 2016). Dieses Phänomen wird als „Overfitting“ bezeichnet und resultiert in einem Modell, welches nicht in der Lage ist, tatsächlich relevante Muster in den Daten zu erkennen. Aus diesem Grund bedient sich der Random Forest eines beliebig großen Ensembles aus Entscheidungsbäumen, welche allesamt unterschiedliche und zufällige Teilmengen der Daten und Parameter zur Verfügung haben. Wenn ein solcher Trainingsprozess abgeschlossen ist, kann entstandener Wald genau wie ein einzelner Baum dazu verwendet werden, Vorhersagen über unbekannte Daten zu treffen. Am Beispiel eines Klassifizierungsproblems entspricht die Vorhersage des Random-Forest-Algorithmus derjenigen Klasse, die die meisten „Stimmen“ der einzelnen Bäume bekommen hat. So kombiniert der Random-Forest-Algorithmus die intuitive und simple Struktur von Entscheidungsbäumen mit der flexiblen und robusten Art von Ensemble-Verfahren, welche Verwendung in zahlreichen „State-of-the-Art“-Methoden des maschinellen Lernens finden (Hastie et al. 2009). Zu guter Letzt, können nach Verwendung des Algorithmus jene Parameter herausgefiltert werden, die insgesamt zu der vergleichsweise besten Vorhersage verholfen haben.

24

Definition

Der Random Forest ist eine Ensemble-Methode des maschinellen Lernens, welche sich durch die Konstruktion zahlreicher leicht unterschiedlicher und unkorrelierter Entscheidungsbäume Klassifizierungs- oder Regressionsaufgaben widmet.


24.3 Anwendungen

► Beispiel 1 (Entscheidungsbaum -> RF)


Um die Verwendung eines einzelnen Entscheidungsbaumes zu skizzieren, wird das Beispiel des bereits erwähnten Basketballspiels gebraucht. Der in  Abb. 24.2 dargestellte Entscheidungsbaum soll anhand der Parameter Ballbesitz (BB) und Laufdistanz (LD) aus bisherigen Spielen den Sieg oder die Niederlage eines beliebigen Teams im kommenden Spiel vorhersagen. Dabei werden die entsprechenden Daten aus vergangenen Spielen gesammelt und in das Modell eingeschleust. Dadurch entsteht der Entscheidungsbaum aus  Abb. 24.2.

Wenn nun ein Team betrachtet wird, startet die Klassifizierung an der Wurzel, wobei man entweder bei einem durchschnittlichen Ballbesitz von über 50 % dem linken Ast und bei unter 50 % dem rechten Ast folgt. Angenommen, unser betrachtetes Team habe einen durchschnittlichen Ballbesitz von 60 %, so folgt ein weiterer Knoten, welcher einen

■ **Abb. 24.2** Exemplarische Darstellung eines Entscheidungsbaumes am Beispiel der Ergebnisvorhersage im Basketball. Die Parameter Ballbesitz (BB) und Laufdistanz (LD) werden als Entscheidungshilfe für die Vorhersage von Sieg (S) und Niederlage (N) verwendet



Basketballteam:
Boston Celtics
Ballbesitz (BB): 0.61
Laufdistanz (LD): 0.54



■ **Abb. 24.3** Random Forest mit sieben Entscheidungsbäumen am Beispiel des Basketballs. Der trainierte RF wird zur Vorhersage für das Team „Boston Celtics“ verwendet, welches einen durchschnittlichen Ballbesitz von 61 % und einen durchschnittlichen Anteil der gesamten Laufdistanz pro Spiel von 54 % aufweist

Schwellenwert bei 75 % hat. Da unser Team unter diesem Wert liegt (*false*), wird ein Sieg prognostiziert. Wenn diese Klassifizierung nun stattdessen mit einem bereits trainierten Random Forest stattfindet, wird jede untersuchte Einheit parallel durch alle Entscheidungsbäume befördert. In ■ Abb. 24.3 sind hypothetische Werte für das Team der Boston Celtics gewählt worden. Dadurch ergibt sich in jedem der unterschiedlichen Entscheidungsbäume eine Vorhersage über Sieg (S) oder Niederlage (N) für das anstehende Spiel.

Hier wird nun überprüft, welche der beiden Klassen häufiger zugeteilt wurde, um letztendlich per Mehrheitsrecht die häufigere Klasse als Vorhersage zu nutzen. ◀

► Beispiel 2 (RF)

In diesem Beispiel wird eine Studie von Smithies et al. (2021) betrachtet, welche darauf abzielt, Performance-Indikatoren des E-Sports „Rocket League“ zu finden, die Expertise und Erfolg der E-Sportler vorhersagen. Beim Videospiel „Rocket League“ steuert jeder Spieler einen Sportwagen mit Raketenantrieb und versucht, ähnlich wie beim teils bekannten „Autoball“, einen großen Ball in das gegnerische Tor zu befördern. Dabei

kann der Sportwagen auch an Wänden fahren und mittels des Raketenabtriebs durch die Luft fliegen. Es wird der Einfluss von Metriken wie „durchschnittliche Geschwindigkeit“, „Anzahl der Torschüsse“ und „Zeit in der Luft verbracht“ auf das Matchergebnis (Erfolg) und den Spielerrang (Expertise) getestet. Hierbei ergab die Analyse von 20.000 Matches, dass „getätigte Torschüsse“, „verhindern gegnerischer Torschüsse“ und „Ballrettungen“ bestmöglich das Endergebnis des Spiels vorhersagen. Andererseits lieferten für die Vorhersage des Spielerrangs (Ligasystem: Bronze, Silber, Gold ...) z. B. die Metriken „Zeit am Boden verbracht“ und „Zeit in Hochgeschwindigkeit“ die höchste Genauigkeit. ◀

24

► Beispiel 3 (RF + Poisson-Regression)

In der Studie von Groll et al (2019) wurde eine Hybridvariante des Random Forest zusammen mit einer Poisson-Regression benutzt, um Ergebnisse des FIFA World Cup 2018 vorherzusagen. Dabei wurden Poisson-Modelle verwendet, um ein Team-Ranking zu erstellen, welches die kürzliche Leistung des Teams stärker miteinberechnet als länger vergangene Leistungen. Somit sollte die aktuelle Teamstärke möglichst exakt bestimmt werden. Dieses erstellte Ranking konnte als weitere Kovariante für das Random-Forest-Modell eingebracht werden. Trainiert wurde das Modell mit Daten der FIFA World Cups 2002–2014. Die Vorhersagekraft war größer als bei anderen zu dieser Zeit bekannten Methoden einschließlich Wettquoten. Dies zeigt außerdem, dass der RF-Algorithmus ohne Weiteres mit anderen Methoden kombiniert werden kann. ◀

► Beispiel 4 (RF)

Der Leistungssport zeigt sich in vielen Sportarten als Business im Bereich der mehrfachen Millionen. Ein Element, welches gerade bei der Rekrutierung von Spielern gerne übersehen wird, ist das Verletzungsrisiko. Durch ernsthafte Verletzungen können nicht nur Ummengen an Geld aus Klubseite verschwendet werden, sondern auch ganze Karrieren und damit die Zukunft von jungen Sportler*innenn zerstört werden. In einer Studie von Jauhiainen et al. (2021) werden mithilfe des Random-Forest-Algorithmus Prädiktoren für Verletzungen identifiziert, sodass sowohl Sportler*innen als auch Vereine eine bessere Einschätzung bezüglich Des Verletzungsrisikos erlangen können. Als hochrelevante Parameter zeigen sich hier das Geschlecht, die Beweglichkeit des Biceps femoris, der Body-Mass-Index (BMI) und die Körpergröße. So können Vereine oder auch die Spieler*innen selbst entsprechende Maßnahmen bezüglich dieser Prädiktoren ergreifen. Selbst bei unveränderbaren Prädiktoren wie Körpergröße oder Geschlecht können Sportler*innen gezielter betreut und beobachtet werden. ◀

Studienbox

In einer Studie zum Fußballsport von Jamil et al. (2021) wurde mithilfe einer Reihe von Key-Performance-Indikatoren (KPIs) versucht, Champions-League-Torhüter von Nicht-Champions-League-Torhütern zu unter-

scheiden. In dieser Studie wurde an einem Datensatz mit einer Beobachtungszahl von $n = 14.671$ Matchszenarien unter anderem der Random-Forest-Algorithmus für die Klassifizierung verwendet. Als Ergebnis dieser

binären Klassifizierung zeigt sich, dass der Hauptunterschied weniger in der Anzahl an gehaltenen Schüssen liegt als im Kurzpassspiel mit dem Fuß. Der Random-Forest-Algorithmus lieferte dabei eine Genauigkeit von 0,66, was bedeutet, dass 66 % aller Vorhersagen korrekt waren. Dies liegt bedeutend über der 50 %-Schwelle (Baserate), welche durch simples Raten erreicht würde. Die Vorhersage von bekannten Spielerlevels

zur Identifikation von Key-Performance-Indikatoren ist eine der häufigsten Anwendungen vom Random Forest in den Sportwissenschaften. Dieses Framework kann ohne Probleme an verschiedene Fragenstellungen angepasst werden. Dafür müssen lediglich die (Input-) Parameter (unabhängige Variablen) sowie die Kodierung der Zielgröße (abhängige Variable) abgewandelt werden.

? Fragen für die Studierenden

1. Wieso geben beim Random-Forest-Algorithmus (Klassifizierung) in der Regel nicht alle Entscheidungsbäume die gleiche Stimme ab?
2. Nennen Sie ein Beispiel aus dem Bereich des Sports, wo RF eingesetzt werden könnte. Geben Sie für dieses Szenario fünf verschiedene mögliche Parameter an.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Biau, G., & Scornet, E. (2016). A random forest guided tour. *Test*, 25(2), 197–227.
- Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). Classification and regression trees. Monterey, CA: Wadsworth & Brooks.
- Breiman, L. (2001). Random forests. *Machine learning*, 45(1), 5–32.
- Groll, A., Ley, C., Schauburger, G., & Van Eetvelde, H. (2019). A hybrid random forest to predict soccer matches in international tournaments. *Journal of quantitative analysis in sports*, 15(4), 271–287.

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). Random forests. In *The elements of statistical learning* (pp. 587–604). Springer, New York, NY.
- Jamil, M., Phatak, A., Mehta, S., Beato, M., Memmert, D., & Connor, M. (2021). Using multiple machine learning algorithms to classify elite and sub-elite goalkeepers in professional men's football. *Scientific Reports*, 11(1), 1–7.
- Jauhiainen, S., Kauppi, J. P., Leppänen, M., Pasanen, K., Parkkari, J., Vasankari, T., ... & Äyrämö, S. (2021). New machine learning approach for detection of injury risk factors in young team sport athletes. *International journal of sports medicine*, 42(02), 175–182.
- Koenigstorfer, J., & Wemmer, F. (2019). What makes sports clubs successful at recruiting and retaining members from the perspective of managers? Results from a random forest analysis. *Journal of Global Sport Management*, 1–20.
- Myles, A. J., Feudale, R. N., Liu, Y., Woody, N. A., & Brown, S. D. (2004). An introduction to decision tree modeling. *Journal of Chemometrics: A Journal of the Chemometrics Society*, 18(6), 275–285.
- Smithies, T. D., Campbell, M. J., Ramsbottom, N., & Toth, A. J. (2021). A Random Forest approach to identify metrics that best predict match outcome and player ranking in the esports Rocket League. *Scientific Reports*, 11(1), 1–12.



Statistisches Lernen

Gunther Schauberger und Andreas Groll

Inhaltsverzeichnis

- 25.1 **Beispiel Sport – 236**
- 25.2 **Hintergrund – 236**
- 25.3 **Anwendungen – 238**
- Literatur – 241**

Kernbotschaften

- Für die Modellierung von Fußballspielen kann die Zielgröße auf unterschiedliche Arten definiert werden. Abhängig von der Wahl der Zielgröße eignen sich unterschiedliche Ansätze des statistischen oder maschinellen Lernens zur Modellierung und Vorhersage von Fußballspielen.
- Während anfangs überwiegend klassische Regressionsverfahren eingesetzt wurden, kamen in den letzten Jahren häufiger maschinelle Lernverfahren wie Extreme Gradient Boosting oder Random Forest zum Einsatz.
- Maschinelle Lernverfahren konnten insbesondere die Vorhersagegüte für neue, in der Zukunft liegende Spiele verbessern, sind aber grundsätzlich auch komplexer und schwieriger zu interpretieren.

25.1 Beispiel Sport

Im Sport, und speziell im Fußball, wird mittlerweile eine Vielzahl von Daten erhoben und ausgewertet. Ein wichtiges Ziel dieser Auswertung ist die Modellierung bzw. die Vorhersage von einzelnen Spielen mithilfe des sogenannten statistischen Lernens. Man interessiert sich dabei häufig für den Spielausgang, der auf unterschiedliche Arten mathematisch erfasst werden kann, und wie dieser von unterschiedlichen Einflussvariablen abhängt. Als Spielausgang kann beispielsweise das konkrete Ergebnis in Toren oder der Spielausgang als ordinale Variable mit den Kategorien „Sieg Team A“, „Unentschieden“ und „Sieg Team B“ betrachtet werden. Die Einflussvariablen sind klassischerweise Eigenschaften der beiden konkurrierenden Mannschaften, wie etwa deren jeweilige Marktwerte, Tabellenstände oder vorangegangene Leistungen. Des Weiteren können auch die Rahmenbedingungen des jeweiligen Spiels (z. B. Wetter, Heimvorteil, Punkt- vs. Freundschaftsspiel,...) in die Modellierung einfließen. Die hier beschriebenen Modellierungsansätze lassen sich prinzipiell auch auf andere Sportarten übertragen, wobei sich je nach Sportart immer spezielle Anforderungen an die Modellierung stellen. Beispielsweise können die Ausgänge von Tennis-Matches einfach als binäre Variablen (Sieg Spieler A oder Sieg Spieler B) betrachtet werden. Die Modellierung von Basketballspielen hebt sich hingegen durch die viel höhere Anzahl an Körben bzw. Punkten von der Modellierung von Fußballspielen ab.

25.2 Hintergrund

Die oben beschriebene Situation, dass mithilfe von Einflussvariablen eine bestimmte Zielgröße (in unserem Fall der Spielausgang) modelliert werden soll, stellt einen klassischen Fall des statistischen Lernens dar, genauer gesagt des sogenannten überwachten statistischen Lernens. Der Begriff „überwacht“ bedeutet dabei, dass für die einzelnen Beobachtungen (i. d. R. die Spiele) nicht nur Einflussgrößen vorliegen, sondern auch die zugehörige Zielgröße. Im Gegensatz dazu ist im Fall des

unüberwachten Lernens die Zielgröße unbekannt bzw. nicht vorliegend. Klassische Ansätze aus dem überwachten Lernen sind (lineare) Regression und Klassifikation, ein typisches Beispiel für unüberwachtes Lernen sind Clusterverfahren. Eine umfassende Einführung in das statistische Lernen findet sich in James et al. (2021).

Zumeist stellt sich für die Wahl der Zielgröße die grundsätzliche Frage, ob die Anzahl an Toren oder der ordinale Spielausgang gewählt werden soll. Die gängigere Wahl ist die Modellierung der Toranzahlen. Da es sich um diskrete Zähldaten (0, 1, 2, 3, ...) handelt, bietet sich anstelle der häufig verwendeten Normalverteilung die Modellierung mithilfe der sogenannten Poisson-Verteilung an. Der Einfachheit halber werden die beiden zu einem Spiel gehörenden Toranzahlen (d. h. die Tore von Team A und Team B) oft als (stochastisch) unabhängig angenommen (Groll et al., 2015). Diese Unabhängigkeit ist aber nur als eine bedingte Unabhängigkeit (gegeben die Information der verschiedenen Einflussgrößen) zu verstehen. Die Konsequenz aus dieser Annahme ist, dass sich die beiden Toranzahlen eines Spiels als zwei (bedingt) unabhängige Beobachtungen im Datensatz behandeln lassen. Beispielsweise würde ein Datensatz über 100 Spiele dabei 200 Beobachtungen enthalten. Die Alternative ist, direkt das Tupel der beiden Toranzahlen eines Spiels als Zielgröße zu verwenden, was eine bivariate Modellierung bzw. Verteilungsannahme (Karlis & Ntzoufras, 2003; Groll et al., 2018) erfordert. Beispielsweise kann dies über die sogenannte Copula-Regression gelöst werden (van der Wurp et al., 2020).

Ein ordinaler Spielausgang würde üblicherweise nur die Information „Sieg Team A“, „Unentschieden“ oder „Sieg Team B“ bzw. „Niederlage Team A“ enthalten, was mit den Werten 1, 2 und 3 kodiert werden kann. Gegebenenfalls kann die Zielgröße auch die Deutlichkeit des Sieges (bzw. der Niederlage) widerspiegeln, wodurch sich auch mehr als drei Kategorien ergeben können. Ein Spiel stellt dabei eine einzelne Beobachtung dar. Die Zielgröße wird hier als ordinale Variable mit den möglichen Ausprägungen 1, 2 oder 3 aufgefasst. Im einfachsten Fall wird zur Modellierung dementsprechend die sogenannte ordinale Regression eingesetzt (Schauberger et al., 2018).

Alle oben genannten Möglichkeiten lassen sich im einfachsten Fall mithilfe einer Regression modellieren, bei der die Zielgröße als Summe der linearen Effekte der einzelnen Einflussgrößen modelliert wird. Dabei wird gewöhnlich pro Einflussgröße ein unbekannter Regressionsparameter (Effekt) geschätzt (vgl. ► Kap. 16). Mitunter können in der konkreten Modellierung sehr viele (potenzielle) Einflussgrößen vorliegen, sodass eine sehr große Anzahl an Parametern zu schätzen wäre und die klassischen Verfahren instabil oder unausführbar wären. Sogenannte Regularisierungsverfahren, insbesondere Techniken zur Variablenselektion wie z. B. Lasso (Tibshirani, 1996) oder Boosting (Friedman, 2001), können hier Abhilfe schaffen.

In diesem Beitrag werden wir uns ausschließlich auf die Modellierung einzelner Spiele beschränken. Dies kann aber dann als Basis für die Modellierung bzw. Simulation von ganzen Turnieren (z. B. Welt- und Europameisterschaften) oder auch nationalen Meisterschaften dienen. Für ein Turnier wird dabei der gesamte Verlauf des Turniers sehr oft (z. B. 1 Mio. Mal) durchgespielt. Die Ergebnisse der einzelnen Spiele basieren dabei auf der Modellierung eines (Lern-)Datensatzes aus früheren Turnieren und werden auf Basis der erhaltenen Schätzungen zufällig gezogen.

Dabei ergeben sich dann beispielsweise zunächst 1 Mio. einzelne Weltmeister. Für alle Teams können die zugehörigen relativen Häufigkeiten ermittelt und daraus Siegwahrscheinlichkeiten abgeleitet werden. Durch die wiederholte Simulation des Turniers werden automatisch alle Besonderheiten der Gruppeneinteilung bzw. des Spielplans berücksichtigt (Groll et al., 2015).

Definition

Statistisches Lernen (Hastie et al., 2009) umfasst eine große Anzahl an Methoden, die darauf ausgelegt sind, Informationen aus Daten zu ziehen. Im sogenannten überwachten Lernen gibt es eine Zielgröße, die mithilfe von verschiedenen Einflussgrößen erklärt und vorhergesagt werden soll. Dabei wird der Zusammenhang zwischen der Zielgröße und den Einflussgrößen auf einem Lerndatensatz beobachtet und ggf. auf neue Beobachtungen übertragen, um für diese die Zielgröße möglichst gut vorherzusagen.

25

25.3 Anwendungen

Im Folgenden geben wir drei Beispiele für die drei genannten Möglichkeiten, die Zielgröße in Fußballspielen zu definieren und entsprechend zu modellieren. In Beispiel 1 werden Anwendungen vorgestellt, bei denen die einzelnen Toranzahlen (bedingt) unabhängig modelliert wurden, während in Beispiel 2 Anwendungen von bivariaten Modellierungen beschrieben werden. Beispiel 3 fokussiert sich schließlich auf Modelle für die ordinale Zielgröße.

► Beispiel 1

Für die Vorhersage der FIFA-Fußballweltmeisterschaft (WM) 2014 betrachteten Groll et al. (2015) die Modellierung von Spielen von vorangegangenen FIFA-WMs, basierend auf einem Lerndatensatz aus den Spielen der WMs 2002–2010. Nach dem Vorbild von Dixon & Coles (1997) wurde ein Poisson-Modell geschätzt, bei dem die Toranzahlen eines Spiels als bedingt unabhängig angenommen wurden. Deren ursprüngliches (eher einfaches) Modell wurde aber um die Einbeziehung von mannschaftsspezifischen Einflussgrößen erweitert. Um mit der großen damit einhergehenden Anzahl an Parametern umgehen zu können, wurde eine Lasso-Regularisierung zur Schätzung des Modells verwendet. Abwandlungen dieses Modells wurden für die Modellierung und Vorhersage der IHF Handball-WM 2019 (Groll et al., 2020) verwendet. Für die Vorhersage der WM 2018 wurde das Poisson-Modell durch sogenannte Random Forests (ein spezielles Modell des maschinellen Lernens) ersetzt (Groll et al., 2019a; vgl. auch Studienbox). Weiterentwicklungen dieses Modells kamen dann bei der Vorhersage der FIFA-WM 2019 im Frauenfußball (Groll et al., 2019b) sowie bei der UEFA-Europameisterschaft (EURO) 2020 der Männer (Groll et al., 2021) zum Einsatz. In der letztgenannten Arbeit wurde die Vorhersagegüte des Ansatzes über Random Forests mit sogenanntem Extreme Gradient Boosting (XGBoost) verglichen. ◀

► Beispiel 2

Im Rahmen der Modellierung und Vorhersage der UEFA-EURO 2016 untersuchten Groll et al. (2018) die Gültigkeit der Annahme der bedingten Unabhängigkeit der beiden Toranzahlen eines Spiels. Sie verwendeten dazu ein Regressionsmodell basierend auf der bivariaten Poisson-Verteilung, die erstmalig von Karlis & Ntzoufras (2003) zur Modellierung von Fußballspielen eingeführt wurde. Die Schätzung dieses Modells wurde über Boosting gelöst. Die bivariate Modellierung hat hier keine Vorteile gegenüber der einfacheren (auf Unabhängigkeit basierenden) Modellierung gezeigt.

Neben der konkreten Modellierungsannahme einer bivariaten Poisson-Verteilung können auch allgemein Copula-Modelle verwendet werden, bei denen die marginalen Verteilungen wiederum auf univariaten Poisson-Verteilungen basieren. Solche Ansätze kamen bei der Modellierung von FIFA-WM-Spielen in van der Wurp et al. (2020) und van der Wurp & Groll (2021) zum Einsatz. ◀

► Beispiel 3

In Schauburger et al. (2018) sollte der Einfluss von sogenannten spielspezifischen Variablen auf den Ausgang von Spielen der deutschen Fußball-Bundesliga untersucht werden. Beispiele für solche spielspezifischen Einflussgrößen sind etwa der Ballbesitzanteil oder die Laufleistung der beiden Teams. Zu diesem Zweck wurde als Zielgröße eine ordinale Variable mit fünf Kategorien verwendet, um neben den Unentschieden auch höhere und knappe Siege differenzieren zu können.

In Schauburger und Groll (2018) wurde eine spezielle ordinale Variante der Random Forests für die Modellierung von FIFA-WM-Spielen verwendet, bei der der Spielausgang als ordinale Variable mit den Kategorien „Sieg Team A“, „Unentschieden“ und „Sieg Team B“ betrachtet und verschiedenen Modellen zur univariaten Tormodellierung gegenübergestellt wurde. ◀

Studienbox

Für die Vorhersage der FIFA-WM 2018 wurde von Groll et al. (2019a) ein Trainingsdatensatz mit allen Spielen der vorangegangenen WMs 2002–2014 erstellt. Dabei wurden als Zielgröße die einzelnen Toranzahlen als (bedingt) unabhängige Beobachtungen betrachtet, d. h., es ergaben sich je zwei Beobachtungen pro Spiel (vgl. Situation von Beispiel 1). Weiter wurden für die jeweils gegeneinander antretenden Mannschaften diverse Einflussgrößen erhoben, und zwar sowohl wirtschaftliche Faktoren (wie etwa das BIP des jeweiligen Landes), sportliche Faktoren (wie

etwa der jeweilige Tabellenplatz in der FIFA-Weltrangliste), Variablen die den Heimvorteil abbilden (z. B. eine Dummy-Variable, ob es sich bei einer der beiden Mannschaften in einem Spiel um die Heimmannschaft, also das Gastgeberland der WM, handelt), Variablen bezüglich der Teamstruktur (wie etwa das Durchschnittsalter des jeweiligen Teams) sowie Variablen bezüglich des jeweiligen Trainers (z. B. die Länge seiner bisherigen Amtszeit). Weiterhin wurde eine weitere sportliche Variable hinzugenommen, der eine gewisse Sonderrolle zukommt, da sie nicht direkt verfügbar

war, sondern selbst durch ein eigenes statistisches Modell geschätzt werden musste. Es handelt sich dabei um Fähigkeitsparameter, die für jede einzelne Mannschaft deren aktuelle Stärke (zum Zeitpunkt des Starts der jeweiligen WM) widerspiegeln und auf Basis historischer Spiele (alle Spiele aus den letzten sechs Jahren mit einem Zeitgewichtungsfaktor) geschätzt wurden.

Auf diesem Trainingsdatensatz wurde dann ein hybrides Random-Forest-Modell angepasst. Das Modell wird als hybrid bezeichnet, da team-spezifische Fähigkeitsparameter, die selbst aus einem statistischen Modell stammen, den Einflussgrößen beigelegt wurden. Auf Basis dieses geschätzten Modells und der Einflussgrößen der

Mannschaften für die bevorstehende WM 2018 wurde dann der gesamte Verlauf des Turniers 100.000 Mal durchsimuliert. Somit konnten Sieg-Wahrscheinlichkeiten für alle 32 teilnehmenden Teams ermittelt werden. Rückblickend wurde dann die Vorhersagefähigkeit dieses hybriden Random-Forest-Modells mit Hilfe aller 64 Spiele der WM 2018 mit diversen anderen statistischen Modellierungsansätzen, insbesondere auch einem gewöhnlichen Random Forest (also ohne die hybriden mannschaftsspezifischen Fähigkeiten), sowie mit den Wettquoten der Buchmacher verglichen. Das hybride Random-Forest-Modell schnitt dabei am besten ab und erzielte insgesamt sehr zufriedenstellende Ergebnisse.

? Fragen für die Studierenden

1. Welche verschiedenen Arten gibt es, Ergebnisse von Fußballspielen mathematisch zu kodieren bzw. zu modellieren?
2. Nennen Sie mögliche Ansätze des statistischen oder maschinellen Lernens, die bereits zur Modellierung von Fußballspielen verwendet wurden.

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Dixon, M.J. & Coles, S.G. (1997). Modelling Association Football Scores and Inefficiencies in the Football Betting Market. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 46, 265–280.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29, 337–407.
- Groll, A., Heiner, J., Schauburger, G. & Uhrmeister, J. (2020). Prediction of the 2019 IHF World Men's Handball Championship – A Sparse Gaussian Approximation Model. *Journal of Sports Analytics* 6 (3), 187–197.
- Groll, A., Hvattum, L. M., Ley, C., Popp, F., Schauburger, G., Van Eetvelde, H., & Zeileis, A. (2021). Hybrid machine learning forecasts for the UEFA EURO 2020. arXiv preprint arXiv:2106.05799.
- Groll, A., Kneib, T., Mayr, A. & Schauburger, G. (2018). On the dependency of soccer scores – a sparse bivariate Poisson model for the UEFA European football championship 2016. *Journal of Quantitative Analysis in Sports*, 14(2), 65–79.
- Groll, A., Ley, C., Schauburger, G., Van Eetvelde, H., & Zeileis, A. (2019a). Hybrid machine learning forecasts for the FIFA Women's World Cup 2019. arXiv preprint arXiv:1906.01131.
- Groll, A., Ley, C., Schauburger, G., & Van Eetvelde, H. (2019b). A hybrid random forest to predict soccer matches in international tournaments. *Journal of quantitative analysis in sports*, 15(4), 271–287.
- Groll, A., Schauburger, G., & Tutz, G. (2015). Prediction of major international soccer tournaments based on team-specific regularized Poisson regression: An application to the FIFA World Cup 2014. *Journal of Quantitative Analysis in Sports*, 11, 115 – 97.
- Hastie, T., Tibshirani, R., & Friedman, J. H. (2009). The elements of statistical learning: data mining, inference, and prediction (Vol. 2). New York: Springer.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An introduction to statistical learning. New York: Springer.
- Karlis, D. & Ntzoufras, I. (2003). Analysis of sports data by using bivariate Poisson models. *Journal of the Royal Statistical Society: Series D (The Statistician)*, 5, 381–393.
- Schauburger, G., Groll, A. & Tutz, G. (2018). Analysis of the importance of on-field covariates in the German Bundesliga. *Journal of Applied Statistics*, 45(9), 1561–1578.
- Schauburger, G., & Groll, A. (2018). Predicting matches in international football tournaments with random forests. *Statistical Modelling*, 18(5–6), 460–482.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society. Series B (Methodological)*, 58(1), 267–288.
- van der Wurp, H., Groll, A., Kneib, T. Marra, G. & Radice, R. (2020). Generalised joint regression for count data: a penalty extension for competitive settings. *Statistics and Computing* 30, 1419–1432.
- Van der Wurp, H., & Groll, A. (2021). Introducing LASSO-type penalisation to generalised joint regression modelling for count data. *AStA Advances in Statistical Analysis*, 1–25.



Open-set Recognition

Ricardo da Silva Torres und Daniel Memmert

Inhaltsverzeichnis

- 26.1 Beispiel Sport – 244
- 26.2 Hintergrund – 244
- 26.3 Anwendungen – 246
- Literatur – 247

Kernbotschaften

- Bei verschiedenen praktischen Problemen der Mustererkennung sollten Lösungen aus dem Bereich des maschinellen Lernens in der Lage sein zu erkennen, wenn Daten zu keiner der im Training definierten Klassen passen.
- Mehrere praktische Probleme aus der Sportwissenschaft können sinnvollerweise als Open-set Recognition modelliert werden.
- Die Verwendung von Open-set Recognition als Lösung in der sportwissenschaftlichen Anwendung ist eine Option, der in der Literatur noch nicht ausreichend Aufmerksamkeit geschenkt wird.

26.1 Beispiel Sport

26

Computer Vision ist einer der Bereiche der Informatik, die sich mit der Interpretation und dem Verständnis von Multimedia-Datensätzen beschäftigen. Diverse Computer-Vision-Ansätze stützen sich auf den Einsatz von Methoden des maschinellen Lernens. Naik et al. (2022) geben einen Überblick über die jüngste Literatur in diesem Bereich mit dem Schwerpunkt auf der Sportwissenschaft. In mehreren der untersuchten Anwendungen konnten Algorithmen zur Open-set Recognition (OSR) untersucht werden. Anhand von zwei Beispielen soll die Verwendung einer OSR-Formulierung veranschaulicht werden. Das erste Beispiel bezieht sich auf die automatische Klassifizierung der von Fußballmannschaften eingesetzten Taktiken. Das zweite Beispiel bezieht sich auf die Erkennung relevanter Spieleraktionen in Fußball-Videomaterial.

26.2 Hintergrund

Aufgrund technologischer Innovationen im Zusammenhang mit der Entwicklung von Monitoringsystemen und der Verfügbarkeit kostengünstiger, leistungsfähiger Speicher- und Verarbeitungssysteme wurden sehr große Mengen von sportbezogenen Daten generiert. Im Sinne einer fundierten Entscheidungsfindung im Kontext sportlicher Analysen wird der differenzierten Auswertung dieser Daten eine große Bedeutung beigemessen (Goes et al., 2021; Rein & Memmert, 2016).

Ein wichtiger Trend im Bereich der Sportwissenschaft ist der Einsatz von datengesteuerten Methoden zur Unterstützung der Erkenntnisgewinnung. Dabei haben sich vor allem Methoden des maschinellen Lernens (ML) bewährt. ML ist ein Teilbereich der Technologien der künstlichen Intelligenz, der zum Lernen aus Daten verwendet wird und darauf abzielt, Vorhersage- und Inferenzaufgaben oder die Identifizierung von Zusammenhängen in Datensätzen zu unterstützen (Enholm et al., 2021). Bestehende ML-Methoden werden häufig in vier verschiedene Kategorien eingeteilt: überwachte, unüberwachte, halbüberwachte und verstärkende Lernansätze (*reinforcement learning*). Bei überwachten Ansätzen (z. B. Klassifikatoren) wird mit der Annahme gearbeitet, dass den im Trainingsprozess verwendeten Stichproben Labels (Klasse oder Kategorie) zugeordnet sind. In diesem Fall ist die Erwartung, dass Modelle, die in der Lernphase mit einer klassifizierten Stichprobe trainiert wurden, in

der Testphase auf ungesehene Daten verallgemeinert werden können, d. h., ein Klassifikator wird als effektiv oder genau angesehen, wenn seine Verwendung zu korrekten Vorhersagen der mit den Teststichproben verbundenen Labels führt.

Was ist, wenn die Testprobe zu keiner der in der Trainingsphase berücksichtigten Kategorien gehört? In diesem Fall sollte die ML-Methode keines der im Trainingsset berücksichtigten Labels zuordnen, sondern in irgendeiner Form mitteilen, dass die Testprobe zu einer unbekannten Klasse gehört. In der Tat kann (oder sollte) die Anzahl der Klassen oder Kategorien, die bei der Entwicklung und Implementierung von ML-Methoden zu berücksichtigen sind, bei einigen praktischen Problemen nicht im Voraus festgelegt werden.

Definition

Beim ML benötigt man in der Regel nicht alle möglichen Klassen, auf die wir zum Zeitpunkt des Trainings zugreifen können (de Oliveira Werneck et al., 2019; Mendes Júnior et al., 2017; Neira et al., 2018). Zum Beispiel kann es bei der Klassifizierung, ob ein Video eine bestimmte Aktion eines Sportlers oder eines Schiedsrichters enthält, dazu kommen, dass wir beispielsweise nur positive Fälle zum Trainieren haben, d. h. Videos, die mit einer vordefinierten Menge möglicher Aktionen verbunden sind (z. B. Naik et al., 2022). Open-set Recognition (OSR) bezieht sich auf das Problem, die unbekannten Klassen in der Testphase zu identifizieren und gleichzeitig die Klassifikationsgüte für die bekannten Klassen beizubehalten (Oza & Patel, 2019).

Die ersten Initiativen zur Definition von OSR-Algorithmen stützten sich auf die Erweiterung konsolidierter Klassifizierungsmethoden – z. B. Support Vector Machines, wie von Scheirer et al. (2012) untersucht, und Informationen zur Klassennähe, wie von Mendes Júnior et al. (2017) und de O. Cardoso et al. (2017) untersucht. In jüngerer Zeit wurden Deep-Learning-Ansätze zu einem Trend. Frühere Initiativen konzentrierten sich auf die Vorhersage unbekannter Stichproben in der letzten Neuronenschicht der vorgeschlagenen Architekturen (Bendale & Boulton, 2016; Ge et al., 2017; Liang et al., 2017). Liang et al. (2017) stellten beispielsweise ODIN vor, einen Ansatz, der Temperaturskalierung und kleine Störungen bei der Erkennung von Out-of-Distribution-Stichproben untersucht. Bendale und Boulton (2016) führten ein Neugewichtungsschema ein, um die Ausgabewahrscheinlichkeiten für die Erkennung unbekannter Stichproben neu zu definieren. Die als OpenMax bekannte vorgeschlagene Formulierung wurde von Ge et al. (2017) weiterentwickelt, die Trainingsverfahren mit synthetischen Bildern ergänzten, die von einem Generative Adversarial Network (GAN) generiert wurden. In einem anderen Forschungsfeld konzentrierten sich Studien auf generative OSR-Algorithmen (Geng et al., 2020), die Fehler bei der Eingaberekonstruktion in den Trainingsprozess von tiefen neuronalen Netzen (s. ► Kap. 21) einbeziehen, um die Klassifizierung von Stichproben zu unterstützen (Oza & Patel, 2019; Sun et al., 2020; Yoshihashi et al., 2019). Yoshihashi et al. (2019) führten Rahmenbedingungen von einem Klassifikations-Rekonstruktions-Lernen für OSR ein. Oza und Patel (2019) wiederum schlugen klassenbedingte Auto-kodierer für das OSR-Problem vor, während Sun et al. (2020) sich auf ein Schema konzentrierten, das auf „Conditional Gaussian Distribution Learning“ beruht.

26.3 Anwendungen

► Beispiel 1 (Schätzung der Mannschaftstaktik in der Fußballanalyse)

Bei diesem Problem geht es darum, die Taktik von Mannschaften auf der Grundlage von Fußballvideos abzuschätzen, wobei häufig primär die Formation der Spieler auf dem Spielfeld herangezogen wird. Suzuki et al. (2018) stellten beispielsweise einen Ansatz vor, der die Beziehung zwischen den Taktiken zweier Mannschaften mithilfe der Deep-Extreme Learning Machine (DELM) herzustellen versucht. Dabei werden fünf Taktiken berücksichtigt (Rückzug, Pressing, Standardsituationen, Ballbesitz und Umschaltssituationen) und ein geschlossenes Szenario charakterisiert. Das vorgeschlagene System berücksichtigt daher keine Taktiken, die von der vordefinierten Liste abweichen. Somit ist die Anwendung dieses Systems in der Praxis einschränkt. ◀

► Beispiel 2 (Handlungserkennung für die Fußballanalyse)

Dieses Problem bezieht sich auf die Erkennung von relevanten Aktionen in Videomaterial aus dem Fußball. Typische Aktionen sind das Passen, Schießen, Kopfballspiel und Dribbeln. Ganesh et al. (2019) stellten beispielsweise Gaussian Weighted event-based Action Classifier (GAWAC) – eine „Convolutional Neural Network Architecture“ – für dieses Problem vor. Die vorgeschlagene Lösung wurde an einem Sechsklassen-Datensatz validiert, der kurze und lange Pässe, Kopfbälle, Drehungen und Dribblings umfasst. Allerdings wurden in ihrer Formulierung in der Testphase keine „unbekannten“ Aktionen berücksichtigt, d. h., das Problem wird als OSR formuliert. In realen Anwendungsszenarien werden solche unbekannten Aktionen fälschlicherweise einer der sechs im Training berücksichtigten Klassen zugeordnet. ◀

► Beispiel 3 (Ereigniserkennung in Videomaterial aus dem Basketball)

Dieses Problem bezieht sich auf die Identifizierung relevanter Ereignisse auf der Grundlage von räumlich-zeitlichen Merkmalen, die aus Basketballvideos extrahiert werden. Wu et al. (2020) untersuchten die Integration lokaler und globaler Bewegungsmuster bei der Erkennung von Gruppenaktivitäten. Später werden diese Informationen mit visuellen Informationen kombiniert, die sich auf die Vorhersage von Erfolg und Misserfolg (z. B. Treffer) beziehen, um das Zielereignis zu klassifizieren. In der Studie wurde auch ein geschlossenes Szenario mit sechs Ereignissen untersucht: Drei-Punkte-Wurf, Freiwurf, Layup, Zwei-Punkte-Wurf, Slam Dunk und Steal. Diese Modellierung berücksichtigt daher keine „unbekannten“ Ereignisse. ◀

Studienbox

Soweit uns bekannt, wird die Untersuchung von OSR-Lösungen im Kontext der Sportwissenschaft in der Literatur immer noch übersehen (s. Boulton et al. (2019) für eine Liste von Anwendungen

von OSR). Jüngste Initiativen haben Open-Set-Ansätze im Zusammenhang mit der Analyse von Sportdaten untersucht. Yoon et al. (2019) untersuchten die Verwendung einer Deep-Learning-Ar-

chitektur für die Open-Set-Erkennung, die die räumlich-zeitliche Repräsentation auf der Grundlage des Lernens von Bewegungs- und Erscheinungsmustern beschreibt. Die Studie untersuchte das Problem der Handlungserkennung anhand von Datensätzen, die aus Aktionen wie Laufen, Gehen, Klettern, Springen, Schießen usw. bestehen. In einer anderen Studie untersuchten Burns et al. (2022) die Verwendung von Deep Triplet Embeddings für die personalisierte Aktivi-

tätserkennung anhand von Daten, die durch Inertialsensoren gewonnen wurden. In ihrer Formulierung wird ein tiefes neuronales Netz trainiert, indem die Abstände von Proben, die zur gleichen Klasse gehören, minimiert und die Abstände von Proben unterschiedlicher Kategorien maximiert werden. Die durchgeführte Validierung umfasste Datensätze, die nicht nur tägliche, sondern auch sportliche und physiotherapeutische Aktivitäten umfassten.

? Fragen für die Studierenden

1. Definieren Sie das Problem der OSR.
2. Nennen Sie zwei weitere Beispiele dafür, wie die OSR in der Sportanalyse eingesetzt werden könnte.
3. Wählen Sie eines der in der vorherigen Frage ausgewählten Beispiele. Welche von Geng et al. (2020) beschriebene Methode zur Erkennung offener Mengen könnte für das Problem verwendet werden? Warum?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

Bendale, A., & Boulton, T. E. (2016). Towards open set deep networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 1563–1572).

- Boult, T. E., Cruz, S., Dhamija, A. R., Gunther, M., Henrydoss, J., & Scheirer, W. J. (2019, July). Learning and the unknown: Surveying steps toward open world recognition. In *Proceedings of the AAAI conference on artificial intelligence* (Vol. 33, No. 01, pp. 9801–9807).
- Burns, D., Boyer, P., Arrowsmith, C., & Whyne, C. (2022). Personalized Activity Recognition with Deep Triplet Embeddings. *Sensors*, 22(14), 5222.
- de Oliveira Werneck, R., Raveaux, R., Tabbone, S., & da Silva Torres, R. (2019). Learning cost function for graph classification with open-set methods. *Pattern Recognition Letters*, 128, 8–15.
- Cardoso, D. O., Gama, J., & França, F. M. (2017). Weightless neural networks for open set recognition. *Machine Learning*, 106(9), 1547–1567.
- Enholm, I. M., Papagiannidis, E., Mikalef, P., & Krogstie, J. (2021). Artificial intelligence and business value: a literature review. *Information Systems Frontiers*, 1–26.
- Ganesh, Y., Sri Teja, A., Munnangi, S. K., & Rama Murthy, G. (2019, June). A novel framework for fine grained action recognition in soccer. In *International Work-Conference on Artificial Neural Networks* (pp. 137–150). Springer, Cham.
- Ge, Z., Demyanov, S., Chen, Z., & Garnavi, R. (2017). Generative OpenMax for multi-class open set classification. *arXiv preprint arXiv:1707.07418*.
- Geng, C., Huang, S. J., & Chen, S. (2020). Recent advances in open set recognition: A survey. *IEEE transactions on pattern analysis and machine intelligence*, 43(10), 3614–3631.
- Goes, F. R., Meerhoff, L. A., Bueno, M. J. O., Rodrigues, D. M., Moura, F. A., Brink, M. S., ... & Lemmink, K. A. P. M. (2021). Unlocking the potential of big data to support tactical performance analysis in professional soccer: A systematic review. *European Journal of Sport Science*, 21(4), 481–496.
- Liang, S., Li, Y., & Srikant, R. (2017). Enhancing the reliability of out-of-distribution image detection in neural networks. *arXiv preprint arXiv:1706.02690*.
- Mendes Júnior, P. R., De Souza, R. M., Werneck, R. D. O., Stein, B. V., Pazinato, D. V., de Almeida, W. R., ... & Rocha, A. (2017). Nearest neighbors distance ratio open-set classifier. *Machine Learning*, 106(3), 359–386.
- Naik, B. T., Hashmi, M. F., & Bokde, N. D. (2022). A Comprehensive Review of Computer Vision in Sports: Open Issues, Future Trends and Research Directions. *Applied Sciences*, 12(9), 4429.
- Neira, M. A. C., Júnior, P. R. M., Rocha, A., & Torres, R. D. S. (2018). Data-fusion techniques for open-set recognition problems. *IEEE Access*, 6, 21242–21265.
- Oza, P., & Patel, V. M. (2019). C2ae: Class conditioned auto-encoder for open-set recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 2307–2316).
- Rein, R., & Memmert, D. (2016). Big data and tactical analysis in elite soccer: future challenges and opportunities for sports science. *SpringerPlus*, 5(1), 1–13.
- Scheirer, W. J., de Rezende Rocha, A., Sapkota, A., & Boult, T. E. (2012). Toward open set recognition. *IEEE transactions on pattern analysis and machine intelligence*, 35(7), 1757–1772.
- Sun, X., Yang, Z., Zhang, C., Ling, K. V., & Peng, G. (2020). Conditional Gaussian distribution learning for open set recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 13480–13489).
- Suzuki, G., Takahashi, S., Ogawa, T., & Haseyama, M. (2018, October). Team tactics estimation in soccer videos via deep extreme learning machine based on players formation. In *2018 IEEE 7th Global Conference on Consumer Electronics (GCCE)* (pp. 116–117). IEEE.
- Wu, L., Yang, Z., Wang, Q., Jian, M., Zhao, B., Yan, J., & Chen, C. W. (2020). Fusing motion patterns and key visual information for semantic event recognition in basketball videos. *Neurocomputing*, 413, 217–229.
- Yoon, Y., Yu, J., & Jeon, M. (2019). Spatio-Temporal Representation Matching-Based Open-Set Action Recognition by Joint Learning of Motion and Appearance. *IEEE Access*, 7, 165997–166010.
- Yoshihashi, R., Shao, W., Kawakami, R., You, S., Iida, M., & Naemura, T. (2019). Classification-reconstruction learning for open-set recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 4016–4025).

Visualisierung

Inhaltsverzeichnis

| | |
|------------|--|
| Kapitel 27 | Visualisierung-Grundlagen und Konzepte – 251 |
| | <i>Daniel Link</i> |



Visualisierung-Grundlagen und Konzepte

Daniel Link

Inhaltsverzeichnis

- 27.1 Beispiel Sport – 252
- 27.2 Hintergrund – 252
- 27.3 Anwendungen – 253
- Literatur – 257

Kernbotschaften

- Visualisierungen im Sport dienen dazu, Muster, Trends oder Ausreißer in sportbezogenen Informationen, wie physiologischen, biomechanischen oder technisch-taktischen Leistungsdaten, sichtbar zu machen.
- Ziel ist es, eine schnelle Beantwortung von leistungsdiagnostischen Fragestellungen beispielsweise in Bezug auf das taktische Verhalten des Gegners, Stärken- und Schwächenprofile oder Zusammenhänge zwischen Trainingsinput und Leistungsentwicklung zu ermöglichen.
- Neben allgemeinen grafischen Elementen wie Netzwerk- oder Balkendiagrammen lohnt sich vielfach der Einsatz von sportartspezifischen Visualisierungsverfahren, die auf das jeweilige Erkenntnisinteresse abgestimmt sind.

27.1 Beispiel Sport

27

Visualisierungen im Sport finden sich in einer ganzen Reihe von Anwendungsfeldern (Link, 2018). Medienunternehmen verwenden Grafiken zur Anreicherung ihrer Berichterstattung, Profiligen bereiten Informationen zu Spielen visuell auf, um das Informationsinteresse von Fans zu bedienen, Trainer und Leistungsdiagnostiker in Vereinen nutzen die grafische Darstellung von Leistungsdaten, um leistungsdiagnostische Fragestellungen in Training und Wettkampf zu beantworten. Im Bereich der Wissenschaft spielen Visualisierungen unter anderem dann eine große Rolle, wenn Aussagen zur Leistungsstruktur von Sportarten getroffen werden sollen. In diesem Kapitel werden Beispiele für die Visualisierung von Spielverläufen und individuellem Angriffsverhalten im Beachvolleyball gegeben. Am Beispiel der Sportart Fußball wird gezeigt, wie Anspielmöglichkeiten bei Pässen und Leistungsvariablen von Freistößen visualisiert werden können.

27.2 Hintergrund

Unter Visualisierung versteht man im Allgemeinen die grafische Darstellung von Informationen (Chen et al., 2007). Im Sport handelt sich dabei zumeist um physiologische, psychologische, biomechanische oder technisch-taktische Leistungsindikatoren sowie räumliche und zeitliche Strukturen und Zusammenhänge zwischen Leistungs- und Kontextvariablen. Visualisierungen dienen dazu, Muster, Trends und Ausreißer besser erkennen und die spezifischen Fragestellungen des Sports leicht und intuitiv beantworten zu können. Dabei handelt es sich meistens um leistungsdiagnostische Fragestellungen wie das taktische Verhalten des Gegners, Stärken- und Schwächenprofile oder Zusammenhänge zwischen Trainingsinput und Leistungsentwicklung. Eine gute Visualisierung von Sportdaten ist jedoch eine Kunst. Aufwendige Darstellungen können vollkommen belanglos sein, ebenso wie einfache Verfahren beeindruckende Aussagen liefern können. Methodisch können allgemeine Elemente wie Farben, Muster, Balkendiagramme, Histogramme,

Netzwerkdiagramme oder Heatmaps zum Einsatz kommen. Vielfach lohnt es sich aber auch zu prüfen, ob nicht ein sportartspezifisches Visualisierungsverfahren, das auf das jeweilige leistungsdiagnostische Erkenntnisinteresse optimiert ist, einen höheren Mehrwert bietet. Hierfür sollen im Folgenden Beispiele gegeben werden.

Definition


Unter Visualisierung im Sport versteht man die grafische Darstellung von sportbezogenen Informationen. Dabei handelt es sich zumeist um physiologische, psychologische, biomechanische oder technisch-taktische Leistungsindikatoren. Die Visualisierungen dienen dazu, Muster, Trends oder Ausreißer in diesen Leistungsdaten zur erkennen und die Erkenntnisse für Training und Wettkampf zu nutzen.

27.3 Anwendungen

► Beispiel 1

Im deutschen Volleyballverband werden im Rahmen von Gegner- und Eigenanalysen im Beachvolleyball Visualisierungen der Satzstruktur eingesetzt. Nach Erhebung der Rohdaten durch Analysten werden diese in eine spezifische Analysesoftware (BeachViewer) (Link & Ahmann, 2013) eingeladen, und es wird eine Grafik zum Spielverlauf erzeugt (Abb. 27.1). Die Visualisierung ist entlang der horizontalen Mittelachse, die den Punktestand enthält, achsensymmetrisch aufgebaut. Die vertikalen Striche trennen die einzelnen Ballwechsel und visualisieren Auszeiten.

Für die erste Angriffssequenz nach dem Aufschlag (Sideout) wird die zeitliche Aktionsfolge eines Teams von innen nach außen symbolisch dargestellt. Für Aufschlag und Annahme werden die Qualitätsstufen angegeben (–, o, +, ++), für die Darstellung der Technik stehen ein gerader (Spike), gebogener (Shot) und gestrichelter




■ Abb. 27.1 Darstellung eines Satzverlaufs im Beachvolleyball

(Drive) Pfeil in grün (Punkt im ersten Angriff), gelb (Ballwechsel wurde nicht durch den ersten Angriff beendet), rot (Angriffsfehler bzw. Kill-Block) und orange (Sonderfälle) zur Verfügung. Der ausgefüllte Kreis (Ballwechselerfolg) zeigt an, ob es sich hierbei um einen Erfolg im Sideout oder um ein Break handelt. Erfolgreiche Sideouts werden mit Grün markiert und Breaks mit Orange. Die Punktedifferenz gibt einen schnellen Überblick, ob und wie hoch ein Team vorne oder hinten liegt. Diese Visualisierung ermöglicht den Analysten, Stärke- und Schwächephasen, Änderungen in der Taktik oder Zusammenhänge zwischen Kontextvariablen (z. B. nach Fehler, nach Auszeit) und Handlungsweisen der Spieler*innen zu erkennen. Diese Grafik ist nicht statisch, sondern es können einzelne Elemente oder auch Ballwechsel über Filtereinstellungen ausgeblendet werden. Beim Klicken auf ein Element wird der entsprechende Ballwechsel im Video wiedergeben, sodass eine qualitative Analyse der Situation erfolgen kann. ◀

► Beispiel 2

Im Beachvolleyball ist es – ebenso wie anderen Sportarten – angeraten, Aktionen in ihrem zeitlichen Kontext zu betrachten (Link, 2022). Eine im Rahmen der Strategieentwicklung relevante Frage ist, wie ein/e Spieler*in nach eigenen Fehlern im Angriff agiert. Spezialisierte Darstellungen, die auf diese Frage angepasst sind, ermöglichen dies. ■ Abb. 27.2 zeigt für eine/n Spieler*in in fünf Spielen die Anzahl der Angriffe nach Spielfeldzone (Line, Mitte, Diagonal) für die Techniken harter Schlag (links) und Shot (rechts), die nach einem harten, diagonalen Schlag in den Block gespielt wurden. Die leistungsdiagnostische Aussagekraft der Häufigkeiten alleine ist allerdings wenig aussagekräftig – ihr Wert entsteht erst, wenn diese relativ zu einer Norm dargestellt werden. Hierfür wird eine farbliche Kodierung der Zielzonen verwendet: Die grüne Färbung einer Zone kodiert eine positive Abweichung von der Norm, eine rote Färbung eine negative. Als Norm dient hier die Verteilung der Angriffsrichtung aller harten Schläge bzw. Shots in der Stichprobe (also nicht nur nach Fehler).

Zu erkennen ist in diesem Beispiel, dass der/die Spieler*in nach einem diagonalen Schlag in den Block eine gewisse Tendenz zeigt, nicht erneut diagonal zu schlagen, sondern im Falle eines erneuten harten Schläges eher versucht, den mittleren Bereich des



■ **Abb. 27.2** Darstellung der räumlichen Verteilung von Angriffen im Beachvolleyball nach Fehler im vorangegangenen Ballwechsel nach Spielfeldzone. Die Farben kodieren die Abweichung in Bezug auf die räumliche Verteilung von allen Angriffen

Felder zu treffen. Wird der Angriff als Shot durchgeführt, lässt sich visuell keine systematische Abweichung von der Norm erkennen. Eine mögliche praktische Konsequenz aus dieser Analyse könnte sein, den Block gegen diese/n Spieler*in, nachdem er/sie diagonal in den Block geschlagen hat, nicht noch einmal diagonal zu stellen, sondern zumindest zu versuchen, mit einer Hand noch die Mitte abzudecken. ◀


► Beispiel 3

Bei Spielanalysen im Fußball greifen Trainer*innen und Videoanalyst*innen zuweilen – explizit oder implizit – auf das Konzept der Anspielbarkeit (Availability) zurück. Dieses taktische Konstrukt beschreibt die Erfolgswahrscheinlichkeit, mit der ein/e Spieler*in den Ball in einer Spielsituation zu einem/r ausgewählten Mitspieler*in spielen kann. Availability ist verwandt mit dem Passrisiko (Power et al. 2017), bezieht sich dabei aber nicht auf die retrospektive Betrachtung des Risikos eines in der Realität gespielten Passes, sondern fragt, ob es überhaupt irgendeinen möglichen Pass gab, den ein/e Mitspieler*in mit akzeptabler Erfolgsaussicht und in einem aus taktischer Sicht lohnenswerten Raum erreichen konnte.

■ Abb. 27.3 zeigt eine Visualisierung der Availability für einen Moment in einem Fußballspiel. Der schwarze Kreis markiert den Spieler mit Ballbesitz, rote Flächen zeigen die Anspielbarkeit eines Spielers, wobei der Grad an Transparenz die Wahrscheinlichkeit für einen erfolgreichen Pass zu diesem Ort angibt. Die Beschriftung der Spieler zeigt den akkumulierten Wahrscheinlichkeitswert für einen erfolgreichen Pass. Die Berechnung erfolgt auf Basis von Positionsdaten und eines physikalischen Modells, das über Verfahren des maschinellen Lernens anhand von ~100.000 realen Pässen der Fußball-Bundesliga kalibriert wurde. Das Modell wird im Detail von Dick, Link & Brefeld (2022) beschrieben und verwendet für jeden Spieler die Dauer bis zum Erreichen eines Abfangortes auf der Balltrajektorie basierend auf einem Bewegungsmodell der Spieler. Die Berechnung erfolgt für eine Vielzahl von Balltrajektorien, Ballgeschwindigkeiten, Ballhöhen und Abfangpunkten.

Die Anwendungsoption einer solchen Visualisierung liegt im Wesentlichen in der Unterstützung der Bewertung einzelner Spielsituationen im Rahmen von qualitativen Spielanalysen. Beispielsweise können automatisch Situationen extrahiert werden, bei denen nach einem Ballgewinn nur wenige Spieler anspielbar waren oder unglückliche Passentscheidungen getroffen wurden. Für den Passgeber lassen sich mit dem Visualisierungsverfahren mögliche Anspielstationen aufzeigen oder auch Risiko-

■ Abb. 27.3 Visualisierung der Anspielbarkeit von potenziellen Passempfänger*innen im Fußball



Nutzen-Abwägungen transparent machen. Auf der Seite des Passempfängers lässt sich die Frage beantworten, ob sich Spieler in freien Räume anbieten oder wie lange ein Spieler dafür benötigt. Beides liefert möglicherweise wertvolle Hinweise für die Trainingsgestaltung. ◀

Studienbox

In der Studie „A Topography of Free Kicks in Soccer“ (Link, et al., 2016) wurden auf Basis einer Stichprobe von 1833 Freistößen der Fußball-Bundesliga die Auswirkungen ihres Ausführungsortes auf die charakterisierenden Leistungsvariablen untersucht. Anstelle von einfachen Heatmaps wurden hierbei sogenannte Isomaps (Stöckl et al., 2012) eingesetzt, die den Mittelwert einer Variablen auf einer zweidimensionalen Fläche über Farbgradienten kontinuierlich (und nicht diskret) darstellen

(Abb. 27.4). Über diese Visualisierung konnte beispielsweise gezeigt werden, wie Zentralität und Nähe zum Tor die Ausführungsart des Freistoßes beeinflussen (Abb. 27.4, links). Die Visualisierung dieses Zusammenhangs liefert eine Art Normwert für die Entscheidung Torschuss vs. Flanke/Pass im Profifußball. Ebenso wurde gezeigt, dass Flanken von rechts tendenziell erfolgreicher waren als von links (Abb. 27.4, rechts). Als Grund lässt sich vermuten, dass Flanken von rechts von Rechtsfü-




Abb. 27.4 Räumliche Verteilung des Wertes von Leistungsvariablen von Freistößen, dargestellt über ISO-Maps. Die linke Grafik liefert eine farbliche Kodierung des Anteils der Freistöße, die als Torschuss gespielt wurden (und nicht als Flanke oder Pass). Die rechte Grafik stellt den Anteil der erfolgreichen Flanken (=nachfolgender Ballkontakt durch eigenes Team) dar

Bern tendenzieller mit einer sich vom Tor wegdrehenden Ballflugbahn gespielt werden und von links mit einer zum Tor hindrehenden Flugbahn. Da mehr Spieler Rechtsfüßer sind, lässt sich argumentieren, dass diese Flugbahn erfolgreicher war, weil die Bälle möglicherweise weniger gut vom Torwart abgefangen werden

konnten. Ebenso zeigt die Abbildung, dass Flanken aus dem Rücken der Abwehr in der Nähe der Torlinie besonders erfolgreich waren – möglicherweise bedingt durch die Tatsache, dass Offensivspieler durch fehlende Abseitsgefahr Laufbewegungen zum Ball schneller einleiten konnten.

? Fragen für die Studierenden

1. Nennen Sie Ziele und Anwendungsfelder für die Visualisierung von Informationen im Sport!
2. Nennen Sie zwei konkrete Anwendungsbeispiele, wie Visualisierungen für den Sport nutzbar gemacht werden können!

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Chen, C. H., Härdle, W. K., & Unwin, A. (Eds.). (2007). *Handbook of data visualization*. Springer Science & Business Media.
- Dick, U., Link, D., & Brefeld, U. (2022). Who Can Receive The Pass? – A Computational Model for Quantifying Availability in Soccer. *Data mining and knowledge discovery*, 36 (3), 987-1014. doi: <https://doi.org/10.1007/s10618-022-00827-2>
- Link, D. (2018). Sports Analytics – How (commercial) sports data create new opportunities for sports science. *German journal of exercise and sport research*, 48(1), 13–26. doi: <https://doi.org/10.1007/s12662-017-0487-7>
- Link, D. (2022). Spielanalyse in der Praxis: Beachvolleyball. In D. Memmert (Hrsg.), *Spielanalyse im Sportspiel* (S. 43–51). Springer Spektrum, Berlin, Heidelberg.

- Link, D., & Ahmann, J. (2013). Moderne Spielbeobachtung auf Basis von Positionsdaten. *Sportwissenschaft*, 43(1), 1–11. doi:<https://doi.org/10.1007/s12662-013-0282-z>
- Link, D., Kolbinger, O., Weber, H., & Stöckl, M. (2016). A topography of free kicks in soccer. *Journal of sports sciences*, 34(24), 2312–2320. doi:<https://doi.org/10.1080/02640414.2016.1232487>
- Power, P., Ruiz, H., Wei, X., Lucey, P. (2017). Not all passes are created equal. In Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Halifax (Canada) 2017; ACM. p. 1605–1613. doi:<https://doi.org/10.1145/3097983.3098051>
- Stöckl, M., Lamb, P. F., & Lames, M. (2012). A model for visualizing difficulty in golf and subsequent performance rankings on the PGA tour. *International Journal of Golf Science*, 1(1), 10–24. doi:<https://doi.org/10.1123/ijgs.1.1.10>

Ausblick

Inhaltsverzeichnis

Kapitel 28 **Ausblick – 261**
Arnold Baca



Ausblick

Arnold Baca

Inhaltsverzeichnis

- 28.1 Tendenzen – 262
- 28.2 Sensoren – 262
- 28.3 Wearables und intelligente Systeme – 263
- 28.4 Big Data & Cloud – 264
- 28.5 Machine Learning & Computer Vision – 265
- 28.6 Virtuelle und augmentierte Realität & Robotik – 265
- 28.7 Datenschutz und Datenmissbrauch – 266
- Literatur – 267

Kernbotschaften

- Neuartige Sensoren werden einen wesentlichen Beitrag zur Online-Trainingskontrolle oder zur Abschätzung von körperinternen Vorgängen und äußeren Einflüssen bei körperlichen Aktivitäten leisten.
- Über Sensordatenfusion ermittelte Datensätze erlauben die Ableitung relevanter physiologischer und taktischer Informationen, aber auch wichtige Rückschlüsse auf Verletzungsrisiken.
- Die Vielfalt an technologischen Möglichkeiten wird auch zu Änderungen in der Sportausübung führen.
- Daten müssen unter klar definierten, standardisierten Bedingungen erfasst werden, damit Untersuchungen vergleichbar werden.

28.1 Tendenzen

Aktuelle Publikationen in der sportinformatischen Fachzeitschrift *International Journal of Computer Science in Sport* und Themen von Beiträgen, die 2022 auf facheinschlägigen Tagungen (insbesondere dem 13th *International Symposium Computer Science in Sport*, das vom 10.–13. September 2022 in Wien stattgefunden hat) lassen in der Sportinformatik zukünftige Schwerpunkte im Bereich des Einsatzes moderner Sensorik, von Wearables und intelligenten Systemen, von Big Data und maschinellem Lernen, von Computer Vision sowie von virtueller sowie augmentierter Realität und – in Ansätzen – von Robotik erkennen. Entwicklungen und Herausforderungen in diesen Themenfeldern werden in Folge skizziert.

28.2 Sensoren

Neben etablierten Technologien (Baca, 2015) zur Bestimmung von Art (Klassifizierung) und Dauer (Quantifizierung) von Aktivitäten (insbesondere Beschleunigungsaufnehmer), zur Objektverfolgung (Tracking; Inertialsensoren, GPS), zur Kraftmessung (z. B. Dehnungsmessstreifen), zur Abschätzung der Sauerstoffsättigung (Pulsoxiometer/Fotoplethysmograf) oder zur Bestimmung der muskulären Aktivität (Oberflächenelektromyograf) kommen vermehrt auch neuartige Sensoren zum Einsatz, die einen wesentlichen Beitrag zur Online-Trainingskontrolle oder zur Abschätzung von körperinternen Vorgängen und äußeren Einwirkungen bei körperlichen Aktivitäten leisten können. Zu erwähnen sind hier etwa:

- smarte Textilien, bei denen die Sensorik direkt in das Textilgewebe integriert ist; diese können z. B. Dehnung erfassen, was für die Bestimmung der Atemfrequenz eingesetzt werden kann, Feuchtigkeit, Temperatur und andere Körperparameter bestimmen, aber auch auf Umgebungseinflüsse reagieren;
- implantierbare Sensoren, die ständig bestimmte Kenngrößen (z. B. Vitalparameter) messen;

- biologische Biomarker-Sensoren zur Bestimmung von Parametern biologischer Prozesse. Vielversprechend ist etwa elektrochemische, auf Oberflächen-Plasmonen-Resonanz basierende und metamaterialbasierte Sensoren.

28.3 Wearables und intelligente Systeme

In mehreren Marktstudien wurden und werden Wearables als ein zentraler Trend in der Entwicklung von Sport gesehen. Anwendungsbereiche liegen im Monitoring von Aktivität, im Tracking, in der Förderung von Motivation zur Bewegung, in der Einschätzung von Fitness (Passos et al., 2021) und zur Feedbackgabe. Neuere Entwicklungen (vgl. Nithya und Nallavan, 2021; Lutz et al., 2019) lassen das Potenzial von holistischen Ansätzen erkennen, bei denen unterschiedliche Parameterwerte einzelner oder mehrerer sporttreibender Personen in ihrem Zusammenspiel und ihrer Wechselwirkung betrachtet werden, sowie von Sensordatenfusion, bei der die erfassten Daten mehrerer Sensoren verknüpft werden. Es ist zu erwarten, dass aus diesem objektiv ermittelten Datenmaterial relevante Informationen zu physiologischen Prozessen, zur Bewegungsausführung und zur Taktik abgeleitet werden können, aber auch wichtige Rückschlüsse auf Verletzungsrisiken ermöglicht werden. Herausforderungen (Lutz et al., 2019; Rana und Mittal, 2021; Zhang et al., 2019) liegen in noch immer bestehenden Defiziten in der längerfristigen Energieversorgung der verwendeten Systeme, in der Verfügbarkeit von Sensoren zur Erfassung effektiver Biomarker zur Einschätzung interner physiologischer Prozesse bzw. Reaktionen und in dem Echtzeitfeedback biomechanischer Parameter. Bei zukünftigen Entwicklungen werden Aspekte der Präsentation und Art der Informationswiedergabe vermehrt im Fokus stehen – nicht immer ist ein am Arm getragenes optisches Display die ideale Lösung.

Mencarini et al. (2019) stellten auf Grundlage einer Literaturstudie Überlegungen an, welche Aspekte in der Entwicklung von Mensch-Maschine-Schnittstellen (Human Computer Interfaces, HCI) bei der Entwicklung von Wearables im Sport berücksichtigungswert sind. Insbesondere wird angeregt,

- Alternativen zur Armbanduhr (Form und Positionierung) und zur simultanen Feedbackgabe zu bedenken – hier könnten etwa Head-up-Displays (HUD), bei denen die Informationen so präsentiert werden, dass keine Änderung der Blickrichtung erforderlich ist, von größerer Bedeutung werden;
- besonderen Fokus auf individuelle Stärken und Schwächen zu legen sowie Unterstützungsfunktionen für Gruppen zu integrieren;
- kognitive und emotionale Aspekte vermehrt zu berücksichtigen.

Es ist davon auszugehen, dass die Vielfalt an technologischen Möglichkeiten auch zu Änderung in der Sportausübung führen wird.

Intelligente Systeme, die ihr Verhalten in gewissem Ausmaß autonom gestalten und dies in Abhängigkeit der Umgebungsbedingungen und der Funktionalität bereitstellen, werden in Zukunft eine noch größere Rolle spielen. Beispiele sind der Mobile Motion Advisor (Preuschl et al., 2010), der Feedback in Abhängigkeit

der aktuellen Leistung und des Leistungsvermögens erteilt, oder intelligente Krafttrainingsgeräte, die aufgrund von während der sportlichen Aktivität gesammelten Informationen Empfehlungen zur weiteren Bewegungsausführung geben.

28.4 Big Data & Cloud

Experimentelle Untersuchungen und Studien im Sport sind durch ein Anfallen hoher Datenmengen charakterisiert. Zum Management und zur Analyse der Daten steht ein breites Methodenspektrum zur Verfügung. Zur Speicherung der Daten wird der Einsatz von Cloud-Speichern an Bedeutung zunehmen. Dabei werden die Daten an einem standortexternen System gespeichert, freigegeben und verwaltet. Neben Fragen der Datenintegrität und der Datenqualität, wo es darum geht, dass Daten wie vorgesehen aufgezeichnet und abgerufen werden und dass unbeabsichtigte Änderungen keine Auswirkungen auf Ergebnisse haben, sowie der Datenverfügbarkeit, wird in Zukunft auch ein noch größeres Augenmerk auf Datenvergleichbarkeit und Datenvollständigkeit zu legen sein. Das bedeutet, dass Daten unter klar definierten, standardisierten Bedingungen erfasst und Untersuchungen damit vergleichbar werden. Dazu ist eine weit verbreitete internationale Zusammenarbeit bei der Aggregation und Harmonisierung von „Open Access“-Datensätzen anzustreben (Richter et al., 2021). Phatak et al. (2021) beklagen ein Defizit in der Sammlung potenziell umfangreicher, qualitativ hochwertiger „Big Data“ auf organisierte, zeitsynchronisierte und ganzheitliche Weise.

Big Data im Sport bieten beträchtliche Möglichkeiten in der Zusammenarbeit zwischen der Sportwissenschaft und der Informatik, wie beispielsweise in der Taktikanalyse im Fußball, insbesondere bei der Verwendung von Positionsdaten (Goes et al., 2020).

Ein hohes Potenzial liegt auch in der Analyse von Daten, die auf diversen Fitnessplattformen gesammelt werden. Auch hier stellt mangelhafte Datenqualität noch einen limitierenden Faktor dar. So führten Zrenner et al. (2021) beispielsweise eine retrospektive Analyse des Trainings und dessen Wirkungen bei Marathonläufern unter Verwendung von Daten von Fitness-Apps durch. Dabei konnte nicht garantiert werden, dass alle Probandinnen und Probanden sämtliche körperlichen Aktivitäten protokolliert und hochgeladen haben. Ebenso waren Kontextinformationen, die sich auf die Leistung auswirken, wie Feuchtigkeit und Temperatur während eines Trainings oder eine Verletzung, nicht verfügbar.

Darüber hinaus steht auch die Analyse von sportbezogenen Daten aus sozialen Medien erst am Anfang.

Zur Integration von Daten aus unterschiedlichsten Mess- und Informationssystemen werden von Sportorganisationen, -verbänden und -vereinen vermehrt auch Sport- und Klubinformationssysteme benötigt, eingesetzt und gepflegt. Auch hier besteht ein Bedarf nach verallgemeinerten und standardisierten Konzepten (Blobel und Lames, 2020; Blobel et al., 2021).

28.5 Machine Learning & Computer Vision

Die Verfügbarkeit von großen Datenmengen und das Potenzial von Methoden des maschinellen Lernens haben auch im Sport und der Sportwissenschaft zum stark steigenden Einsatz von datenbasierenden Ansätzen für unterschiedliche Fragestellungen geführt (Bai und Bai, 2021). Für Mannschaftssportarten können beispielsweise folgende Anwendungsbereiche unterschieden werden (vgl. Baca, 2021):

- Ergebnisvorhersage (Horvat und Job, 2020),
- Verletzungsprävention (Van Eetvelde et al., 2021) & Gesundheitsüberwachung (Wu, et al., 2021),
- Analyse der Leistungen von Spielerinnen und Spielern,
- Erkennung von Bewegungsmustern,
- Taktik- und Strategieanalyse.

Diese Entwicklung wird sich in den nächsten Jahren fortsetzen. Das wird besonders auf die Vorhersage von Spiel- und Wettkampfergebnissen zutreffen, da im Wettbereich große Geldsummen involviert sind. Darüber hinaus ist ein vermehrter Einsatz zur Bereicherung von Sportübertragungen durch zusätzliche Informationen zu erwarten.

Verfahren des maschinellen Lernens werden aber auch schon lange im Bereich der Computer Vision bzw. zum Verständnis und zur Interpretation digitaler Bilder und Videos eingesetzt. Mit der Entwicklung von auf Deep Learning basierenden Verfahren können hier beeindruckende Ergebnisse erzielt werden, die auch für den Sport bisher nicht gekannte Möglichkeiten eröffnen. Durch die automatische Identifikation zwei- oder dreidimensionaler Strukturen und Eigenschaften aus einzelnen zweidimensionalen Bildern oder Serien solcher Bilder, die von einer einzigen oder von mehreren Kameras aufgenommen wurden, können sowohl Informationen zu Bewegungen einzelner Personen bzw. derer Körpersegmente als auch von interagierenden Mannschaften extrahiert werden.

28.6 Virtuelle und augmentierte Realität & Robotik

Zur Unterstützung des Trainings und als Erweiterung der Präsentationsmöglichkeiten für Zuschauer sind auch weitere imposante Entwicklungen im Bereich der virtuellen Realität (VR) und der augmentierten (auch erweiterten) Realität (AR) zu erwarten. Während bei VR interaktiv in einer in Echtzeit generierten virtuellen Umgebung agiert wird, werden bei AR zusätzlich auch reale Objekte und Umgebungen dreidimensional dargestellt.

Im Training betrifft das insbesondere virtuelle und erweiterte Umgebungen zur Interaktion mit virtuellen Charakteren als Wettkampfvorbereitung (Petri et al., 2018). Auf diese Weise kann beispielsweise die Reaktionsfähigkeit in der Sportart Karate trainiert werden. In Zukunft werden neben optischen Sinneseindrücken vermehrt auch akustische (z. B. das Eintauchen eines Ruderblatts in das Wasser)

und haptische (z. B. das Berühren von Sportgeräten) Rückmeldungen simuliert werden.

Im Medienbereich geht es darum, Möglichkeiten zu schaffen, Sportveranstaltungen direkt aus der Sicht des jeweiligen Spielers zu erleben und so wirklich mitten im Geschehen zu sein.

Das wohl bekannteste Beispiel für den Einsatz von Robotern im Sport ist Roboterfußball. Dieses Anwendungsfeld wird wohl auch künftig ein Testszenario für den Einsatz von neuen Methoden der künstlichen Intelligenz und von Sensortechnologien sein, ist es im RoboCup doch weiterhin Ziel, bis zum Jahr 2050 den Fußballweltmeister zu schlagen.

Aber auch andere Einsatzmöglichkeiten werden vorangetrieben. So könnten humanoide Roboter auch dazu eingesetzt werden, Sportübungen anzuleiten und (Fitness-)Trainer*innen zu unterstützen (Griffiths et al., 2021).

28.7 Datenschutz und Datenmissbrauch

Viele der in diesem Abschnitt angesprochenen Methoden und Technologien erfassen, verarbeiten oder speichern vertrauliche, personenbezogene Daten. Nicht immer ist ein Schutz dieser Daten gewährleistet. Über Apps und Wearables erhobene Fitness-Daten werden beispielsweise oft auch direkt in Clouds geladen oder an Anbieter übermittelt. Das kann durchaus mit Risiken verbunden sein, denen man sich bewusst sein sollte.

28

? Fragen für die Studierenden

1. Nennen Sie offene Herausforderungen in der Entwicklung von Wearables für den Sport.
2. Welche Entwicklungen sind im Bereich der virtuellen Realität im Sport zu erwarten?

Digitale Fragen und Antworten

Mit der kostenlosen Flashcard-App „SN Flashcards“ können Sie Ihr Wissen anhand von Fragen überprüfen und Themen vertiefen. Für die Nutzung folgen Sie bitte den folgenden Anweisungen:

1. Gehen Sie auf ► <https://flashcards.springernature.com/login>
2. Erstellen Sie ein Benutzerkonto, indem Sie Ihre Mailadresse angeben und ein Passwort vergeben.
3. Verwenden Sie den folgenden Link, um Zugang zu Ihrem SN Flashcards Set zu erhalten: ► www.sn.pub/aE7Uuc

Sollte der Link fehlen oder nicht funktionieren, senden Sie uns bitte eine E-Mail mit dem Betreff „SN Flashcards“ und dem Buchtitel an customerservice@springernature.com.

Literatur

- Baca, A. (2015). Data Acquisition and Processing. In Baca, A. (Hrsg.), *Computer science in sport: research and practice*, (S. 46–81). Routledge.
- Baca, A. (2021) Machine Learning. In Pino-Ortega, J., & Rico-Gonzalez, M. (Hrsg.), *The use of applied technology in team sport*, (S. 230–241). Routledge.
- Bai, Z., & Bai, X. (2021). Sports Big Data: Management, Analysis, Applications, and Challenges. *Complexity*, 2021, 1–11. <https://doi.org/10.1155/2021/6676297>
- Blobel, T., & Lames, M. (2020). A Concept for Club Information Systems (CIS) – An Example for Applied Sports Informatics. *International Journal of Computer Science in Sport*, 19(1), 102–122. <https://doi.org/10.2478/ijcss-2020-0006>
- Blobel, T., Rumo, M., & Lames, M. (2021). Sports Information Systems: A systematic review. *International Journal of Computer Science in Sport*, 20(1), 1–22. <https://doi.org/10.2478/ijcss-2021-0001>
- Goes, F. R., Meerhoff, L. A., Bueno, M. J. O., Rodrigues, D. M., Moura, F. A., Brink, M. S., Elferink-Gemser, M. T., Knobbe, A. J., Cunha, S. A., Torres, R. S., & Lemmink, K. A. P. M. (2020). Unlocking the potential of big data to support tactical performance analysis in professional soccer: A systematic review. *European Journal of Sport Science*, 1–16. <https://doi.org/10.1080/17461391.2020.1747552>
- Griffiths, S., Alpay, T., Sutherland, A., Kerzel, M., Eppe, M., Strahl, E., & Wermter, S. (2021). Exercise with Social Robots: Companion or Coach? *ArXiv:2103.12940 [Cs]*. <https://arxiv.org/abs/2103.12940v1>
- Horvat, T., & Job, J. (2020). The use of machine learning in sport outcome prediction: A review. *WIREs Data Mining and Knowledge Discovery*, 10(5). <https://doi.org/10.1002/widm.1380>
- Lutz, J., Memmert, D., Raabe, D., Dornberger, R., & Donath, L. (2019). Wearables for Integrative Performance and Tactic Analyses: Opportunities, Challenges, and Future Directions. *International Journal of Environmental Research and Public Health*, 17(1), 59. <https://doi.org/10.3390/ijerph17010059>
- Mencarini, E., Rapp, A., Tirabeni, L., & Zancanaro, M. (2019). Designing Wearable Systems for Sports: A Review of Trends and Opportunities in Human-Computer Interaction. *IEEE Transactions on Human-Machine Systems*, 49(4), 314–325. <https://doi.org/10.1109/THMS.2019.2919702>
- Nithya, N., & Nallavan, G. (2021). Role of Wearables in Sports based on Activity recognition and biometric parameters: A Survey. 2021 *International Conference on Artificial Intelligence and Smart Systems (ICAIS)*. <https://doi.org/10.1109/icaais50930.2021.9395761>
- Passos, J., Lopes, S. I., Clemente, F. M., Moreira, P. M., Rico-González, M., Bezerra, P., & Rodrigues, L. P. (2021). Wearables and Internet of Things (IoT) Technologies for Fitness Assessment: A Systematic Review. *Sensors (Basel, Switzerland)*, 21(16). <https://doi.org/10.3390/s21165418>
- Petri, K., Bandow, N., & Witte, K. (2018). Using Several Types of Virtual Characters in Sports – a Literature Survey. *International Journal of Computer Science in Sport*, 17(1), 1–48. <https://doi.org/10.2478/ijcss-2018-0001>
- Phatak, A. A., Wieland, F.-G., Vempala, K., Volkmar, F., & Memmert, D. (2021). Artificial Intelligence Based Body Sensor Network Framework – Narrative Review: Proposing an End-to-End Framework using Wearable Sensors, Real-Time Location Systems and Artificial Intelligence/Machine Learning Algorithms for Data Collection, Data Mining and Knowledge Discovery in Sports and Healthcare. *Sports Medicine – Open*, 7(1). <https://doi.org/10.1186/s40798-021-00372-0>
- Preuschl, E., Baca, A., Novatchkov, H., Kornfeind, P., Bichler, S., & Boeskoer, M. (2010). Mobile Motion Advisor – a feedback system for physical exercise in schools. *Procedia Engineering*, 2(2), 2741–2747. <https://doi.org/10.1016/j.proeng.2010.04.060>
- Rana, M., & Mittal, V. (2021). Wearable Sensors for Real-Time Kinematics Analysis in Sports: A Review. *IEEE Sensors Journal*, 21(2), 1187–1207. <https://doi.org/10.1109/jsen.2020.3019016>
- Richter, C., O'Reilly, M., & Delahunt, E. (2021). Machine learning in sports science: challenges and opportunities. *Sports Biomechanics*, 1–7. <https://doi.org/10.1080/14763141.2021.1910334>

- Van Eetvelde, H., Mendonça, L. D., Ley, C., Seil, R., & Tischer, T. (2021). Machine learning methods in sport injury prediction and prevention: a systematic review. *Journal of Experimental Orthopaedics*, 8(1). <https://doi.org/10.1186/s40634-021-00346-x>
- Wu, X., Liu, C., Wang, L., & Bilal, M. (2021). Internet of things-enabled real-time health monitoring system using deep learning. *Neural Computing and Applications*. <https://doi.org/10.1007/s00521-021-06440-6>
- Zhang, X., Shan, G., Wang, Y., Wan, B., & Li, H. (2019). Wearables, Biomechanical Feedback, and Human Motor-Skills' Learning & Optimization. *Applied Sciences*, 9(2), 226. <https://doi.org/10.3390/app9020226>
- Zrenner, M., Heyde, C., Duemler, B., Dykman, S., Roecker, K., & Eskofier, B. M. (2021). Retrospective Analysis of Training and Its Response in Marathon Finishers Based on Fitness App Data. *Frontiers in Physiology*, 12: 669884. <https://doi.org/10.3389/fphys.2021.669884>

Serviceteil

Anhang – 271

Stichwortverzeichnis – 273

Anhang

Von deutschen Sportwissenschaftlerinnen und Sportwissenschaftler kompetitiv eingeworbene Drittmittel der Deutschen Forschungsgemeinschaft (DFG) im Fachkollegium Informatik

| Antragsteller: | Titel: | Förderdauer: | Link: |
|-------------------------------|--|--------------|---|
| Daniel Memmert | Implementierung der floodlight e-Research Technologie für die Analyse von raum-zeitlichen Bewegungsdaten in der Sportwissenschaft | 2023–2026 | ► https://www.dshs-koeln.de/aktuelles/meldungen-pressemitteilungen/detail/meldung/sportspieldaten-effektiv-nutzbar-machen/ |
| Kerstin Witte | Visuelle periphere Wahrnehmung in der virtuellen Realität | 2023–2025 | ► https://gepris.dfg.de/gepris/projekt/404484468 |
| Daniel Memmert | Datenbasierte Ansätze zur Analyse von Fußballspielen aus der e-science Perspektive | seit 2020 | ► https://gepris.dfg.de/gepris/projekt/432920202?context=projekt&task=show-Detail&id=432920202& |
| Daniel Memmert | Ein theoretisches Simulations-Framework zur Analyse von prädiktiven Ratingverfahren auf Netzwerken mit Anwendungsbezug im Sport | 2019–2022 | ► https://gepris.dfg.de/gepris/projekt/432919559?context=projekt&task=show-Detail&id=432919559& |
| Kerstin Witte | Training in VR unter besonderer Berücksichtigung der visuellen Wahrnehmung und des Vergleiches zur Realität | 2018–2022 | ► https://gepris.dfg.de/gepris/projekt/404484468 |
| Daniel Memmert | Simulation interaktiver Handlungssequenzen am Beispiel des Hochleistungs-Fußballs | 2018–2024 | ► DFG – GEPRIS – Simulation interaktiver Handlungssequenzen am Beispiel des Hochleistungs-Fußballs |
| Dietmar Saupe | Powerbike – Modellbasierte Optimierung für Rennradfahren | 2013–2018 | ► https://gepris.dfg.de/gepris/projekt/432919559?context=projekt&task=show-Detail&id=432919559& |
| Kerstin Witte
G. Brunnett | Entwicklung eines autonom interagierenden Gegners in einer Virtual Reality-Umgebung zur Untersuchung der Antizipationsfähigkeit in den Kampfsportarten | 2014–2016 | ► https://gepris.dfg.de/gepris/projekt/252070407 |
| Daniel Memmert
Jürgen Perl | Simulation von Interaktionsmustern und simulative Wirksamkeitsanalyse kreativer Handlungen im Sportspiel mittels Neuronaler Netze | 2008–2018 | ► DFG – GEPRIS – Simulation von Interaktionsmustern und simulative Wirksamkeitsanalyse kreativer Handlungen im Sportspiel mittels Neuronaler Netze |

Stichwortverzeichnis

A

Abbildung 66
 Abfolge von Ereignissen 40
 Aktion 32
 Aktivierungsfunktion 191
 Analyse/Berechnung 66
 Analyseroutine 145
 Anomalie-Erkennung 162
 Anspielbarkeit 257
 Antagonismus 115
 Antizipation 195
 API-Schnittstelle 58

B

Basketball 170
 Beachvolleyball 254
 Beanspruchung 84, 114
 Belastung 84
 Belastungsprofil 96
 Benchmark-Datensatz 200, 205
 Beschleunigung 87
 Bewegung 32
 Bibliothek 145
 Big Data 154, 266
 Bildverarbeitung 218
 Biomarker-Sensor 265

C

Cloud-Speicher 266
 Clustering 162
 CNN 201, 203, 208, 213
 Computer Vision 7, 200, 267
 Computersystem 218
 Computerwissenschaft 218
 Conformance Checking 170, 172
 Convolutional Layer 210
 Convolutional Neural Network
 (CNN) 201, 208
 CRAN 128
 Critical power 105

D

Data Mining 160
 Daten
 – künstliche 16
 Datenanalyse 126

Datenrepräsentation 218
 Datenverarbeitungspipeline 144
 Datenverfügbarkeit 15, 74
 Datenwissenschaftler*in 144
 Deep Learning 202
 Differenzialgleichung 105
 Distanz 87
 Dropout 201
 dvs-Sektion Sportinformatik 6
 Dynamic pricing 56

E

Einzelfall 115
 ELO-Rating 77
 Energiebereitstellung 104
 Ensemble-Methode 228
 Entscheidungsbaum 228, 230
 Ergebnis
 – binäres 154
 Erholung 114
 Ermüdung 114
 Eventdaten 40, 144
 Expected Goal 41
 Expected-Goals-Modell 208

F

Fantasy Sport 56
 Feature 201
 Fehlerfunktion 192
 Fully-Connected Neural Network 209
 Fußball 32, 48, 156, 254
 Fußballspiel 238

G

Geschlecht 50
 Geschwindigkeit 87
 Geschwindigkeitszone 86
 Gradient Boosting 238

H

Haltung (Pose) 32
 Handball 194
 Herzfrequenz 104
 HTML 57
 Human Computer Interface 265

I

IACSS 7
 Information 218
 In-play betting odds 59
 In-Play-Wettquote 58
 Institutionalisierung 4
 Intelligenz
 – kollektive 26
 Isomap 258

K

Key-Performance-Indikator 49, 228, 232
 KI-basierter Ansatz 32
 Klassifizierung 154, 161
 K-nächste-Nachbarn 203
 Kommandozeile 129
 Kontextinformation 50
 KPI. *Siehe* Key-Performance-Indikator
 Kreativität 70
 Künstliche Intelligenz 192, 228
 Künstliches neuronales Netz 190

L

Label 230
 Laktat 104
 Lasso 239
 Leistungsanalyse 178
 Leistungsfähigkeit 114
 Leistungsindikator 49, 254
 Lernregel 192
 Literate Programming 137
 Logistische Regression 154
 Logistisches Modell 155
 Logistisches Regressionsmodell 77

M

Machine Learning 7
 Machine-Learning-Modell 74
 Markdown 137
 Markteffizienz 75
 Maschinelles Lernen 238, 246, 257, 267
 Merkmal 208
 – domänenunabhängiges 219
 Merkmalsvektor 219
 Metainformation 32
 Meta-Modell 117
 Modell 67, 94
 – antagonistisches 118
 – hydraulisches 109
 Modellbildung 66, 74

Modellierung 17, 147, 238
 Modellparameter 116
 Monte-Carlo-Simulation 16
 Motiverkennung 163
 Multidimensionale Zeitreihe 162
 Multimedia-Datensatz 246
 Mustererkennung
 – praktische Probleme 246

N

Netzwerk
 – graphenbasiertes neuronales 204
 Netzwerkanalyse 178
 Netzwerkforschung 178
 Neuronales Netz 49, 209
 Norm 257
 Notation
 – automatische 42

O

Onlinedaten 56
 Open-set Recognition 246, 247
 OSR. *Siehe* Open-set Recognition
 Overfitting 230

P

Paket 128
 Passnetzwerk 43
 PerPot-Modell 94
 Physiologisches Modell 69, 84
 Poisson-Verteilung 239
 Positionsdaten 48, 144, 160, 164, 208, 213, 257
 Prädiktive Qualität 74
 Prädiktives Modell 74
 Process Discovery 170, 172
 Process Enhancement 172
 Process Mining 170, 171
 Programmieren
 – interaktives 146
 Programmiersprache 144
 Programmiersprache R 126
 Propagierungsfunktion 191
 Prozess
 – komplexer 14
 Prozessmodell 171
 Python 144

Q

Qualitative Spielanalyse 257

R

Random Forest 77, 228, 230, 238
Raumkontrolle 51
Realität
– augmentierte 267
Reduktion 66
Regressionsanalyse 108
Regressionsverfahren 238
Rekurrentes neuronales Netz 201
Repräsentation 208
RMarkdown 138
Robotik 268
R (Statistikprogramm) 57

S

Sauerstoffaufnahme 104
Selbstständiger Lernprozess
(unsupervised) 190
Sensordatenfusion 264
Sentiment-Analyse 25
Sequenzbasierte Analyse 44
Simulation 94
SOCCER 49
Soziale Netzwerkanalyse 179
Spieler-Ball-Interaktion 66
Spielfeldregistrierung 32
Sportinformatik
– Definition 4
– wissenschaftliche Disziplin 4
Sportliche Leistung 114
Sportliches Training 114
Sportwettenmarkt 75
Statistisches Lernen 238, 240
Stressor
– externer 85
System 69, 94
– komplexes 43

T

Tennis 98
Text Mining 24

Text-Klassifikator
– automatischer 26
Time Series Data Mining (TSDM) 161
Trainingswirkungsanalyse 118
Transferlernen 218, 220, 222
Transformation 220
Translationsäquivalenz 210

U

Überwachter Lernprozess (supervised) 190
Überwachtes statistisches Lernen 238

V

VAEP-Framework 43
VAR 156
Verhalten
– interaktives 178
Videodaten 32
Virtuelle Realität 267
Visualisierung 66, 254, 255
Vorhersage 238
Vorhersagemodell 51
Voronoi-Zelle 68

W

Wearable 265
Web Crawling 56
Web Scraping 56
Wettquote 156
Workflow 171
Wörterbuchbasierte Kategorisierung von
Textdaten 27

Z

Zeitreihe 160, 161
Zeitreihen-Data-Mining 160
Zeitreihenklassifikation 162
Zufallszahl 14
Zufallszahlengenerator 14



Jetzt bestellen:

link.springer.com/978-3-662-63444-8

